

Distribuția uniformă

Laboratorul 2, DEPI

Table of contents

1	Obiectiv	1
2	Aspecte teoretice	2
2.1	Funcția densitate de probabilitate	2
	Eșantioane aleatoare	3
2.2	Distribuția uniformă	3
	Definiție și parametri	3
	Generarea eşantioanelor uniforme în Matlab	4
	Probabilități pentru distribuția uniformă	5
2.3	Histograme pentru vizualizarea distribuțiilor	5
2.4	Estimarea probabilităților din eşantioane	6
2.5	Rezumat: funcții și notații pe care trebuie să le cunoașteți	6
3	Exerciții teoretice	8
4	Exerciții	8
4.1	Exercițiu suplimentar	9
5	Întrebări finale	9

1 Obiectiv

Generarea de eşantioane uniforme în Matlab, reprezentare prin histograme și studierea efectelor parametrilor. Calcularea probabilităților teoretice și compararea cu estimările obținute din eşantioane.

2 Aspecte teoretice

2.1 Funcția densitate de probabilitate

În acest laborator considerăm **variabile aleatoare continue**.

O variabilă aleatoare continuă A este descrisă de o **funcție densitate de probabilitate** $w_A(x)$, care descrie modul în care probabilitatea este distribuită între valorile posibile. Probabilitatea unui interval se obține prin integrarea funcției densitate de probabilitate, nu prin evaluarea ei într-un singur punct.

Probabilitatea ca A să se afle în intervalul $[a, b]$ este **aria de sub funcția densitate de probabilitate** pe acel interval, adică integrala funcției densitate de probabilitate de la a la b :

$$P(a < A \leq b) = \int_a^b w_A(x) dx,$$

Doar intervalele au probabilitate nenulă. Probabilitatea ca A să fie exact egală cu o anumită valoare este întotdeauna zero.




Figure 1: Probabilitatea = Aria de sub funcția densitate de probabilitate

Funcția densitate de probabilitate satisface întotdeauna $w_A(x) \geq 0$, iar integrala ei este 1, dar valorile ei pot fi mai mari decât 1.

Funcția de repartiție (FR) este definită ca probabilitatea ca $A \leq x$:

$$F_A(x) = P(A \leq x)$$

FR este nedescrescătoare și ia valori între 0 și 1.

FR poate fi folosită și pentru a calcula probabilități pe intervale:

$$P(a < A \leq b) = F_A(b) - F_A(a).$$

Cele două funcții sunt legate. Funcția densitate de probabilitate este derivata FR:

$$w_A(x) = \frac{dF_A(x)}{dx} \quad F_A(x) = \int_{-\infty}^x w_A(t) dt.$$

Eșantioane aleatoare

Un vector de N valori generate dintr-o distribuție este un **eșantion aleator**:

$$x = [x_1, x_2, \dots, x_N].$$

Valorile se schimbă la fiecare rulare, dar comportamentul lor statistic ar trebui să rămână același.

Media și varianța (sau deviația standard) calculate pentru un vector de valori sunt numite **media eșantionului** și **varianța eșantionului** (sau deviația standard).

```
% Media, deviația standard și varianța eșantionului
sample_mean = mean(x)
sample_std = std(x)
sample_var = var(x)
```

Media și varianța eșantionului sunt apropiate, dar nu exact egale cu media și varianța teoretice ale distribuției (sunt „estimări” ale acestor valori teoretice).

2.2 Distribuția uniformă

Definiție și parametri

Distribuția uniformă descrie o variabilă aleatoare care are șanse egale de a lua orice valoare dintr-un interval dat $[a, b]$.

Se notează:

$$A \sim \mathcal{U}[a, b], \quad \text{cu } a < b.$$

Funcția sa densitate de probabilitate este definită prin:

$$w_A(x) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b, \\ 0, & \text{în rest.} \end{cases}$$

Funcția densitate de probabilitate este constantă pe $[a, b]$.




Figure 2: Funcția densitate de probabilitate pentru $\mathcal{U}[-2, 2]$.

Media statistică și varianța sunt

$$E\{A\} = \frac{a+b}{2}, \quad \sigma_A^2 = \frac{(b-a)^2}{12}.$$

Generarea eșantioanelor uniforme în Matlab

`rand()` generează valori uniforme cu $0 < A < 1$. Nu contează dacă limitele 0 și 1 sunt incluse sau nu, deoarece în interval există oricum o infinitate de valori.

```
A = rand()           % o valoare din U[0,1]
A = rand(1, 10)      % vector linie cu 10 valori independente din U[0,1]
```

Pentru a obține valori dintr-un interval general $[a, b]$, scalați și deplasați valorile:

$$B = a + (b - a)A, \quad A \sim \mathcal{U}[0, 1].$$

```

a = 5;
b = 7;
N = 1000;

x_uniform = a + (b-a)*rand(1, N);

```

Aici, $b - a$ stabilește lățimea intervalului, iar a stabilește limita inferioară.

Probabilități pentru distribuția uniformă

Probabilitățile sunt arii de sub funcția densitate de probabilitate.

Pentru o variabilă uniformă, calculul probabilităților se reduce la calculul ariei unui dreptunghi și se poate realiza ușor.

Exemplu: pentru $X \sim \mathcal{U}[2, 10]$, probabilitatea ca X să fie între 3 și 5 este $\frac{2}{8} = 0.25$.

2.3 Histograme pentru vizualizarea distribuțiilor

O **histogramă** grupează valorile eșantionului în intervale (“bins”). Înălțimea fiecărei bare este numărul de valori din intervalul respectiv:

```

x = -4 + 14*rand(1, 10000);
histogram(x, 30)
xlabel('Valoare')
ylabel('Număr de valori')
grid on

```

Folosiți `figure` pentru a deschide o fereastră nouă înainte de a reprezenta altă histogramă. Numărul de intervale controlează nivelul de detaliu: mai multe intervale oferă mai multe detalii, dar vor fi mai puține valori în fiecare interval și, deci, înălțimi mai neregulate ale barelor.

Pentru comparația cu o funcție densitate de probabilitate, folosiți `'Normalization', 'pdf'`:

```

figure
histogram(x, 30, 'Normalization', 'pdf')
xlabel('Valoare')
ylabel('Densitate de probabilitate estimată')
grid on

```

Cu această opțiune, înălțimea fiecărei bare este numărul de valori din clasă împărțit la numărul total de valori și la lățimea clasei. **Aria totală a barelor**, nu suma înălțimilor, este 1, în mod similar cu o funcție densitate de probabilitate teoretică.

Pentru un eșantion de lungime mare, înălțimile barelor ar trebui să fie apropiate de valoarea teoretică $1/(b - a)$.

2.4 Estimarea probabilităților din eșantioane

Se poate estima o probabilitate dintr-un vector de eșantioane, numărând valorile care satisfac condiția și împărțind la numărul total. De exemplu, pentru a estima $P(-1 \leq A \leq 3)$ dintr-un vector de eșantioane `x`:

```
p_estimated = sum(x >= -1 & x <= 3)/numel(x);
```

Explicație: comparațiile $x \geq -1$ și $x \leq 3$ produc vectori logici, iar operatorul `&` combină cele două condiții. `sum()` numără elementele adevărate din vectorul rezultat, iar `numel()` întoarce numărul total de valori din vector.

Eșantioane generate diferit dau estimări diferite. Eșantioanele mai mari oferă, în general, estimări mai precise, dar îmbunătățirea nu este garantată la fiecare rulare.

2.5 Rezumat: funcții și notații pe care trebuie să le cunoașteți

Sintaxă sau notație	Exemplu	Descriere
$w_A(x)$	$P(c < A \leq d) = \int_c^d w_A(x) dx$	Densitate de probabilitate; probabilitatea unui interval este o arie
$F_A(x)$	$F_A(x) = P(A \leq x)$	Funcția de repartiție (FR)
$A \sim \mathcal{U}[a, b]$	$A \sim \mathcal{U}[-4, 10]$	Distribuție uniformă pe $[a, b]$
<code>rand(m,n)</code>	<code>rand(1,1000)</code>	$m \times n$ valori uniforme pe $[0, 1]$
<code>a + (b-a)*rand(m,n)</code>	<code>-4 + 14*rand(1,1000)</code>	Valori uniforme pe $[a, b]$
<code>mean(x)</code> , <code>std(x)</code> , <code>var(x)</code>	<code>mean(x)</code>	Media, deviația standard și varianța eșantionului
<code>histogram(x,n)</code>	<code>histogram(x,30)</code>	Histogramă cu <code>n</code> clase; adăugați <code>'Normalization','pdf'</code> pentru arie unitară
<code>figure</code>	<code>figure</code>	Deschide o fereastră nouă pentru figuri

Sintaxă sau notăție	Exemplu	Descriere
<code>sum(condition)/numel(x)</code>	<code>sum(x > 7)/numel(x)</code>	Probabilitate empirică

3 Exerciții teoretice

1. Fie A o variabilă aleatoare continuă cu distribuția uniformă $\mathcal{U}[0, 6]$
 - a. Desenați funcția densitate de probabilitate a lui A .
 - b. Calculați probabilitatea $P(A > 2.7)$.
 - c. Calculați probabilitatea $P(A \in (0, 2.3))$.
 - d. Desenați funcția de repartiție $F_A(x)$ și scrieți expresia sa matematică.
 - e. Care este distribuția variabilei aleatoare B definite prin $B = A - 2$?
 - f. Care este distribuția variabilei aleatoare C definite prin $C = 3 * A$?

4 Exerciții

Scrieți singuri toate comenzile într-un script sau live script. Etichetați figurile și răspundeți la întrebările de interpretare în comentarii.

1. Eșantioane aleatoare uniforme:
 - a. Generați $N = 10000$ valori din $\mathcal{U}[-4, 10]$ și stocați-le în `x_uniform`.
 - b. Afișați minimul și maximul. Sunt egale cu limitele intervalului?
 - c. Calculați media eșantionului și comparați-o cu $(a + b)/2$.
 - d. Reprezentați primele 100 de valori. Folosiți indicele valorii pe axa orizontală.
2. Histograme:
 - a. Reprezentați o histogramă a lui `x_uniform` cu 30 de clase.
 - b. Într-o figură nouă, reprezentați o histogramă cu 30 de clase, normalizată ca densitate de probabilitate. Comparați înălțimile barelor cu densitatea teoretică $1/(b - a)$.
 - c. Repetați cu 10 și 100 de clase. Ce se schimbă? Care histogramă este mai neregulată?
 - d. Generați un vector nou cu $N = 100$ și repetați histograma cu 30 de clase normalizată ca densitate de probabilitate. Comparați-o cu cea pentru $N = 10000$.
3. Efectul intervalului:
 - a. Generați câte 10000 de valori din $\mathcal{U}[0, 1]$, $\mathcal{U}[5, 6]$, și $\mathcal{U}[5, 7]$.
 - b. Reprezentați histograme normalizate ca densitate de probabilitate, cu 30 de clase, în figuri separate.
 - c. Comparați poziția, lățimea și înălțimea. Care pereche diferă doar printr-o deplasare?
 - d. Calculați media fiecărui eșantion și comparați-o cu valoarea sa teoretică.
4. Probabilități pentru o variabilă uniformă:

Fie $A \sim \mathcal{U}[-4, 10]$.

- a. Calculați teoretic $P(-1 \leq A \leq 3)$ și $P(A > 7)$.
- b. Estimați ambele probabilități din `x_uniform` folosind comparații logice și `sum()`.
- c. Repetați cu $N = 100, 1000$ și 100000 . Comparați estimările cu teoria.
- d. Repetați experimentul. Eșantionul cel mai mare dă întotdeauna estimarea cea mai apropiată?

4.1 Exercițiu suplimentar

5. Scrieți `p = myCDF(v, x)` pentru a estima $P(V \leq x)$ ca proporția valorilor din `v` care sunt mai mici sau egale cu `x`.
 - a. Pentru $A \sim \mathcal{U}[-4, 10]$, scrieți FR teoretică în interiorul și în exteriorul intervalului.
 - b. Generați 10000 de valori. Evaluați `myCDF` în 100 de puncte de la -6 la 12 folosind o buclă `for`.
 - c. Reprezentați împreună FR estimată și cea teoretică.

5 Întrebări finale

1. O funcție densitate de probabilitate uniformă pe un interval scurt poate fi mai mare decât 1. De ce acest lucru nu implică o probabilitate mai mare decât 1?
2. Poate o clasă goală din histogramă să demonstreze că probabilitatea reală a acelui interval este zero?
3. Dacă dublați numărul de valori, dar păstrați aceleași limite ale claselor, ce ar trebui să se întâmple cu o histogramă de numărare? Dar cu una normalizată ca densitate de probabilitate?
4. Pot două histograme ale aceluiași vector să arate foarte diferit? Ce ați verifica înainte de a concluziona că distribuțiile lor diferă?