

# Distribuții ale variabilelor aleatoare

Laboratorul 2, DEDP

## Table of contents

|          |                                                                        |           |
|----------|------------------------------------------------------------------------|-----------|
| <b>1</b> | <b>Obiectiv</b>                                                        | <b>1</b>  |
| <b>2</b> | <b>Considerații teoretice</b>                                          | <b>2</b>  |
| 2.1      | Densitate de probabilitate . . . . .                                   | 2         |
|          | Eșantioane aleatoare . . . . .                                         | 3         |
| 2.2      | Distribuția uniformă . . . . .                                         | 3         |
|          | Definiție și parametri . . . . .                                       | 3         |
|          | Generarea eşantioanelor uniforme în Matlab . . . . .                   | 4         |
|          | Probabilități pentru distribuția uniformă . . . . .                    | 5         |
| 2.3      | Distribuția normală . . . . .                                          | 5         |
|          | Definiție și parametri . . . . .                                       | 5         |
|          | Generarea eşantioanelor normale în Matlab . . . . .                    | 6         |
|          | Calcularea probabilităților pentru distribuția normală . . . . .       | 7         |
| 2.4      | Histogramele ca reprezentare vizuală a distribuțiilor . . . . .        | 8         |
| 2.5      | Rezumat: funcții și notații pe care trebuie să le cunoașteți . . . . . | 8         |
| <b>3</b> | <b>Exerciții</b>                                                       | <b>10</b> |
| 3.1      | Exerciții suplimentare . . . . .                                       | 11        |
| <b>4</b> | <b>Întrebări finale</b>                                                | <b>11</b> |

## 1 Obiectiv

Generarea în Matlab a unor eşantioane cu distribuții uniforme și normale, cu diferiți parametri. Calcularea probabilităților teoretice și din vectori de eşantioane. Crearea de histograme. Folosirea funcției `erf()` pentru funcția de repartiție normală.

## 2 Considerații teoretice

### 2.1 Densitate de probabilitate

În acest laborator considerăm **variabile aleatoare continue**.

O variabilă aleatoare continuă  $A$  este descrisă de o **funcție densitate de probabilitate** (PDF)  $w_A(x)$ , care arată cât de probabil este ca  $A$  să ia valori în jurul lui  $x$ . Densitatea de probabilitate mai este numită și **distribuția** lui  $A$ .

Probabilitatea ca  $A$  să se afle în intervalul  $[a, b]$  este **aria de sub PDF** pe acel interval, adică integrala PDF de la  $a$  la  $b$ :

$$P(a < A \leq b) = \int_a^b w_A(x) dx,$$

Probabilitatea se calculează numai pentru **intervale** de valori. Probabilitatea ca  $A$  să fie exact egală cu o anumită valoare este întotdeauna zero.




Figure 1: Probabilitatea = aria de sub densitate

PDF satisface întotdeauna  $w_A(x) \geq 0$ , iar integrala sa este 1, însă valorile sale pot fi mai mari decât 1.

**Funcția de repartiție** (CDF) este definită ca probabilitatea ca  $A \leq x$ :

$$F_A(x) = P(A \leq x)$$

CDF este nedescrescătoare și ia valori între 0 și 1.

CDF poate fi folosită și pentru a calcula probabilități pe intervale:

$$P(a < A \leq b) = F_A(b) - F_A(a).$$

Cele două funcții sunt legate. PDF este derivata CDF:

$$w_A(x) = \frac{dF_A(x)}{dx} \quad F_A(x) = \int_{-\infty}^x w_A(t) dt.$$

## Eșantioane aleatoare

O valoare sau un vector cu  $N$  valori generate dintr-o anumită distribuție reprezintă un **eșantion aleator**:

$$x = [x_1, x_2, \dots, x_N].$$

Valorile se schimbă la fiecare rulare, dar comportamentul lor statistic ar trebui să rămână același.

Media și varianța (sau deviația standard) calculate dintr-un anumit vector de eșantioane se numesc **media eșantionului** și **varianța eșantionului** (sau deviația standard a eșantionului).

```
% Media, deviația standard și varianța eșantionului, calculate din date
sample_mean = mean(x_normal)
sample_std = std(x_normal)
sample_var = var(x_normal)
```

Media și varianța eșantionului sunt apropiate, dar nu exact egale cu media și varianța teoretică ale distribuției (sunt „estimări” ale acestor valori teoretice).

## 2.2 Distribuția uniformă

### Definiție și parametri

Distribuția uniformă descrie o variabilă aleatoare care are șanse egale să ia orice valoare dintr-un interval dat  $[a, b]$ .

Se notează:

$$A \sim \mathcal{U}[a, b], \quad \text{unde } a < b.$$

Funcția sa densitate de probabilitate (PDF) este definită astfel:

$$f_A(x) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b, \\ 0, & \text{în rest.} \end{cases}$$

PDF este constantă pe  $[a, b]$ .




Figure 2: PDF pentru  $\mathcal{U}[-2, 2]$ .

Media și varianța sa statistică sunt

$$E\{A\} = \frac{a+b}{2}, \quad \sigma_A^2 = \frac{(b-a)^2}{12}.$$

### Generarea eșantioanelor uniforme în Matlab

`rand()` generează valori uniforme cu  $0 < A < 1$ . Nu contează dacă valorile extreme 0 și 1 sunt incluse sau nu, deoarece oricum există o infinitate de valori în interval.

```
A = rand()           % o valoare din U[0,1]
A = rand(1, 10)      % vector linie cu 10 valori independente din U[0,1]
```

Pentru a obține valori dintr-un interval general  $[a, b]$ , scalați și deplasați valorile:

$$B = a + (b-a)A, \quad A \sim \mathcal{U}[0, 1].$$

```
a = 5;  
b = 7;  
N = 1000;  
  
x_uniform = a + (b-a)*rand(1, N);
```

Aici,  $b - a$  stabilește lățimea, iar  $a$  stabilește limita inferioară.

### Probabilități pentru distribuția uniformă

Probabilitățile sunt arii de sub PDF.

Pentru o variabilă uniformă, calcularea probabilităților se reduce la calcularea ariei unui dreptunghi și se poate face ușor.

Exemplu: pentru  $X \sim \mathcal{U}[2, 10]$ , probabilitatea ca  $X$  să fie între 3 și 5 este  $\frac{2}{8} = 0.25$ .

## 2.3 Distribuția normală

### Definiție și parametri

Distribuția normală descrie o variabilă aleatoare care ia mai probabil valori apropiate de media sa  $\mu$  decât valori îndepărtate, conform unei PDF în formă de clopot („clopotul lui Gauss”).

O variabilă normală se notează:

$$X \sim \mathcal{N}(\mu, \sigma^2), \quad \sigma > 0.$$

Funcția sa densitate de probabilitate este

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left[ -\frac{(x - \mu)^2}{2\sigma^2} \right].$$




Figure 3: Modificarea lui  $\mu$  deplasează PDF normală; creșterea lui  $\sigma$  o face mai lată și mai aplatizată.

Parametrii sunt:

- $\mu$ : media (centrul);
- $\sigma^2$ : varianța;
- $\sigma = \sqrt{\sigma^2}$ : abaterea standard.

Modificarea lui  $\mu$  înseamnă deplasarea PDF. Un  $\sigma$  mai mare înseamnă o funcție mai lată și mai aplatizată, iar un  $\sigma$  mai mic înseamnă una mai îngustă și mai înaltă.

**Distribuția normală standard** este distribuția normală cu  $\mu = 0$  și  $\sigma = 1$ :

$$Z \sim \mathcal{N}(\mu = 0, \sigma^2 = 1).$$

### Generarea eșantioanelor normale în Matlab

`randn()` generează valori din distribuția normală standard  $\mathcal{N}(\mu = 0, \sigma^2 = 1)$ :

```
z = randn()           % o valoare din N(0,1)
z = randn(1, 10)      % 10 valori independente din N(0,1)
```

Pentru valori arbitrare  $\mu$  și  $\sigma$ , scalați cu  $\sigma$  și deplasați cu  $\mu$ :

$$B = \mu + \sigma A, \quad \text{unde } A \sim \mathcal{N}(\mu = 0, \sigma^2 = 1).$$

```
mu = 5;
sigma = 2;
N = 1000;

x_normal = mu + sigma*randn(1, N);
```

Notă: înmulțiți cu abaterea standard  $\sigma$ , nu cu varianța  $\sigma^2$ .

### Calcularea probabilităților pentru distribuția normală

Integrala din densitatea de probabilitate normală nu poate fi calculată analitic. În schimb, folosim funcția predefinită `erf()` din Matlab pentru acest scop.

Pentru o variabilă normală  $A \sim \mathcal{N}(\mu, \sigma^2)$ , probabilitatea ca  $A$  să se afle în intervalul  $[a, b]$  este:

$$P(a \leq A \leq b) = F_A(b) - F_A(a),$$

unde  $F_A(x)$  este funcția de repartiție (CDF) a lui  $A$  și se calculează folosind funcția de eroare `erf()`:

$$F_A(x) = P(A \leq x) = \frac{1}{2} \left[ 1 + \operatorname{erf} \left( \frac{x - \mu}{\sigma\sqrt{2}} \right) \right].$$

În Matlab:

Exemplu:  $A \sim \mathcal{N}(\mu = 10, \sigma^2 = 4)$  și  $P(8 \leq X \leq 12)$ :

```
mu = 10;
sigma = 2;
a = 8;
b = 12;

F_a = 0.5*(1 + erf((a-mu)/(sigma*sqrt(2))));
F_b = 0.5*(1 + erf((b-mu)/(sigma*sqrt(2))));
p_normal_theory = F_b - F_a
```

Rezultatul este aproximativ 0.6827. Probabilitatea poate fi estimată și din eșantioane, empiric:

```
N = 10000;
x_normal = mu + sigma*randn(1, N);
p_normal_estimated = sum(x_normal >= a & x_normal <= b)/N;
```

## 2.4 Histogramele ca reprezentare vizuală a distribuțiilor

O **histogramă** este un grafic cu bare care afișează distribuția eșantioanelor, numărând câte eșantioane se află în fiecare interval de valori. În Matlab, se poate folosi funcția `histogram()`:

```
% Generează 10000 de eșantioane dintr-o distribuție uniformă pe [-4, 10]
x_uniform = -4 + 14*rand(1, 10000);

% Afișează o histogramă cu 30 de clase
histogram(x_uniform, 30)
xlabel('Valoare')
ylabel('Număr de eșantioane')
title('Eșantioane uniforme')
grid on
```

Pentru a o compara cu o PDF, trebuie să-i normalizăm aria la 1, folosind opțiunea `'Normalization','pdf'`:

```
% Generează 10000 de eșantioane dintr-o distribuție normală cu media 5 și abaterea standard 2
x_normal = 5 + 2*randn(1, 10000);

% Afișează o histogramă normalizată ca PDF, cu 35 de clase
histogram(x_normal, 35, 'Normalization', 'pdf')
xlabel('Valoare')
ylabel('Densitate de probabilitate estimată')
title('Eșantioane normale')
grid on
```

Histogramele sunt o metodă practică de a vizualiza distribuția eșantioanelor (valori, pixeli etc.) pentru a înțelege datele.

## 2.5 Rezumat: funcții și notații pe care trebuie să le cunoașteți

| Signatură sau notație               | Exemplu                           | Descriere                                              |
|-------------------------------------|-----------------------------------|--------------------------------------------------------|
| $X \sim \mathcal{U}[a, b]$          | $X \sim \mathcal{U}[-4, 10]$      | Distribuție uniformă pe $[a, b]$                       |
| $X \sim \mathcal{N}(\mu, \sigma^2)$ | $X \sim \mathcal{N}(5, 2^2)$      | Distribuție normală: media $\mu$ , varianța $\sigma^2$ |
| <code>rand(m,n)</code>              | <code>rand(1,1000)</code>         | $m \times n$ eșantioane din $\mathcal{U}[0, 1]$        |
| <code>a + (b-a)*rand(m,n)</code>    | <code>-4 + 14*rand(1,1000)</code> | Eșantioane din $\mathcal{U}[a, b]$                     |
| <code>randn(m,n)</code>             | <code>randn(1,1000)</code>        | $m \times n$ eșantioane din $\mathcal{N}(0, 1)$        |

| Signatură sau notație                                                      | Exemplu                                                                  | Descriere                                                                                           |
|----------------------------------------------------------------------------|--------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------|
| <code>mu + sigma*randn(m,n)</code><br><code>mean(x), std(x), var(x)</code> | <code>5 + 2*randn(1,1000)</code><br><code>mean(x), std(x), var(x)</code> | Eșantioane din $\mathcal{N}(\mu, \sigma^2)$<br>Media, abaterea standard și<br>varianța eșantionului |
| <code>histogram(x,n)</code>                                                | <code>histogram(x,30)</code>                                             | Histogramă cu n clase;<br>adăugați<br>'Normalization', 'pdf'<br>pentru arie unitară                 |
| <code>erf(x)</code>                                                        | <code>erf(1/sqrt(2))</code>                                              | Funcția de eroare folosită în<br>CDF normală                                                        |
| <code>sum(condition)/N</code>                                              | <code>sum(x &gt;= a &amp; x &lt;= b)/N</code>                            | Probabilitate empirică                                                                              |

### 3 Exerciții

Scrieți singuri toate comenzile într-un script sau live script. Etichetați figurile și răspundeți la întrebările de interpretare în comentarii.

1. Eșantioane aleatoare uniforme:

- Generați  $N = 10000$  de eșantioane din  $\mathcal{U}[-4, 10]$ .
- Afișați valorile minime și maxime ale vectorului. De ce lipsesc valorile extreme? Și de ce acest lucru nu schimbă distribuția teoretică?
- Comparați `mean()` cu  $(a + b)/2$ .
- Reprezentați grafic primele 100 de valori generate folosind `plot()`.
- Reprezentați o histogramă normalizată a datelor, cu 30 de intervale. Care este înălțimea sa teoretică?

2. Efectul parametrilor distribuției uniforme:

- Generați câte 10000 de eșantioane din  $\mathcal{U}[0, 1]$  și  $\mathcal{U}[5, 7]$ .
- Reprezentați histogramele normalizate, cu același număr de clase, în ferestre separate (`figure`).
- Descrieți modificările poziției, lățimii și înălțimii PDF.

3. Eșantioane aleatoare normale:

- Stabiliți `mu1 = 2`, `sigma1 = sqrt(2)` și generați 10000 de eșantioane din  $\mathcal{N}(\mu = 2, \sigma^2 = 2)$  în `x_normal_1`. Al doilea parametru este varianța.
- Reprezentați grafic primele 100 de valori din vector.
- Reprezentați histograma tuturor valorilor.
- Calculați media și abaterea standard ale eșantionului cu `mean()` și `std()` și comparați-le cu 2 și  $\sqrt{2}$ . De ce nu sunt exact egale?
- Păstrați `sigma1`, schimbați  $\mu$  la  $-3$  și comparați histogramele. Ce se schimbă?
- Păstrați `mu1`, schimbați  $\sigma$  la 0.5 și comparați din nou.

4. Probabilități pentru o variabilă uniformă:

Fie  $X \sim \mathcal{U}[-4, 10]$ .

- Calculați teoretic  $P(-1 \leq X \leq 3)$ .
- Estimați-o din Exercițiul 1 folosind comparații logice și `sum()`.
- Calculați și estimați  $P(X > 7)$ .
- Repetăți pentru  $N = 100, 1000$  și 100000. Cum tinde să se modifice eroarea? Trebuie să scadă la fiecare rulare?

5. Probabilități pentru o variabilă normală folosind `erf()`:

Fie  $X \sim \mathcal{N}(\mu = 2, \sigma^2 = 2)$ .

- Folosiți `erf()` pentru a calcula valorile teoretice ale  $P(X \leq 3)$ , apoi  $P(0 \leq X \leq 4)$  și apoi  $P(X > 5)$ .
- Estimați-le pe toate trei din `x_normal_1`.
- Folosiți funcția `normcdf()` pentru a calcula aceleași probabilități (citiți documentația despre utilizarea ei).

### 3.1 Exerciții suplimentare

- Scrieți `p = myCDF(v, x)` pentru a estima  $P(V \leq x)$ :

$$\hat{F}_V(x) = \frac{\text{numărul elementelor lui } v \text{ care sunt } \leq x}{\text{numărul total de elemente ale lui } v}.$$

Evaluati-o în 100 de puncte folosind o buclă `for`. Reprezentați estimările uniforme și normale împreună cu funcțiile lor de repartiție teoretice.

- Scrieți `p = myPDF(v, x, epsilon)` pentru a estima PDF în jurul lui `x` din eșantioanele aflate în  $[x - \varepsilon, x + \varepsilon]$ :

$$\hat{f}_V(x) = \frac{\text{numărul eșantioanelor din } [x - \varepsilon, x + \varepsilon]}{2\varepsilon N}.$$

Încercați mai multe valori  $\varepsilon$ . Explicați compromisul dintre netezime și detalii.

## 4 Întrebări finale

- Poate o PDF să fie mai mare decât 1? De ce probabilitățile nu pot totuși să depășească 1?
- De ce o estimare din  $N = 1000$  de eșantioane poate fi mai slabă decât una din  $N = 100$ ?
- Două seturi de date au aceeași medie și varianță. Trebuie să aibă aceeași distribuție?
- Cum ați putea decide dacă datele măsurate sunt modelate mai bine de o distribuție uniformă sau de una normală?