

Distribuții ale variabilelor aleatoare

Laboratorul 2, DEDP

Table of contents

1	Obiectiv	1
2	Considerații teoretice	2
2.1	Densitate de probabilitate	2
	Eșantioane aleatoare	3
2.2	Distribuția uniformă	3
	Definiție și parametri	3
	Generarea eşantioanelor uniforme în Matlab	4
	Probabilități pentru distribuția uniformă	5
2.3	Distribuția normală	5
	Definiție și parametri	5
	Generarea eşantioanelor normale în Matlab	6
	Calcularea probabilităților pentru distribuția normală	7
2.4	Histogramele ca reprezentare vizuală a distribuțiilor	8
2.5	Rezumat: funcții și notații pe care trebuie să le cunoașteți	8
3	Exerciții	10
3.1	Exerciții suplimentare	11
4	Întrebări finale	11

1 Obiectiv

Generarea în Matlab a unor eşantioane cu distribuții uniforme și normale, cu diferiți parametri. Calcularea probabilităților teoretice și din vectori de eşantioane. Crearea de histograme. Folosirea funcției `erf()` pentru funcția de repartiție normală.

2 Considerații teoretice

2.1 Densitate de probabilitate

În acest laborator considerăm **variabile aleatoare continue**.

O variabilă aleatoare continuă A este descrisă de o **funcție densitate de probabilitate** (PDF) $w_A(x)$, care arată cât de probabil este ca A să ia valori în jurul lui x . Densitatea de probabilitate mai este numită și **distribuția** lui A .

Probabilitatea ca A să se afle în intervalul $[a, b]$ este **aria de sub PDF** pe acel interval, adică integrala PDF de la a la b :

$$P(a < A \leq b) = \int_a^b w_A(x) dx,$$

Probabilitatea se calculează numai pentru **intervale** de valori. Probabilitatea ca A să fie exact egală cu o anumită valoare este întotdeauna zero.




Figure 1: Probabilitatea = aria de sub densitate

PDF satisface întotdeauna $w_A(x) \geq 0$, iar integrala sa este 1, însă valorile sale pot fi mai mari decât 1.

Funcția de repartiție (CDF) este definită ca probabilitatea ca $A \leq x$:

$$F_A(x) = P(A \leq x)$$

CDF este nedescrescătoare și ia valori între 0 și 1.

CDF poate fi folosită și pentru a calcula probabilități pe intervale:

$$P(a < A \leq b) = F_A(b) - F_A(a).$$

Cele două funcții sunt legate. PDF este derivata CDF:

$$w_A(x) = \frac{dF_A(x)}{dx} \quad F_A(x) = \int_{-\infty}^x w_A(t) dt.$$

Eșantioane aleatoare

O valoare sau un vector cu N valori generate dintr-o anumită distribuție reprezintă un **eșantion aleator**:

$$x = [x_1, x_2, \dots, x_N].$$

Valorile se schimbă la fiecare rulare, dar comportamentul lor statistic ar trebui să rămână același.

Media și varianța (sau deviația standard) calculate dintr-un anumit vector de eșantioane se numesc **media eșantionului** și **varianța eșantionului** (sau deviația standard a eșantionului).

```
% Media, deviația standard și varianța eșantionului, calculate din date
sample_mean = mean(x_normal)
sample_std = std(x_normal)
sample_var = var(x_normal)
```

Media și varianța eșantionului sunt apropiate, dar nu exact egale cu media și varianța teoretică ale distribuției (sunt „estimări” ale acestor valori teoretice).

2.2 Distribuția uniformă

Definiție și parametri

Distribuția uniformă descrie o variabilă aleatoare care are șanse egale să ia orice valoare dintr-un interval dat $[a, b]$.

Se notează:

$$A \sim \mathcal{U}[a, b], \quad \text{unde } a < b.$$

Funcția sa densitate de probabilitate (PDF) este definită astfel:

$$f_A(x) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b, \\ 0, & \text{în rest.} \end{cases}$$

PDF este constantă pe $[a, b]$.




Figure 2: PDF pentru $\mathcal{U}[-2, 2]$.

Media și varianța sa statistică sunt

$$E\{A\} = \frac{a+b}{2}, \quad \sigma_A^2 = \frac{(b-a)^2}{12}.$$

Generarea eșantioanelor uniforme în Matlab

`rand()` generează valori uniforme cu $0 < A < 1$. Nu contează dacă valorile extreme 0 și 1 sunt incluse sau nu, deoarece oricum există o infinitate de valori în interval.

```
A = rand()           % o valoare din U[0,1]
A = rand(1, 10)      % vector linie cu 10 valori independente din U[0,1]
```

Pentru a obține valori dintr-un interval general $[a, b]$, scalați și deplasați valorile:

$$B = a + (b - a)A, \quad A \sim \mathcal{U}[0, 1].$$

```
a = 5;  
b = 7;  
N = 1000;  
  
x_uniform = a + (b-a)*rand(1, N);
```

Aici, $b - a$ stabilește lățimea, iar a stabilește limita inferioară.

Probabilități pentru distribuția uniformă

Probabilitățile sunt arii de sub PDF.

Pentru o variabilă uniformă, calcularea probabilităților se reduce la calcularea ariei unui dreptunghi și se poate face ușor.

Exemplu: pentru $X \sim \mathcal{U}[2, 10]$, probabilitatea ca X să fie între 3 și 5 este $\frac{2}{8} = 0.25$.

2.3 Distribuția normală

Definiție și parametri

Distribuția normală descrie o variabilă aleatoare care ia mai probabil valori apropiate de media sa μ decât valori îndepărtate, conform unei PDF în formă de clopot („clopotul lui Gauss”).

O variabilă normală se notează:

$$X \sim \mathcal{N}(\mu, \sigma^2), \quad \sigma > 0.$$

Funcția sa densitate de probabilitate este

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left[-\frac{(x - \mu)^2}{2\sigma^2} \right].$$




Figure 3: Modificarea lui μ deplasează PDF normală; creșterea lui σ o face mai lată și mai aplatizată.

Parametrii sunt:

- μ : media (centrul);
- σ^2 : varianța;
- $\sigma = \sqrt{\sigma^2}$: abaterea standard.

Modificarea lui μ înseamnă deplasarea PDF. Un σ mai mare înseamnă o funcție mai lată și mai aplatizată, iar un σ mai mic înseamnă una mai îngustă și mai înaltă.

Distribuția normală standard este distribuția normală cu $\mu = 0$ și $\sigma = 1$:

$$Z \sim \mathcal{N}(\mu = 0, \sigma^2 = 1).$$

Generarea eșantioanelor normale în Matlab

`randn()` generează valori din distribuția normală standard $\mathcal{N}(\mu = 0, \sigma^2 = 1)$:

```
z = randn()           % o valoare din N(0,1)
z = randn(1, 10)      % 10 valori independente din N(0,1)
```

Pentru valori arbitrare μ și σ , scalați cu σ și deplasați cu μ :

$$B = \mu + \sigma A, \quad \text{unde } A \sim \mathcal{N}(\mu = 0, \sigma^2 = 1).$$

```
mu = 5;
sigma = 2;
N = 1000;

x_normal = mu + sigma*randn(1, N);
```

Notă: înmulțiți cu abaterea standard σ , nu cu varianța σ^2 .

Calcularea probabilităților pentru distribuția normală

Integrala din densitatea de probabilitate normală nu poate fi calculată analitic. În schimb, folosim funcția predefinită `erf()` din Matlab pentru acest scop.

Pentru o variabilă normală $A \sim \mathcal{N}(\mu, \sigma^2)$, probabilitatea ca A să se afle în intervalul $[a, b]$ este:

$$P(a \leq A \leq b) = F_A(b) - F_A(a),$$

unde $F_A(x)$ este funcția de repartiție (CDF) a lui A și se calculează folosind funcția de eroare `erf()`:

$$F_A(x) = P(A \leq x) = \frac{1}{2} \left[1 + \operatorname{erf} \left(\frac{x - \mu}{\sigma\sqrt{2}} \right) \right].$$

În Matlab:

Exemplu: $A \sim \mathcal{N}(\mu = 10, \sigma^2 = 4)$ și $P(8 \leq X \leq 12)$:

```
mu = 10;
sigma = 2;
a = 8;
b = 12;

F_a = 0.5*(1 + erf((a-mu)/(sigma*sqrt(2))));
F_b = 0.5*(1 + erf((b-mu)/(sigma*sqrt(2))));
p_normal_theory = F_b - F_a
```

Rezultatul este aproximativ 0.6827. Probabilitatea poate fi estimată și din eșantioane, empiric:

```
N = 10000;
x_normal = mu + sigma*randn(1, N);
p_normal_estimated = sum(x_normal >= a & x_normal <= b)/N;
```

2.4 Histogramele ca reprezentare vizuală a distribuțiilor

O **histogramă** este un grafic cu bare care afișează distribuția eșantioanelor, numărând câte eșantioane se află în fiecare interval de valori. În Matlab, se poate folosi funcția `histogram()`:

```
% Generează 10000 de eșantioane dintr-o distribuție uniformă pe [-4, 10]
x_uniform = -4 + 14*rand(1, 10000);

% Afișează o histogramă cu 30 de clase
histogram(x_uniform, 30)
xlabel('Valoare')
ylabel('Număr de eșantioane')
title('Eșantioane uniforme')
grid on
```

Pentru a o compara cu o PDF, trebuie să-i normalizăm aria la 1, folosind opțiunea `'Normalization','pdf'`:

```
% Generează 10000 de eșantioane dintr-o distribuție normală cu media 5 și abaterea standard 2
x_normal = 5 + 2*randn(1, 10000);

% Afișează o histogramă normalizată ca PDF, cu 35 de clase
histogram(x_normal, 35, 'Normalization', 'pdf')
xlabel('Valoare')
ylabel('Densitate de probabilitate estimată')
title('Eșantioane normale')
grid on
```

Histogramele sunt o metodă practică de a vizualiza distribuția eșantioanelor (valori, pixeli etc.) pentru a înțelege datele.

2.5 Rezumat: funcții și notații pe care trebuie să le cunoașteți

Signatură sau notație	Exemplu	Descriere
$X \sim \mathcal{U}[a, b]$	$X \sim \mathcal{U}[-4, 10]$	Distribuție uniformă pe $[a, b]$
$X \sim \mathcal{N}(\mu, \sigma^2)$	$X \sim \mathcal{N}(5, 2^2)$	Distribuție normală: media μ , varianța σ^2
<code>rand(m,n)</code>	<code>rand(1,1000)</code>	$m \times n$ eșantioane din $\mathcal{U}[0, 1]$
<code>a + (b-a)*rand(m,n)</code>	<code>-4 + 14*rand(1,1000)</code>	Eșantioane din $\mathcal{U}[a, b]$
<code>randn(m,n)</code>	<code>randn(1,1000)</code>	$m \times n$ eșantioane din $\mathcal{N}(0, 1)$

Signatură sau notație	Exemplu	Descriere
<code>mu + sigma*randn(m,n)</code> <code>mean(x), std(x), var(x)</code>	<code>5 + 2*randn(1,1000)</code> <code>mean(x), std(x), var(x)</code>	Eșantioane din $\mathcal{N}(\mu, \sigma^2)$ Media, abaterea standard și varianța eșantionului
<code>histogram(x,n)</code>	<code>histogram(x,30)</code>	Histogramă cu n clase; adăugați 'Normalization', 'pdf'
<code>erf(x)</code>	<code>erf(1/sqrt(2))</code>	pentru arie unitară Funcția de eroare folosită în CDF normală
<code>sum(condition)/N</code>	<code>sum(x >= a & x <= b)/N</code>	Probabilitate empirică

3 Exerciții

Scrieți singuri toate comenzile într-un script sau live script. Etichetați figurile și răspundeți la întrebările de interpretare în comentarii.

1. Eșantioane aleatoare uniforme:

- Generați $N = 10000$ de eșantioane din $\mathcal{U}[-4, 10]$.
- Afișați valorile minime și maxime ale vectorului. De ce lipsesc valorile extreme? Și de ce acest lucru nu schimbă distribuția teoretică?
- Comparați `mean()` cu $(a + b)/2$.
- Reprezentați grafic primele 100 de valori generate folosind `plot()`.
- Reprezentați o histogramă normalizată a datelor, cu 30 de intervale. Care este înălțimea sa teoretică?

2. Efectul parametrilor distribuției uniforme:

- Generați câte 10000 de eșantioane din $\mathcal{U}[0, 1]$ și $\mathcal{U}[5, 7]$.
- Reprezentați histogramele normalizate, cu același număr de clase, în ferestre separate (`figure`).
- Descrieți modificările poziției, lățimii și înălțimii PDF.

3. Eșantioane aleatoare normale:

- Stabiliți `mu1 = 2`, `sigma1 = sqrt(2)` și generați 10000 de eșantioane din $\mathcal{N}(\mu = 2, \sigma^2 = 2)$ în `x_normal_1`. Al doilea parametru este varianța.
- Reprezentați grafic primele 100 de valori din vector.
- Reprezentați histograma tuturor valorilor.
- Calculați media și abaterea standard ale eșantionului cu `mean()` și `std()` și comparați-le cu 2 și $\sqrt{2}$. De ce nu sunt exact egale?
- Păstrați `sigma1`, schimbați μ la -3 și comparați histogramele. Ce se schimbă?
- Păstrați `mu1`, schimbați σ la 0.5 și comparați din nou.

4. Probabilități pentru o variabilă uniformă:

Fie $X \sim \mathcal{U}[-4, 10]$.

- Calculați teoretic $P(-1 \leq X \leq 3)$.
- Estimați-o din Exercițiul 1 folosind comparații logice și `sum()`.
- Calculați și estimați $P(X > 7)$.
- Repetăți pentru $N = 100, 1000$ și 100000. Cum tinde să se modifice eroarea? Trebuie să scadă la fiecare rulare?

5. Probabilități pentru o variabilă normală folosind `erf()`:

Fie $X \sim \mathcal{N}(\mu = 2, \sigma^2 = 2)$.

- Folosiți `erf()` pentru a calcula valorile teoretice ale $P(X \leq 3)$, apoi $P(0 \leq X \leq 4)$ și apoi $P(X > 5)$.
- Estimați-le pe toate trei din `x_normal_1`.
- Folosiți funcția `normcdf()` pentru a calcula aceleași probabilități (citiți documentația despre utilizarea ei).

3.1 Exerciții suplimentare

- Scrieți `p = myCDF(v, x)` pentru a estima $P(V \leq x)$:

$$\hat{F}_V(x) = \frac{\text{numărul elementelor lui } v \text{ care sunt } \leq x}{\text{numărul total de elemente ale lui } v}.$$

Evaluati-o în 100 de puncte folosind o buclă `for`. Reprezentați estimările uniforme și normale împreună cu funcțiile lor de repartiție teoretice.

- Scrieți `p = myPDF(v, x, epsilon)` pentru a estima PDF în jurul lui `x` din eșantioanele aflate în $[x - \varepsilon, x + \varepsilon]$:

$$\hat{f}_V(x) = \frac{\text{numărul eșantioanelor din } [x - \varepsilon, x + \varepsilon]}{2\varepsilon N}.$$

Încercați mai multe valori ε . Explicați compromisul dintre netezime și detalii.

4 Întrebări finale

- Poate o PDF să fie mai mare decât 1? De ce probabilitățile nu pot totuși să depășească 1?
- De ce o estimare din $N = 1000$ de eșantioane poate fi mai slabă decât una din $N = 100$?
- Două seturi de date au aceeași medie și varianță. Trebuie să aibă aceeași distribuție?
- Cum ați putea decide dacă datele măsurate sunt modelate mai bine de o distribuție uniformă sau de una normală?