

Distribuția normală

Laboratorul 3, DEPI

Table of contents

1	Obiectiv	1
2	Aspecte teoretice	2
2.1	Distribuția normală	2
	Definiție și parametri	2
	Generarea eșantioanelor normale în Matlab	3
	Calculul probabilităților pentru distribuția normală	3
2.2	Calculul statisticilor din eșantioane de date	4
2.3	Rezumat: funcții și notații pe care trebuie să le cunoașteți	5
3	Exerciții teoretice	6
4	Exerciții	6
4.1	Exercițiu suplimentar	7
5	Întrebări finale	7

1 Obiectiv

Generarea de eșantioane normale pentru diferite valori ale lui μ și σ . Compararea histogramelor și a statisticilor eșantioanelor cu teoria. Calculul probabilităților pentru distribuția normală folosind `erf()` și estimarea lor din eșantioane.

2 Aspecte teoretice

2.1 Distribuția normală

Definiție și parametri

Distribuția normală descrie o variabilă aleatoare care ia valori cu probabilitate mai mare în jurul mediei sale μ decât valori îndepărtate de aceasta, conform unei funcții densitate de probabilitate în formă de clopot („clopotul lui Gauss”).

O variabilă normală se notează:

$$X \sim \mathcal{N}(\mu, \sigma^2), \quad \sigma > 0.$$

Densitatea de probabilitate normală are expresia matematică:

$$w_X(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left[-\frac{(x - \mu)^2}{2\sigma^2} \right].$$




Figure 1: Distribuții normale diferite

Distribuția normală are doi parametri:

- μ , **media** („centrul”), care controlează poziția maximului densității de probabilitate;
- σ , **deviația standard**, care controlează lățimea lobului.
- Uneori se specifică valoarea lui σ^2 , **varianța**, în locul lui σ .

Modificarea lui μ deplasează densitatea de probabilitate într-o parte sau în alta. Un σ mai mare înseamnă o funcție mai lată și mai aplatizată, iar un σ mai mic înseamnă o funcție mai îngustă și mai înaltă.

Distribuția normală standard este distribuția normală cu $\mu = 0$ și $\sigma = 1$:

$$Z \sim \mathcal{N}(\mu = 0, \sigma^2 = 1).$$

Generarea eșantioanelor normale în Matlab

`randn()` generează valori din distribuția normală standard $\mathcal{N}(\mu = 0, \sigma^2 = 1)$:

```
z = randn()           % o valoare din N(0,1)
z = randn(1, 10)      % 10 valori independente din N(0,1)
```

Pentru valori arbitrare ale lui μ și σ , scalați cu σ și deplasați cu μ :

$$B = \mu + \sigma A, \quad \text{unde } A \sim \mathcal{N}(\mu = 0, \sigma^2 = 1).$$

```
mu = 5;
sigma = 2;
N = 1000;
x_normal = mu + sigma*randn(1, N);
```

Observație: înmulțiți cu deviația standard σ , nu cu varianța σ^2 .

Calculul probabilităților pentru distribuția normală

FR a distribuției normale nu poate fi exprimată prin funcții elementare. Se folosește funcția `erf()` din Matlab pentru a o evalua.

Pentru o variabilă normală $A \sim \mathcal{N}(\mu, \sigma^2)$, probabilitatea ca A să fie în intervalul $[a, b]$ este:

$$P(a \leq A \leq b) = F_A(b) - F_A(a),$$

unde $F_A(x)$ este funcția de repartiție (FR) a lui A și se calculează folosind funcția de eroare `erf()`:

$$F_A(x) = P(A \leq x) = \frac{1}{2} \left[1 + \operatorname{erf} \left(\frac{x - \mu}{\sigma\sqrt{2}} \right) \right].$$

În Matlab:

Exemplu: $A \sim \mathcal{N}(\mu = 10, \sigma^2 = 4)$ și $P(8 \leq A \leq 12)$:

```
mu = 10;
sigma = 2;
a = 8;
b = 12;

F_a = 0.5*(1 + erf((a-mu)/(sigma*sqrt(2))));
F_b = 0.5*(1 + erf((b-mu)/(sigma*sqrt(2))));
p_normal_theory = F_b - F_a
```

Rezultatul este aproximativ 0.6827. Îl putem estima și din eșantioane, folosind metoda introdusă în Laboratorul 2 bazată pe numărarea valorilor care satisfac condiția:

```
N = 10000;
x_normal = mu + sigma*randn(1, N);
p_normal_estimated = sum(x_normal >= a & x_normal <= b)/N;
```

2.2 Calculul statisticilor din eșantioane de date

Pentru un vector de valori:

- se pot folosi `mean()`, `std()` și `var()` pentru a calcula statistici din date. Acestea estimează valorile teoretice μ , σ și σ^2 , dar precizia depinde de numărul de valori folosite.
- se poate reprezenta histograma normalizată introdusă în Laboratorul 2 pentru comparația cu o densitate teoretică:

```
histogram(x, 35, 'Normalization', 'pdf')
xlabel('Valoare')
ylabel('Densitate de probabilitate estimată')
grid on
```

- se poate estima orice probabilitate numărând valorile care satisfac condiția și împărțind la `numel()`:

```
p_estimated = sum(x >= a & x <= b)/numel(x);
```

2.3 Rezumat: funcții și notații pe care trebuie să le cunoașteți

Sintaxă sau notație	Exemplu	Descriere
$A \sim \mathcal{N}(\mu, \sigma^2)$	$A \sim \mathcal{N}(2, 2)$	Distribuție normală: media μ , varianța σ^2
$\sigma = \sqrt{\sigma^2}$	$\sigma = \sqrt{2}$	Deviația standard, folosită pentru scalarea lui <code>randn()</code>
<code>randn(m,n)</code> <code>mu + sigma*randn(m,n)</code>	<code>randn(1,1000)</code> <code>2 +</code> <code>sqrt(2)*randn(1,1000)</code>	$m \times n$ valori din $\mathcal{N}(0, 1)$ Valori din $\mathcal{N}(\mu, \sigma^2)$
<code>mean(x)</code> , <code>std(x)</code> , <code>var(x)</code>	<code>std(x)</code>	Media, deviația standard și varianța eșantionului
<code>histogram(x,n)</code>	<code>histogram(x,35)</code>	Histogramă cu <code>n</code> intervale; adăugați 'Normalization', 'pdf'
<code>erf(x)</code>	<code>0.5*(1+erf((x-mu)/(sigma*sqrt(2))))</code>	pentru arie unitară Funcția de eroare folosită
$F_A(b) - F_A(a)$	$P(a \leq A \leq b)$	pentru evaluarea FR normale Probabilitatea unui interval din FR
<code>sum(condition)/numel(x)</code>	<code>sum(x > 5)/numel(x)</code>	Probabilitate empirică

3 Exerciții teoretice

1. Fie A o variabilă aleatoare continuă cu distribuția normală $\mathcal{N}(\mu = 1, \sigma^2 = 20)$.
 - a. Calculați probabilitatea $P(A \in [2, 4])$.
 - b. Care este distribuția variabilei aleatoare B definite prin $B = A - 2$?
 - c. Care este valoarea maximă a densității $w_A(x)$ și pentru ce valoare x este atinsă?
 - d. Care este distribuția variabilei aleatoare C definite prin $C = 3 * A$?(Indiciu: Porniți de la $\mu_C = \overline{C}$ și $\sigma_C^2 = \overline{(C - \mu_C)^2}$ și înlocuiți C .)

4 Exerciții

Scrieți singuri toate comenzile într-un script sau live script. Etichetați figurile și răspundeți la întrebările de interpretare în comentarii.

1. Eșantioane aleatoare normale:
 - a. Generați 10000 de valori din $\mathcal{N}(\mu = 2, \sigma^2 = 2)$ și stocați-le în `x_normal_1`. Al doilea parametru este varianța.
 - b. Reprezentați primele 100 de valori în funcție de indicii lor.
 - c. Reprezentați o histogramă cu 35 de intervale, normalizată ca densitate de probabilitate.
 - d. Calculați media, deviația standard și varianța eșantionului. Comparați-le cu 2, $\sqrt{2}$ și 2.
 - e. Generați din nou vectorul. Care rezultate se schimbă?
2. Efectul parametrilor distribuției normale:
 - a. Generați 10000 de valori din $\mathcal{N}(\mu = -3, \sigma^2 = 2)$. Comparați histograma normalizată ca densitate de probabilitate cu cea din Exercițiul 1.
 - b. Păstrați $\mu = 2$, dar setați $\sigma = 0.5$. Generați 10000 de valori și comparați din nou.
 - c. Descrieți schimbările de poziție, lățime și înălțime în fiecare comparație.
 - d. Calculați media și deviația standard ale eșantionului pentru cei doi vectori noi. Comparați-le cu valorile lor teoretice.
3. Probabilități pentru o variabilă normală:

Fie $A \sim \mathcal{N}(\mu = 2, \sigma^2 = 2)$.

 - a. Folosiți `erf()` pentru a calcula $P(A \leq 3)$, $P(0 \leq A \leq 4)$ și $P(A > 5)$.
 - b. Estimați toate cele trei probabilități din `x_normal_1`.

- c. Repetați estimările cu 100000 de valori. Comparați cu teoria.
 - d. Calculați numărul așteptat de valori mai mari decât 5 pentru $N = 10000$. Comparați-l cu numărul observat în `x_normal_1`.
4. Aceeași medie și varianță, distribuții diferite:
- a. Generați 10000 de valori uniforme în intervalul $[2 - \sqrt{6}, 2 + \sqrt{6}]$.
 - b. Folosiți formulele distribuției uniforme din Laboratorul 2 pentru a verifica faptul că media și varianța teoretice sunt ambele 2.
 - c. Comparați histograma normalizată ca densitate de probabilitate cu cea a lui `x_normal_1`.
 - d. Comparați mediile și varianțele eșantioanelor. Pot doar aceste două mărimi să distingă distribuțiile?
 - e. Estimați $P(1 \leq A \leq 3)$ pentru fiecare vector. Sunt probabilitățile similare?

4.1 Exercițiu suplimentar

5. Estimați o densitate de probabilitate direct din eșantioane:

Scrieți `p = myPDF(v, x, epsilon)` folosind

$$\hat{w}_A(x) = \frac{\text{numărul de valori în } [x - \varepsilon, x + \varepsilon]}{2\varepsilon N}, \quad N = \text{numel}(v).$$

- a. Evaluați-o în 100 de puncte de la -4 la 8 folosind `x_normal_1`.
- b. Reprezentați estimarea împreună cu densitatea normală teoretică. Folosiți operații element cu element când evaluați densitatea pe un vector.
- c. Repetați cu $\varepsilon = 0.1, 0.3$ și 0.8 . Comparați netezimea și nivelul de detaliu.

5 Întrebări finale

- 1. Un vector normal generat are valori minime și maxime. De ce nu ar trebui folosite ca limite fixe pentru eșantioane viitoare din aceeași distribuție?
- 2. Poate un experiment să nu conțină nicio valoare peste un prag, chiar dacă probabilitatea teoretică de depășire este pozitivă?
- 3. De ce pot două distribuții cu aceeași medie și varianță să dea probabilități diferite pentru același interval?
- 4. O histogramă are formă de clopot. Este suficient pentru a concluziona că datele urmează o distribuție normală? Ce comparații suplimentare ați putea face?