

Medii temporale și statistice

Laboratorul 3, DEPI

Table of contents

1	Obiectiv	1
2	Aspecte teoretice	1
2.1	Media, varianța și devianța standard statistică	1
2.2	Media, varianța și devianța standard temporală	2
2.3	Calculul mediilor în Matlab	3
2.4	Încărcarea variabilelor dintr-un fișier	4
2.5	Rezumat: funcții și notații de cunoscut	4
3	Exerciții	6
4	Întrebări finale	8

1 Obiectiv

Folosiți `mean()`, `std()` și `var()` pentru a caracteriza măsurători reale. Distingeți mediile calculate în timp de cele calculate pe un ansamblu de observații, alegeți dimensiunea corectă a matricei și explicați de ce media unor rapoarte diferă de raportul sumelor.

2 Aspecte teoretice

2.1 Media, varianța și devianța standard statistică

Mediile statistice sunt definite pe baza distribuției de probabilitate, nu pe baza unei anumite secvențe de măsurători.

Pentru o variabilă aleatoare continuă A , cu densitatea de probabilitate $w_A(x)$, **media statistică** este

$$\mu_A = E\{A\} = \int_{-\infty}^{\infty} x w_A(x) dx.$$

Varianța statistică este:

$$\sigma_A^2 = E\{(A - \mu_A)^2\} = \int_{-\infty}^{\infty} (x - \mu_A)^2 w_A(x) dx.$$

Devianța standard este rădăcina pătrată a varianței:

$$\sigma_A = \sqrt{\sigma_A^2}.$$

Pentru o variabilă aleatoare discretă, integralele se înlocuiesc cu sume.

Observație: Când lucrăm cu date, nu putem calcula direct aceste integrale, deoarece ele presupun cunoașterea distribuției de probabilitate. În practică, folosind vectori lungi de date măsurate, calculăm **medii temporale**. Dacă este îndeplinită proprietatea numită *ergodicitate*, mediile temporale converg către mediile statistice când numărul de eșantioane tinde la infinit.

2.2 Media, varianța și devianța standard temporală

Mediile temporale sunt cele pe care le calculăm în practică, de exemplu în Matlab, când avem un vector finit de eșantioane.

Pentru un vector finit $x[1], \dots, x[N]$, **media temporală** este

$$m = \bar{X} = \frac{1}{N} \sum_{n=1}^N x[n].$$

Varianța temporală este:

$$v = \frac{1}{N-1} \sum_{n=1}^N (x[n] - \bar{X})^2$$

sau:

$$v = \frac{1}{N} \sum_{n=1}^N (x[n] - \bar{X})^2$$

Diferența constă în primul termen, numit **factor de normalizare**, care este $\frac{1}{N-1}$ sau $\frac{1}{N}$. Alegerea depinde de faptul că media $\bar{X}$ este estimată din aceleași date sau este cunoscută *a priori*:

- folosiți $\frac{1}{N-1}$ când media $\bar{X}$ este estimată din aceleași date;
- folosiți $\frac{1}{N}$ când media $\bar{X}$ este media adevărată, cunoscută *a priori*.

Devianța standard temporală este rădăcina pătrată a varianței:

$$s = \sqrt{v}.$$

Pentru o secvență de lungime infinită, mediile temporale sunt definite ca limite ale mediilor calculate pe intervale din ce în ce mai lungi.

2.3 Calculul mediilor în Matlab

Pentru un vector, `mean()` calculează media aritmetică. Implicit, `var()` și `std()` folosesc normalizarea cu $N - 1$, iar `var(x,1)` și `std(x,1)` folosesc N :

```
x = [1, 2, 1, 5, 6, 5, 6, 6, 7, 10, 14, -3];
m = mean(x)
v = var(x)          % numitor N-1
s = std(x)          % rădăcina pătrată a lui var(x)
vN = var(x, 1)      % numitor N
sN = std(x, 1)      % rădăcina pătrată a lui var(x, 1)
```

Pentru o matrice **X**, funcțiile `mean(X)`, `std(X)` și `var(X)` operează implicit **de-a lungul coloanelor**, obținând un rezultat pentru fiecare coloană.

Pentru a calcula mediile de-a lungul liniilor, specificați argumentul de dimensiune `dim=2` (consultați documentația). De exemplu, pentru o matrice **X** de dimensiune $N \times M$, următoarele comenzi calculează medii temporale și medii pe ansamblu:

```
% mean(X, dim)
mean(X)      % Operează pe coloane. Produce un vector 1 x M de medii pe coloane
mean(X, 2)   % Operează pe linii. Produce un vector N x 1 de medii pe linii
% La fel pentru var()
% Apel: var(X, normalizare, dim)
var(X)       % Folosește 1/(N-1), operează pe coloane
var(X, 1)    % Folosește 1/N, operează pe coloane
var(X, 0, 2) % Folosește 1/(N-1), operează pe linii
```

```

var(X, 1, 2)    % Folosește 1/N, operează pe linii
% La fel pentru std()
std(X)         % Folosește 1/(N-1), operează pe coloane
std(X, 1)      % Folosește 1/N, operează pe coloane
std(X, 0, 2)   % Folosește 1/(N-1), operează pe linii
std(X, 1, 2)   % Folosește 1/N, operează pe linii

```

2.4 Încărcarea variabilelor dintr-un fișier

`load()` citește variabile salvate într-un fișier `.mat`, salvat în prealabil cu `save()`:

```

D = load('data.mat');    % Stochează variabilele salvate într-o structură
x = D.x;                 % Accesează variabila cu numele x

load('data.mat');        % Încarcă variabilele direct în Workspace

```

Cu un argument de ieșire, variabilele devin câmpuri ale unei **structuri**, accesibile folosind punctul. Fără un argument de ieșire, ele apar direct în Workspace și pot suprascrie variabile cu aceleași nume. Fișierul trebuie să fie în directorul curent sau să fie indicat prin calea sa.

2.5 Rezumat: funcții și notații de cunoscut

Sintaxă sau notație	Exemplu	Descriere
$E\{A\}$	$\mu_A = E\{A\}$	Media statistică, definită prin distribuție
σ_A^2, σ_A	$\sigma_A = \sqrt{\sigma_A^2}$	Varianța și devianța standard statistică
<code>mean(x)</code>	<code>mean(x)</code>	Media aritmetică a unui vector; media temporală dacă elementele sunt eșantioane în timp
<code>std(x,1), var(x,1)</code>	<code>var(x,1)</code>	Deviația standard și varianța observată, normalizate cu N
<code>std(x), var(x)</code>	<code>std(x), var(x)</code>	Deviația standard și varianța eșantionului, normalizate cu $N - 1$
<code>mean(X,dim)</code>	<code>mean(X,2)</code>	Media de-a lungul dimensiunii alese a matricei

Sintaxă sau notație	Exemplu	Descriere
<code>std(X,w,dim),</code> <code>var(X,w,dim)</code>	<code>std(X,0,1)</code>	Deviația standard și varianța de-a lungul unei dimensiuni: w=0 folosește $N - 1$, w=1 folosește N
<code>X(:)</code>	<code>mean(X(:))</code>	Toate elementele matricei într-un singur vector coloană
<code>load(filename)</code>	<code>load('data.mat')</code>	Încarcă variabilele salvate direct în Workspace
<code>D = load(filename)</code>	<code>D = load('data.mat'); x = D.x;</code>	Încarcă variabilele salvate într-o structură; câmpurile se accesează folosind punctul

3 Exerciții

Scrieți singuri toate comenzile într-un script sau live script. Etichetați figurile și răspundeți la întrebările de interpretare în comentarii. Rulați scriptul din directorul care conține fișierele `ElectionsData.mat` și `ECG_test.mat`, astfel încât căile relative către date să funcționeze.

1. Media, deviația standard și varianța:

- Generați un vector $\mathbf{x}$ cu $N = 1000$ valori aleatoare din distribuția $\mathcal{N}(\mu = 3, \sigma^2 = 4)$, folosind `randn()` și operațiile de scalare și deplasare învățate în Laboratorul 2.
- Calculați media, deviația standard și varianța vectorului și comparați-le cu media, deviația standard și varianța teoretică. De ce nu sunt exact egale?
- Rulați din nou toate comenzile (generați din nou vectorul, recalculați statisticile și comparați rezultatele). Se schimbă rezultatele? De ce?
- Calculați media manual, folosind `sum()` și `numel()`, apoi comparați rezultatul cu `mean()`.
- Verificați că `std(x)^2` coincide cu `var(x)` în limita preciziei numerice.
- Precizați media, deviația standard și varianța pentru $\mathbf{x}+10$ și $2*\mathbf{x}$. Ce mărimi se schimbă la deplasare? Dar la scalare?
- Verificați predicțiile calculând efectiv $\mathbf{x}+10$ și $2*\mathbf{x}$, apoi media, deviația standard și varianța lor.

2. Prezența la vot:

Încărcați `ElectionsData.mat`, care conține date de la alegerile locale din Iași, din 27 septembrie 2020:

```
D = load('ElectionsData.mat');  
values = double(D.values);
```

`double()` convertește numerele întregi stocate în valori în virgulă mobilă, înainte de efectuarea calculelor.

Fiecare linie din `values` corespunde unei secții de votare. Coloanele sunt:

Coloană	Semnificație
1	Alegători înscriși pe listele permanente
2	Alegători înscriși pe listele complementare
3	Voturi de pe listele permanente
4	Voturi de pe listele complementare
5	Voturi de pe listele suplimentare
6	Voturi prin urna mobilă

Pentru acest exercițiu, definiți prezența la vot astfel:

$$\text{prezența la vot (\%)} = 100 \frac{\text{total voturi (coloanele 3-6)}}{\text{alegători înscriși (coloanele 1-2)}}.$$

- Calculați numărul total de alegători înscriși și numărul total de voturi pentru fiecare secție. Stocați-le în vectorii coloană **registered** și **votes**. Indiciu: folosiți **sum()** și specificați dimensiunea de-a lungul liniilor.
 - Asigurați-vă că toate elementele din **registered** și **votes** sunt pozitive. Scrieți codul care înlocuiește cu zero toate elementele negative, dacă există.
 - Calculați procentul de prezență la vot pentru fiecare secție (folosiți **./**).
 - Reprezentați grafic prezența la vot în funcție de indicele secției. Reprezentați histograma prezenței la vot.
 - Calculați media, deviația standard și varianța prezenței la vot. Exprimați deviația standard în puncte procentuale.
 - Calculați prezența la vot pentru întregul oraș: numărul total de voturi din toate secțiile împărțit la numărul total de alegători înscriși, înmulțit cu 100. Comparați cu media de la punctul e. De ce diferă?
 - Împărțiți secțiile în două grupuri:
 - cele cu un număr de alegători înscriși mai mic decât **median(registered)**;
 - cele cu un număr de alegători înscriși mai mare sau egal cu **median(registered)**.
- Calculați media și deviația standard pentru fiecare grup. Care grup are o împrăștiere mai mare?

3. Semnale ECG:

Încărcați **ECG_test.mat**, care conține 80 de semnale ECG:

```
E = load('ECG_test.mat');
X = E.test;
```

Fiecare coloană din **X** conține un semnal cu 256 de eșantioane. Fiecare linie conține valorile tuturor semnalelor la același indice de eșantion. Folosiți indicele eșantionului pe axa orizontală și amplitudinea, în unitățile setului de date, pe axa verticală.

- Extrageți primul semnal, adică prima coloană din **X**, și stocați-l într-o variabilă **s**. Reprezentați-l grafic. Calculați media, deviația standard și varianța.
- Împărțiți **s** în patru blocuri consecutive de câte 64 de eșantioane. Calculați media și deviația standard pentru fiecare bloc. Care bloc are cea mai mare deviație standard? Comparați cu graficul.
- Calculați media temporală, deviația standard și varianța fiecărui semnal. Stocați rezultatele în trei vectori linie cu câte 80 de elemente. Indiciu: apălați fiecare funcție o singură dată și specificați dimensiunea de-a lungul căreia operează.
- Reprezentați mediile temporale și deviațiile standard în funcție de indicele semnalului, în figuri separate. Au toate semnalele medii similare? Dar împrăștierea similară?

- e. Calculați media și deviația standard pe ansamblul celor 80 de semnale, la fiecare indice de eșantion. Stocați rezultatele în doi vectori coloană cu câte 256 de elemente. Indiciu: specificați dimensiunea de-a lungul liniilor.
- f. Reprezentați grafic semnalul mediu de la punctul e.
- g. Reprezentați semnalele 1, 2 și 3 împreună cu semnalul mediu (folosiți funcția `plot()` cu o matrice de date; consultați documentația). Apar vârfurile lor la indici de eșantion similari?

4 Întrebări finale

1. Reordonați aleator eșantioanele unui semnal ECG. Ce se întâmplă cu media și varianța lui? Se schimbă sau nu?
2. Împărțiți o secție de votare în două jumătăți identice, împărțind în mod egal atât voturile, cât și alegătorii înscriși. Se poate schimba media prezenței la vot pe secții, deși voturile tuturor alegătorilor au rămas aceleași? Ce se întâmplă cu prezența la vot pentru întregul oraș?
3. Deplasați independent fiecare semnal ECG cu un număr diferit de eșantioane, mutând circular eșantioanele care depășesc capetele. Fiecare semnal își păstrează media și varianța. Rămâne neschimbat semnalul mediu calculat pe ansamblul înregistrărilor?