

Decizie și Estimare în Prelucrarea Informației

Capitolul II. Elemente de teorie statistică a detecției

II.1 Introdurre

- ▶ Detecția semnalelor = a decide care semnal este prezent dintre două sau mai multe posibilități
 - ▶ inclusiv că nu există nici un semnal (este 0)
- ▶ Avem la dispoziție observații **cu zgomot**
 - ▶ semnalele sunt afectate de zgomot
 - ▶ zgomotul este aditiv (se adună la semnalul original)

Schema bloc a detecției semnalelor




Figure 1: Signal detection model

► Conținut:

- Sursa de informație: generează mesaje a_n cu probabilitățile $p(a_n)$
- Generator: generează semnalele diferite $s_1(t), \dots, s_n(t)$
- Modulator: transmite semnalul $s_n(t)$ la mesajul a_n
- Canal: adaugă zgomot aleator
- Eșantionare: ia eșantioane din semnalul $s_n(t)$
- Receptor: **decide** ce mesaj a_n s-a fost recepționat
- Utilizator: primește mesajele recuperate

► Transmisie de date

- nivele constante de tensiune (de ex. $s_n(t) = \text{constant } 0 \text{ sau } 5V$)
- modulație PSK (Phase Shift Keying): $s_n(t) = \text{cosinus}$ cu aceeași frecvență dar faze inițiale diferite
- modulație FSK (Frequency Shift Keying): $s_n(t) = \text{cosinus}$ cu frecvențe diferite
- modulație OFDM (Orthogonal Frequency Division Multiplexing): caz particular de FSK

► Radar

- se emite un semnal; în cazul unui obstacol, semnalul se reflectă înapoi
- receptorul așteaptă posibilele reflecții ale semnalului emis și decide
 - nu este prezentă o reflecție -> nici un obiect
 - semnalul reflectat este prezent -> obiect detectat

- ▶ Decizie între mai mult de două semnale
- ▶ Numărul de eşantioane (observații):
 - ▶ un singur eşantion
 - ▶ mai multe eşantioane
 - ▶ observarea întregului semnal continuu, pentru un timp T

II.2 Detectia semnalelor folosind 1 esantion

Detecția unui semnal cu 1 eșantion

- ▶ Cel mai simplu caz: detecția unui semnal afectat de zgomot, folosind un singur eșantion
 - ▶ două mesaje a_0 și a_1
 - ▶ mesajele sunt modulate cu semnalele $s_0(t)$ și $s_1(t)$
 - ▶ pentru a_0 : se transmite $s(t) = s_0(t)$
 - ▶ pentru a_1 : se transmite $s(t) = s_1(t)$
 - ▶ peste semnal se suprapune zgomot aditiv, alb, $n(t)$
 - ▶ se recepționează un semnal cu zgomot, $r(t) = s(t) + n(t)$
 - ▶ eșantionarea preia un singur eșantion la timpul t_0 , $r(t_0)$
 - ▶ decizie: pe baza $r(t_0)$, care semnal a fost cel transmis?

Ipoteze și decizii

- ▶ Există două **ipoteze**:
 - ▶ H_0 : semnalul adevărat este $s(t) = s_0(t)$ (s-a transmis a_0)
 - ▶ H_1 : semnalul adevărat este $s(t) = s_1(t)$ (s-a transmis a_1)
- ▶ Receptorul poate lua una din două **decizii**:
 - ▶ D_0 : receptorul decide că semnalul corect este $s(t) = s_0(t)$
 - ▶ D_1 : receptorul decide că semnalul corect este $s(t) = s_1(t)$

► Există 4 situații posibile:

1. **Rejecție corectă**: ipoteza corectă este H_0 , decizia este D_0
 - Probabilitatea este $P_r = P(D_0 \cap H_0)$
2. **Alarmă falsă** (detecție falsă): ipoteza corectă este H_0 , decizia este D_1
 - Probabilitatea este $P_{af} = P(D_1 \cap H_0)$
3. **Pierdere** (rejecție falsă): ipoteza corectă este H_1 , decizia este D_0
 - Probabilitatea este $P_p = P(D_0 \cap H_1)$
4. **Detecție corectă**: ipoteza corectă este H_1 , decizia este D_1
 - Probabilitatea este $P_d = P(D_1 \cap H_1)$

- ▶ Terminologia are la origine aplicații radar (prima aplicație a teoriei detecției)
 - ▶ un semnal se emite de către sursă
 - ▶ semnal recepționat = o posibilă reflecție din partea unei ținte, puternic afectată de zgomot
 - ▶ H_0 = nu există un obiect, nu există semnal reflectat (doar zgomot)
 - ▶ H_1 = există un obiect, există un semnal reflectat
 - ▶ de aceea numele celor 4 scenarii sugerează “detecția unui obiect”

- ▶ În general se consideră zgomot **aditiv, alb, staționar**
 - ▶ aditiv = zgomotul se adună ci semnalul
 - ▶ alb = două eșantioane distincte sunt necorelate
 - ▶ staționar = are aceleași proprietăți statistice la orice moment de timp
- ▶ Semnalul de zgomot $n(t)$ este necunoscut
 - ▶ este o realizare a unui proces aleator
 - ▶ se cunoaște doar distribuția sa, nu și valorile particulare

Eșantionul preluat la recepție

- ▶ La recepție se primește semnalul $r(t) = s(t) + n(t)$
 - ▶ $s(t)$ = semnalul original, fie $s_0(t)$, fie $s_1(t)$
 - ▶ $n(t)$ = semnalul de zgomot necunoscut
- ▶ Valoarea eșantionului luat la momentul t_0 este $r(t_0) = s(t_0) + n(t_0)$
 - ▶ $s(t_0)$ = fie $s_0(t_0)$, fie $s_1(t_0)$
 - ▶ $n(t_0)$ este un eșantion din semnalul de zgomot

Eșantionul preluat la recepție

- ▶ Eșantionul $n(t_0)$ este o **variabilă aleatoare**
 - ▶ fiind un eșantion de zgomot (un eșantion dintr-un proces aleator)
 - ▶ presupunem o v.a. continuă , adică intervalul valorilor posibile e continuă
- ▶ $r(t_0) = s(t_0) + n(t_0)$ = o constantă + o variabilă aleatoare
 - ▶ este de asemenea o variabilă aleatoare
 - ▶ $s(t_0)$ este o constantă, egală fie cu $s_0(t_0)$, fie cu $s_1(t_0)$
- ▶ Care e distribuția lui $r(t_0)$?
 - ▶ o constantă + o v.a. = aceeași distribuție ca v.a., dar translată cu valoarea constantei

Funcții de plauzibilitate

- ▶ Fie distribuția zgomotului $w(x)$, cunoscută
 - ▶ aceasta este distribuția v.a. $n(t_0)$
- ▶ Distribuția lui $r(t_0) = s(t_0) + n(t_0) = w(x)$ translată cu $s(t_0)$
- ▶ În ipoteza H_0 , distribuția eșantionului este $w(r|H_0) = w(x)$ translată cu $s_0(t_0)$
- ▶ În ipoteza H_1 , distribuția eșantionului este $w(r|H_1) = w(x)$ translată cu $s_1(t_0)$
- ▶ Distribuțiile $w(r|H_0)$ și $w(r|H_1)$ se numesc **distribuții condiționate** sau **funcțiile de plauzibilitate**
 - ▶ “|” înseamnă “condiționat de”, “dat fiind”
 - ▶ adică dat fiind una sau cealaltă dintre ipoteze
 - ▶ r reprezintă necunoscuta funcției

Criteriul plauzibilității maxime (Maximum Likelihood)

- ▶ Cum se decide care ipoteză este adevărată, pe baza eșantionului observat $r = r(t_0)$?
- ▶ **Criteriul plauzibilității maxime**: se alege ipoteza care este **cea mai plauzibilă** a fi generat eșantionul observat $r = r(t_0)$
 - ▶ se alege valoarea maximă dintre $w(r(t_0)|H_0)$ și $w(r(t_0)|H_1)$
 - ▶ în engleză: Maximum Likelihood (ML)
- ▶ Criteriul ML exprimat la un **raport de plauzibilitate**:

$$\frac{w(r|H_1)}{w(r|H_0)} \underset{H_0}{\overset{H_1}{\gtrless}} 1$$

- ▶ criteriul este evaluat pentru eșantionul observat $r = r(t_0)$

Exemplu: zgomot gaussian

- ▶ Fie cazul în care zgomotul are distribuție normală
- ▶ La tablă:
 - ▶ schiță a celor două distribuții condiționate $w(r|H_0)$ și $w(r|H_1)$
 - ▶ discuție: ce decizie se ia pentru diferite valori ale lui r
 - ▶ discuție: care este pragul T pentru decizii

Zgomot cu distribuție normală (AWGN)

- ▶ Caz particular: zgomotul are distribuția normală $\mathcal{N}(0, \sigma^2)$
 - ▶ zgomot de tip AWGN
- ▶ Raportul de plauzibilitate este $\frac{w(r|H_1)}{w(r|H_0)} = \frac{e^{-\frac{(r-s_1(t_0))^2}{2\sigma^2}}}{e^{-\frac{(r-s_0(r_0))^2}{2\sigma^2}}} \underset{H_0}{\overset{H_1}{\geq}} 1$
- ▶ Pentru distribuția normală, e preferabil să aplicăm **logaritmul natural**
 - ▶ logaritmul este o funcție monoton crescătoare, deci nu schimbă rezultatul comparației
 - ▶ dacă $A < B$, atunci $\log(A) < \log(B)$
- ▶ Valoarea **log-likelihood** al unei observații = logaritmul plauzibilității (likelihood)
 - ▶ de obicei se folosește logaritmul natural, dar poate fi în orice bază

Raportul “log-likelihood” în cazul ML

- ▶ Aplicarea logaritmului natural la ambii termeni ai relației conduce la:

$$-(r - s_1(t_0))^2 + (r - s_0(t_0))^2 \underset{H_0}{\overset{H_1}{\geq}} 0$$

- ▶ Care este echivalent cu:

$$|r - s_0(t_0)| \underset{H_0}{\overset{H_1}{\geq}} |r - s_1(t_0)|$$

- ▶ Notă: $|r - A|$ = distanța dintre r și A

- ▶ $|r|$ = distanța de la r la 0

- ▶ Așadar, se alege distanța minimă dintre $r(t_0)$ și $s_1(t_0)$ sau $s_0(t_0)$

Criteriul ML pentru zgomot gaussian

- ▶ Criteriul ML **pentru zgomot gaussian**: ipoteza se alege pe baza **cele mai apropiate** valori dintre $s_0(t_0)$ și $s_1(t_0)$ față de eșantionul $r = r(t_0)$
 - ▶ principiul **cel mai apropiat vecin** ("*nearest neighbor*")
 - ▶ un principiu foarte general, întâlnit în multe alte scenarii
 - ▶ un receptor ce folosește ML se mai numește **receptor de distanță minimă** ("*minimum distance receiver*")

Etape pentru decizia pe baza ML

1. Se schițează cele două distribuții condiționate $w(r|H_0)$ și $w(r|H_1)$
2. Se determină care dintre cele două funcții este mai mare în dreptul valorii eșantionului observat $r = r(t_0)$

Etape pentru decizia pe baza ML, zgomot gaussian

- ▶ Doar dacă zgomotul este gaussian, identic pentru toate ipotezele:
 1. Se determină $s_0(t_0)$ = valoarea semnalului original, în absența zgomotului, în cazul ipotezei H_0
 2. Se determină $s_1(t_0)$ = valoarea semnalului original, în absența zgomotului, în cazul ipotezei H_1
 3. Se compară cu eșantionul observat $r(t_0)$, se alege cea mai apropiată valoare

Decizie pe bază de prag

- ▶ Alegerea valorii celei mai apropiate = identic cu compararea r cu un prag $T = \frac{s_0(t_0) + s_1(t_0)}{2}$
 - ▶ i.e. dacă cele două valori sunt 0 și 5, decidem prin compararea lui r cu 2.5
- ▶ În general, pragul = punctul de intersecție al celor două distribuții condiționate

- Un semnal poate avea două valori posibile, 0 sau 5. Semnalul este afectat de zgomot alb, gaussian, cu distribuția $\mathcal{N}(\mu = 0, \sigma^2 = 2)$. Receptorul ia un singur eșantion, cu valoarea $r = 2.25$
- Scrieți expresiile celor două distribuții condiționate, și reprezentați-le
 - Ce decizie se ia pe baza criteriului plauzibilității maxime?
 - Dar dacă semnalul 0 este afectat de zgomot gaussian $\mathcal{N}(0, 0.5)$, iar semnalul 5 de zgomot uniform $\mathcal{U}[-4, 4]$?
 - Repetați b. și c. dacă valoarea 0 se înlocuiește cu -1

Regiuni de decizie

- ▶ **Regiuni de decizie** = intervalul de valori ale eșantionului r pentru care se ia o anumită decizie
- ▶ Regiunea de decizie R_0 = intervalul de valori ale lui r care conduc la decizia D_0
- ▶ Regiunea de decizie R_1 = intervalul de valori ale lui r care conduc la decizia D_1
- ▶ Regiunile de decizie acoperă întreg domeniul de valori ale lui r (toată axa reală)
- ▶ Exemplu: indicați regiunile de decizie la exercițiul anterior
 - ▶ $R_0 = [-\infty, 2.5]$
 - ▶ $R_1 = [2.5, \infty]$

Funcția de plauzibilitate

- ▶ Să notăm în mod generic ipotezele cu H_i , și semnalele $s_i(t)$, unde i este 0 sau 1
- ▶ Să considerăm distribuția condiționată $w(r|H_i)$
 - ▶ fie cea de la exemplul anterior:

$$w(r|H_i) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(r-s_i(t_0))^2}{2\sigma^2}}$$

- ▶ Care este variabila necunoscută în această expresie?
 - ▶ nu r , din moment ce acesta ni se dă în problemă
 - ▶ i este necunoscută

Terminologie: probabilitate și plauzibilitate

- ▶ În aceeași expresie matematică a funcției de distribuție:
 - ▶ dacă se cunosc parametrii statistici (de ex. μ , σ , H_i), și necunoscuta este valoarea însăși (de ex. r , x) atunci funcția reprezintă densitatea de **probabilitate**
 - ▶ dacă se cunoaște valoarea însăși (de ex. r , x), și necunoscuta o reprezintă un parametru statistic (de ex. μ , σ , i), atunci avem o **funcție de plauzibilitate**
- ▶ Distincție subtilă între termenii “probabilitate” și “plauzibilitate”

Funcția de plauzibilitate

- ▶ În cazul detecției semnalelor, funcția $w(r|H_i) = f(i)$ este o funcție de plauzibilitate
 - ▶ necunoscuta este i
- ▶ Funcția este definită doar pentru $i = 0$ și $i = 1$
 - ▶ sau, în general, pentru $i =$ câte ipoteze are problema
- ▶ Criteriul ML = se alege i pentru care această funcție este maximă

$$\text{Decizia } D_i = \arg \max_i w(r|H_i)$$

- ▶ Notăție:
 - ▶ $\arg \max f(x)$ = argumentul x pentru care funcția $f(x)$ este maximă
 - ▶ $\max f(x)$ = valoarea maximă a funcției $f(x)$
 - ▶ a se vedea exemplul grafic la tablă
- ▶ Criteriul plauzibilității maxime înseamnă “se alege i care maximizează funcția de plauzibilitate $f(i) = w(r|H_i)$ ”

- ▶ Dacă zgomotul are altă distribuție?
 - ▶ Se schițează distribuțiile condiționate
 - ▶ Se evaluează pentru $r = r(t_0)$
 - ▶ Criteriul ML = se alege cea mai mare funcție $w(r|H_i)$ în punctul r dat
- ▶ Regiunile de decizie sunt date de puncte de intersecție ale distribuțiilor condiționate
 - ▶ Pot fi mai multe intersecții, în general, deci mai multe praguri

- ▶ Dacă zgomotul are distribuție diferită în ipoteza H_0 față de ipoteza H_1 ?
- ▶ Similar:
 - ▶ Se schițează distribuțiile condiționate
 - ▶ Se evaluează pentru $r = r(t_0)$
 - ▶ Criteriul ML = se alege cea mai mare funcție $w(r|H_i)$ în punctul r dat

- ▶ Dacă cele două semnale $s_0(t)$ și $s_1(t)$ sunt constante / nu sunt constante?
- ▶ Nu contează forma semnalelor
 - ▶ Tot ce contează sunt valorile celor două semnale la momentul de eșantionare t_0 :
 - ▶ $s_0(t_0)$
 - ▶ $s_1(t_0)$

- ▶ Dacă avem mai mult de 2 ipoteze?
- ▶ Se extinde raționamentul la n ipoteze
 - ▶ Avem n semnale posibile $s_0(t), \dots, s_{n-1}(t)$
 - ▶ Avem n valori diferite $s_0(t_0), \dots, s_{n-1}(t_0)$
 - ▶ Avem n distribuții condiționate $w(r|H_i)$
 - ▶ Pentru $r = r(t_0)$ dat, se alege valoarea maximă dintre cele n valori $w(r|H_i)$

- ▶ Dacă se iau mai multe eşantioane din semnale?
- ▶ Va fi tratat separat într-un subcapitol ulterior

- ▶ Un semnal poate avea patru valori posibile: -6 , -2 , 2 , 6 . Fiecare valoare este transmisă timp de o secundă. Semnalul este afectat de zgomot alb cu distribuție normală. Receptorul ia un singur eșantion pe secundă. Folosind criteriul plauzibilității maxime, decideți ce semnal s-a transmis, dacă receptorul primește eșantioanele următoare:

4, 6.6, -5.2 , 1.1, 0.3, -1.5 , 7, -7 , 4.4

Probabilități condiționate

- ▶ Putem calcula **probabilitățile condiționate** ale celor 4 rezultate posibile
- ▶ Fie regiunile de decizie:
 - ▶ R_0 : dacă $r \in R_0$, decizia este D_0
 - ▶ R_1 : dacă $r \in R_1$, decizia este D_1
- ▶ Probabilitatea condiționată a rejecției corecte
 - ▶ = probabilitatea de a lua decizia D_0 când ipoteza este H_0
 - ▶ = probabilitatea ca r să fie în R_0 , calculată pe distribuția $w(r|H_0)$

$$P(D_0|H_0) = \int_{R_0} w(r|H_0) dx$$

- ▶ Probabilitatea condiționată a alarmei false
 - ▶ = probabilitatea de a lua decizia D_1 când ipoteza este H_0
 - ▶ = probabilitatea ca r să fie în R_1 , calculată pe distribuția $w(r|H_0)$

$$P(D_1|H_0) = \int_{R_1} w(r|H_0) dx$$

Probabilități condiționate

- ▶ Probabilitatea condiționată de pierdere
 - ▶ = probabilitatea de a lua decizia D_0 când ipoteza este H_1
 - ▶ = probabilitatea ca r să fie în R_0 , calculată pe distribuția $w(r|H_1)$

$$P(D_0|H_1) = \int_{R_0} w(r|H_1) dx$$

- ▶ Probabilitatea condiționată a detecției corecte
 - ▶ = probabilitatea de a lua decizia D_1 când ipoteza este H_1
 - ▶ = probabilitatea ca r să fie în R_1 , calculată pe distribuția $w(r|H_1)$

$$P(D_1|H_1) = \int_{R_1} w(r|H_1) dx$$

Probabilități condiționate

- ▶ Relații între probabilitățile condiționate
 - ▶ suma rejecție corectă + alarmă falsă = 1
 - ▶ suma pierdere + detecție corectă = 1
 - ▶ De ce? Justificați.

Probabilități condiționate




Figure 2: Probabilități condiționate

- Ignorați textul, contează zonele colorate
- [sursa: <http://gru.stanford.edu/doku.php/tutorials/sdt>]*

Probabilitățile celor 4 rezultate

- ▶ Probabilitățile condiționate sunt calculate **dat fiind** una sau alta dintre ipoteze
- ▶ Nu includ și probabilitățile *ipotezelor însele*
 - ▶ adică, $P(H_0)$ = probabilitatea de a avea ipoteza H_0
 - ▶ $P(H_1)$ = probabilitatea de a avea ipoteza H_1
- ▶ Pentru a le lua în calcul, se multiplică cu $P(H_0)$ sau $P(H_1)$
 - ▶ $P(H_0)$ și $P(H_1)$ se numesc probabilitățile **inițiale** (sau **a priori**) ale ipotezelor

Reamintire (TCl): regula lui Bayes

- ▶ Reamintire (TCl): regula lui Bayes

$$P(A \cap B) = P(B|A) \cdot P(A)$$

- ▶ Interpretare

- ▶ Probabilitatea $P(A)$ este extrasă din $P(B|A)$
- ▶ $P(B|A)$ nu mai conține nici o informație despre $P(A)$, șansele ca A chiar să aibă loc
- ▶ Exemplu: $P(\text{gol} \mid \text{șut la poartă}) = \frac{1}{2}$. Câte goluri se înscriu?

- ▶ La noi: $P(D_i \cap H_j) = P(D_i|H_j) \cdot P(H_j)$

- ▶ pentru toți i și j (în toate cele 4 cazuri)

- Un semnal constant poate avea două valori posibile, 0 sau 5. Semnalul este afectat de zgomot gaussian $\mathcal{N}(\mu = 0, \sigma^2 = 2)$. Receptorul decide pe baza criteriului plauzibilității maxime, folosind un singur eșantion din semnal.
- Calculați probabilitatea condiționată a alarmei false
 - Calculați probabilitatea condiționată de pierdere
 - Dacă $P(H_0) = \frac{1}{3}$ și $P(H_1) = \frac{2}{3}$, calculați probabilitatea rejecției corecte și a detecției corecte (nu cele condiționate)

Dezavantaje ale criteriului plauzibilității maxime

- ▶ Criteriul ML compară distribuțiile **condiționate** ale eșantionului observat
 - ▶ condiționate de ipotezele H_0 sau H_1
- ▶ Condiționarea de ipotezele H_0 și H_1 ignoră probabilitatea celor două ipoteze H_0 și H_1
 - ▶ Decizia e aceeași indiferent dacă $P(H_0) = 99.99\%$ și $P(H_1) = 0.01\%$, sau invers
- ▶ Dacă $P(H_0) > P(H_1)$, am vrea să împingem pragul de decizie înspre H_1 , și vice-versa
 - ▶ pentru că este mai probabil ca semnalul să fie $s_0(t)$
 - ▶ și de aceea vrem să “favorizăm”/“încurajăm” decizia D_0
- ▶ Avem nevoie de un criteriu mai general ...

Criteriul probabilității minime de eroare

- ▶ Se iau în calcul probabilitățile $P(H_0)$ și $P(H_1)$
- ▶ Se urmărește **minimizarea probabilității totale de eroare**
$$P_e = P_{af} + P_p$$
 - ▶ erori = alarmă falsă și pierdere
- ▶ Trebuie să găsim un nou criteriu
 - ▶ adică, alte regiuni de decizie R_0 și R_1

Probabilitatea de eroare

- Probabilitatea unei alarme false este:

$$\begin{aligned}P(D_1 \cap H_0) &= P(D_1|H_0) \cdot P(H_0) \\&= \int_{R_1} w(r|H_0) dx \cdot P(H_0) \\&= (1 - \int_{R_0} w(r|H_0) dx) \cdot P(H_0)\end{aligned}$$

- Probabilitatea de pierdere este:

$$\begin{aligned}P(D_0 \cap H_1) &= P(D_0|H_1) \cdot P(H_1) \\&= \int_{R_0} w(r|H_1) dx \cdot P(H_1)\end{aligned}$$

- Probabilitatea totală a erorilor (suma lor) este:

$$P_e = P(H_0) + \int_{-\infty}^T [w(r|H_1) \cdot P(H_1) - w(r|H_0) \cdot P(H_0)] dx$$

Probabilitatea de eroare minimă

- ▶ Urmărim minimizarea P_e , adică să minimizăm integrala
- ▶ Putem alege R_0 cum dorim, pentru acest scop
- ▶ Pentru a minimiza integrala, se alege R_0 astfel încât pentru toți $r \in R_0$, termenul din integrala este **negativ**
 - ▶ integrarea pe întregul interval în care o funcție este negativă conduce la valoarea minimă
- ▶ Așadar, când $w(r|H_1) \cdot P(H_1) - w(r|H_0) \cdot P(H_0) < 0$ avem $r \in R_0$, adică decizia D_0
- ▶ Invers, dacă $w(r|H_1) \cdot P(H_1) - w(r|H_0) \cdot P(H_0) > 0$ avem $r \in R_1$, adică decizia D_1
- ▶ Astfel

$$w(r|H_1) \cdot P(H_1) - w(r|H_0) \cdot P(H_0) \underset{H_0}{\overset{H_1}{\gtrless}} 0$$

$$\frac{w(r|H_1)}{w(r|H_0)} \underset{H_0}{\overset{H_1}{\gtrless}} \frac{P(H_0)}{P(H_1)}$$

- ▶ **Criteriul probabilității minime de eroare (MPE):**

$$\frac{w(r|H_1)}{w(r|H_0)} \underset{H_0}{\overset{H_1}{\gtrless}} \frac{P(H_0)}{P(H_1)}$$

- ▶ prescurtat MPE (Minimum Probability of Error)

- ▶ Criteriul MPE este o generalizare a criteriului ML, depinde de probabilitățile celor două ipoteze (cazuri, simboluri)
 - ▶ se exprimă tot sub forma unui raport de plauzibilitate
- ▶ Când una dintre ipoteze este mai probabilă decât cealaltă, pragul este împins în favoarea sa, înspre cealaltă ipoteză
- ▶ Criteriul ML este un caz particular al MPE pentru for $P(H_0) = P(H_1) = \frac{1}{2}$

Criteriul probabilității minime de eroare - zgomot gaussian

- Presupunând că zgomotul este gaussian (normal), $\mathcal{N}(0, \sigma^2)$

$$w(r|H_1) = e^{-\frac{(r-s_1(t_0))^2}{2\sigma^2}}$$

$$w(r|H_0) = e^{-\frac{(r-s_0(t_0))^2}{2\sigma^2}}$$

- Se aplică logaritmul natural

$$-\frac{(r-s_1(t_0))^2}{2\sigma^2} + \frac{(r-s_0(t_0))^2}{2\sigma^2} \underset{H_0}{\overset{H_1}{\geq}} \ln\left(\frac{P(H_0)}{P(H_1)}\right)$$

- Echivalent

$$(r-s_0(t_0))^2 \underset{H_0}{\overset{H_1}{\geq}} (r-s_1(t_0))^2 + 2\sigma^2 \cdot \ln\left(\frac{P(H_0)}{P(H_1)}\right)$$

- sau, dacă se desfac parantezele:

$$r \underset{H_0}{\overset{H_1}{\geq}} \frac{s_0(t_0) + s_1(t_0)}{2} + \frac{\sigma^2}{s_1(t_0) - s_0(t_0)} \cdot \ln\left(\frac{P(H_0)}{P(H_1)}\right)$$

Interpretarea 1: Comparație între distanțe

- ▶ La criteriul ML, se compară distanțele (la pătrat):

$$|r - s_0(t_0)| \underset{H_0}{\overset{H_1}{\geq}} |r - s_1(t_0)|$$

$$(r - s_0(t_0))^2 \underset{H_0}{\overset{H_1}{\geq}} (r - s_1(t_0))^2$$

- ▶ La criteriul MPE, se compară pătratul distanțelor, dar cu un termen suplimentar în favoarea ipotezei mai probabile:

$$(r - s_0(t_0))^2 \underset{H_0}{\overset{H_1}{\geq}} (r - s_1(t_0))^2 + 2\sigma^2 \cdot \ln \left(\frac{P(H_0)}{P(H_1)} \right)$$

- ▶ termenul depinde de raportul $\frac{P(H_0)}{P(H_1)}$

Interpretarea 2: valoarea de prag

- La criteriul ML, se compară r cu un prag T

$$r \underset{H_0}{\overset{H_1}{\gtrless}} \frac{s_0(t_0) + s_1(t_0)}{2}$$

- La criteriul MPE, pragul este împins înspre ipoteza mai puțin probabilă:

$$r \underset{H_0}{\overset{H_1}{\gtrless}} \frac{s_0(t_0) + s_1(t_0)}{2} + \frac{\sigma^2}{s_1(t_0) - s_0(t_0)} \cdot \ln \left(\frac{P(H_0)}{P(H_1)} \right)$$

- în funcție de raportul $\frac{P(H_0)}{P(H_1)}$

- ▶ Fie decizia între două semnale constante: $s_0(t) = -5$ și $s_1(t) = 5$. Semnalele sunt afectate de zgomot alb cu distribuție gaussiană $\mathcal{N}(0, \sigma^2 = 1)$. Receptorul ia un singur eșantion cu valoarea r .
 - Să se găsească regiunile de decizie conform criteriului MPE
 - Calculați probabilitatea alarmei false și probabilitatea de pierdere
 - Repetăți a) și b) dacă $s_1(t)$ este afectat de zgomot uniform $\mathcal{U}[-4, 4]$?

Criteriul riscului minim

- ▶ Dacă ne afectează mai mult un anumit tip de erori (de ex. alarme false) decât celelalte (pierderi)?
 - ▶ Criteriul MPE tratează toate erorile la fel
 - ▶ Ne trebuie un criteriu mai general
- ▶ Idee: se atribuie **un cost** fiecărui scenariu, apoi se minimizează costul mediu
- ▶ C_{ij} = costul deciziei D_i când ipoteza adevărată este H_j
 - ▶ C_{00} = costul unei rejecții corecte
 - ▶ C_{10} = costul unei alarme false
 - ▶ C_{01} = costul unei pierderi
 - ▶ C_{11} = costul unei detecții corecte
- ▶ Ideea de “costuri” și minimizarea costului mediu este general întâlnită
 - ▶ de ex. TCI: codare: “costul” unui mesaj este lungimea cuvântului de cod, vrem să minimizăm costul mediu, adică lungimea medie

Criteriul riscului minim

- ▶ Definim **riscul** = **media costurilor**

$$R = C_{00}P(D_0 \cap H_0) + C_{10}P(D_1 \cap H_0) + C_{01}P(D_0 \cap H_1) + C_{11}P(D_1 \cap H_1)$$

- ▶ Criteriul riscului minim: **se minimizează riscul R**
 - ▶ adică se minimizează costul mediu
 - ▶ se mai numește “criteriul costului minim”

- ▶ Demonstrație la tablă
 - ▶ se folosește regula lui Bayes
- ▶ Concluzie: regula de decizie este

$$\frac{w(r|H_1)}{w(r|H_0)} \underset{H_0}{\overset{H_1}{\gtrless}} \frac{(C_{10} - C_{00})p(H_0)}{(C_{01} - C_{11})p(H_1)}$$

Criteriul riscului minim (MR):

$$\frac{w(r|H_1)}{w(r|H_0)} \underset{H_0}{\overset{H_1}{\gtrless}} \frac{(C_{10} - C_{00})p(H_0)}{(C_{01} - C_{11})p(H_1)}$$

* prescurtat MR (Minimum Risk)

- ▶ Criteriul MR este o generalizare a MPE (la rândul lui o generalizare a ML)
 - ▶ se exprimă tot printr-un raport de plauzibilitate
- ▶ Atât **probabilitățile** cât și **costurile** pot influența decizia în favoarea uneia sau alteia dintre ipoteze
- ▶ Caz particular: dacă $C_{10} - C_{00} = C_{01} - C_{11}$, MR se reduce la criteriul MPE
 - ▶ de ex.: dacă $C_{00} = C_{11} = 0$ și $C_{10} = C_{01}$

În zgomot gaussian

- ▶ Dacă zgomotul este gaussian (normal), la fel ca la celelalte criterii, se aplică logaritmul natural
- ▶ Se obține:

$$(r - s_0(t_0))^2 \underset{H_0}{\overset{H_1}{\geq}} (r - s_1(t_0))^2 + 2\sigma^2 \cdot \ln \left(\frac{(C_{10} - C_{00})p(H_0)}{(C_{01} - C_{11})p(H_1)} \right)$$

- ▶ sau

$$r \underset{H_0}{\overset{H_1}{\geq}} \frac{s_0(t_0) + s_1(t_0)}{2} + \frac{\sigma^2}{s_1(t_0) - s_0(t_0)} \cdot \ln \left(\frac{(C_{10} - C_{00})p(H_0)}{(C_{01} - C_{11})p(H_1)} \right)$$

Interpretarea 1: Comparație între distanțe

- ▶ La criteriul MPE, se compară pătratul distanțelor, dar cu un termen suplimentar în favoarea ipotezei mai probabile:

$$(r - s_0(t_0))^2 \underset{H_0}{\overset{H_1}{\gtrless}} (r - s_1(t_0))^2 + 2\sigma^2 \cdot \ln \left(\frac{P(H_0)}{P(H_1)} \right)$$

- ▶ termenul depinde de raportul $\frac{P(H_0)}{P(H_1)}$
- ▶ La criteriul MR, pe lângă probabilități apar și costurile

$$(r - s_0(t_0))^2 \underset{H_0}{\overset{H_1}{\gtrless}} (r - s_1(t_0))^2 + 2\sigma^2 \cdot \ln \left(\frac{(C_{10} - C_{00})p(H_0)}{(C_{01} - C_{11})p(H_1)} \right)$$

Interpretarea 2: Valoarea de prag

- ▶ La criteriul MPE, pragul este împins înspre ipoteza mai puțin probabilă:

$$r \underset{H_0}{\overset{H_1}{\gtrless}} \frac{s_0(t_0) + s_1(t_0)}{2} + \frac{\sigma^2}{s_1(t_0) - s_0(t_0)} \cdot \ln \left(\frac{P(H_0)}{P(H_1)} \right)$$

- ▶ în funcție de raportul $\frac{P(H_0)}{P(H_1)}$
- ▶ La criteriul MR, pragul este influențat și de costuri

$$r \underset{H_0}{\overset{H_1}{\gtrless}} \frac{s_0(t_0) + s_1(t_0)}{2} + \frac{\sigma^2}{s_1(t_0) - s_0(t_0)} \cdot \ln \left(\frac{(C_{10} - C_{00})p(H_0)}{(C_{01} - C_{11})p(H_1)} \right)$$

- ▶ Criteriul MR împinge decizia înspre **minimizarea scenariilor cu cost ridicat**
- ▶ Exemplu: din ecuații:
 - ▶ ce se întâmplă dacă costul C_{01} crește, iar celelalte rămân la fel?
 - ▶ ce se întâmplă dacă costul C_{10} crește, iar celelalte rămân la fel?
 - ▶ ce se întâmplă dacă ambele costuri C_{01} și C_{10} cresc, iar celelalte rămân la fel?

Forma generală a criteriilor ML, MPE și MR

- ▶ Criteriile ML, MPE și MR au toate forma următoare

$$\frac{w(r|H_1)}{w(r|H_0)} \underset{H_0}{\overset{H_1}{\gtrless}} K$$

- ▶ pentru ML: $K = 1$
- ▶ pentru MPE: $K = \frac{P(H_0)}{P(H_1)}$
- ▶ pentru MR: $K = \frac{(C_{10} - C_{00})p(H_0)}{(C_{01} - C_{11})p(H_1)}$

Forma generală a criteriilor ML, MPE și MR

În zgomot gaussian, criteriile se reduc la:

- Compararea pătratului distanțelor:

$$(r - s_0(t_0))^2 \underset{H_0}{\overset{H_1}{\gtrless}} (r - s_1(t_0))^2 + 2\sigma^2 \cdot \ln(K)$$

- Compararea eșantionului r cu un prag T :

$$r \underset{H_0}{\overset{H_1}{\gtrless}} \underbrace{\frac{s_0(t_0) + s_1(t_0)}{2} + \frac{\sigma^2}{s_1(t_0) - s_0(t_0)} \cdot \ln(K)}_T$$

Exercițiu

- ▶ Un sistem *airbag* detectează un accident prin eșantionarea semnalului de la un senzor cu 2 valori posibile: $s_0(t) = 0$ (OK) sau $s_1(t) = 5$ (accident).
- ▶ Semnalul este afectat de zgomot gaussian $\mathcal{N}(\mu = 0, \sigma^2 = 1)$.
- ▶ Se ia un singur eșantion din semnal.
- ▶ Costurile scenariilor sunt: $C_{00} = 0$, $C_{01} = 100$, $C_{10} = 10$, $C_{11} = -100$
 - a. Găsiți regiunile de decizie R_0 și R_1 .

Criteriul Neyman-Pearson

- ▶ Un criteriu mai general decât toate cele de până acum
- ▶ Criteriul Neyman-Pearson: se maximizează probabilitatea de detecție ($P(D_1 \cap H_1)$) păstrând probabilitatea alarmei false sub o limită fixată ($P(D_1 \cap H_0) \leq \lambda$)
 - ▶ Se deduce pragul T din constrângerea la limită $P(D_1 \cap H_0) = \lambda$
- ▶ Criteriile ML, MPE și MR sunt cazuri particulare ale Neyman-Pearson, pentru diverse valori ale λ .

Exercițiu

- ▶ O sursă de informație produce două mesaje cu probabilitățile $p(a_0) = \frac{2}{3}$ și $p(a_1) = \frac{1}{3}$.
- ▶ Mesajele sunt codate ca semnale constante cu valorile -5 (a_0) și 5 (a_1).
- ▶ Semnalele sunt afectate de zgomot alb cu distribuție uniformă $U[-5, 5]$.
- ▶ Receptorul ia un singur eșantion r .
 - a. Găsiți regiunile de decizie conform criteriului Neyman-Pearson, pentru $P_{fa} \leq 10^{-2}$
 - b. Care este probabilitatea de detecție corectă?

Aplicație: Semnale diferențiale sau unipolare

- ▶ Aplicație: transmisie binară cu semnale constante (de ex. nivele constante de tensiune)
- ▶ Două modalități frecvent întâlnite:
 - ▶ Semnal unipolar: o valoare este 0, cealaltă este nenulă
 - ▶ $s_0(t) = 0, s_1(t) = A$
 - ▶ Semnal diferențial: două valori nenule cu semne contrare, aceeași valoare absolută
 - ▶ $s_0(t) = -\frac{A}{2}, s_1(t) = \frac{A}{2}$
- ▶ Care metodă este mai bună?

Semnale diferențiale sau unipolare

- ▶ Pentru că există aceeași diferență între nivele, performanțele deciziei sunt identice
- ▶ Dar puterea medie a semnalelor diferă
- ▶ Pentru semnale diferențiale: $P = \left(\pm \frac{A}{2}\right)^2 = \frac{A^2}{4}$
- ▶ Pentru semnale unipolare: $P = P(H_0) \cdot 0 + P(H_1) (A)^2 = \frac{A^2}{2}$
 - ▶ presupunând probabilități egale $P(H_0) = P(H_1) = \frac{1}{2}$
- ▶ Semnalul diferențial necesită putere la jumătate față de cel unipolar (mai bine)

Sumar: criterii de decizie

- ▶ Am văzut: decizie între două semnale, bazată pe 1 eșantion
- ▶ Toate criteriile au la bază raportul de plauzibilitate

$$\frac{w(r|H_1)}{w(r|H_0)} \underset{H_0}{\overset{H_1}{\gtrless}} K$$

- ▶ Criterii diferite conduc la valori diferite pentru K
- ▶ În funcție de distribuția zgomotului, axa reală este împărțită în regiuni de decizie
 - ▶ regiunea R_0 : dacă r este aici, se decide D_0
 - ▶ regiunea R_1 : dacă r este aici, se decide D_1
- ▶ Pentru zgomot gaussian, granița între regiuni (valoarea de prag) este:

$$T = \frac{s_0(t_0) + s_1(t_0)}{2} + \frac{\sigma^2}{s_1(t_0) - s_0(t_0)} \cdot \ln(K)$$

Caracteristica de operare a receptorului (ROC)

- ▶ Performanța unui receptor este ilustrată cu un grafic numit **“Caracteristica de operare a receptorului” (“Receiver Operating Characteristic”, ROC)**
- ▶ Reprezintă probabilitatea $P_d = P(D_1|H_1)$ în funcție de probabilitatea $P_{af} = P(D_1|H_0)$




Figure 3: Sample ROC curves

Caracteristica de operare a receptorului (ROC)

- ▶ Există întotdeauna un **compromis** între P_d (bun) și P_{fa} (rău)
 - ▶ creșterea P_d implică și creșterea P_{fa}
 - ▶ pentru a fi siguri că nu ratăm nici un semnal (creșterea P_d), plătim prin creșterea probabilității de alarme false
- ▶ Criterii diferite = diferite praguri K = diferite puncte pe grafic = compromisuri diferite
- ▶ Cum să creștem performanțele unui receptor?
 - ▶ adică să creștem P_D menținând P_{fa} la aceeași valoare

- ▶ Următoarele trei slide-uri nu se cer pentru examenul 2018-2019 (până la Raportul semnal zgomot).

Performanțele detecției în zgomot alb gaussian

- ▶ Considerăm probabilități egale $P(H_0) = P(H_1) = \frac{1}{2}$
 - ▶ Sau, echivalent, considerăm doar probabilități condiționate
- ▶ Deciziile se iau pe baza raportului de plauzibilitate

$$\frac{w(r|H_1)}{w(r|H_0)} \underset{H_0}{\overset{H_1}{\gtrless}} K$$

- ▶ Probabilitatea detecției corecte este

$$\begin{aligned} P_d &= P(D_1|H_1) \\ &= \int_T^\infty w(r|H_1) \\ &= (F(\infty) - F(T)) \\ &= \frac{1}{2} \left(1 - \operatorname{erf} \left(\frac{T - s_1(t_0)}{\sqrt{2}\sigma} \right) \right) \\ &= Q \left(\frac{T - s_1(t_0)}{\sqrt{2}\sigma} \right) \end{aligned}$$

Performanțele detecției în zgomot alb gaussian

- Probabilitatea alarmei false este

$$\begin{aligned}P_{fa} &= P(D_1 | H_0) \\&= \int_T^\infty w(r | H_0) \\&= (F(\infty) - F(T)) \\&= \frac{1}{2} \left(1 - \operatorname{erf} \left(\frac{T - s_0(t_0)}{\sqrt{2}\sigma} \right) \right) \\&= Q \left(\frac{T - s_0(t_0)}{\sqrt{2}\sigma} \right)\end{aligned}$$

- Rezultă $\frac{T - s_0(t_0)}{\sqrt{2}\sigma} = Q^{-1}(P_{fa})$,
- Și: $\frac{T - s_1(t_0)}{\sqrt{2}\sigma} = Q^{-1}(P_{fa}) + \frac{s_0(t_0) - s_1(t_0)}{\sqrt{2}\sigma}$

Performanțele detecției în zgomot alb gaussian

- ▶ Înlocuind în P_d , obținem:

$$P_d = Q \left(\underbrace{Q^{-1}(P_{fa})}_{constant} + \frac{s_0(t_0) - s_1(t_0)}{\sqrt{2}\sigma} \right)$$

- ▶ Fie un scenariu simplu:

- ▶ $s_0(t_0) = 0$
- ▶ $s_1(t_0) = A = constant$

- ▶ Obținem:

$$P_d = Q \left(\underbrace{Q^{-1}(P_{fa})}_{constant} - \frac{A}{\sqrt{2}\sigma} \right)$$

Raportul semnal zgomot

- ▶ **Raportul semnal zgomot (SNR)** = $\frac{\text{puterea semnalului original}}{\text{puterea zgomotului}}$
- ▶ Puterea medie a unui semnal = valoarea pătratică medie = $\overline{X^2}$
 - ▶ Puterea semnalului original este $\frac{A^2}{2}$
 - ▶ Puterea zgomotului este $\overline{X^2} = \sigma^2$ (pentru valoare medie nulă $\mu = 0$)
- ▶ În cazul nostru, $\text{SNR} = \frac{A^2}{2\sigma^2}$

$$P_d = Q \left(\underbrace{Q^{-1}(P_{fa})}_{\text{constant}} - \sqrt{\text{SNR}} \right)$$

- ▶ Pentru P_{fa} de valoare fixă, P_d crește odată cu SNR
 - ▶ Q este o funcție monoton descrescătoare

Performanța depinde de SNR

- ▶ Performanța receptorului crește odată cu creșterea SNR
 - ▶ SNR mare: performanță bună
 - ▶ SNR mic: performanță slabă




Figure 4: Performanțele detecției depind de SNR

[sursa: *Fundamentals of Statistical Signal Processing*, Steven Kay]

Alte aplicații ale teoriei deciziei

- ▶ Se pot utiliza aceste criterii de decizie în alte aplicații?
 - ▶ nu pentru a decide între semnale, ci în alte scopuri
- ▶ Matematic, problema se pune sub forma următoare:
 - ▶ avem 2 (sau mai multe) distribuții posibile
 - ▶ avem 1 valoare observată
 - ▶ determinăm cea mai plauzibilă distribuție, pe baza valorii observate
- ▶ În acest caz particular, decidem între două semnale
- ▶ Dar acest model matematic se poate aplica și în alte contexte:
 - ▶ medicină: un semnal ECG indică o boală sau nu?
 - ▶ business: va cumpăra clientul un produs, sau nu?
 - ▶ De obicei se folosesc mai multe eșantioane, dar principiul matematic este același

Exemplu (pur imaginar):

- ▶ O persoană sănătoasă cu greutatea $= X$ kg are concentrația de trombocite pe ml de sânge distribuită aproximativ $\mathcal{N}(\mu = 10 \cdot X, \sigma^2 = 20)$.
- ▶ O persoană suferind de boala B are o valoare mult mai scăzută, distribuită aproximativ $\mathcal{N}(100, \sigma^2 = 10)$.
- ▶ În urma analizelor de laborator, ai obținut valoarea $r = 255$. Greutatea este 70 kg.
- ▶ Decideți: sănătos sau nu?

II.3 Detectia semnalelor cu mai multe esantioane

Eșantioane multiple dintr-un semnal

- ▶ Contextul rămâne același:
 - ▶ Se transmite un semnal $s(t)$
 - ▶ Există **două ipoteze**:
 - ▶ H_0 : semnalul original este $s(t) = s_0(t)$
 - ▶ H_1 : semnalul original este $s(t) = s_1(t)$
 - ▶ Receptorul poate lua **două decizii**:
 - ▶ D_0 : se decide că semnalul a fost $s(t) = s_0(t)$
 - ▶ D_1 : se decide că semnalul a fost $s(t) = s_1(t)$
 - ▶ Există 4 scenarii posibile

Eșantioane multiple dintr-un semnal

- ▶ Fiecare eșantion r_i este o **variabilă aleatoare**
 - ▶ $r(t_i) = s(t_i) + n(t_i) = \text{constantă} + \text{o v.a.}$
- ▶ Vectorul \mathbf{r} reprezintă un set de N v.a. dintr-un proces aleator
- ▶ Considerând întreg vectorul \mathbf{r} , valorile vectorului \mathbf{r} sunt descrise de **distribuții de ordin N**

- ▶ În ipoteza H_0 :

$$w_N(\mathbf{r}|H_0) = w_N(r_1, r_2, \dots, r_N|H_0)$$

- ▶ În ipoteza H_1 :

$$w_N(\mathbf{r}|H_1) = w_N(r_1, r_2, \dots, r_N|H_1)$$

Plauzibilitatea vectorului de eşantioane

- ▶ Se aplică **aceleaşi criterii** bazate pe raportul de plauzibilitate în cazul unui singur eşantion

$$\frac{w_N(\mathbf{r}|H_1)}{w_N(\mathbf{r}|H_0)} \underset{H_0}{\overset{H_1}{\gtrless}} K$$

- ▶ Observaţii
 - ▶ \mathbf{r} este un vector; prin el se consideră plauzibilitatea tuturor eşantioanelor
 - ▶ $w_N(\mathbf{r}|H_0)$ = plauzibilitatea vectorului \mathbf{r} în ipoteza H_0
 - ▶ $w_N(\mathbf{r}|H_1)$ = plauzibilitatea vectorului \mathbf{r} în ipoteza H_1
 - ▶ valoarea lui K este dată de criteriul de decizie utilizat
- ▶ Interpretare: se alege ipoteza cea mai plauzibilă de a fi generat datele observate
 - ▶ identic ca la 1 eşantion, doar că acum datele = mai multe eşantioane

- ▶ Presupunând că zgomotul este alb, eşantioanele r_i sunt independente
- ▶ În acest caz, distribuția totală $w_N(\mathbf{r}|H_j)$ se poate descompune ca un produs

$$w_N(\mathbf{r}|H_j) = w(r_1|H_j) \cdot w(r_2|H_j) \cdot \dots \cdot w(r_N|H_j)$$

- ▶ Termenii $w(r_i|H_j)$ sunt plauzibilitățile fiecărui eşantion în parte
 - ▶ de ex. plauzibilitatea obținerii vectorului $[5.1, 4.7, 4.9] = \text{plauzibilitatea obținerii lui } 5.1 \times \text{plauzibilitatea obținerii lui } 4.7 \times \text{plauzibilitatea obținerii lui } 4.9$
- ▶ Funcțiile $w(r_i|H_j)$ sunt distribuțiile condiționate ale fiecărui eşantion
 - ▶ de care am mai văzut deja

- ▶ Prin urmare, criteriile bazate pe raportul de plauzibilitate devin

$$\frac{w_N(\mathbf{r}|H_1)}{w_N(\mathbf{r}|H_0)} = \frac{w(r_1|H_1)}{w(r_1|H_0)} \cdot \frac{w(r_2|H_1)}{w(r_2|H_0)} \cdots \frac{w(r_N|H_1)}{w(r_N|H_0)} \underset{H_0}{\overset{H_1}{\gtrless}} K$$

- ▶ Raportul de plauzibilitate al unui vector de eşantioane = produsul rapoartelor plauzibilitate ale fiecărui eşantion
- ▶ **Se înmulţesc** rapoartele de plauzibilitate ale fiecărui eşantion în parte, şi se aplică criteriile asupra rezultatului final

- ▶ Toate criteriile de decizie pot fi scrise astfel:

$$\frac{w_N(\mathbf{r}|H_1)}{w_N(\mathbf{r}|H_0)} = \frac{w(r_1|H_1)}{w(r_1|H_0)} \cdot \frac{w(r_2|H_1)}{w(r_2|H_0)} \cdots \frac{w(r_N|H_1)}{w(r_N|H_0)} \underset{H_0}{\overset{H_1}{\gtrless}} K$$

- ▶ Valoarea lui K se alege ca pentru 1 esantion:

- ▶ criteriul ML: $K = 1$
- ▶ criteriul MPE: $K = \frac{P(H_0)}{P(H_1)}$
- ▶ criteriul MR: $K = \frac{(C_{10} - C_{00})p(H_0)}{(C_{01} - C_{11})p(H_1)}$

Caz particular: AWGN

- ▶ AWGN = “Additive White Gaussian Noise” = Zgomot alb, gaussian, aditiv
- ▶ În ipoteza H_1 : $w(r_i|H_1) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(r_i-s_1(t_i))^2}{2\sigma^2}}$
- ▶ În ipoteza H_0 : $w(r_i|H_0) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(r_i-s_0(t_i))^2}{2\sigma^2}}$
- ▶ Raportul de plauzibilitate al vectorului \mathbf{r}

$$\frac{w_N(\mathbf{r}|H_1)}{w_N(\mathbf{r}|H_0)} = \frac{e^{-\frac{\sum (r_i-s_1(t_i))^2}{2\sigma^2}}}{e^{-\frac{\sum (r_i-s_0(t_i))^2}{2\sigma^2}}} = e^{\frac{\sum (r_i-s_0(t_i))^2 - \sum (r_i-s_1(t_i))^2}{2\sigma^2}}$$

Criterii de decizie pentru AWGN

- ▶ Raportul de plauzibilitate global se compară cu K :

$$\frac{w_N(\mathbf{r}|H_1)}{w_N(\mathbf{r}|H_0)} = e^{\frac{\sum (r_i - s_0(t_i))^2 - \sum (r_i - s_1(t_i))^2}{2\sigma^2}} \underset{H_0}{\overset{H_1}{\gtrless}} K$$

- ▶ Se aplică logaritmul natural, obținându-se:

$$\sum (r_i - s_0(t_i))^2 \underset{H_0}{\overset{H_1}{\gtrless}} \sum (r_i - s_1(t_i))^2 + 2\sigma^2 \ln(K)$$

Interpretarea 1: distanța geometrică

- Sumele reprezintă **distanța geometrică** la pătrat:

$$\sum (r_i - s_1(t_i))^2 = \|\mathbf{r} - \mathbf{s}_1(\mathbf{t})\|^2 = d(\mathbf{r}, s_1(t))^2$$

$$\sum (r_i - s_0(t_i))^2 = \|\mathbf{r} - \mathbf{s}_0(\mathbf{t})\|^2 = d(\mathbf{r}, s_0(t))^2$$

- distanța între vectorul observat \mathbf{r} și semnalele originale $s_1(t)$, respectiv $s_0(t)$
- vectori cu N eșantioane \Rightarrow distanța între vectori de dimensiune N
- Totul se reduce la a compara distanțele

Interpretarea 1: distanța geometrică

- ▶ Criteriul Maximum Likelihood:
 - ▶ $K = 1$, $\ln(K) = 0$
 - ▶ se alege **distanța minimă** între \mathbf{r} și vectorii $s_1(t)$, respectiv $s_0(t)$
 - ▶ de unde și numele “receptor de distanță minimă”
- ▶ Criteriul Minimum Probability of Error:
 - ▶ $K = \frac{P(H_0)}{P(H_1)}$
 - ▶ Apare un termen suplimentar, în favoarea ipotezei mai probabile
- ▶ Criteriul Minimum Risk:
 - ▶ $K = \frac{(C_{10} - C_{00})p(H_0)}{(C_{01} - C_{11})p(H_1)}$
 - ▶ Termenul suplimentar depinde și de probabilități, și de costuri

Exercițiu:

- ▶ Un semnal poate avea două valori, 0 (ipoteza H_0) sau 6 (ipoteza H_1). Semnalul este afectat de AWGN $\mathcal{N}(0, \sigma^2 = 1)$. Receptorul ia 5 eșantioane cu valorile $\{1.1, 4.4, 3.7, 4.1, 3.8\}$.
 - a. Ce decizie se ia conform criteriului plauzibilității maxime?
 - b. Ce decizie se ia conform criteriului probabilității minime de eroare. dacă $P(H_0) = 2/3$ și $P(H_1) = 1/3$?
 - c. Ce decizie se ia conform criteriului rოსcului minim. dacă $P(H_0) = 2/3$ și $P(H_1) = 1/3$, iar $C_{00} = 0$, $C_{10} = 10$, $C_{01} = 20$, $C_{11} = 5$?

Alt exercițiu

Alt exercițiu:

- ▶ Fie detecția unui semnal $s(t) = 3 \sin(2\pi ft)$ care poate fi prezent (ipoteza H_1) sau absent ($s_0(t) = 0$, ipoteza H_0). Semnalul este afectat de zgomot alb Gaussian $\mathcal{N}(0, \sigma^2 = 1)$. Receptorul ia două eșantioane.
 - a. Care sunt cele mai bune momente de eșantionare t_1 și t_2 pentru a maximiza performanțele detecției?
 - b. Receptorul ia două eșantioane $\{1.1, 4.4\}$, la momentele de timp $t_1 = \frac{0.125}{f}$ și $t_2 = \frac{0.625}{f}$. Care este decizia, conform criteriului plauzibilității maxime?
 - c. Dacă se folosește criteriul probabilității minime de eroare, cu $P(H_0) = 2/3$ și $P(H_1) = 1/3$?
 - d. Dacă se folosește criteriul riscului minim, cu $P(H_0) = 2/3$ și $P(H_1) = 1/3$, iar $C_{00} = 0$, $C_{10} = 10$, $C_{01} = 20$, $C_{11} = 5$?
 - e. Dar dacă receptorul ia un al treilea eșantion la momentul $t_3 = \frac{0.5}{f}$. Se poate îmbunătăți detecția?

Interpretarea 2: produs scalar

- ▶ Dacă se descompun parantezele:

$$\sum (r_i - s_0(t_i))^2 \underset{H_0}{\overset{H_1}{\geq}} \sum (r_i - s_1(t_i))^2 + 2\sigma^2 \ln(K)$$

- ▶ Se obține:

$$\begin{aligned} \sum (r_i)^2 + \sum s_0(t_i)^2 - 2 \sum r_i s_0(t_i) &\underset{H_0}{\overset{H_1}{\geq}} \sum (r_i)^2 + \\ &+ \sum s_1(t_i)^2 - 2 \sum r_i s_1(t_i) + 2\sigma^2 \ln(K) \end{aligned}$$

- ▶ Echivalent cu:

$$\sum r_i s_1(t_i) - \frac{\sum (s_1(t_i))^2}{2} \underset{H_0}{\overset{H_1}{\geq}} \sum r_i s_0(t_i) - \frac{\sum (s_0(t_i))^2}{2} + \sigma^2 \ln(K)$$

Interpretarea 2: produs scalar

- ▶ Algebră: **produsul scalar** al vectorilor **a** și **b**:

$$\langle a, b \rangle = \sum_i a_i b_i$$

- ▶ $\sum r_i s_1(t_i) = \langle \mathbf{r}, \mathbf{s}_1(\mathbf{t}) \rangle$ este produsul scalar al vectorului $\mathbf{r} = [r_1, r_2, \dots, r_N]$ cu $\mathbf{s}_1(\mathbf{t}) = [s_1(t_1), s_1(t_2), \dots, s_1(t_N)]$
- ▶ $\sum r_i s_0(t_i) = \langle \mathbf{r}, \mathbf{s}_0(\mathbf{t}) \rangle$ este produsul scalar al vectorului $\mathbf{r} = [r_1, r_2, \dots, r_N]$ cu $\mathbf{s}_0(\mathbf{t}) = [s_0(t_1), s_0(t_2), \dots, s_0(t_N)]$
- ▶ $\sum (s_1(t_i))^2 = \sum s_1(t_i) \cdot s_1(t_i) = \langle \mathbf{s}_1(\mathbf{t}), \mathbf{s}_1(\mathbf{t}) \rangle = E_1$ este **energia** vectorului $s_1(t)$
- ▶ $\sum (s_0(t_i))^2 = \sum s_0(t_i) \cdot s_0(t_i) = \langle \mathbf{s}_0(\mathbf{t}), \mathbf{s}_0(\mathbf{t}) \rangle = E_0$ este **energia** vectorului $s_0(t)$

Interpretarea 2: produs scalar

- Decizia se poate rescrie sub forma:

$$\langle \mathbf{r}, \mathbf{s}_1 \rangle - \frac{E_1}{2} \underset{H_0}{\overset{H_1}{\gtrless}} \langle \mathbf{r}, \mathbf{s}_0 \rangle - \frac{E_0}{2} + \sigma^2 \ln(K)$$

- Interpretare: **comparăm produsele scalare**

- se scad energiile semnalelor, pentru o comparație corectă
- există de asemenea termenul care depinde de criteriul ales

- Caz particular:

- Dacă cele două semnale au energii egale:

$$E_1 = \sum s_1(t_i)^2 = E_0 = \sum s_0(t_i)^2$$

- Exemple:

- modulație BPSK: $s_1 = A \cos(2\pi ft)$, $s_0 = -A \cos(2\pi ft)$

- modulație 4-PSK: $s_{n=0,1,2,3} = A \cos(2\pi ft + n \frac{\pi}{4})$

- Atunci formula se simplifică:

$$\langle \mathbf{r}, \mathbf{s}_1 \rangle \underset{H_0}{\overset{H_1}{\gtrless}} \langle \mathbf{r}, \mathbf{s}_0 \rangle + \sigma^2 \ln(K)$$

Interpretarea 2: produs scalar

- ▶ În domeniul prelucrărilor de semnale, produsul scalar măsoară **similitudinea** a două semnale
- ▶ Interpretare: verificăm dacă vectorul eșantioanelor **\mathbf{r}** este **mai asemănător** cu $s_1(t)$ sau cu $s_0(t)$
 - ▶ Se alege cel mai similar cu **\mathbf{r}**
 - ▶ Se scad și energiile semnalelor (necesar d.p.d.v. matematic)

Legătura între produs scalar și corelație

- ▶ **Produsul scalar** al vectorilor **a** și **b**:

$$\langle a, b \rangle = \sum_i a_i b_i$$

- ▶ Funcția de corelație (temporală):

$$R_{ab}[\tau] = E\{a_i b_{i+\tau}\}$$

- ▶ Funcția de corelație (temporală) pentru $\tau = 0$:

$$R_{ab}[0] = E\{a_i b_i\} = \frac{1}{N} \sum_i a_i b_i$$

- ▶ Produsul scalar = funcția de corelație în $\tau = 0$
 - ▶ cu un factor de scalare $\frac{1}{N}$ în față

Implementare cu circuite de corelare




Figure 5: Decizie între două semnale

[sursa: *Fundamentals of Statistical Signal Processing*, Steven Kay]

- Convoluția lui $r[n]$ cu $h[n]$ este

$$y[n] = \sum_k r[k]h[n-k] = \sum_k r[k]h[N-1-n+k]$$

- Rezultatul convoluției, la finalul semnalului de intrare, $y[N-1]$ ($n = N-1$), este chiar produsul scalar:

$$y[N-1] = \sum_k r[k]s[k]$$

- ▶ Pentru detecția unui semnal $s[n]$ se poate folosi un **filtru a cărui răspuns la impuls = oglindirea lui $s[n]$** , luându-se eșantionul de la finalul semnalului de intrare

$$h[n] = s[N - 1 - n]$$

- ▶ se obține valoarea produsului scalar
- ▶ **Filtru adaptat** = un filtru proiectat să aibă răspunsul la impuls egal cu oglindirea semnalului care se dorește a fi detectat (eng. “matched filter”)
 - ▶ filtrul este *adaptat* semnalului dorit

Detecția semnalelor cu filtre adaptate

- ▶ Se folosește un filtru adaptat la semnalul $s_1(t_i)$
- ▶ Se folosește un filtru adaptat la semnalul $s_0(t_i)$
- ▶ Se eșantionează ieșirile la momentul final $n = N - 1$
 - ▶ se obțin valorile produselor scalare
- ▶ Se folosește regula de decizie cu produse scalare

Detectia semnalelor cu filtre adaptate

- ▶ Dacă $s_0(t) = 0$, avem nevoie doar de un singur filtru adaptat pentru $s_1(t)$, și se compară rezultatul cu un prag




Figure 6: Detectie folosind un filtru adaptat

[sursa: *Fundamentals of Statistical Signal Processing*, Steven Kay]

II.4 Detectia unui semnal oarecare cu observare continuă

Observarea continuă a unui semnal oarecare

- ▶ Observare continuă = fără eșantionare, se folosește **întreg semnalul continuu**
 - ▶ similar cazului cu N eșantioane, dar cu $N \rightarrow \infty$
- ▶ Semnalele originale sunt $s_0(t)$ și $s_1(t)$
- ▶ Semnalele sunt afectate de zgomot
 - ▶ Presupunem **doar zgomot Gaussian**, pentru simplitate
- ▶ Semnalul recepționat este $r(t)$

Spațiu Euclidean

- ▶ Se extinde cazul precedent cu N eșantioane la cazul unui semnal continuu, $N \rightarrow \infty$
- ▶ Fiecare semnal $r(t)$, $s_1(t)$ și $s_0(t)$ reprezintă un punct într-un spațiu Euclidian infinit dimensional
- ▶ **Distanța** între două semnale este:

$$d(\mathbf{r}, \mathbf{s}) = \sqrt{\int (r(t) - s(t))^2 dt}$$

- ▶ **Produsul scalar** între două semnale:

$$\langle \mathbf{r}, \mathbf{s} \rangle = \int r(t)s(t)dt$$

- ▶ Similar cu cazul N dimensional, dar cu integrală în loc de sumă

Decizie în cazul AWGN: distanțe

- ▶ În cazul AWGN este aceeași regula de decizie:

$$d(\mathbf{r}, \mathbf{s}_0)^2 \underset{H_0}{\overset{H_1}{\geq}} d(\mathbf{r}, \mathbf{s}_1)^2 + 2\sigma^2 \ln(K)$$

- ▶ Distanța = se calculează cu formula precedentă, cu integrală
- ▶ Aceleași criterii de decizie:
 - ▶ Criteriul Maximum Likelihood: $K = 1$, $\ln(K) = 0$
 - ▶ se alege **distanța minimă**
 - ▶ Criteriul Minimum Probability of Error: $K = \frac{P(H_0)}{P(H_1)}$
 - ▶ Criteriul Minimum Risk: $K = \frac{(C_{10} - C_{00})p(H_0)}{(C_{01} - C_{11})p(H_1)}$

Decizie în cazul AWGN: produse scalare

- ▶ În cazul AWGN este aceeași regulă de decizie:

$$\langle \mathbf{r}, \mathbf{s}_1 \rangle - \frac{E_1}{2} \underset{H_0}{\overset{H_1}{\geq}} \langle \mathbf{r}, \mathbf{s}_0 \rangle - \frac{E_0}{2} + \sigma^2 \ln(K)$$

- ▶ Produsul scalar = formula precedentă, cu integrală
- ▶ Toate interpretările rămân identice
 - ▶ se schimbă doar **tipul de semnal** cu care lucrăm

Filtru adaptat

- ▶ Produsul scalar a două semnale se poate calcula cu un **filtru adaptat**
- ▶ **Filtru adaptat** = filtru proiectat să aibă răspunsul la impuls egal cu **oglundirea** semnalului căutat
 - ▶ dacă semnalul original $s(t)$ are lungimea T
 - ▶ atunci $h(t) = s(T - t)$
 - ▶ filtrul este analogic, răspunsul la impuls este continuu
- ▶ ieșirea unui filtru adaptat la momentul $t = T$ este egală cu produsul scalar al intrării $r(t)$ cu $s(t)$

Detecția semnalelor cu filtre adaptate

- ▶ Se folosește un filtru adaptat la semnalul $s_1(t)$
- ▶ Se folosește un alt filtru adaptat la semnalul $s_0(t)$
- ▶ Se eșantionează ieșirile filtrelor la sfârșitul semnalelor, $t = T$
 - ▶ se obțin valorile produselor scalare
- ▶ Se utilizează regula de decizie cu produse scalare

Spații vectoriale Euclidiene

- ▶ Recapitulare: Spații vectoriale Euclidiene
- ▶ Spațiu vectorial
 - ▶ suma a două elemente = rămâne în același spațiu
 - ▶ multiplicarea cu o constantă = rămâne în același spațiu
 - ▶ există operații aritmetice de bază: sumă, multiplicare cu o constantă
 - ▶ Exemple
 - ▶ 1D = o dreaptă
 - ▶ 2D = un plan
 - ▶ 3D = spațiu tridimensional
 - ▶ N-D = ...
 - ▶ ∞ -D = ..

Spații vectoriale Euclidiene

- ▶ Operația fundamentală: **produsul scalar**

- ▶ pentru semnale discrete

$$\langle \mathbf{x}, \mathbf{y} \rangle = \sum_i x_i y_i$$

- ▶ pentru semnale continue

$$\langle \mathbf{x}, \mathbf{y} \rangle = \int x(t)y(t)$$

- ▶ Norma (lungimea) unui vector = radical(produsul scalar cu sine însuși)

$$\|\mathbf{x}\| = \sqrt{\langle \mathbf{x}, \mathbf{x} \rangle}$$

- ▶ Distanța între doi vectori = norma diferenței dintre ei

$$d(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|$$

- ▶ Energia unui semnal = norma la pătrat

$$E_x = \|x\|^2 = \langle x, x \rangle$$

- ▶ Unghiul dintre doi vectori

$$\cos(\alpha) = \frac{\langle x, y \rangle}{\|x\| \cdot \|y\|}$$

- ▶ are valoare între -1 și 1
- ▶ dacă $\langle x, y \rangle = 0$, vectorii sunt **ortogonali** (perpendiculari)

- Bonus: transformata Fourier = produs scalar cu $e^{j\omega t}$

$$\mathcal{F}\{x(t)\} = \langle x(t), e^{j\omega t} \rangle = \int x(t) e^{-j\omega t}$$

- pentru semnale complexe, al doilea termen se conjugă, de aceea este $-j$ în loc de j

$$\langle \mathbf{x}, \mathbf{y} \rangle = \sum_i x_i y_i^*$$

$$\langle \mathbf{x}, \mathbf{y} \rangle = \int x(t) y(t)^*$$

- Identic pentru semnale discrete

- ▶ Concluzie: definirea algoritmilor în mod generic, pe bază de produse scalare / distanțe / norme, este extrem de folositoare!
 - ▶ se aplică automat tuturor spațiilor vectoriale
 - ▶ un singur algoritm, utilizări pentru multiple tipuri de semnale

II.5 Detectia semnalelor cu distributii necunoscute

Distribuții necunoscute

- ▶ Până acum, se cunoștea dpdv. matematic statistica tuturor datelor:
 - ▶ Se cunoșteau semnalele:
 - ▶ $s_0(t) = \dots$
 - ▶ $s_1(t) = \dots$
 - ▶ Se cunoștea zgomotul
 - ▶ gaussian, uniform, etc.
 - ▶ Se cunoșteau distribuțiile condiționate:
 - ▶ $w(r|H_0) = \dots$
 - ▶ $w(r|H_1) = \dots$
- ▶ În aplicații reale, lucrurile pot fi mai complicate

Exemplu

- ▶ Dacă semnalele $s_0(t)$ și $s_1(t)$ nu există / nu se cunosc?
- ▶ Exemplu: recunoașterea feței unei persoane
 - ▶ Identificarea persoanei A sau B bazată pe o imagine a feței
 - ▶ Avem:
 - ▶ 100 imagini ale persoanei A, în condiții diverse
 - ▶ 100 imagini ale persoanei B, în condiții diverse

Eșantioane vs distribuții

- ▶ Să comparăm recunoașterea fețelor cu detecția semnalelor
- ▶ Aspecte comune:
 - ▶ două ipoteze H_0 (persoana A) și H_1 (persoana B)
 - ▶ un vector de eșantioane \mathbf{r} = imaginea pe baza căreia se face decizia
 - ▶ se pot lua două decizii
 - ▶ 4 scenarii: rejectie corectă, alarmă falsă, pierdere, detecție corectă
- ▶ Ce diferă? Nu există formule matematice
 - ▶ nu există semnalele “originale” $s_0(t) = \dots$ și $s_1(t) \dots$
 - ▶ (fețele persoanelor A și B nu pot fi exprimate matematic ca semnale)
 - ▶ în schimb, avem multe exemple din fiecare distribuție
 - ▶ 100 imagini ale lui A = exemple ale \mathbf{r} în ipoteza H_0
 - ▶ 100 imagini ale lui B = exemple ale \mathbf{r} în ipoteza H_1

- ▶ Terminologia folosită în domeniul **învățării automate** (*machine learning*):
 - ▶ Acest tip de problemă = problemă de **clasificare** a semnalelor
 - ▶ se dă un vector de date, găsiți-i clasa
 - ▶ **Clase de semnal** = categoriile posibile ale semnalelor (ipotezele H_i , persoanele A/B etc)
 - ▶ **Set de antrenare** = un set de semnale cunoscute inițial
 - ▶ de ex. 100 de imagini ale fiecărei persoane
 - ▶ setul de date va fi folosit în procesul de decizie

- ▶ Terminologia folosită în domeniul **învățării automate** (*machine learning*):
 - ▶ **Învățare supervizată** = algoritmi unde se cunosc clasele semnalelor din setul de antrenare
 - ▶ se știe care semnale sunt din clasa A și care din clasa B
 - ▶ **Învățare nesupervizată** = algoritmi unde nu se cunosc clasele semnalelor din setul de antrenare
 - ▶ mai dificil, mai puțină informație disponibilă

- ▶ În învățarea supervizată, setul de antrenare conține informațiile pe care le-ar conține distribuțiile condiționate $w(r|H_0)$ și $w(r|H_1)$
 - ▶ $w(r|H_0)$ exprimă cum arată valorile lui r în ipoteza H_0
 - ▶ $w(r|H_1)$ exprimă cum arată valorile lui r în ipoteza H_1
 - ▶ setul de antrenare exprimă același lucru, nu prin formule, dar prin multe exemple
- ▶ Cum se face clasificarea în aceste condiții?

Algoritmul k-NN

Algoritmul *k-Nearest Neighbours* (k-NN)

► Intrare:

- set de antrenare cu vectorii $\mathbf{x}_1 \dots \mathbf{x}_N$, din L clase posibile de semnal $C_1 \dots C_L$
- clasele vectorilor de antrenare sunt cunoscute
- vector de test \mathbf{r} care trebuie clasificat
- parametrul k

1. Se calculează distanța între \mathbf{r} și fiecare vector de antrenare \mathbf{x}_i
 - se poate utiliza distanța Euclidiană, aceeași utilizată pentru detecția semnalelor din secțiunile precedente
 2. Se aleg cei mai apropiați k vectori de \mathbf{r} (cei k "*nearest neighbours*")
 3. Se determină clasa lui $\mathbf{r} =$ clasa majoritară între cei k cei mai apropiați vecini
- Ieșire: clasa vectorului \mathbf{r}

- ▶ k-NN este un algoritm de învățare supervizată
 - ▶ se cunosc clasele vectorilor din setul de antrenare
- ▶ Efectul lui k : netezirea frontierei de decizie:
 - ▶ k mic: frontieră foarte variată
 - ▶ k mare: frontieră netedă
- ▶ Ce valoare se folosește pentru k ?

- ▶ Cum se găsește o valoare optimă pentru k ?
 - ▶ prin încercări (“băbește”)
- ▶ **Cross-validation** = se folosește un mic set de test pentru a verifica care valoare a parametrului e mai bună
 - ▶ acest set de date se numește set de **cross-validare**
 - ▶ se impune $k = 1$, se testează cu setul de *cross-validare* câți vectori sunt clasificați corect
 - ▶ se repetă pentru $k = 2, 3, \dots, \max$
 - ▶ se alege valoarea lui k cu care s-au obținut rezultatele cele mai bune

Evaluarea algoritmilor

- ▶ Cum se evaluează performanța algoritmului k-NN?
 - ▶ Se folosește un set de date de testare, și se calculează procentajul vectorilor clasificați corect
- ▶ Setul de date pentru evaluarea finală trebuie să fie diferit de setul de *cross-validare*
 - ▶ pentru evaluarea finală se folosesc date pe care algoritmul nu le-a mai utilizat niciodată
- ▶ Cum se împarte setul de date disponibile?
 - ▶ Presupunem că avem în total 200 imagini tip fețe, 100 imagini ale persoanei A și 100 ale lui B

Seturi de date

- ▶ Setul de date total se împarte în:
 - ▶ Set de antrenare
 - ▶ vectorii care vor fi utilizați de algoritm
 - ▶ cel mai numeros, aprox. 60% din datele totale
 - ▶ de ex. 60 imagini ale persoanei A și 60 ale lui B
 - ▶ Set de *cross-validare*
 - ▶ utilizat pentru a testa algoritmul în vederea alegerii parametrilor optimi (k)
 - ▶ mai mic, aprox. 20% din date (de ex. 20 imagini ale lui of A și 20 ale lui B)
 - ▶ Set de testare
 - ▶ utilizat pentru evaluarea finală a algoritmului, cu valorile parametrilor fixate
 - ▶ mai mic, aprox. 20% din date (de ex. 20 imagini ale lui of A și 20 ale lui B)

Algoritmul *k-Means*

- ▶ k-Means: un algoritm pentru ***clusterizarea*** datelor
 - ▶ identificarea grupurilor de date apropiate între ele
- ▶ Un exemplu de algoritm de învățare nesupervizată
 - ▶ nu se cunosc clasele din setul de antrenare

Algoritmul *k*-Means

Algoritmul *k*-Means

- ▶ Intrare:
 - ▶ set de antrenare cu vectorii $\mathbf{x}_1 \dots \mathbf{x}_N$
 - ▶ numărul de clase C
- ▶ Inițializare: centroizii C iau valori aleatoare

$$\mathbf{c}_i \leftarrow \text{valori aleatoare}$$

- ▶ Repetă
 1. Clasificare: se clasifică fiecare vector \mathbf{x}_n pe baza celui mai apropiat vecin:

$$l_n = \arg \min_i d(\mathbf{x}_n, \mathbf{c}_i)$$

2. Actualizare: se actualizează centroizii \mathbf{c}_i

$$\mathbf{c}_i \leftarrow \text{media datelor } \mathbf{x}_n, \forall \mathbf{x}_n \text{ din clasa } i$$

- ▶ Ieșire: centroizii \mathbf{c}_i , clasele l_i ale datelor de intrare \mathbf{x}_i

Algoritmul *k-Means*

- ▶ Algoritmul *k-Means* poate să nu convergă spre niște grupuri adecvate de date
 - ▶ rezultatele depind de inițializarea aleatoare a centroizilor
 - ▶ se rulează de mai multe ori, se alege cel mai bun rezultat
 - ▶ există metode de inițializare optimizată (*k-Means++*)