

## Decizie și Estimare în Prelucrarea Informației

## Chapter III. Elemente de Teoria Estimării

## II.1 Introdurre

# Ce înseamnă “estimare”?

- ▶ Un emițător transmite un semnal  $s_{\Theta}(t)$  care depinde de parametru **necunoscut**  $\Theta$
- ▶ Semnalul este afectat de zgomot, se recepționează  
 $r(t) = s_{\Theta}(t) + \text{zgomot}$
- ▶ Vrem să **găsim** valoarea parametrului
  - ▶ pe baza eșantioanelor din semnalul recepționat, sau a întregului semnal
  - ▶ datele recepționate au zgomot  $\Rightarrow$  parametrul este “estimat”
- ▶ Valoarea găsită este  $\hat{\Theta}$ , **estimatul** lui  $\Theta$ 
  - ▶ există întotdeauna eroare de estimare  $\epsilon = \hat{\Theta} - \Theta$
- ▶ Exemple:
  - ▶ Amplitudinea unui semnal constant:  $r(t) = A + \text{zgomot}$ , trebuie estimat  $A$
  - ▶ Faza unui semnal sinusoidal:  $r(t) = \cos(2\pi ft + \phi) + \text{zgomot}$ , de estimat  $\phi$
  - ▶ Semnal vocal înregistrat, de estimat/decis ce cuvânt este pronunțat

- ▶ Fie următoarea problemă de estimare:  $r(t) = A + z_{gomot}$ , de estimat  $A$
- ▶ La detecție se alege între **două valori cunoscute** ale  $A$ :
  - ▶ de ex.  $A$  poate fi 0 sau 5 (ipotezele  $H_0$  și  $H_1$ )
- ▶ La estimare,  $A$  poate fi oricât  $\Rightarrow$  se alege între **o infinitate de opțiuni** ale  $A$ 
  - ▶  $A$  poate fi orice valoare din  $\mathbb{R}$ , în general

- ▶ Detecție = Estimare restrânsă doar la un set discret de opțiuni
- ▶ Estimare = Detecție cu un număr infinit de opțiuni posibile
- ▶ Metodele statistice sunt similare
  - ▶ În practică, distincția între estimare și detecție nu este strictă
  - ▶ (de ex. când trebuie să alegem între 1000 de ipoteze, este “detecție” sau “estimare”?)

# Semnalul recepționat

- ▶ Semnalul recepționat este  $r(t)$ 
  - ▶ este afectat de zgomot, și depinde de parametrul necunoscut  $\Theta$
- ▶ Considerăm **N eșantioane** din  $r(t)$ , luate la momentele de timp  $t_i$

$$\mathbf{r} = [r_1, r_2, \dots, r_N]$$

- ▶ Fiecare eșantion  $r_i$  este o variabilă aleatoare ce depinde de  $\Theta$  (și zgomot)
  - ▶ Fiecare eșantion are o distribuție care depinde de  $\Theta$

$$w_i(r_i; \Theta)$$

- ▶ Întregul vector de eșantioane  $\mathbf{r}$  este o variabilă aleatoare N-dimensională ce depinde de  $\Theta$  (și de zgomot)
  - ▶ Are o distribuție N-dimensională ce depinde de  $\Theta$
  - ▶ Egală cu produsul tuturor  $w_i(r_i; \Theta)$

$$w(\mathbf{r}; \Theta) = w_1(r_1; \Theta) \cdot w_2(r_2; \Theta) \cdot \dots \cdot w_N(r_N; \Theta)$$

- ▶ Considerăm estimarea lui  $\Theta$  în două cazuri:
- 1. Nu cunoaștem alte informații despre parametru, decât cel mult vreun domeniu de existență (de ex.  $\Theta > 0$ )
  - ▶ Parametrul poate avea orice valoare din domeniul de existență, în mod echiprobabil
- 2. Se cunoaște o distribuție  $w(\Theta)$  a lui  $\Theta$ , care indică ce valori ale lui  $\Theta$  sunt mai probabile / mai puțin probabile
  - ▶ este distribuția *a priori* (“cea cunoscută de dinainte”)



## II.2 Estimarea de plauzibilitate maximă (Maximum Likelihood)

# Definiția plauzibilității maxime

- ▶ Dacă nu se cunoaște vreo distribuție *a priori* se folosește metoda estimării de plauzibilitate maximă (“Maximum Likelihood”, ML)
- ▶ Distribuția vectorului recepționat,  $w(\mathbf{r}; \Theta)$ , reprezintă **funcția de plauzibilitate**
  - ▶ vectorul recepționat  $\mathbf{r}$  este cunoscut, deci e o constantă
  - ▶ necunoscuta aici este  $\Theta$

$$L(\Theta) = w(\mathbf{r}; \Theta)$$

- ▶ Estimarea de plauzibilitate maximă: estimatul  $\hat{\Theta}$  este **valoarea care maximizează plauzibilitatea semnalului recepționat**
  - ▶ i.e. valoarea  $\Theta$  care maximizează  $w(\mathbf{r}; \Theta)$

$$\hat{\Theta} = \arg \max_{\Theta} L(\Theta) = \arg \max_{\Theta} w(\mathbf{r}; \Theta)$$

- ▶ Dacă  $\Theta$  aparține doar unui anumit domeniu, se face maximizarea doar asupra acelui domeniu.

- ▶ Maximul se găsește prin derivare și egalare cu 0

$$\frac{dL(\Theta)}{d\Theta} = 0$$

- ▶ Se poate aplica **logaritmul natural** asupra funcției  $L(\Theta)$  înainte de derivare (“log-likelihood function”)

$$\frac{d \ln (L(\Theta))}{d\Theta} = 0$$

# Calculul maximului

Metoda:

1. Se găsește expresia funcției

$$L(\Theta) = w(\mathbf{r}; \Theta)$$

2. Se pune condiția ca derivata lui  $L(\Theta)$  sau a lui  $\ln(L(\Theta))$  să fie 0

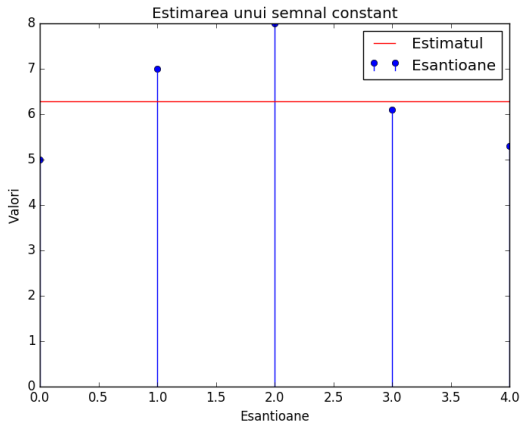
$$\frac{dL(\Theta)}{d\Theta} = 0, \text{ or } \frac{d \ln(L(\Theta))}{d\Theta} = 0$$

3. Se rezolvă ecuația, se găsește valoarea  $\hat{\Theta}$
4. Se verifică că derivata a doua în punctul  $\hat{\Theta}$  este negativă, pentru a verifica că este un punct de maxim
  - ▶ întrucât derivata = 0 și pentru maxime și pentru minime

Semnal constant în zgomot gaussian:

- ▶ Găsiți estimatul Maximum Likelihood pentru constanta  $A$  din 5 măsurători afectate de zgomot  $r_i = A + noise$ , cu valori egale cu  $[5, 7, 8, 6.1, 5.3]$ . Zgomotul este AWGN  $\mathcal{N}(\mu = 0, \sigma^2)$ .
- ▶ Soluție: la tablă
- ▶ Estimatul  $\hat{A}$  este chiar valoarea medie a eșantioanelor (deloc surprinzător)

# Simulare numerică



# Semnal oarecare în AWGN

- ▶ Fie semnalul original “curat”  $s_{\Theta}(t)$
- ▶ Zgomotul este AWGN  $\mathcal{N}(\mu = 0, \sigma^2)$
- ▶ Eșantioanele  $r_i$  sunt luate la momentele  $t_i$
- ▶ Eșantioanele  $r_i$  au distribuție normală, cu media  $s_{\Theta}(t_i)$  și varianța  $\sigma^2$
- ▶ Funcția de plauzibilitate globală = produsul plauzibilității fiecărui eșantion  $r_i$

$$\begin{aligned} L(\Theta) &= \prod_{i=1}^N \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(r_i - s_{\Theta}(t_i))^2}{2\sigma^2}} \\ &= \left( \frac{1}{\sigma\sqrt{2\pi}} \right)^N e^{-\frac{\sum (r_i - s_{\Theta}(t_i))^2}{2\sigma^2}} \end{aligned}$$

- ▶ Logaritmul plauzibilității (“log-likelihood”) este

$$\ln(L(\Theta)) = \underbrace{N \ln \left( \frac{1}{\sigma\sqrt{2\pi}} \right)}_{\text{constant}} - \frac{\sum (r_i - s_{\Theta}(t_i))^2}{2\sigma^2}$$

# Semnal oarecare în AWGN

- ▶ Maximul funcției = minimul exponentului

$$\hat{\Theta} = \arg \max_{\Theta} w(r; \Theta) = \arg \min \sum (r_i - s_{\Theta}(t_i))^2$$

- ▶ Termenul  $\sum (r_i - s_{\Theta}(t_i))^2$  este **distanța  $d(\mathbf{r}, s_{\Theta})$  la pătrat**

$$d(\mathbf{r}, s_{\Theta}) = \sqrt{\sum (r_i - s_{\Theta}(t_i))^2}$$

$$(d(\mathbf{r}, s_{\Theta}))^2 = \sum (r_i - s_{\Theta}(t_i))^2$$

- ▶ Estimatul de plauzibilitate maximă  $\hat{\Theta}$  = valoarea care face  $s_{\Theta}(t_i)$  **cel mai apropiat de vectorul recepționat  $\mathbf{r}$** 
  - ▶ mai aproape = mai probabil
  - ▶ cel mai aproape = cel mai probabil = plauzibilitate maximă
- ▶ Pentru semnale continue? Similar, dar utilizând distanța între semnale continue



# Semnal oarecare în AWGN

- ▶ Estimatul se găsește prin setarea derivatei la 0

$$\frac{d \ln (L(\Theta))}{d\Theta} = 0$$


înseamnă

$$\sum (r_i - s_{\Theta}(t_i)) \frac{ds_{\Theta}(t_i)}{d\Theta} = 0$$

Estimarea frecvenței  $f$  a unui semnal sinusoidal


- ▶ Găsiți estimatul Maximum Likelihood pentru frecvența  $f$  a unui semnal cosinus, din 10 măsurători afectate de zgomot  $r_i = \cos(2\pi f t_i) + \text{zgomot}$  de valori [...]. Zgomotul este AWGN  $\mathcal{N}(\mu = 0, \sigma^2)$ . Momentele de eșantionare sunt  $t_i = [0, 1, 2, 3, 4, 5, 6, 7, 8, 9]$
- ▶ Soluție: la tablă

Funcția de plauzibilitate este



# Simulare numerică

Frecventa originala = 0.070000, estimatul = 0.071515



# Estimare ML și Detecție ML

- ▶ La estimarea ML, estimatul  $\hat{\Theta}$  este valoarea care maximizează funcția de plauzibilitate
- ▶ La detecție ML, criteriul de decizie  $\frac{w(r|H_1)}{w(r|H_0)} \underset{H_0}{\overset{H_1}{\gtrless}} 1$  înseamnă “alege ipoteza pentru care funcția de plauzibilitate este mai mare”
- ▶ Același principiu, doar în contexte diferite:
  - ▶ la detecție, avem de ales doar între câteva opțiuni predefinite
  - ▶ la estimare nu mai avem constrângeri  $\Rightarrow$  se alege valoarea maximă a întregii funcții

## II.3 Estimare Bayesiană

# Distribuția *a priori*

- ▶ Presupunem că se știe de dinainte o distribuție a lui  $\Theta$ ,  $w(\Theta)$ 
  - ▶ știm de dinainte care e probabilitatea de a fi a anume valoare sau alta
  - ▶ se numește distribuția *a priori*
- ▶ Estimarea trebuie să ia în calcul și distribuția *a priori*
  - ▶ estimatul va fi “tras” înspre valori mai probabile
- ▶ Cunoscută sub numele de “estimare Bayesiană”
  - ▶ Thomas Bayes = a descoperit regula lui Bayes
  - ▶ Chestiile bazate pe regula lui Bayes poartă deseori numele de “Bayesian”

# Funcția de cost

- ▶ **Eroarea de estimare** = diferența între estimatul  $\hat{\Theta}$  și valoarea reală  $\Theta$

$$\epsilon = \hat{\Theta} - \Theta$$

- ▶ **Funcția de cost**  $C(\epsilon)$  atribuie un cost pentru fiecare eroare de estimare posibilă
  - ▶ când  $\epsilon = 0$ , costul  $C(0) = 0$
  - ▶ erori  $\epsilon$  mici au costuri mici
  - ▶ erori  $\epsilon$  mari au costuri mari
- ▶ Funcții de cost uzuale:
  - ▶ Pătratică:  $C(\epsilon) = \epsilon^2 = (\hat{\Theta} - \Theta)^2$
  - ▶ Uniformă:  $C(\epsilon) = \begin{cases} 0, & \text{if } |\epsilon| = |\hat{\Theta} - \Theta| \leq E \\ 1, & \text{if } |\epsilon| = |\hat{\Theta} - \Theta| > E \end{cases}$
  - ▶ Liniară:  $C(\epsilon) = |\epsilon| = |\hat{\Theta} - \Theta|$
  - ▶ (desenate la tablă)



- ▶ Pentru fiecare pereche de valori  $\mathbf{r}$  și  $\Theta$ ,  $w(\mathbf{r}; \Theta)$  indică cât de probabilă este acea pereche de valori
- ▶ Prin multiplicare cu  $C(\epsilon)$  se obține costul pentru fiecare pereche  $\mathbf{r}$  și  $\Theta$

$$C(\epsilon)w(\mathbf{r}; \Theta)$$

- ▶ Integrând după  $\Theta$  se obține costul total pentru un anumit  $\mathbf{r}$  și toți  $\Theta$

$$\int_{-\infty}^{\infty} C(\epsilon)w(\mathbf{r}; \Theta)d\Theta$$

- ▶ Integrând mai de parte și după  $\mathbf{r}$  se obține costul global pentru toți  $\mathbf{r}$  și toți  $\Theta$

$$R = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} C(\epsilon)w(\mathbf{r}; \Theta)d\Theta d\mathbf{r}$$

# Minimizarea riscului

- ▶ Se dorește minimizarea riscului  $R$  (= a costului global)
- ▶ Regula lui Bayes:  $w(\mathbf{r}; \Theta) = w(\Theta|\mathbf{r})w(\mathbf{r})$
- ▶ Înlocuind în  $R$ , se obține

$$\begin{aligned} R &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} C(\epsilon) w(\Theta|\mathbf{r}) w(\mathbf{r}) d\Theta d\mathbf{r} \\ &= \int_{-\infty}^{\infty} w(\mathbf{r}) \left[ \int_{-\infty}^{\infty} C(\epsilon) w(\Theta|\mathbf{r}) d\Theta \right] d\mathbf{r} \end{aligned}$$

- ▶ Cum  $w(\mathbf{r}) \geq 0$ , minimizarea integralei  $I$  din interior asigură minimumul lui  $R$

$$I = \int_{-\infty}^{\infty} C(\epsilon) w(\Theta|\mathbf{r}) d\Theta$$

- ▶ Vom înlocui  $C(\epsilon)$  cu definiția sa și derivăm după  $\hat{\Theta}$ 
  - ▶ Atenție: derivăm după  $\hat{\Theta}$ , nu  $\Theta$ !

# Estimatorul EPMM (eroare pătratică medie minimă)

- ▶ Când funcția de cost este pătratică  $C(\epsilon) = \epsilon^2 = (\hat{\Theta} - \Theta)^2$

$$I = \int_{-\infty}^{\infty} (\hat{\Theta} - \Theta)^2 w(\Theta|\mathbf{r}) d\Theta$$

- ▶ Vrem  $\hat{\Theta}$  care minimizează  $I$ , deci derivăm

$$\frac{dI}{d\hat{\Theta}} = 2 \int_{-\infty}^{\infty} (\hat{\Theta} - \Theta) w(\Theta|\mathbf{r}) d\Theta = 0$$

- ▶ Echivalent cu

$$\hat{\Theta} \underbrace{\int_{-\infty}^{\infty} w(\Theta|\mathbf{r}) d\Theta}_1 = \int_{-\infty}^{\infty} \Theta w(\Theta|\mathbf{r}) d\Theta$$

- ▶ Estimatorul de **eroare pătratică medie minimă (EPMM)** (“**Minimum Mean Squared Error, MMSE**”):

$$\hat{\Theta} = \int_{-\infty}^{\infty} \Theta \cdot w(\Theta|\mathbf{r}) d\Theta$$

- ▶  $w(\Theta|\mathbf{r})$  este distribuția **a posteriori** a lui  $\Theta$ 
  - ▶ este distribuția lui  $\Theta$  **după** ce cunoaștem semnalul recepționat  $\mathbf{r}$
  - ▶ distribuția *a priori*  $w(\Theta)$  este cea de dinainte de a recepționa datele
- ▶ Estimatorul EPMM este **valoarea medie** a distribuției *a posteriori*

# Estimatorul MAP

- ▶ Dacă funcția de cost este uniformă

$$C(\epsilon) = \begin{cases} 0, & \text{if } |\epsilon| = |\hat{\Theta} - \Theta| \leq E \\ 1, & \text{if } |\epsilon| = |\hat{\Theta} - \Theta| > E \end{cases}$$

- ▶ Știm că  $\Theta = \hat{\Theta} - \epsilon$
- ▶ Se obține

$$I = \int_{-\infty}^{\hat{\Theta}-E} w(\Theta|\mathbf{r})d\Theta + \int_{\hat{\Theta}+E}^{\infty} w(\Theta|\mathbf{r})d\Theta$$

$$I = 1 - \int_{\hat{\Theta}-E}^{\hat{\Theta}+E} w(\Theta|\mathbf{r})d\Theta$$

# Estimatorul MAP

- ▶ Pentru minimizarea  $I$ , trebuie să maximizăm  $\int_{\hat{\Theta}-E}^{\hat{\Theta}+E} w(\Theta|\mathbf{r})d\Theta$ , integrala din jurul punctului  $\hat{\Theta}$
- ▶ Pentru  $E$  foarte mic, funcția  $w(\Theta|\mathbf{r})$  este aproximativ constantă, deci se va alege punctul unde funcția este maximă
- ▶ Estimatorul **Maximum A Posteriori (MAP)** este

$$\hat{\Theta} = \arg \max w(\Theta|\mathbf{r})$$

- ▶  $\arg \max$  = “valoarea la care funcția este maximă”
  - ▶  $\max f(x)$  = valoarea maximă a unei funcții
  - ▶  $\arg \max f(x)$  = valoarea  $x$  pentru care funcția atinge valoarea maximă

# Interpretare

- ▶ Estimatorul MAP:  $\hat{\Theta} =$  valoarea care maximizează distribuția *a posteriori*
- ▶ Estimatorul EPMM:  $\hat{\Theta} =$  valoarea medie a distribuției *a posteriori*




Figure 1: Estimatorul MAP vs EPMM(MMSE)

## Cum se găsește distribuția *a posteriori*

- ▶ Cum găsim distribuția *a posteriori*  $w(\Theta|\mathbf{r})$ ?
- ▶ Regula lui Bayes

$$w(\Theta|\mathbf{r}) = \frac{w(\mathbf{r}; \Theta)}{w(\mathbf{r})} = \frac{w(\mathbf{r}|\Theta) \cdot w(\Theta)}{w(\mathbf{r})}$$

- ▶ Cum  $w(\mathbf{r})$  e constant pentru un  $\mathbf{r}$  dat, estimatorul MAP este

$$\hat{\Theta} = \arg \max w(\Theta|\mathbf{r}) = \arg \max w(\mathbf{r}|\Theta)w(\Theta)$$

- ▶ Estimatorul MAP este valoarea care maximizează plauzibilitatea datelor recepționate, dar **multiply** cu distribuția *a priori*  $w(\Theta)$
- ▶ Estimatorul EPMM este valoarea medie a aceleiași funcții



- ▶ Estimatorul ML este  $\arg \max w(\mathbf{r}|\Theta)$
- ▶ Estimatorul MAP = similar cu cel ML dar multiplicând în prealabil funcția cu distribuția *a priori*  $w(\Theta)$
- ▶ Dacă  $w(\Theta)$  ar fi constant, estimatorul MAP se reduce la cel ML
  - ▶  $w(\Theta) = \text{constant}$  înseamnă că toate valorile  $\Theta$  sunt la fel de posibile
  - ▶ adică nu avem nici o idee/preferință unde s-ar afla valoarea reală  $\Theta$

# Relația cu detecția semnalelor

- ▶ Criteriul probabilității minime de eroare  $\frac{w(r|H_1)}{w(r|H_0)} \underset{H_0}{\overset{H_1}{\gtrless}} \frac{P(H_0)}{P(H_1)}$
- ▶ Se poate rescrie ca  $w(r|H_1) \cdot P(H_1) \underset{H_0}{\overset{H_1}{\gtrless}} w(r|H_0)P(H_0)$ 
  - ▶ adică se alege ipoteza pentru care  $w(r|H) \cdot P(H)$  este mai mare
  - ▶  $w(r|H_1)$ ,  $w(r|H_0)$  sunt plauzibilitățile semnalului recepționat
  - ▶  $P(H_1)$ ,  $P(H_0)$  sunt probabilitățile *a priori* (inițiale) ale ipotezelor
- ▶ Estimatorul MAP = valoarea pentru care  $w(\mathbf{r}|\Theta)w(\Theta)$  e maxim
  - ▶  $w(\mathbf{r}|\Theta)$  este plauzibilitatea semnalului recepționat
  - ▶  $w(\Theta)$  este distribuția *a priori*
- ▶ Același principiu, doar în contexte diferite:
  - ▶ la detecție, avem de ales doar între câteva opțiuni predefinite
  - ▶ la estimare, nu avem constrângeri  $\Rightarrow$  se alege valoarea care maximizează întreaga funcție

Exercițiu: valoare constantă, 1 măsurătoare, zgomot Gaussian același  $\sigma$

- ▶ Vrem să estimăm temperatura de astăzi din Sahara
- ▶ Termometrul indică 40 grade, dar valoarea este afectată de zgomot Gaussian  $\mathcal{N}(0, \sigma^2 = 2)$  (termometru ieftin)
- ▶ Se știe că de obicei în această perioadă a anului temperatura este în jur de 35 grade, cu o distribuție Gaussiană  $\mathcal{N}(35, \sigma^2 = 2)$ .
- ▶ Estimați valoarea reală a temperaturii folosind estimarea ML, MAP și EPMM(MMSE)

# Exercițiu

Exercițiu: valoare constantă, 1 măsurătoare, zgomot Gaussian același  $\sigma$

- ▶ Dacă avem trei termometre, care indică 40, 38, 41 grade?

Exercițiu: valoare constantă, 1 măsurătoare, zgomot Gaussian  $\sigma$  diferit

- ▶ Dacă temperatura în această perioadă a anului are distribuție Gaussiană  $\mathcal{N}(35, \sigma_2^2 = 3)$ 
  - ▶ cu varianță diferită,  $\sigma_2 \neq \sigma$

# Semnal oarecare în zgomot Gaussian (AWGN)

- ▶ Fie semnalul original “curat”  $s_{\Theta}(t)$
- ▶ Zgomotul este Gaussian (AWGN)  $\mathcal{N}(\mu = 0, \sigma^2)$
- ▶ Ca în cazul estimării de plauzibilitate maximă, funcția de plauzibilitate este:

$$w(\mathbf{r}|\Theta) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{\sum (r_i - s_{\Theta}(t_i))^2}{2\sigma^2}}$$

- ▶ Dar acum aceasta **se înmulțește cu**  $w(\Theta)$

$$w(\mathbf{r}|\Theta) \cdot w(\Theta)$$

# Semnal oarecare în zgomot Gaussian (AWGN)

- ▶ Estimatorul MAP estimator este cel care maximizează produsul

$$\hat{\Theta}_{MAP} = \arg \max w(\mathbf{r}|\Theta)w(\Theta)$$

- ▶ Logaritmând:

$$\begin{aligned}\hat{\Theta}_{MAP} &= \arg \max \ln (w(\mathbf{r}|\Theta)) + \ln (w(\Theta)) \\ &= \arg \max -\frac{\sum (r_i - s_{\Theta}(t_i))^2}{2\sigma^2} + \ln (w(\Theta))\end{aligned}$$

# Distribuție “a priori” Gaussiană

- ▶ Dacă distribuția “a priori” este de asemenea Gaussiană  $\mathcal{N}(\mu_{\Theta}, \sigma_{\Theta}^2)$

$$\ln(w(\Theta)) = -\frac{\sum(\Theta - \mu_{\Theta})^2}{2\sigma_{\Theta}^2}$$

- ▶ Estimatorul MAP devine

$$\hat{\Theta}_{MAP} = \arg \min \frac{\sum(r_i - s_{\Theta}(t_i))^2}{2\sigma^2} + \frac{\sum(\Theta - \mu_{\Theta})^2}{2\sigma_{\Theta}^2}$$

- ▶ Poate fi rescris

$$\hat{\Theta}_{MAP} = \arg \min d(\mathbf{r}, s_{\Theta})^2 + \underbrace{\frac{\sigma^2}{\sigma_{\Theta}^2}}_{\lambda} \cdot d(\Theta, \mu_{\Theta})^2$$

- ▶ Estimatorul MAP în zgomot Gaussian și cu distribuție “a priori” Gaussiană

$$\hat{\Theta}_{MAP} = \arg \min d(\mathbf{r}, s_{\Theta})^2 + \underbrace{\frac{\sigma^2}{\sigma_{\Theta}^2}}_{\lambda} \cdot d(\Theta, \mu_{\Theta})^2$$

- ▶  $\hat{\Theta}_{MAP}$  este apropiat de valoarea medie  $\mu_{\Theta}$  și de asemenea face ca semnalul adevărat să fie apropiat de eșantioanele recepționate  $\mathbf{r}$ 
  - ▶ Exemplu: “caut locuință aproape de serviciu dar și aproape de Mall”
  - ▶  $\lambda$  controlează importanța relativă a celor doi termeni
- ▶ Cazuri particulare
  - ▶  $\sigma_{\Theta}$  foarte mic = distribuția “a priori” este foarte specifică (îngustă) =  $\lambda$  mare = termenul al doilea este dominant =  $\hat{\Theta}_{MAP}$  foarte apropiat de  $\mu_{\Theta}$
  - ▶  $\sigma_{\Theta}$  foarte mare = distribuția “a priori” este foarte nespecifică =  $\lambda$  mic = primul termen este dominant =  $\hat{\Theta}_{MAP}$  apropiat de estimatorul de plauzibilitate maximă



- ▶ În general, aplicațiile practice:
  - ▶ utilizează diverse tipuri de distribuții “a priori”
  - ▶ estimează **mai mulți parametri** (un vector de parametri)
- ▶ Aplicații
  - ▶ reducerea zgomotului din semnale
  - ▶ restaurarea semnalelor (parți lipsă din imagini, imagini *blurate* etc)
  - ▶ compresia semnalelor

- ▶ Cum caracterizăm calitatea unui estimator?
  - ▶ Există diverse abordări
- ▶ Un estimator  $\hat{\Theta}$  este **o variabilă aleatoare**
  - ▶ poate avea diverse valori, pentru că se calculează pe baza eșantioanelor recepționate, care depind de zgomot
  - ▶ exemplu: se repetă aceeași estimare pe calculatoare diferite  $\Rightarrow$  valori estimate ușor diferite
- ▶ Fiind o variabilă aleatoare, se pot defini:
  - ▶ valoarea medie a estimatorului:  $E \{ \hat{\Theta} \}$
  - ▶ varianța estimatorului:  $E \{ (\hat{\Theta} - \Theta)^2 \}$

# Estimatori nedeplasați

- ▶ Estimator **nedeplasat** = valoarea medie a estimatorului este egală cu valoarea adevărată a parametrului  $\Theta$

$$E \{ \hat{\Theta} \} = \Theta$$

- ▶ Estimator **deplasat** = valoarea medie a estimatorului diferă de valoarea adevărată a parametrului  $\Theta$ 
  - ▶ diferența  $E \{ \hat{\Theta} \} - \Theta$  se numește **deplasarea** estimatorului

# Estimatori nedeplasati

- ▶ Exemplu: semnal constant  $A$ , zgomot Gaussian (cu media), estimatorul de plauzibilitate maximă este  $\hat{A}_{ML} = \frac{1}{N} \sum_i r_i$
- ▶ Atunci:

$$\begin{aligned} E \{ \hat{A}_{ML} \} &= \frac{1}{N} E \left\{ \sum_i r_i \right\} \\ &= \frac{1}{N} \sum_{i=1}^N E \{ r_i \} \\ &= \frac{1}{N} \sum_{i=1}^N E \{ A + \text{zgomot} \} \\ &= \frac{1}{N} \sum_{i=1}^N A \\ &= A \end{aligned}$$

- ▶ Acest estimator este nedeplasat

# Varianța unui estimator

- ▶ Dacă un estimator are **varianța** mare, valoarea estimată poate fi departe de cea reală
  - ▶ indiferent dacă estimatorul este nedeplasat sau nu
- ▶ De obicei se preferă estimatori de **varianță redusă**, tolerându-se o eventuală mică deplasare