Section 1

Decizie și Estimare în Prelucrarea Informației

Section 2

Chapter III. Elemente de Teoria Estimării

Subsection 1

II.1 Introducere

Ce înseamnă “estimare”?

- Un emițător transmite un semnal $s_\Theta(t)$ care depinde de parametru **necunoscut** Θ
- Semnalul este afectat de zgomot, se recepționează $r(t) = s_\Theta(t) + zgomot$
- Vrem să **găsim** valoarea parametrului
  - pe baza eșantioanelor din semnalul recepționat, sau a întregului semnal
  - datele recepționate au zgomot => parametrul este “estimat”
- Valoarea găsită este $\hat{\Theta}$, **estimatul** lui Θ
  - există întotdeauna eroare de estimare $\epsilon = \hat{\Theta} - \Theta$
- Exemple:
  - Amplitudinea unui semnal constant: $r(t) = A + zgomot$, trebuie estimat A
  - Faza unui semnal sinusoidal: $r(t) = \cos(2\pi f t + \phi) + zgomot$, de estimat ϕ
  - Semnal vocal înregistrat, de estimat/decis ce cuvânt este pronunțat

Estimare și Decizie

- Fie următoarea problemă de estimare: $r(t) = A + zgomot$, de estimat A
- La detecție se alege între **două valori cunoscute** ale A:
  - de ex. A poate fi 0 sau 5 (ipotezele H_0 și H_1)
- La estimare, A poate fi oricât $=>$ se alege între **o infinitate de opțiuni** ale A
  - A poate fi orice valoare din $\mathbb{R}$, în general

Estimare și Detecție

- Detecție = Estimare restrânsă doar la un set discret de opțiuni
- Estimare = Detecție cu un număr infinit de opțiuni posibile
- Metodele statistice sunt similare
  - În practică, distincția între estimare și detecție nu este strictă
  - (de ex. când trebuie să alegem între 1000 de ipoteze, este “detecție” sau “estimare”?)

Semnalul recepționat

- Semnalul recepționat este $r(t)$
  - este afectat de zgomot, și depinde de parametrul necunoscut Θ
- Considerăm **N eșantioane** din $r(t)$, luate la momentele de timp t_i

$$\mathbf{r} = [r_1, r_2, ...r_N]$$

- Fiecare eșantion r_i este o variabilă aleatoare ce depinde de Θ (și zgomot)
  - Fiecare eșantion are o distribuție care depinde de Θ

$$w_i(r_i; \Theta)$$

- Întregul vector de eșantioane **r** este o variabilă aleatoare N-dimensională ce depinde de Θ (și de zgomot)
  - Are o distribuție N-dimensională ce depinde de Θ
  - Egală cu produsul tuturor $w_i(r_i; \Theta)$

$$w(\mathbf{r}; \Theta) = w_1(r_1; \Theta) \cdot w_2(r_2; \Theta) \cdot ... \cdot w_N(r_N; \Theta)$$

Tipuri de estimare

- Considerăm estimarea lui Θ în două cazuri:

1. Nu cunoaștem alte informații despre parametru, decât cel mult vreun domeniu de existență (de ex. $\Theta > 0$)
   - Parametrul poate avea orice valoare din domeniul de existență, în mod echiprobabil
2. Se cunoaște o distribuție $w(\Theta)$ a lui Θ, care indică ce valori ale lui Θ sunt mai probabile / mai puțin probabile
   - este distribuția *a priori* ("cea cunoscută de dinainte")

Subsection 2

II.2 Estimarea de plauzibilitate maximă (Maximum Likelihood)

Estimarea tip Maximum Likelihood

- Dacă nu se cunoaște vreo distribuție *a priori* se folosește metoda estimării de plauzibilitate maximă ("Maximum Likelihood", ML)
- Distribuția vectorului recepționat, $w(\mathbf{r};\Theta)$, reprezintă **funcția de plauzibilitate**
  - vectorul recepționat $\mathbf{r}$ este cunoscut, deci e o constantă
  - necunoscuta aici este Θ

$$L(\Theta) = w(\mathbf{r};\Theta)$$

Estimarea tip Maximum Likelihood

Estimarea de plauzibilitate maximă (Maximum Likelihood, ML):

- Estimatul $\hat{\Theta}$ este **valoarea care maximizează plauzibilitatea semnalului recepționat**
  - i.e. valoarea Θ care maximizează $w(\mathbf{r}; \Theta)$

$$\hat{\Theta} = \arg\max_{\Theta} L(\Theta) = \arg\max_{\Theta} w(\mathbf{r}; \Theta)$$

- Dacă Θ aparține doar unui anumit domeniu, se face maximizarea doar asupra acelui domeniu.

Găsirea maximului

- Cum se rezolvă problema de maximizare?
  - cum se găsește estimatul Θ care maximizează $L(\Theta)$
- Maximul se găsește prin derivare și egalare cu 0

$$\frac{dL(\Theta)}{d\Theta} = 0$$

- Se poate aplica **logaritmul natural** asupra funcției $L(\Theta)$ înainte de derivare ("log-likelihood function")

$$\frac{d \ln \left(L(\Theta)\right)}{d\Theta} = 0$$

Procedura de găsire a estimatului

Procedura de găsire a estimatului ML:

1. Se găsește expresia funcției

$$L(\Theta) = w(\mathbf{r}; \Theta)$$

2. Se pune condiția ca derivata lui $L(\Theta)$ sau a lui $\ln((L(\Theta))$ să fie 0

$$\frac{dL(\Theta)}{d\Theta} = 0, \text{ or } \frac{d\ln\left(L(\Theta)\right)}{d\Theta} = 0$$

3. Se rezolvă ecuația, se găsește valoarea $\hat{\Theta}$
4. Se verifică că derivata a doua în punctul $\hat{\Theta}$ este negativă, pentru a verifica că este un punct de maxim
   - întrucât derivata $= 0$ și pentru maxime și pentru minime

Exemple

Semnal constant în zgomot gaussian:

- Găsiți estimatul Maximum Likelihood pentru constanta A din 5 măsurători afectate de zgomot $r_i = A + noise$, cu valori egale cu $[5, 7, 8, 6.1, 5.3]$. Zgomotul este AWGN $\mathcal{N}(\mu = 0, \sigma^2)$.
- Soluție: la tablă
- Estimatul $\hat{A}$ este chiar valoarea medie a eșantioanelor (deloc surprinzător)

Simulare numerică

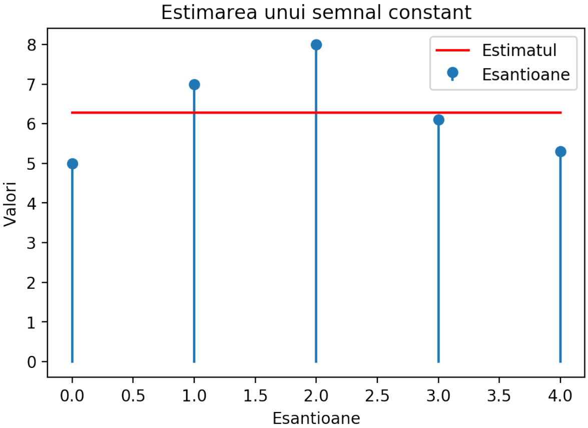

Aproximare a unei curbe

- Estimare = aproximare a unei curbe
- Din exemplul grafic anterior:
  - avem un set de date $\mathbf{r}$
  - se cunoaște forma semnalului = o dreaptă orizontală (A constant)
  - se aproximează în mod optim linia prin setul de date

Semnal oarecare în AWGN

- Fie semnalul original "curat" $s_\Theta(t)$
- Zgomotul este AWGN $\mathcal{N}(\mu = 0, \sigma^2)$
- Eșantioanele r_i sunt luate la momentele t_i
- Eșantioanele r_i au distribuție normală, cu media $s_\Theta(t_i)$ și varianța σ^2
- Funcția de plauzibilitate globală $=$ produsul plauzibilității fiecărui eșantion r_i

$$L(\Theta) = \prod_{i=1}^{N} \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(r_i - s_\Theta(t_i))^2}{2\sigma^2}}$$

$$= \left(\frac{1}{\sigma\sqrt{2\pi}}\right)^N e^{-\frac{\sum (r_i - s_\Theta(t_i))^2}{2\sigma^2}}$$

Semnal oarecare în AWGN

- Logaritmul plauzibilității ("log-likelihood") este

$$\ln\left(L(\Theta)\right) = \underbrace{N \ln\left(\frac{1}{\sigma\sqrt{2\pi}}\right)}_{constant} - \frac{\sum(r_i - s_\Theta(t_i))^2}{2\sigma^2}$$

Semnal oarecare în AWGN

- Maximul funcției = minimul exponentului

$$\hat{\Theta} = \arg\max_{\Theta} w(r; \Theta) = \arg\min \sum (r_i - s_\Theta(t_i))^2$$

- Termenul $\sum (r_i - s_\Theta(t_i))^2$ este **distanța** $d(\mathbf{r}, s_\Theta)$ **la pătrat**

$$d(\mathbf{r}, s_\Theta) = \sqrt{\sum (r_i - s_\Theta(t_i))^2}$$

$$(d(\mathbf{r}, s_\Theta))^2 = \sum (r_i - s_\Theta(t_i))^2$$

Semnal oarecare în AWGN

- Estimarea ML se poate rescrie sub forma:

$$\hat{\Theta} = \arg\max_{\Theta} w(r;\Theta) = \arg\min d(\mathbf{r}, \mathbf{s}_{\Theta})^2$$

- Estimatul de plauzibilitate maximă (estimatul ML) $\hat{\Theta}$ = valoarea care face $s_{\Theta}(t_i)$ **cel mai apropiat de vectorul recepționat r**
  - mai aproape = mai probabil
  - cel mai aproape = cel mai probabil = plauzibilitate maximă
- Estimare ML = minimizarea distanței
- Relația e valabilă pentru orice fel de spații vectoriale
  - vectori cu N elemente, semnale continue, etc
  - doar se înlocuiește definiția distanței Euclidiene

Semnal oarecare în AWGN

- Estimatul se găsește prin setarea derivatei la 0

$$\frac{d \ln \left(L(\Theta)\right)}{d\Theta} = 0$$

înseamnă

$$\sum (r_i - s_\Theta(t_i)) \frac{ds_\Theta(t_i)}{d\Theta} = 0$$

Simulare numerică

Estimarea frecvenței f a unui semnal sinusoidal

- Găsiți estimatul Maximum Likelihood pentru frecvența f a unui semnal cosinus, din 10 măsurători afectate de zgomot $r_i = cos(2\pi f t_i) + zgomot$ de valori [...]. Zgomotul este AWGN $\mathcal{N}(\mu = 0, \sigma^2)$. Momentele de eșantionare sunt $t_i = [0, 1, 2, 3, 4, 5, 6, 7, 8, 9]$
- Soluție: la tablă

Simulare numerică

Funcția de plauzibilitate este

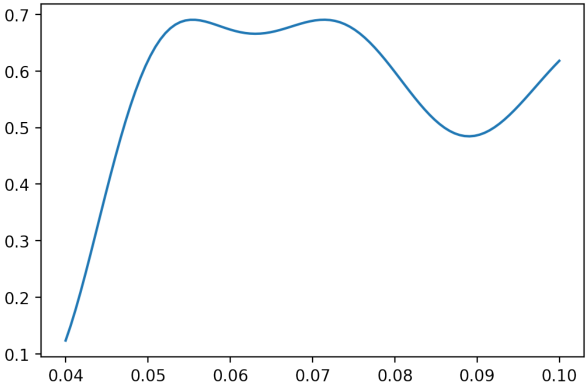

Simulare numerică

```
Frecventa originala = 0.070000, estimatul = 0.071515
```

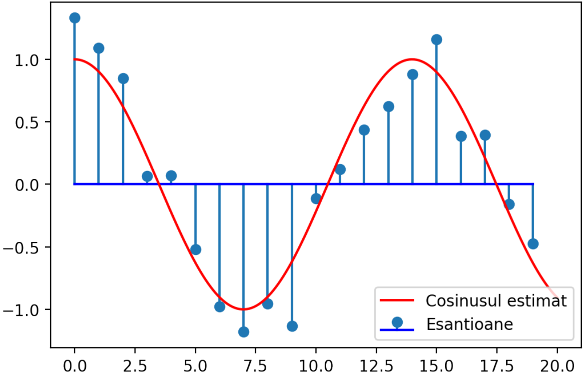

Estimare ML și Detecție ML

- La estimarea ML, estimatul $\hat{\Theta}$ este valoarea care maximizează funcția de plauzibilitate
- La detecție ML, criteriul de decizie $\frac{w(r|H_1)}{w(r|H_0)} \underset{H_0}{\overset{H_1}{\gtrless}} 1$ înseamnă “alege ipoteza pentru care funcția de plauzibilitate este mai mare”
- Același principiu, doar în contexte diferite:
  - la detecție, avem de ales doar între câteva opțiuni predefinite
  - la estimare nu mai avem constrângeri => se alege valoarea maximă a întregii funcții

Funcția de pierdere ("Loss function")

- Distanța $d(\mathbf{r}, \mathbf{s}_\Theta)$ se mai numește funcție de pierdere ("**loss function**") în domeniul *Machine Learning*
  - distanța Euclidiană = funcția de pierdere tip "**Mean Squared Error**" (MSE)
- Pentru un $\mathbf{r}$ dat, valoarea de pierdere MSE $= \frac{1}{N} d(\mathbf{r}, \mathbf{s}_\Theta)$
- Alte funcții de pierdere sunt folosite în diverse aplicații

Parametri multipli

- Dacă semnalul depinde de mai mulți parametri?
  - de ex. amplitudinea, frecvența și faza inițială a unui cosinus:

$$s_{\hat{}}(t) = A\cos(2\pi f t + \phi)$$

- Se va considera Θ ca fiind un vector:

$$\boldsymbol{\Theta} = [\Theta_1, \Theta_2, ...\Theta_M]$$

  - e.g. $\boldsymbol{\Theta} = [\Theta_1, \Theta_2, \Theta_3] = [A, f, \phi]$

Coborâre după gradient (Gradient Descent)

- Cum se estimează parametrii $\boldsymbol{\Theta}$ în cazuri complicate?
  - în aplicații reale, unde pot fi foarte mulți parametri ($\boldsymbol{\Theta}$ este vector)
- De obicei nu se pot găsi valorile optime prin formule directe
- Se îmbunătățesc valorile în mod iterativ cu algoritmi tip **coborâre după gradient**

Coborâre după gradient (Gradient Descent)

1. Se inițializează parametrii cu valori aleatoare $\mathbf{\Theta}^{(0)}$
2. Repetă la fiecare iterație k:
   2.1 Se calculează valoarea de pierdere $L(\mathbf{\Theta}^{(k)})$
   2.2 Se calculează derivata $\frac{\partial L}{\partial \Theta_i^{(k)}}$ pentru toți Θ_i
   2.3 Se actualizează toate valorile Θ_i prin scăderea derivatei:

$$\Theta_i^{(k+1)} = \Theta_i^{(k)} - \mu \frac{\partial L}{\partial \Theta_i^{(k)}}$$

   - sau, sub formă vectorială:

$$\mathbf{\Theta}^{(k+1)} = \mathbf{\Theta}^{k} - \mu \frac{\partial L}{\partial \mathbf{\Theta}^{(k)}}$$

3. Până la îndeplinirea unui criteriu de terminare (de ex. parametrii nu se mai modifică mult)

Coborâre după gradient (Gradient Descent)

- Explicații la tablă
- Exemplu: regresia logistică cu valori 2D
  - exemplu la tablă

Rețele Neurale

- Cel mai proeminent exemplu: **Rețele Neurale Artificiale** (a.k.a. “Rețele Neurale”, “Deep Learning”, etc.)
  - Pot fi văzute ca un exemplu de estimare ML
  - Utilizează o funcție de pierdere (de obicei nu funcția tip MSE)
  - Se utilizează algoritmul *Gradient Descent* pentru găsirea parametrilor
  - Aplicații de vârf: recunoașterea de imagini, automated driving etc.
- Mai multe informații despre rețele neurale / machine learning:
  - căutați cursuri sau cărți, eventual online (de ex. cartea dl.prof. Iulian Ciocoiu)
  - participați la IASI AI Meetup

Subsection 3

II.3 Estimare Bayesiană

Distribuția *a priori*

- Presupunem că se știe de dinainte o distribuție a lui Θ, $w(\Theta)$
  - știm de dinainte care e probabilitatea de a fi a anume valoare sau alta
  - se numește distribuția *a priori*
- Estimarea trebuie să ia în calcul și distribuția *a priori*
  - estimatul va fi "tras" înspre valori mai probabile
- Cunoscută sub numele de "estimare Bayesiană"
  - Thomas Bayes = a descoperit regula lui Bayes
  - Chestiile bazate pe regula lui Bayes poartă deseori numele de "Bayesian"

Funcția de cost

- **Eroarea de estimare** = diferența între estimatul $\hat{\Theta}$ și valoarea reală Θ

$$\epsilon = \hat{\Theta} - \Theta$$

- **Funcția de cost** $C(\epsilon)$ atribuie un cost pentru fiecare eroare de estimare posibilă
  - când $\epsilon = 0$, costul $C(0) = 0$
  - erori ϵ mici au costuri mici
  - erori ϵ mari au costuri mari
- Funcții de cost uzuale:
  - Pătratică: $C(\epsilon) = \epsilon^2 = \left(\hat{\Theta} - \Theta\right)^2$
  - Uniformă: $C(\epsilon) = \begin{cases} 0, \text{ if } |\epsilon| = |\hat{\Theta} - \Theta| \leq E \\ 1, \text{ if } |\epsilon| = |\hat{\Theta} - \Theta| > E \end{cases}$
  - Liniară: $C(\epsilon) = |\epsilon| = |\hat{\Theta} - \Theta|$
  - (desenate la tablă)

Riscul Bayesian

- Pentru fiecare pereche de valori $\mathbf{r}$ și Θ, $w(\mathbf{r};\Theta)$ indică cât de probabilă este acea pereche de valori
- Prin multiplicare cu $C(\epsilon$ se obține costul pentru fiecare pereche $\mathbf{r}$ și Θ

$$C(\epsilon)w(\mathbf{r};\Theta)$$

- Integrând după Θ se obține costul total pentru un anume $\mathbf{r}$ și toți Θ

$$\int_{-\infty}^{\infty} C(\epsilon)w(\mathbf{r};\Theta)d\Theta$$

- Integrând mai de parte și după $\mathbf{r}$ se obține costul global pentru toți $\mathbf{r}$ și toți Θ

$$R = \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} C(\epsilon)w(\mathbf{r};\Theta)d\Theta d\mathbf{r}$$

Minimizarea riscului

- Se dorește minimizarea riscului R (= a costului global)
- Regula lui Bayes: $w(\mathbf{r}; \Theta) = w(\Theta|\mathbf{r})w(\mathbf{r})$
- Înlocuind în R, se obține

$$\begin{aligned} R &= \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} C(\epsilon)w(\Theta|\mathbf{r})w(\mathbf{r})d\Theta d\mathbf{r} \\ &= \int_{-\infty}^{\infty} w(\mathbf{r})\left[\int_{-\infty}^{\infty} C(\epsilon)w(\Theta|\mathbf{r})d\Theta\right] d\mathbf{r} \end{aligned}$$

- Cum $w(\mathbf{r}) \geq 0$, minimizarea integralei I din interior asigură minimul lui R

$$I = \int_{-\infty}^{\infty} C(\epsilon)w(\Theta|\mathbf{r})d\Theta$$

- Vom înlocui $C(\epsilon)$ cu definiția sa și derivăm după $\hat{\Theta}$
  - Atenție: derivăm după $\hat{\Theta}$, nu Θ!

Estimatorul EPMM (eroare pătratică medie minimă)

- Când funcția de cost este pătratică $C(\epsilon) = \epsilon^2 = \left(\hat{\Theta} - \Theta\right)^2$

$$I = \int_{-\infty}^{\infty} (\hat{\Theta} - \Theta)^2 w(\Theta|\mathbf{r}) d\Theta$$

- Vrem $\hat{\Theta}$ care minimizează I, deci derivăm

$$\frac{dI}{d\hat{\Theta}} = 2 \int_{-\infty}^{\infty} (\hat{\Theta} - \Theta) w(\Theta|\mathbf{r}) d\Theta = 0$$

- Echivalent cu

$$\hat{\Theta} \underbrace{\int_{-\infty}^{\infty} w(\Theta|\mathbf{r})\, d\Theta}_{1} = \int_{-\infty}^{\infty} \Theta w(\Theta|\mathbf{r}) d\Theta$$

- Estimatorul de **eroare pătratică medie minimă (EPMM)** **("Minimum Mean Squared Error, MMSE")**:

$$\hat{\Theta} = \int_{-\infty}^{\infty} \Theta \cdot w(\Theta|\mathbf{r}) d\Theta$$

Interpretare

- $w(\Theta|\mathbf{r})$ este distribuția **a posteriori** a lui Θ
  - este distribuția lui Θ **după** ce cunoaștem semnalul recepționat $\mathbf{r}$
  - distribuția *a priori* $w(\Theta)$ este cea de dinainte de a recepționa datele
- Estimatorul EPMM este **valoarea medie** a distribuției *a posteriori*

Estimatorul MAP

- Dacă funcția de cost este uniformă
  $$C(\epsilon) = \begin{cases} 0, & \text{if } |\epsilon| = |\hat{\Theta} - \Theta| \leq E \\ 1, & \text{if } |\epsilon| = |\hat{\Theta} - \Theta| > E \end{cases}$$
- Știm că $\Theta = \hat{\Theta} - \epsilon$
- Se obține

$$\begin{aligned} I &= \int_{-\infty}^{\hat{\Theta}-E} w(\Theta|\mathbf{r}) d\Theta + \int_{\hat{\Theta}+E}^{\infty} w(\Theta|\mathbf{r}) d\Theta \\ I &= 1 - \int_{\hat{\Theta}-E}^{\hat{\Theta}+E} w(\Theta|\mathbf{r}) d\Theta \end{aligned}$$

Estimatorul MAP

- Pentru minimizarea I, trebuie să maximizăm $\int_{\hat{\Theta}-E}^{\hat{\Theta}+E} w(\Theta|\mathbf{r}) d\Theta$, integrala din jurul punctului $\hat{\Theta}$
- Pentru E foarte mic, funcția $w(\Theta|\mathbf{r})$ este aproximativ constantă, deci se va alege punctul unde funcția este maximă
- Estimatorul **Maximum A Posteriori (MAP)** este

$$\hat{\Theta} = \arg\max w(\Theta|\mathbf{r})$$

- $\arg\max$ = "valoarea la care funcția este maximă"
  - $\max f(x)$ = valoarea maximă a unei funcții
  - $\arg\max f(x)$ = valoarea x pentru care funcția atinge valoarea maximă

Interpretare

- Estimatorul MAP: $\hat{\Theta}$ = valoarea care maximizează distribuția *a posteriori*
- Estimatorul EPMM: $\hat{\Theta}$ = valoarea medie a distribuției *a posteriori*

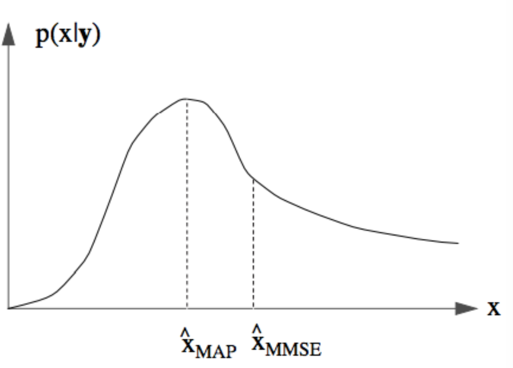

Figure 1: Estimatorul MAP vs EPMM(MMSE)

[image from https://allenlu2007.wordpress.com]

Cum se găsește distribuția *a posteriori*

- Cum găsim distribuția *a posteriori* $w(\Theta|\mathbf{r})$?
- Regula lui Bayes

$$w(\Theta|\mathbf{r}) = \frac{w(\mathbf{r};\Theta)}{w(\mathbf{r})} = \frac{w(\mathbf{r}|\Theta)\cdot w(\Theta)}{w(\mathbf{r})}$$

- Cum $w(\mathbf{r})$ e constant pentru un $\mathbf{r}$ dat, estimatorul MAP este

$$\hat{\Theta} = \arg\max w(\Theta|\mathbf{r}) = \arg\max w(\mathbf{r}|\Theta)w(\Theta)$$

- Estimatorul MAP este valoarea care maximizează plauzibilitatea datelor recepționate, dar **multiplicate** cu distribuția *a priori* $w(\Theta)$
- Estimatorul EPMM este valoarea medie a aceleiași funcții

Relația cu estimatorul ML

- Estimatorul ML este $\arg\max w(\mathbf{r}|\Theta)$
- Estimatorul MAP $=$ similar cu cel ML dar multiplicând în prealabil funcția cu distribuția *a priori* $w(\Theta)$
- Dacă $w(\Theta)$ ar fi constant, estimatorul MAP se reduce la cel ML
  - $w(\Theta) =$ constant înseamnă că toate valorile Θ sunt la fel de posibile
  - adică nu avem nici o idee/preferință unde s-ar afla valoarea reală Θ

Relația cu detecția semnalelor

- Criteriul probabilității minime de eroare $\frac{w(r|H_1)}{w(r|H_0)} \underset{H_0}{\overset{H_1}{\gtrless}} \frac{P(H_0)}{P(H_1)}$

- Se poate rescrie ca $w(r|H_1) \cdot P(H_1) \underset{H_0}{\overset{H_1}{\gtrless}} w(r|H_0)P(H_0)$
    - adică se alege ipoteza pentru care $w(r|H) \cdot P(H)$ este mai mare
    - $w(r|H_1)$, $w(r|H_0)$ sunt plauzibilitățile semnalului recepționat
    - $P(H_1)$, $P(H_0)$ sunt probabilitățile *a priori* (inițiale) ale ipotezelor

- Estimatorul MAP = valoarea pentru care $w(\mathbf{r}|\Theta)w(\Theta)$ e maxim
    - $w(\mathbf{r}|\Theta)$ este plauzibilitatea semnalului recepționat
    - $w(\Theta)$ este distribuția *a priori*

- Același principiu, doar în contexte diferite:
    - la detecție, avem de ales doar între câteva opțiuni predefinite
    - la estimare, nu avem constrângeri => se alege valoarea care maximizează întreaga funcție

Exerciţiu

Exerciţiu: valoare constantă, 1 măsurătoare, zgomot Gaussian acelaşi σ

- Vrem să estimam temperatura de astăzi din Sahara
- Termometrul indică 40 grade, dar valoarea este afectată de zgomot Gaussian $\mathcal{N}(0, \sigma^2 = 2)$ (termometru ieftin)
- Se ştie că de obicei în această perioadă a anului temperatura este în jur de 35 grade, cu o distribuţie Gaussiană $\mathcal{N}(35, \sigma^2 = 2)$.
- Estimaţi valoarea reală a temperaturii folosind estimarea ML, MAP şi EPMM(MMSE)

Exerciții

Exercițiu: valoare constantă, 1 măsurătoare, zgomot Gaussian același σ

- Dacă avem trei termometre, care indică 40, 38, 41 grade?

Exercițiu: valoare constantă, 1 măsurătoare, zgomot Gaussian σ diferit

- Dacă temperatura în această perioadă a anului are distribuție Gaussiană $\mathcal{N}(35, \sigma_2^2 = 3)$
  - cu variantă diferită, $\sigma_2 \neq \sigma$

Semnal oarecare în zgomot Gaussian (AWGN)

- Fie semnalul original "curat" $s_\Theta(t)$
- Zgomotul este Gaussian (AWGN) $\mathcal{N}(\mu = 0, \sigma^2)$
- Ca în cazul estimării de plauzibilitate maximă, funcția de plauzibilitate este:

$$w(\mathbf{r}|\Theta) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{\sum (r_i - s_\Theta(t_i))^2}{2\sigma^2}}$$

- Dar acum aceasta **se înmulțește cu** $w(\Theta)$

$$w(\mathbf{r}|\Theta) \cdot w(\Theta)$$

Semnal oarecare în zgomot Gaussian (AWGN)

- Estimatorul MAP estimator este cel care maximizează produsul

$$\hat{\Theta}_{MAP} = \arg\max w(\mathbf{r}|\Theta) w(\Theta)$$

- Logaritmând:

$$\begin{aligned}\hat{\Theta}_{MAP} &= \arg\max \ln\left(w(\mathbf{r}|\Theta)\right) + \ln\left(w(\Theta)\right)\\ &= \arg\max -\frac{\sum (r_i - s_\Theta(t_i))^2}{2\sigma^2} + \ln\left(w(\Theta)\right)\end{aligned}$$

Distribuție “a priori” Gaussiană

- Dacă distribuția “a priori” este de asemenea Gaussiană $\mathcal{N}(\mu_\Theta, \sigma_\Theta^2)$

$$\ln\left(w(\Theta)\right) = -\frac{\sum(\Theta - \mu_\Theta)^2}{2\sigma_\Theta^2}$$

- Estimatorul MAP devine

$$\hat{\Theta}_{MAP} = \arg\min \frac{\sum(r_i - s_\Theta(t_i))^2}{2\sigma^2} + \frac{\sum(\Theta - \mu_\Theta)^2}{2\sigma_\Theta^2}$$

- Poate fi rescris

$$\hat{\Theta}_{MAP} = \arg\min d(\mathbf{r}, s_\Theta)^2 + \underbrace{\frac{\sigma^2}{\sigma_\Theta^2}}_{\lambda} \cdot d(\Theta, \mu_\Theta)^2$$

Interpretare

- Estimatorul MAP în zgomot Gaussian și cu distribuție “a priori” Gaussiană

$$\hat{\Theta}_{MAP} = \arg\min d(\mathbf{r}, s_\Theta)^2 + \underbrace{\frac{\sigma^2}{\sigma_\Theta^2}}_{\lambda} \cdot d(\Theta, \mu_\Theta)^2$$

- $\hat{\Theta}_{MAP}$ este apropiat de valoarea medie μ_Θ și de asemenea face ca semnalul adevărat să fie apropiat de eșantioanele recepționate $\mathbf{r}$
  - Exemplu: “caut locuință aproape de serviciu dar și aproape de Mall”
  - λ controlează importanța relativă a celor doi termeni
- Cazuri particulare
  - σ_Θ foarte mic = distribuția “a priori” este foarte specifică (îngustă) = λ mare = termenul al doilea este dominant = $\hat{\Theta}_{MAP}$ foarte apropiat de μ_Θ
  - σ_Θ foarte mare = distribuția “a priori” este foarte nespecifică = λ mic = primul termen este dominant = $\hat{\Theta}_{MAP}$ apropiat de estimatorul de plauzibilitate maximă

Aplicații

- În general, aplicațiile practice:
  - utilizează diverse tipuri de distribuții "a priori"
  - estimează **mai mulți parametri** (un vector de parametri)
- Aplicații
  - reducerea zgomotului din semnale
  - restaurarea semnalelor (parți lipsă din imagini, imagini *blurate* etc)
  - compresia semnalelor

Estimatori nedeplasați

- Cum caracterizăm calitatea unui estimator?
  - Există diverse abordări
- Un estimator $\hat{\Theta}$ este **o variabilă aleatoare**
  - poate avea diverse valori, pentru că se calculează pe baza eșantioanelor recepționate, care depind de zgomot
  - exemplu: se repetă aceeași estimare pe calculatoare diferite => valori estimate ușor diferite
- Fiind o variabilă aleatoare, se pot defini:
  - valoarea medie a estimatorului: $E\left\{\hat{\Theta}\right\}$
  - varianța estimatorului: $E\left\{(\hat{\Theta} - \Theta)^2\right\}$

Estimatori nedeplasați

- Estimator **nedeplasat** $=$ valoarea medie a estimatorului este egală cu valoarea adevărată a parametrului Θ

$$E\left\{\hat{\Theta}\right\} = \Theta$$

- Estimator **deplasat** $=$ valoarea medie a estimatorului diferă de valoarea adevărată a parametrului Θ
  - diferența $E\left\{\hat{\Theta}\right\} - \Theta$ se numește **deplasarea** estimatorului

Estimatori nedeplasați

- Exemplu: semnal constant A, zgomot Gaussian (cu media), estimatorul de plauzibilitate maximă este $\hat{A}_{ML} = \frac{1}{N} \sum_i r_i$
- Atunci:

$$
\begin{aligned}
E\left\{\hat{A}_{ML}\right\} &= \frac{1}{N} E\left\{\sum_i r_i\right\} \\
&= \frac{1}{N} \sum_{i=1}^{N} E\left\{r_i\right\} \\
&= \frac{1}{N} \sum_{i=1}^{N} E\left\{A + zgomot\right\} \\
&= \frac{1}{N} \sum_{i=1}^{N} A \\
&= A
\end{aligned}
$$

- Acest estimator este nedeplasat

Varianța unui estimator

- Dacă un estimator are **varianța** mare, valoarea estimată poate fi departe de cea reală
  - indiferent dacă estimatorul este nedeplasat sau nu
- De obicei se preferă estimatori de **varianță redusă**, tolerându-se o eventuală mică deplasare