Capitolul III. Elemente de Teoria Estimării

III.1 Introducere

Ce înseamnă “estimare”?

- Un emițător transmite un semnal $s_\Theta(t)$ care depinde de parametru **necunoscut** Θ
- Semnalul este afectat de zgomot, se recepționează

$$r(t) = s_\Theta(t) + zgomot$$

- Vrem să **găsim** valoarea parametrului Θ
  - pe baza eșantioanelor din semnalul recepționat, sau a întregului semnal
  - datele recepționate au zgomot $=>$ parametrul este “estimat”
- Valoarea găsită este $\hat{\Theta}$, **estimatul** lui Θ
  - există întotdeauna eroare de estimare $\epsilon = \hat{\Theta} - \Theta$

Ce înseamnă “estimare”?

- Exemple:
  - Amplitudinea unui semnal constant: $r(t) = A + zgomot$, trebuie estimat A
  - Faza unui semnal sinusoidal: $r(t) = \cos(2\pi ft + \phi) + zgomot$, de estimat ϕ
  - Exemple mai complicate:
    - De estimat/decis ce cuvânt este pronunțat într-un semnal vocal

Estimare și Detecție/Decizie

- Fie următoarea problemă de estimare:

  Se recepționează un semnal $r(t) = A + zgomot$, estimați-l pe A
- La detecție: se alege între **două valori cunoscute** ale A:
  - de ex. A poate fi 0 sau 5 (ipotezele H_0 și H_1)
- La estimare: A poate fi oricât $=>$ se alege între **o infinitate de opțiuni** ale A
  - A poate fi orice valoare din $\mathbb{R}$, în general

Estimare și Detecție/Decizie

- Detecție = Estimare **restrânsă** doar la un set discret de opțiuni
- Estimare = Detecție cu un număr **infinit de opțiuni** posibile
- Metodele statistice sunt similare
  - În practică, distincția între estimare și detecție nu este strictă
  - (de ex. când trebuie să alegem între 1000 de ipoteze, este “detecție” sau “estimare”?)

Semnalul recepționat

- Semnalul recepționat este $r(t) = s_\Theta(t) + zgomot$
  - este afectat de zgomot
  - depinde de parametrul necunoscut Θ
- Considerăm **N eșantioane** din $r(t)$, luate la momentele de timp t_i

$$\mathbf{r} = [r_1, r_2, ...r_N]$$

- Eșantioanele depind de valoarea lui Θ

Semnalul recepționat

- Fiecare eșantion r_i este o variabilă aleatoare ce depinde de Θ (și de zgomot)
  - Fiecare eșantion are o distribuție care depinde de Θ

$$w_i(r_i|\Theta)$$

- Întregul vector de eșantioane $\mathbf{r}$ este o variabilă aleatoare N-dimensională ce depinde de Θ (și de zgomot)
  - Are o distribuție N-dimensională ce depinde de Θ
  - Egală cu produsul tuturor $w_i(r_i|\Theta)$

$$w(\mathbf{r}|\Theta) = w_1(r_1|\Theta) \cdot w_2(r_2|\Theta) \cdot \ldots \cdot w_N(r_N|\Theta)$$

Tipuri de estimare

- Considerăm două tipuri de estimare:
  1. **Estimare de plauzibilitate maximă** (Maximum Likelihood Estimation, MLE): În afară de **r** nu se cunoaște nimic despre Θ, decât cel mult vreun domeniu de existență (de ex. $\Theta > 0$)
  2. **Estimare Bayesiană**: În afară de **r** se mai cunoaște o distribuție *a priori* $w(\Theta)$ a lui Θ, care indică ce valori ale lui Θ sunt mai probabile / mai puțin probabile
     - caz mai general decât primul

II.2 Estimarea de plauzibilitate maximă (Maximum Likelihood)

Estimarea tip Maximum Likelihood

- Dacă nu se cunoaște vreo distribuție *a priori* se folosește metoda estimării de plauzibilitate maximă ("Maximum Likelihood", ML)
- Se definește **plauzibilitatea** unui valori Θ, dat fiind vectorul de observații $\mathbf{r}$:

$$L(\Theta|\mathbf{r}) = w(\Theta|\mathbf{r})$$

- $L(\Theta|\mathbf{r})$ reprezintă funcția de plauzibilitate
- "Plauzibilitatea unei valori Θ, date fiind măsurătorile $\mathbf{r} = =$ probabilitatea de a se fi generat $\mathbf{r}$ dacă valoarea parametrului ar fi fost Θ"
- A se compara cu formula din Cap. 2, slide 20
  - e aceeași
  - aici "ghicim" pe Θ, acolo "ghiceam" pe H_i

Estimarea tip Maximum Likelihood

Estimarea de plauzibilitate maximă (Maximum Likelihood, ML):

- Estimatul $\hat{\Theta}_{ML}$ este **valoarea care maximizează plauzibilitatea, dat fiind valorile observate r**
  - i.e. valoarea care maximizează $L(\Theta|\mathbf{r})$, adică maximizează $w(\mathbf{r}|\Theta)$

$$\hat{\Theta}_{ML} = \arg\max_{\Theta} L(\Theta|\mathbf{r}) = \arg\max_{\Theta} w(\mathbf{r}|\Theta)$$

- Dacă Θ aparține doar unui anumit interval, se face maximizarea doar pe acel interval

Notații matematice

- Notații matematice generale
  - $\arg\max_x f(x)$ = "valoarea x are maximizează funcția f(x)"
  - $\max_x f(x)$ = "valoarea maximă a funcției f(x)"

Estimare vs decizie Maximum Likelihood

- Estimarea ML este foarte similară cu decizia ML!
- Criteriul de decizie ML:
  - "se alege ipoteza cu plauzibilitate mai mare":

$$\frac{L(H_1|r)}{L(H_0|r)} = \frac{w(r|H_1)}{w(r|H_0)} \underset{H_0}{\overset{H_1}{\gtrless}} 1$$

- Estimare ML:
  - "se alege valoarea care maximizează plauzibilitatea"

$$\hat{\Theta}_{ML} = \arg\max_{\Theta} L(\Theta|\mathbf{r}) = \arg\max_{\Theta} w(\mathbf{r}|\Theta)$$

Găsirea maximului

- Cum se rezolvă problema de maximizare?
  - adică cum se găsește estimatul $\hat{\Theta}_{ML}$ care maximizează $L(\Theta|vecr)$
- Maximul se găsește prin derivare și egalare cu 0

$$\frac{dL(\Theta|\mathbf{r})}{d\Theta} = 0$$

- Se poate aplica **logaritmul natural** asupra funcției $L(\Theta|\mathbf{r})$ înainte de derivare (funcția "log-likelihood")

$$\frac{d \ln\left(L(\Theta|\mathbf{r})\right)}{d\Theta} = 0$$

Procedura de găsire a estimatului

Procedura de găsire a estimatului ML:

1. Se găsește expresia funcției

$$L(\Theta|\mathbf{r}) = w(\mathbf{r}|\Theta)$$

2. Se pune condiția ca derivata lui $L(\Theta|\mathbf{r})$ sau a lui $\ln((L(\Theta|\mathbf{r}))$ să fie 0

$$\frac{dL(\Theta)}{d\Theta} = 0, \text{ sau } \frac{d\ln(L(\Theta))}{d\Theta} = 0$$

3. Se rezolvă ecuația, se găsește valoarea $\hat{\Theta}_{ML}$
4. Se verifică că derivata a doua în punctul $\hat{\Theta}_{ML}$ este negativă, pentru a verifica că este un punct de maxim
   - întrucât derivata = 0 și pentru maxime și pentru minime
   - uneori sărim peste această etapă

Exemplu

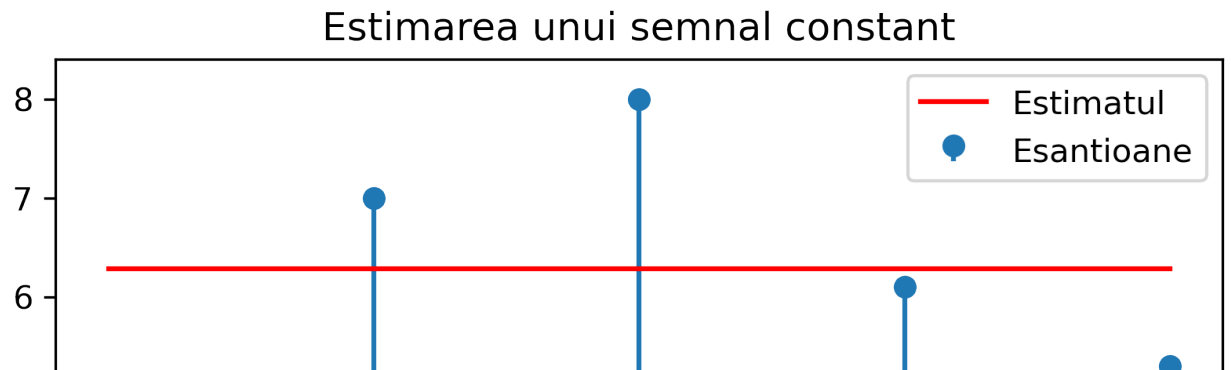
- Estimarea unui semnal constant în zgomot gaussian:

  Găsiți estimatul Maximum Likelihood pentru un semnal de valoare constantă $s_\Theta(t) = A$ din 5 măsurători afectate de zgomot $r_i = A + zgomot$, cu valori egale cu $[5, 7, 8, 6.1, 5.3]$. Zgomotul este AWGN $\mathcal{N}(\mu = 0, \sigma^2)$.

- Soluție: la tablă
- Estimatul $\hat{A}_{ML}$ este chiar valoarea medie a eșantioanelor
  - (deloc surprinzător)

Simulare numerică

```
import matplotlib.pyplot as plt, numpy as np, math;
mu = 0;
sigma = 1;
r = np.array([5, 7, 8, 6.1, 5.3])
plt.stem(r, basefmt=" ", use_line_collection=True)
plt.plot(np.mean(r) * np.ones(r.shape), color = 'red')
plt.xlabel('Esantioane');
plt.ylabel('Valori');
plt.title('Estimarea unui semnal constant');
plt.legend(('Estimatul', 'Esantioane'))
plt.savefig('fig/03_NumericalSim_Constant.png', transparent=T
plt.close()
```



Aproximare a unei curbe

- Estimare = aproximare a unei curbe
  - se găsește cea mai bună potrivire a lui $s_\Theta(t)$ pri datele $\mathbf{r}$
- Din exemplul grafic anterior:
  - avem un set de date $\mathbf{r}$
  - se cunoaște forma semnalului = o dreaptă orizontală (A constant)
  - se aproximează în mod optim dreapta prin setul de date

Semnal oarecare în AWGN

- Fie semnalul original $s_\Theta(t)$
- Zgomotul este AWGN $\mathcal{N}(\mu = 0, \sigma^2)$
- Eșantioanele r_i sunt luate la momentele t_i
- Eșantioanele r_i au distribuție normală, cu media $\mu = s_\Theta(t_i)$ și varianța σ^2
- Funcția de plauzibilitate globală = produsul plauzibilităților fiecărui eșantion r_i

$$L(\Theta|\mathbf{r}) = w(\mathbf{r}|\Theta) = \prod_{i=1}^{N} \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(r_i - s_\Theta(t_i))^2}{2\sigma^2}}$$

$$= \left(\frac{1}{\sigma\sqrt{2\pi}}\right)^N e^{-\frac{\sum (r_i - s_\Theta(t_i))^2}{2\sigma^2}}$$

Semnal oarecare în AWGN

- Logaritmul plauzibilității ("log-likelihood") este

$$\ln\left(L(\Theta|\mathbf{r})\right) = \underbrace{\ln\left(\frac{1}{\sigma\sqrt{2\pi}}\right)}_{constant} - \frac{\sum(r_i - s_\Theta(t_i))^2}{2\sigma^2}$$

Semnal oarecare în AWGN

- Maximul funcției = minimul exponentului

$$\hat{\Theta}_{ML} = \arg\max_{\Theta} L(\Theta|\mathbf{r}) = \arg\min \sum (r_i - s_\Theta(t_i))^2$$

- Termenul $\sum (r_i - s_\Theta(t_i))^2$ este **distanța** $d(\mathbf{r}, s_\Theta)$ **la pătrat**

$$d(\mathbf{r}, s_\Theta) = \sqrt{\sum (r_i - s_\Theta(t_i))^2}$$

$$(d(\mathbf{r}, s_\Theta))^2 = \sum (r_i - s_\Theta(t_i))^2$$

Semnal oarecare în AWGN

- Estimarea ML se poate rescrie sub forma:

$$\hat{\Theta}_{ML} = \arg\max_{\Theta} L(\Theta|\mathbf{r}) = \arg\min_{\Theta} d(\mathbf{r}, \mathbf{s}_{\Theta})^2$$

- Estimatul de plauzibilitate maximă (ML) $\hat{\Theta}_{ML}$ = valoarea care face $s_{\Theta}(t_i)$ **cel mai apropiat de vectorul recepționat r**
  - mai aproape = potrivire mai bună = mai probabil
  - cel mai aproape = cea mai bună potrivire = cel mai probabil = plauzibilitate maximă

Semnal oarecare în AWGN

- Estimare ML în zgomot gaussian = **minimizarea distanței**
- Aveam aceeași interpretare și la decizia ML!
  - dar la decizie alegeam minimul din 2 opțiuni
  - aici alegem minimul dintre toate opțiunile posibile
- Relația e valabilă pentru orice fel de spații vectoriale
  - vectori cu N elemente, semnale continue, etc
  - doar se înlocuiește definiția distanței Euclidiene

Semnal oarecare în AWGN

Procedura pentru estimarea tip ML în zgomot AWGN:

1. Se scrie expresia pentru pătratul distanței:

$$D = (d(\mathbf{r}, s_\Theta))^2 = \sum (r_i - s_\Theta(t_i))^2$$

2. Vrem minimul, deci egalăm derivata cu 0:

$$\frac{dD}{d\Theta} = \sum 2(r_i - s_\Theta(t_i))(-\frac{ds_\Theta(t_i)}{d\Theta}) = 0$$

3. Se rezolvă și obținem valoarea $\hat{\Theta}_{ML}$
4. Se verifică că derivata a doua în punctul $\hat{\Theta}_{ML}$ este pozitivă, pentru a se verifica că punctul este un minim
   - uneori sărim peste această etapă

Simulare numerică

Estimarea frecvenței f a unui semnal sinusoidal

- Găsiți estimatul Maximum Likelihood pentru frecvența f a unui semnal $s_\Theta(t) = cos(2\pi f t_i)$, din 10 măsurători afectate de zgomot $r_i = cos(2\pi f t_i) + zgomot$ de valori [...]. Zgomotul este AWGN $\mathcal{N}(\mu = 0, \sigma^2)$. Momentele de eșantionare sunt $t_i = [0, 1, 2, 3, 4, 5, 6, 7, 8, 9]$
- Soluție: la tablă

Simulare numerică

Funcția de plauzibilitate este

```
import matplotlib.pyplot as plt, numpy as np, math;
np.random.seed(102)
mu = 0;
sigma = 0.2;
ftrue = 0.07;
n = np.arange(0,20)
r = np.cos(2 * math.pi * ftrue * n) + sigma*np.random.randn(2

# Log-likelihood function
fvalues = np.linspace(0.04, 0.1, 100);
L = np.zeros((1,500))
L = [np.log(1./(sigma*math.sqrt(2*math.pi))) - (sum(r - np.co
fhat = np.amax(L)
plt.plot(fvalues,L)
plt.savefig('fig/03_NumericalSim_CosineFreq_LogLik.png', tran
plt.close()
```

Simulare numerică

```
import matplotlib.pyplot as plt, numpy as np, math;
np.random.seed(102)
mu = 0;
sigma = 0.2;
ftrue = 0.07;
n = np.arange(0,20)
r = np.cos(2 * math.pi * ftrue * n) + sigma*np.random.randn(2

# Log-likelihood function
fvalues = np.linspace(0.04, 1/10, 100);
L = np.zeros((1,500))
L = [np.log(1./(sigma*math.sqrt(2*math.pi))) - (sum(r - np.co
imax = np.argmax(L)
fhat = fvalues[imax]
plt.stem(n,r, basefmt="b", use_line_collection=True)
ntoplot = np.linspace(0,20,200)
plt.plot(ntoplot, np.cos(2 * math.pi * fhat * ntoplot), color
plt.legend(('Cosinusul estimat','Esantioane'))
```

Estimarea parametrilor unor distribuții

- Estimarea ML se poate folosi și pentru a estima parametrii unor distribuții
- Avem un set de valori r_i, pe care le modelăm ca fiind eșantioane dintr-o distribuție. Cum găsim parametrii acelei distribuții?
- Momentan, considerăm un singur parametru necunoscut

Estimarea parametrilor distribuției normale

- Presupunem că r_i sunt eșantioane dintr-o distribuție normală $\mathcal{N}(\mu, \sigma^2)$
- Distribuția are doi parametri: media μ și deviația standard σ
- Estimarea lui μ:

  Este identică cu estimarea unui semnal constant în zgomot gaussian cu media 0:

$$\hat{\mu}_{ML} = \frac{1}{N} \sum_{i=1}^{N} r_i$$

- Estimarea lui σ^2:

  Nu se poate formula ca estimarea unui semnal afectat, prin adunare, de zgomot gaussian, dar cu toate acestea se poate utiliza în continuare metoda ML:

$$\hat{\sigma}_{ML} = \arg\max_{\sigma} w(\mathbf{r}|\sigma)$$

Estimarea parametrilor distribuției normale

$$\hat{\sigma}_{ML} = \arg\max_{\sigma} w(\mathbf{r}|\sigma)$$

$$= \arg\max_{\sigma} \left(\frac{1}{\sigma\sqrt{2\pi}}\right)^{N} e^{-\frac{\sum(r_i-\mu)^2}{2\sigma^2}} \quad (\text{ aplicăm } \ln() \text{ })$$

$$= \arg\max_{\sigma} \left(-N\ln(\sigma\sqrt{2\pi}) - \frac{\sum(r_i-\mu)^2}{2\sigma^2}\right)$$

Derivăm și egalăm cu 0 pentru a obține minimul:

$$-N\frac{1}{\sigma\sqrt{2\pi}}\sqrt{2\pi} - \frac{\sum(r_i-\mu)^2}{2}(-2)\sigma^{-3} = 0$$

$$-\frac{N}{\sigma} + \frac{\sum(r_i-\mu)^2}{\sigma^3} = 0$$

$$\sigma^2 = \frac{\sum(r_i-\mu)^2}{N}$$

Estimarea parametrilor distribuției normale

- Estimarea parametrilor unei distribuții normale e similară cu definițiile mediei și variației:

$$\hat{\mu}_{ML} = \frac{1}{N}\sum_{i=1}^{N} r_i$$

$$\hat{\sigma}_{ML} = \sqrt{\frac{\sum_{i=1}^{N}(r_i - \mu)^2}{N}}$$

- Notă: estimarea lui σ_{ML} necesită valoarea lui μ
  - Dacă μ este cunoscut, totul e în regulă
  - Dacă μ este necunoscut, se poate folosi $\hat{\mu}_{ML}$, dar atunci estimăm pe baza unei alte estimări, ceea ce e problematic (estimatorul este deplasat, vom vedea)

Estimarea parametrilor distribuției uniforme

- Presupunem că r_i sunt eșantioane dintr-o distribuție uniformă $\mathcal{U}[a, b]$
- Distribuția are doi parametri: limitele a și b
- Estimarea lui a și b:

$$\hat{a}_{ML} = \arg\max_a w(\mathbf{r}|a)$$
$$\hat{b}_{ML} = \arg\max_b w(\mathbf{r}|b)$$

Prin raționament:

$$\hat{a}_{ML} = \min(r_i)$$
$$\hat{b}_{ML} = \max(r_i)$$

- Intervalul trebuie să cuprindă toate valorile (altfel, probabilitatea ar fi 0), dar nu trebuie să fie mai mare decât strict necesar (altfel, probabilitatea ar fi mai mică)

Parametri multipli

- Dacă semnalul depinde de mai mulți parametri?
  - de ex. amplitudinea, frecvența și faza inițială a unui cosinus:

$$s(t) = A\cos(2\pi ft + \phi)$$

- Se va considera Θ ca fiind un vector:

$$\boldsymbol{\Theta} = [\Theta_1, \Theta_2, ...\Theta_M]$$

  - e.g. $\boldsymbol{\Theta} = [\Theta_1, \Theta_2, \Theta_3] = [A, f, \phi]$

Parametri multipli

- Se rezolvă cu aceeași procedură, dar în loc de o singură derivată vom avea M derivate
- Se rezolvă sistemul:

$$\begin{cases} \frac{\partial L}{\partial \Theta_1} = 0 \\ \frac{\partial L}{\partial \Theta_2} = 0 \\ \dots \\ \frac{\partial L}{\partial \Theta_M} = 0 \end{cases}$$

  - uneori este dificil/imposibil

Coborâre după gradient (Gradient Descent)

- Cum se estimează parametrii Θ în cazuri complicate?
  - în aplicații reale, unde pot fi foarte mulți parametri (Θ este vector)
- De obicei nu se pot găsi valorile optime prin formule directe
- Se îmbunătățesc valorile în mod iterativ cu algoritmi tip **coborâre după gradient** (Gradient Descent)
- Gradient Descent este o metodă generală de găsire a minimului (sau a maximului) unei funcții

Coborâre după gradient (Gradient Descent)

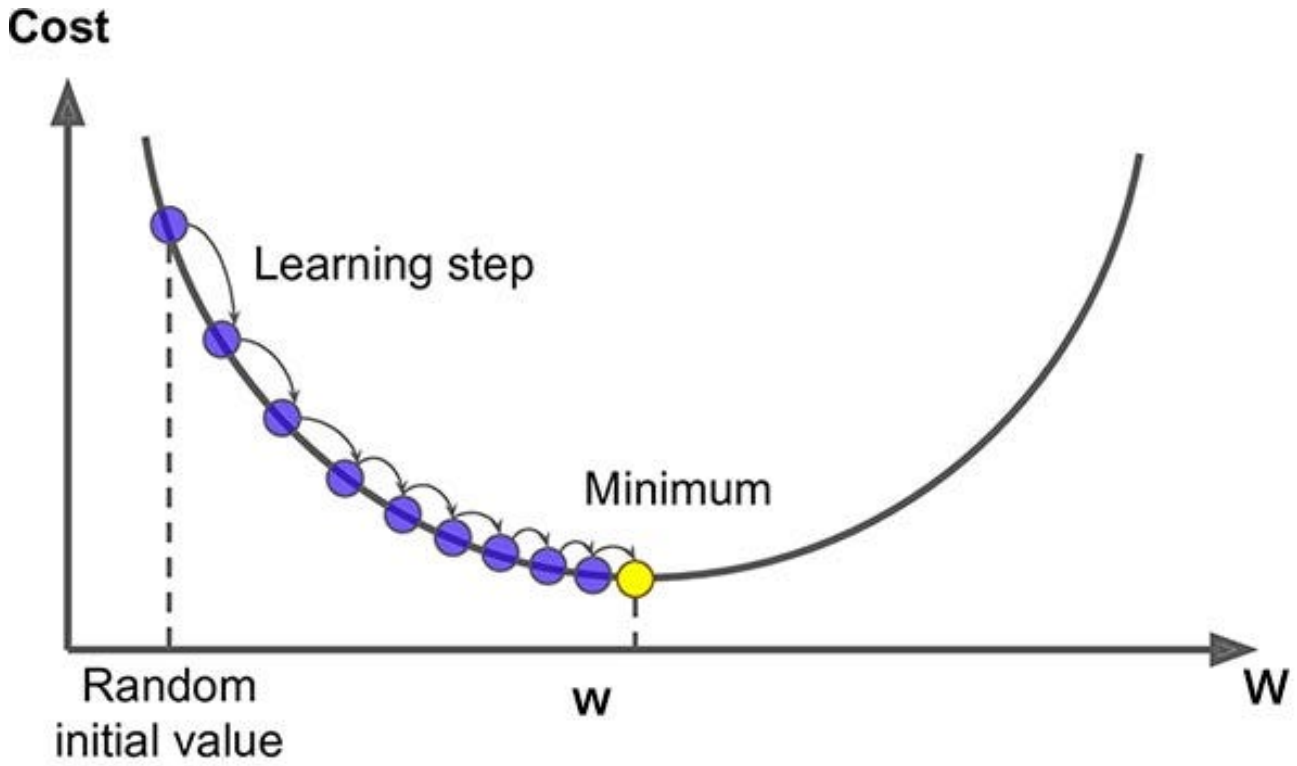


Figure 1: Coborâre după gradient[1]

[1]Imagine: Quick Guide to Gradient Descent and Its Variants, Sahdev Kansal, Towards Data Science, 2020

Coborâre după gradient (Gradient Descent)

1. Se inițializează parametrii cu valori aleatoare $\mathbf{\Theta}^{(0)}$
2. Repetă la fiecare iterație k:
   - 2.1 Se calculează funcția $L(\mathbf{\Theta}^{(k)}|\mathbf{r})$
   - 2.2 Se calculează derivatele $\frac{\partial L}{\partial \Theta_i^{(k)}}$ pentru toți Θ_i ("**Gradient**")
   - 2.3 Se actualizează toate valorile Θ_i prin scăderea derivatei ("**Descent**"):

$$\Theta_i^{(k+1)} = \Theta_i^{(k)} - \mu \frac{\partial L}{\partial \Theta_i^{(k)}}$$

   - sau, sub formă vectorială:

$$\mathbf{\Theta}^{(k+1)} = \mathbf{\Theta}^{k} - \mu \frac{\partial L}{\partial \mathbf{\Theta}^{(k)}}$$

3. Până la îndeplinirea unui criteriu de terminare (de ex. parametrii nu se mai modifică mult)

Coborâre după gradient (Gradient Descent)

- În fiecare punct, derivata ne spune în ce direcție să mergem
- Pentru găsirea minimului unei funcții, se scade derivata (coborâre după gradient)

$$\Theta^{(k+1)} = \Theta^{(k)} - \mu \frac{\partial L}{\partial \Theta^{(k)}}$$

- Pentru găsirea maximului unei funcții, se adună derivata (urcare după gradient)

$$\Theta^{(k+1)} = \Theta^{(k)} + \mu \frac{\partial L}{\partial \Theta^{(k)}}$$

- Parametrul μ se numește **rată de învățare** (learning rate) și se alege empiric, la o valoare mică
- GD depinde de valoarea inițială, și poate ajunge la minimul local, nu global
- Alte explicații la tablă
- Exemplu practic: regresia logistică cu valori 2D

Rețele Neurale

- Cel mai proeminent exemplu: **Rețele Neurale Artificiale** (a.k.a. "Rețele Neurale", "Deep Learning", etc.)
  - Pot fi văzute ca un exemplu de estimare ML
  - Se utilizează algoritmul *Gradient Descent* pentru găsirea parametrilor
  - Aplicații de vârf: recunoașterea de imagini, automated driving etc.
- Mai multe informații despre rețele neurale / machine learning:
  - căutați cursuri sau cărți online
  - IASI AI Meetup

Deplasarea și varianța estimatorilor

- Cum caracterizăm calitatea unui estimator?
- Un estimator $\hat{\Theta}$ este **o variabilă aleatoare**
  - poate avea diverse valori, pentru că se calculează pe baza eșantioanelor recepționate, care depind de zgomot
  - exemplu: se repetă aceeași estimare pe calculatoare diferite $=>$ valori estimate ușor diferite
- Fiind o variabilă aleatoare, se pot defini:
  - valoarea medie a estimatorului: $E\left\{\hat{\Theta}\right\}$
  - varianța estimatorului: $E\left\{(\hat{\Theta} - E\left\{\hat{\Theta}\right\})^2\right\}$

Deplasarea și varianța estimatorilor

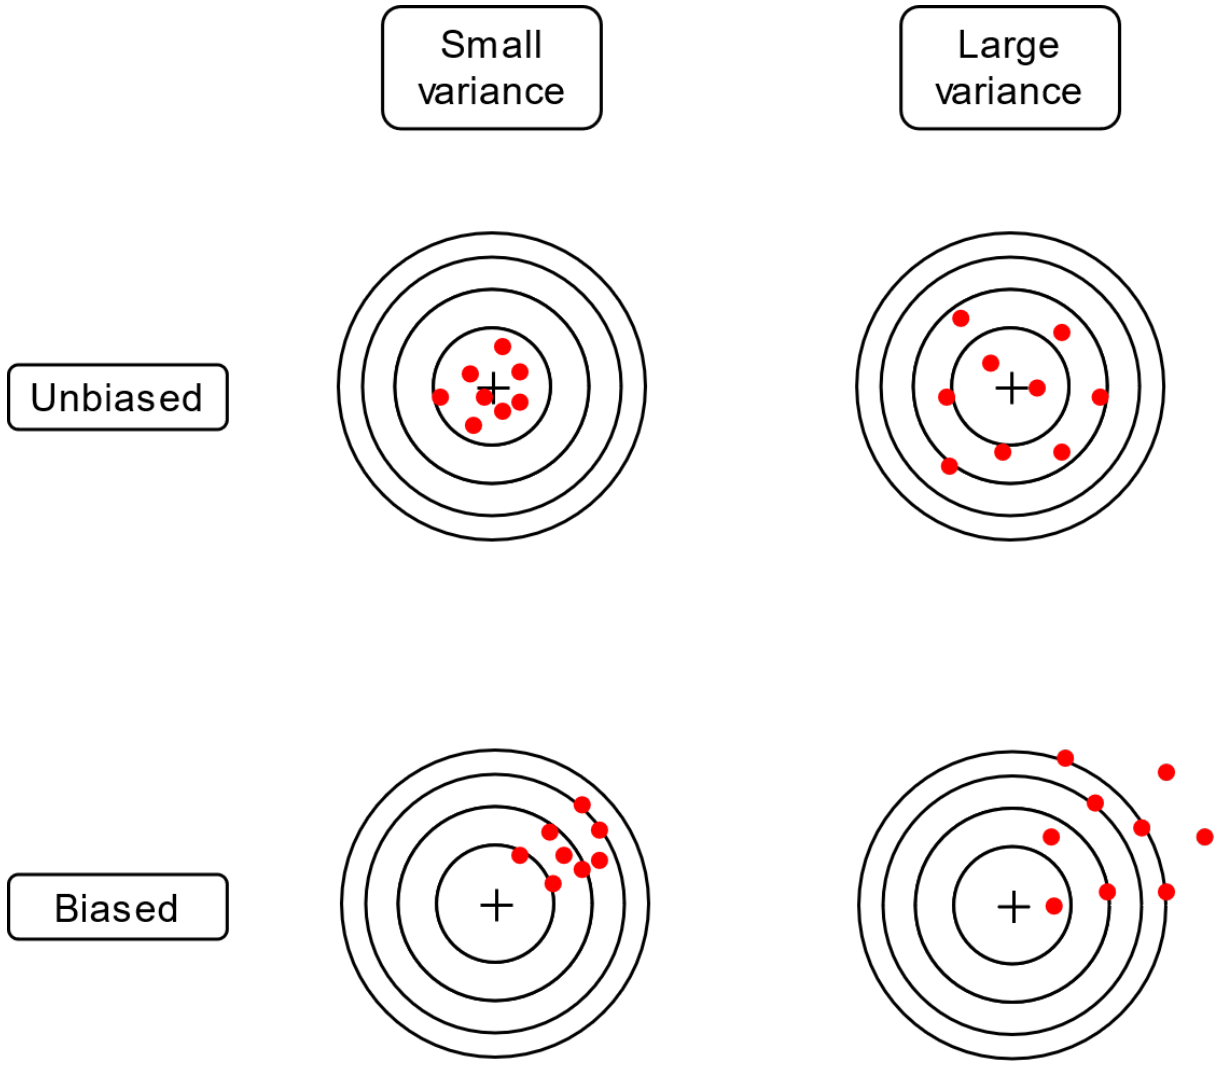


Figure 2: Deplasarea și varianța estimatorilor

Deplasarea unui estimator

- **Deplasarea** ("bias") unui estimator = diferența dintre valoarea medie a estimatorului și valoarea adevărată Θ

$$Deplasare = E\left\{\hat{\Theta}\right\} - \Theta$$

- Estimator **nedeplasat** = valoarea medie a estimatorului este egală cu valoarea adevărată a parametrului Θ

$$E\left\{\hat{\Theta}\right\} = \Theta$$

- Estimator **deplasat** = valoarea medie a estimatorului diferă de valoarea adevărată a parametrului Θ
  - diferența $E\left\{\hat{\Theta}\right\} - \Theta$ este **deplasarea** estimatorului

Deplasarea unui estimator

- Exemplu: semnal constant A, zgomot Gaussian (cu media 0), estimatorul de plauzibilitate maximă este $\hat{A}_{ML} = \frac{1}{N} \sum_i r_i$
- Atunci:

$$\begin{aligned} E\left\{\hat{A}_{ML}\right\} &= \frac{1}{N} E\left\{\sum_i r_i\right\} \\ &= \frac{1}{N} \sum_{i=1}^{N} E\left\{r_i\right\} \\ &= \frac{1}{N} \sum_{i=1}^{N} E\left\{A + zgomot\right\} \\ &= \frac{1}{N} \sum_{i=1}^{N} A \\ &= A \end{aligned}$$

- Acest estimator este nedeplasat

Deplasarea unui estimator

- Exemplu: estimatorul varianței unei distribuții normale, când se folosește media estimată $\hat{\mu}_{ML}$:

$$\hat{\sigma}^2_{ML} = \frac{\sum_{i=1}^{N}(r_i - \hat{\mu}_{ML})^2}{N}$$

- Acest estimator este **deplasat**:

$$\begin{aligned} E\left\{\hat{\sigma}^2_{ML}\right\} &= E\left\{\frac{\sum_{i=1}^{N}(r_i - \hat{\mu}_{ML})^2}{N}\right\} \\ &= \ldots \\ &= \frac{N-1}{N}\sigma^2 \end{aligned}$$

  unde σ^2 este varianța reală a distribuției

- Demonstrație: *Wikipedia* sau "*Maximum Likelihood Estimator for Variance is Biased: Proof*", Dawen Liang, Carnegie Mellon University

Estimatorul nedeplasat al variației

- Estimatorul ML al variației este deplasat, și **subestimează** varianța reală a distribuției cu un factor (N-1)/N
- Pentru a obține un estimator nedeplasat al variației, se folosește formula:

$$\hat{\sigma}^2_{ML} = \frac{1}{N-1}\sum_{i=1}^{N}(r_i - \hat{\mu}_{ML})^2$$

- Diferența: se împarte la $N-1$ în loc de N
- Justificare intuitivă: discuție la tablă, cazul cu 2 puncte; media este la mijloc; varianța e minimizată, deci subestimează varianța reală

Varianța unui estimator

- **Varianța** unui estimator măsoară "abaterile" estimatorului în jurul valorii medii
  - aceasta e definiția variației σ^2 în general
- Dacă un estimator are **varianța** mare, valoarea estimată poate fi departe de cea reală, chiar daca estimatorul este nedeplasat
- De obicei se preferă estimatori cu **varianță mică**, tolerându-se o eventuală mică deplasare

II.3 Estimare Bayesiană

Estimare Bayesiană

- **Estimarea Bayesiană** ia în calcul termeni suplimentari pe lângă $w(\mathbf{r}|\Theta)$:
  - o distribuție *a priori* $w(\Theta)$
  - opțional, o funcție de cost
- Se obține echivalentul din estimare pentru criteriile de decizie MPE și MR

Estimare Bayesiană

- Conceptual, estimarea Bayesiană constă în doi pași:
  1. Găsirea distribuției **posterioare** $w(\Theta|\mathbf{r})$
  2. Estimarea unei valori din această distribuție, pe baza unei **funcții de cost**

Estimare Bayesiană

- Se definește **distribuția *a posteriori*** a lui Θ, date fiind observațiile $\mathbf{r}$, folosind **regula lui Bayes**:

$$w(\Theta|\mathbf{r}) = \frac{w(\mathbf{r}|\Theta) \cdot w(\Theta)}{w(\mathbf{r})}$$

- Termenii:
  - Θ este parametrul necunoscut
  - $\mathbf{r}$ este vectorul de observații
  - $w(\Theta|\mathbf{r})$ este probabilitatea ca parametrul să aibă valoarea Θ, dat fiind vectorul de observații $\mathbf{r}$;
  - $w(\mathbf{r}|\Theta)$ este funcția de plauzibilitate
  - $w(\Theta)$ este distribuția **a priori** a lui Θ
  - $w(\mathbf{r})$ este o constantă (distribuția **a priori** a lui $\mathbf{r}$); singurul său rol este să normalizeze expresia, astfel încât integrala lui $w(\Theta|\mathbf{r})$ să fie 1, așa cum stă bine unei distribuții de probabilitate

Estimare Bayesiană

Comentarii:

- La estimarea ML, avem doar termenul $w(\mathbf{r}|\Theta)$. Acesta este o funcție de Θ, dar nu e chiar distribuția de probabilitate lui Θ. E doar o mărime pe care vrem să o maximizăm.
- Estimarea Bayesiană folosește însă chiar distribuția de probabilitate a lui Θ, $w(\Theta|\mathbf{r})$, calculată cu regula lui Bayes, care ne spune riguros șansele ca Θ să aibă o anumită valoare sau alta.

Regula lui Bayes

- Relația precedentă arată că, în general, estimarea lui Θ depinde de două lucruri:
  1. De vectorul observațiilor $\mathbf{r}$, prin termenul $w(\mathbf{r}|\Theta)$
  2. De informația "a priori" avută despre Θ, prin termenul $w(\Theta)$
  - (numitorul $w(\mathbf{r})$ se presupune constant și are doar rol de normalizare)
- Distribuția a priori $w(\Theta)$ reflectă cunoștințele noastre anterioare despre parametrul Θ, înainte de a avea observațiile $\mathbf{r}$.
- Distribuția a posteriori $w(\Theta|\mathbf{r})$ reflectă cunoștințele noastre după ce avem și observațiile $\mathbf{r}$.
- Numele este "estimare Bayesiană"
  - Thomas Bayes = matematician englez, a descoperit regula cu acest nume
  - Noțiunile bazate pe regula lui Bayes poartă deseori numele de "Bayesiene"

Distribuția *a priori*

- Presupunem că se știe de dinainte o distribuție a lui Θ, $w(\Theta)$
  - adică, știm de dinainte care e probabilitatea de a fi a anume valoare sau alta, sau un anume interval interzis etc.
  - se numește distribuția *a priori*, adică "de dinainte de a avea observațiile"
- Care este efectul ei? Estimarea va fi "trasă" puțin înspre valorile preferate de distribuția *a priori*
  - de exemplu, dacă distribuția *a priori* este concentrată în jurul unei valori, estimarea va fi mai probabil să cadă în jurul acelei valori
- Dacă nu avem informații *a priori*, putem folosi o distribuție uniformă, adică $w(\Theta) = \text{constant}$

Estimatorul MAP

- Cunoaștem distribuția *a posteriori* $w(\Theta|\mathbf{r})$. Care este valoarea estimată?
- Se poate alege valoarea care are probabilitate maximă
- Estimatorul **Maximum A Posteriori (MAP)** este

$$\hat{\Theta}_{MAP} = \arg\max_{\Theta} w(\Theta|\mathbf{r}) = \arg\max_{\Theta} w(\mathbf{r}|\Theta) \cdot w(\Theta)$$

- Estimatorul MAP alege acea valoare Θ unde distribuția *a posteriori* $w(\Theta|\mathbf{r})$ este maximă
- Estimatorul MAP maximizează **produsul** dintre plauzibilitate și **distribuția *a priori*** $w(\Theta)$

Estimatorul MAP

Exemplu: Imagine

Relația dintre estimarea MAP și ML

- Estimatorul ML:

$$\arg\max w(\mathbf{r}|\Theta)$$

- Estimatorul MAP:

$$\arg\max w(\mathbf{r}|\Theta) \cdot w(\Theta)$$

- Estimatorul ML este un caz particular de MAP pentru $w(\Theta)$ constant
  - $w(\Theta) =$ constant înseamnă că toate valorile lui Θ sunt *a priori* echiprobabile
  - i.e. nu avem extra informații despre valoarea lui Θ

Relația cu detecția semnalelor

- Criteriul probabilității minime de eroare: $\frac{w(r|H_1)}{w(r|H_0)} \underset{H_0}{\overset{H_1}{\gtrless}} \frac{P(H_0)}{P(H_1)}$
- Se poate rescrie ca $w(r|H_1) \cdot P(H_1) \underset{H_0}{\overset{H_1}{\gtrless}} w(r|H_0)P(H_0)$
  - adică se alege ipoteza pentru care $w(r|H_i) \cdot P(H_i)$este mai mare
- **Criteriul de decizie MPE**: se alege ipoteza care maximizează $w(r|H_i) \cdot P(H_i)$
  - dintre cele două ipoteze H_0, H_1
- **Estimarea MAP**: se alege valoarea care maximizează $w(\mathbf{r}|\Theta) \cdot w(\Theta)$
  - dintre toate valorile posibile pentru Θ
- Același principiu!

Funcția de cost

- Vrem s găsim un echivalent și pentru criteriul MR
- Avem nevoie de un echivalent pentru costurile C_{ij}
- **Eroarea de estimare** = diferența între estimatul $\hat{\Theta}$ și valoarea reală Θ

$$\epsilon = \hat{\Theta} - \Theta$$

- **Funcția de cost** $C(\epsilon)$ = atribuie un cost pentru fiecare eroare de estimare posibilă
  - când $\epsilon = 0$, costul $C(0) = 0$
  - erori ϵ mici au costuri mici
  - erori ϵ mari au costuri mari

Funcția de cost

- Funcții de cost uzuale:
  - Pătratică:
$$C(\epsilon) = \epsilon^2 = \left(\hat{\Theta} - \Theta\right)^2$$
  - Uniformă:
$$C(\epsilon) = \begin{cases} 0, & \text{if } |\epsilon| = |\hat{\Theta} - \Theta| \leq E \\ 1, & \text{if } |\epsilon| = |\hat{\Theta} - \Theta| > E \end{cases}$$
  - Liniară:
$$C(\epsilon) = |\epsilon| = |\hat{\Theta} - \Theta|$$
- De desenat la tablă

Funcția de cost

- Funcția de cost $C(\epsilon)$ reprezintă echivalentul costurilor C_{ij} de la detecție
  - la detecție aveam doar 4 valori: C_{00}, C_{01}, C_{10}, C_{11}
  - aici avem un cost pentru fiecare eroare posibilă ϵ
- Funcția de cost dictează ce valoarea alegem din distribuția $w(\Theta|\mathbf{r})$

Importanța funcției de cost

- Fie distribuția *a posteriori* următoare:

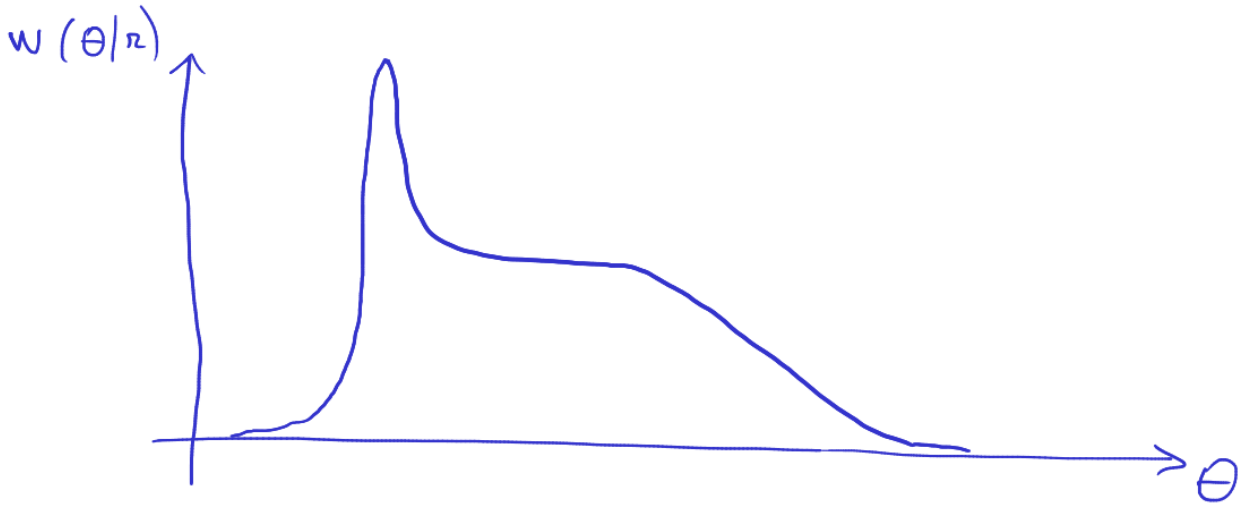


Figure 3: Asymmetrical posterior distribution

- Care este estimatorul MAP?
- Dar dacă avem funcția de cost următoare:
  - dacă estimarea $\hat{\Theta}$ este $<$ valoarea reală Θ, te costă 1000 dolari
  - dacă estimarea $\hat{\Theta}$ este $>$ valoarea reală Θ, plătești 1 dolar
  - schimbăm valoarea estimată ? :)

Importanța funcției de cost

- Funcția de cost este cea care impune alegerea unei anume valori estimate $\hat{\Theta}$ de pe distribuția valorilor posibile
- Valoarea cea mai probabilă nu este întotdeauna cea mai bună!
- Valoarea cea mai bună este cea care minimizează costul (adică, valoarea medie ("expected value") a costului, întrucât acesta poate fi unoeri mai mic, alteori mai mare)

Riscul Bayesian

- Distribuția *a posteriori* $w(\Theta|\mathbf{r})$ dă probabilitatea fiecărei valori Θ de a fi cea corectă
- Alegerea unui estimat $\hat{\Theta}$ implică o anume eroare ϵ
- Eroarea de estimare are un anumit cost $C(\epsilon) = C(\hat{\Theta} - \Theta)$
- **Riscul** = costul mediu în raport cu toate valorile posibile ale Θ = integrala din $C(\epsilon) \times$ probabilitatea:

$$R = \int_{-\infty}^{\infty} C(\hat{\Theta} - \Theta) w(\Theta|\mathbf{r}) d\Theta$$

The Bayesian risk

- Alegem valoarea $\hat{\Theta}$ care **minimizează costul mediu** R

$$\hat{\Theta} = \arg\min_{\hat{\Theta}} \int_{-\infty}^{\infty} C(\hat{\Theta} - \Theta) w(\Theta|\mathbf{r}) d\Theta$$

- O obținem înlocuind $C(\epsilon) = C(\hat{\Theta} - \Theta)$ cu definiția sa, și derivând după $\hat{\Theta}$
  - Atenție: se derivează după $\hat{\Theta}$, nu Θ!

Estimatorul EPMM (eroare pătratică medie minimă)

- Când funcția de cost este pătratică $C(\epsilon) = \epsilon^2 = \left(\hat{\Theta} - \Theta\right)^2$

$$R = \int_{-\infty}^{\infty} (\hat{\Theta} - \Theta)^2 w(\Theta|\mathbf{r}) d\Theta$$

- Vrem $\hat{\Theta}$ care minimizează R, deci derivăm

$$\frac{dR}{d\hat{\Theta}} = 2 \int_{-\infty}^{\infty} (\hat{\Theta} - \Theta) w(\Theta|\mathbf{r}) d\Theta = 0$$

- Echivalent cu

$$\hat{\Theta} \underbrace{\int_{-\infty}^{\infty} w(\Theta|\mathbf{r})}_{1} d\Theta = \int_{-\infty}^{\infty} \Theta w(\Theta|\mathbf{r}) d\Theta$$

- Estimatorul de **eroare pătratică medie minimă (EPMM) ("Minimum Mean Squared Error, MMSE")**:

$$\hat{\Theta}_{EPMM} = \int_{-\infty}^{\infty} \Theta \cdot w(\Theta|\mathbf{r}) d\Theta$$

Interpretare

- **Estimatorul EPMM**: estimatorul $\hat{\Theta}$ este **valoarea medie** a distribuției *a posteriori* $w(\Theta|\mathbf{r})$

$$\hat{\Theta}_{EPMM} = \int_{-\infty}^{\infty} \Theta \cdot w(\Theta|\mathbf{r}) d\Theta$$

  - EPMM = "Eroare Pătratică Medie Minimă"
  - valoarea medie = sumă (integrală) din fiecare Θ ori probabilitatea sa $w(\Theta|\mathbf{r})$

- Estimatprul EPMM se obține din distribuția *a posteriori* $w(\Theta|\mathbf{r})$, considerând funcția de cost pătratică

Estimatorul MAP

- Dacă funcția de cost este uniformă

$$C(\epsilon) = \begin{cases} 0, \text{ if } |\epsilon| = |\hat{\Theta} - \Theta| \leq E \\ 1, \text{ if } |\epsilon| = |\hat{\Theta} - \Theta| > E \end{cases}$$

- Știm că $\Theta = \hat{\Theta} - \epsilon$
- Se obține

$$R = \int_{-\infty}^{\hat{\Theta}-E} w(\Theta|\mathbf{r})d\Theta + \int_{\hat{\Theta}+E}^{\infty} w(\Theta|\mathbf{r})d\Theta$$

$$R = 1 - \int_{\hat{\Theta}-E}^{\hat{\Theta}+E} w(\Theta|\mathbf{r})d\Theta$$

Estimatorul MAP

- Pentru minimizarea R, trebuie să maximizăm $\int_{\hat{\Theta}-E}^{\hat{\Theta}+E} w(\Theta|\mathbf{r})d\Theta$, integrala din jurul punctului $\hat{\Theta}$
- Pentru E foarte mic, funcția $w(\Theta|\mathbf{r})$ este aproximativ constantă, deci se va alege punctul unde funcția este maximă
- **Estimatorul Maximum A Posteriori (MAP)** = valoarea $\hat{\Theta}$ care maximizează $w(\Theta|\mathbf{r})$

$$\hat{\Theta}_{MAP} = \arg\max_{\Theta} w(\Theta|\mathbf{r}) = \arg\max \Theta w(\mathbf{r}|\Theta) \cdot w(\Theta)$$

Interpretare

- Estimatorul MAP: $\hat{\Theta}$ = valoarea care maximizează distribuția *a posteriori*
- Estimatorul EPMM: $\hat{\Theta}$ = valoarea medie a distribuției *a posteriori*

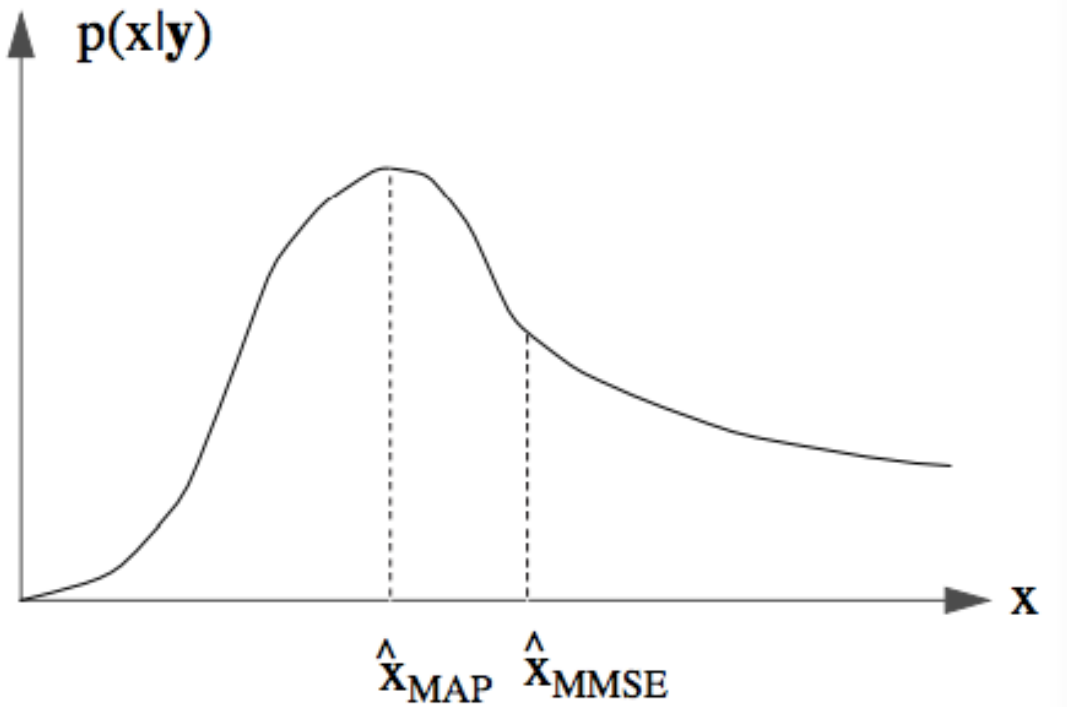


Figure 4: Estimatorul MAP vs EPMM(MMSE)

[image from https://allenlu2007.wordpress.com]

Relația între estim. MAP and EPMM

- Estimatorul MAP = minimizează costul mediu, folosind funcția de cost uniformă
  - ca le detecție: criteriul MPE = criteriul MR când costurile sunt la fel
- Estimatorul EPMM = minimizează costul mediu, folosind funcția de cost pătratică
  - similar cu criteriul MR, dar la estimare

Aplicații practice

1. Filtru Kalman: estimarea poziției unui obiect în mișcare

- Se cunosc poziția și viteza inițiale ale obiectului
- Se fac măsurători succesive ale poziției obiectului
- Se estimează poziția obiectului la fiecare măsurătoare nouă

La fiecare măsuratoare nouă, avem două distribuții ale poziției:

- cea dată de măsurătoare respectivă, $w(r|\Theta)$ ("likelihood")
- cea **prezisă** pe baza poziției și vitezei de data trecută, $w(\Theta)$ ("prior")
- ambele presupuse a fi Gaussiene, caracterizate doar prin medie și variantă

Cele două se combină prin regula lui Bayes $=>$ o distribuție mai precisă $w(\Theta|r)$, tot Gaussiană ("posterior")

- poziția exactă se estimează prin EPMM (media lui $w(\Theta|r)$)
- $w(\Theta|r)$ prezice poziția de la momentul următor

Filtru Kalman pentru estimarea poziției unui obiect în mișcare

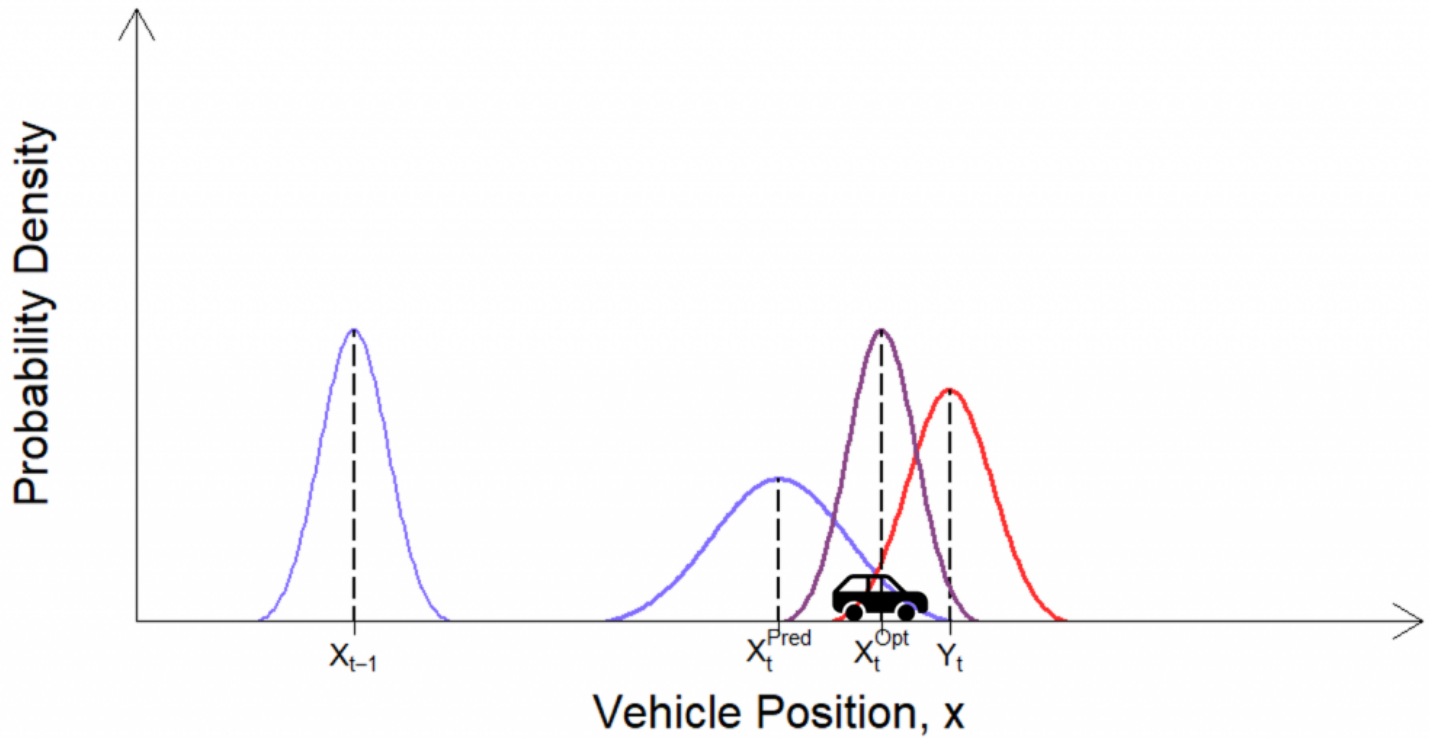


Figure 5: Estimarea poziției cu filtru Kalman [2]

[2]Image source: https://www.lancaster.ac.uk/stor-i-student-sites/jack-trainer/how-nasa-used-the-kalman-filter-in-the-apollo-program/

Filtru Kalman pentru estimarea poziției unui obiect în mișcare

- Predicția poziției obiectului la pasul următor necesită cunoașterea vitezei
- În exemplul anterior, viteza este cunoscută (constantă, sau cu o distribuție cunoscută)
- În general, filtrele Kalman estimează și **viteza** unui obiect în mișcare, doar pe baza pozițiilor măsurate

Filtru Kalman pentru estimarea poziției unui obiect în mișcare

Filtru Kalman pentru estimarea poziției și vitezei simultan (de-a lungul unei singure axe)

- Se estimează simultan poziția și viteza, adică starea $\mathbf{s} = \begin{bmatrix} x \\ v \end{bmatrix}$
- Se lucrează cu distribuții Gaussiene 2D (poziție, viteză) (mișcarea este pe o singură axă)

Etape:

1. La pasul k, se cunoaște distribuția stării s^k
2. Se prezice distribuția stării la pasul $k+1$ ("prior distribution")
3. Se face o măsurătoare a poziției z^{k+1} ("likelihood")
4. Se calculează noua distribuție a stării ("posterior distibution"), pe baza regulii lui Bayes, înmulțindu-le
5. Media acestei distribuții este estimatul stării (poziției și vitezei) la pasul $k+1$ (estimare EPMM)

Filtru Kalman pentru estimarea poziției unui obiect în mișcare

Ilustrare:

1. https://www.bzarg.com/p/how-a-kalman-filter-works-in-pictures/
2. https://towardsdatascience.com/what-i-was-missing-while-using-the-kalman-filter-for-object-tracking-8e4c29f6b795

Aplicație:

- Netezirea traiectoriilor: proiect TrafAlert