

Decizie și Estimare în Prelucrarea Informației

## Capitolul I. Semnale aleatoare

## I.1 Variabile aleatoare

- ▶ **Variabilă aleatoare** = o variabilă care denumește o valoare produsă printr-un fenomen aleator
  - ▶ Practic, reprezintă *un nume* atașat unei valori arbitrarе
  - ▶ Prescurtat: v.a.
- ▶ Notație uzuală:  $X$ ,  $Y$  etc..
- ▶ Exemple:
  - ▶  $X$  = Numărul obținut prin aruncarea unui zar
  - ▶  $V_{in}$  = Voltajul măsurat într-un punct dintr-un circuit

- ▶ **Realizare** a unei v.a. = o valoare particulară posibilă
- ▶ **Spațiul realizărilor**  $\Omega$  = mulțimea valorilor posibile ale unei v.a
  - ▶ mulțimea tuturor realizărilor
- ▶ Exemplu: aruncarea unui zar
  - ▶ V.a. se notează  $X$
  - ▶ Se poate obține o realizare  $X = 3$
  - ▶ Dar s-ar fi putut obține orice valoare din spațiul realizărilor

$$\Omega = \{1, 2, 3, 4, 5, 6\}$$

## Aruncarea unei monede

- ▶ Variabila aleatoare  $X$  = “față obținută la aruncarea unei monede”

<i>Random Variable</i>	<i>Possible Values</i>	<i>Random Events</i>
$X = \{$	<b>0</b>	
	<b>1</b>	

(sursa imaginii: <https://www.mathsisfun.com/data/random-variables.html>)


## V.a. discrete și continue

- ▶ V.a. **discretă**: dacă  $\Omega$  este o mulțime discretă
  - ▶ Exemplu: Numărul obținut prin aruncarea unui zar
- ▶ V.a. **continuă**: dacă  $\Omega$  este o mulțime compactă
  - ▶ Exemplu: Valoarea tensiunii măsurate într-un punct

## Unde se întâlnesc variabile aleatoare?

- Variabilele aleatoare modeleză semnale de **zgomot**
- Exemple:
  - Se măsoară tensiunea într-un punct dintr-un circuit
  - Dacă se măsoară de mai multe ori, se obțin valori *ușor diferite*.
  - Valoarea este afectată de zgomot
  - Valoarea tensiunii este o *variabilă aleatoare*


# Funcția masă de probabilitate



- ▶ Fie o v.a. discretă  $A$
- ▶ **Funcția masă de probabilitate** (FMP) (*probability mass function*)  
= probabilitatea ca  $A$  să aibă valoarea egală cu  $x$

$$w_A(x) = P\{A = x\}$$

- ▶ pe scurt, se mai numește distribuția variabilei  $A$
- ▶ Exemplu: FMP pentru valoarea unui zar, grafic pe tablă



# Calculul probabilității cu FMP

- ▶ Probabilitatea ca  $A$  să aibă valoarea  $v$

$$P\{A = v\} = w_A(v)$$

- ▶ Probabilitatea ca  $A$  să fie între valorile  $a$  și  $b$  (inclusiv):

$$P\{a \leq A \leq b\} = \sum_{x=a}^b w_A(x)$$

$$\mathcal{P}(A \in [1, 4]) = \frac{1}{6} + \frac{1}{6} + \frac{1}{6} + \frac{1}{6} = \frac{4}{6}$$

zor

# Functia de repartitie

- ▶ Functia de repartitie (FR) = probabilitatea ca  $A$  să aibă valoarea mai mică sau egală cu  $x$


$$F_A(x) = P\{A \leq x\}$$

$$F_A(1) = P(A \leq 1)$$

$$F_A(1.5) = P(A$$

- ▶ Exemplu: FR pentru un zar, grafic la tablă

Pentru  
 $F_{\text{de } A} = \text{zar}$



## Calculul probabilității cu FR

$$\underbrace{F_A(4)}_{\leq 4} - \underbrace{F_A(3)}_{\leq 3} = \frac{1}{6} = P(A=4)$$

- ▶ Probabilitatea ca  $A$  să aibă valoarea  $v$

$$P\{A = v\} = F_A(v) - F_A(v - 1)$$

- ▶ Probabilitatea ca  $A$  să fie între valorile  $a$  și  $b$  (inclusiv):


$$P\{a \leq A \leq b\} = F_A(b) - F_A(a - 1)$$

# Relația între FMP și FR

- FR este *suma cumulativă* (un fel de “integrală discretă”) a FMP

$$F_A(x) = \sum_{t=-\infty}^{t=x} w_A(t)$$


- Exemplu pentru zar: grafic, la tablă




O

$\neq R$  = integrala distribuției



Distrib. = derivata  $\neq R$




# Funcția densitate de probabilitate



- ▶ Fie o v.a. **continuă A**
- ▶ **Funcția densitate de probabilitate (FDP)** = probabilitatea ca valoarea lui A să fie într-o vecinătate  $\epsilon$  mică în jurul lui  $x$ , totul supra  $\epsilon$
- ▶ Se notează  $w_A(x)$ , se mai numește **distribuția** variabilei A
- ▶ Informal: FDP reprezintă probabilitatea ca valoarea lui A să fie **în jurul lui x**



# Variabile aleatoare discrete și continue



(sursa imaginii: “Probability Distributions: Discrete and Continuous”,  
Seema Singh, <https://towardsdatascience.com/probability-distributions-discrete-and-continuous-7a94ede66dc0>)

- ▶ Probabilitatea ca o v.a. continuă  $A$  să ia **exact** o valoare  $x$  este **zero**
  - ▶ pentru că există o infinitate de valori posibile (v.a. continuă)
  - ▶ de aceea nu se poate defini o funcție masă de probabilitate ca la v.a. discrete
- ▶ De aceea FDP reprezintă probabilitatea de a fi într-o vecinătate a valorii  $x$ , și nu exact egal cu  $x$

# Calculul probabilității cu FDP

V.a. continuu

$$P(A = v) = 0$$

- ▶ Probabilitatea ca  $A$  să aibă exact valoarea  $v$  este întotdeauna 0


$$P\{A = v\} = 0$$

- ▶ Probabilitatea ca  $A$  să fie între valorile  $a$  și  $b$  = integrala FDP între  $a$  și  $b$ :

$$P\{a \leq A \leq b\} = \int_a^b w_A(x) dx$$

$$P(A \in (7, 9))$$

$$P(A \in [a, b]) = \int_a^b w_A(x) dx$$




# Functia de repartitie

- ▶ **Functia de repartitie (FR)** = probabilitatea ca  $A$  să aibă valoarea mai mică sau egală cu  $x$

$$F_A(x) = P\{A \leq x\}$$

- ▶ Aceeași definiție ca și la v.a. discrete



## Calculul probabilității cu FR

$$P(A \in [7, 9]) = F(9) - F(7)$$
$$\leq 9 \quad \leq 7$$

- ▶ Probabilitatea ca valoarea lui A să fie între a și b:

$$P\{a \leq A \leq b\} = F_A(b) - F_A(a)$$

- ▶ Nu contează dacă intervalul este deschis sau închis

- ▶  $[a, b]$  sau  $(a, b)$ , nu contează
  - ▶ de ce?

$$P(A \in [7, 9]) \quad P(A \in (7, 9))$$

$$P(A \in [7, 9]) = \int_{7}^{9} w_A(x) dx = F(9) - F(7)$$

## Relația între FDP și FR

distribuția


- FR este **integrala** FDP
- FDP este **derivata** FR

$$F_A(x) = \int_{-\infty}^x w_A(x) dx$$

$$\begin{aligned}w_A(x) &= \frac{dF_A(x)}{dx} \\&= \lim_{\epsilon \rightarrow 0} \frac{F_A(x + \epsilon) - F_A(x - \epsilon)}{2\epsilon} \\&= \lim_{\epsilon \rightarrow 0} \frac{P(A \in [x - \epsilon, x + \epsilon])}{2\epsilon}\end{aligned}$$

## Interpretare grafică

- ▶ Probabilitatea ca  $A$  să fie între  $a$  și  $b$  este **suprafața de sub FDP**
  - ▶ adică integrala de la  $a$  la  $b$
- ▶ Probabilitatea ca  $A$  să fie exact egal cu o valoare este zero
  - ▶ aria de sub un punct este nulă



$$P(A \in (a, b)) = \int_a^b w_f(x) dx$$

(sursa: "[https://intellipaat.com/blog/tutorial/statistics-and-probability-tutorial/probability-distributions-of-continuous-variables/\\*](https://intellipaat.com/blog/tutorial/statistics-and-probability-tutorial/probability-distributions-of-continuous-variables/*)")


### Comparatie intre v.a. discrete si continue

- ▶ FR  $F_A(x)$  are aceeași definiție, înseamnă același lucru
- ▶ FDP/FMP  $w_A(x)$  este derivata FR
  - ▶ la v.a. continue:
    - ▶ este o derivată obișnuită
    - ▶ reprezintă probabilitatea de a fi "in jurul" valorii  $x$
  - ▶ la v.a. discrete:
    - ▶ un fel de "derivată discretă"
    - ▶ reprezintă probabilitatea de a avea exact valoarea  $x$

# Proprietățile v.a

FR:

- FR este mereu pozitivă,  $F_A(x) \geq 0$
- FR este monoton crescătoare (nu descrește)
- FR pornește din 0 și ajunge la valoarea 1



$$F_A(-\infty) = 0 \quad F_A(\infty) = 1$$

$$\mathbb{P}(A \leq -\infty) = 0 \quad \mathbb{P}(A \leq \infty) = 1$$


FDP/FMP:

- PDF/PMF sunt mereu pozitive  $w_A(x) \geq 0$
- Integrala/suma pe întreg domeniul = 1

Aria totală = 1


$$\int_{-\infty}^{\infty} w_A(x) dx = 1$$

$$\sum_{x=-\infty}^{\infty} w_A(x) = 1$$




## ► Semnal sinusoidal

Python was not found; run without arguments to install from t

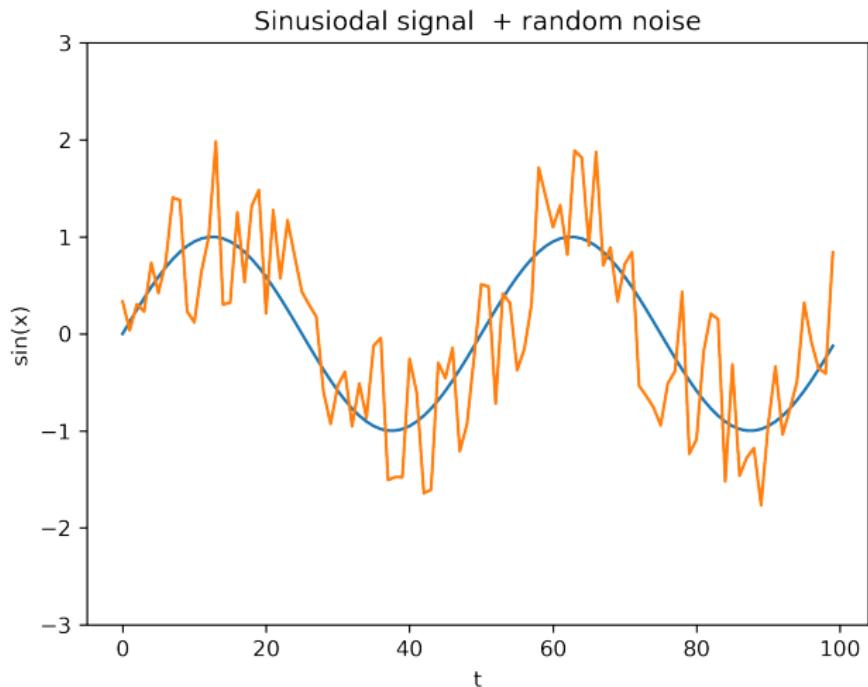


- ▶ Sinus + zgomot (normal,  $\mu = 0, \sigma^2 = 1$ )



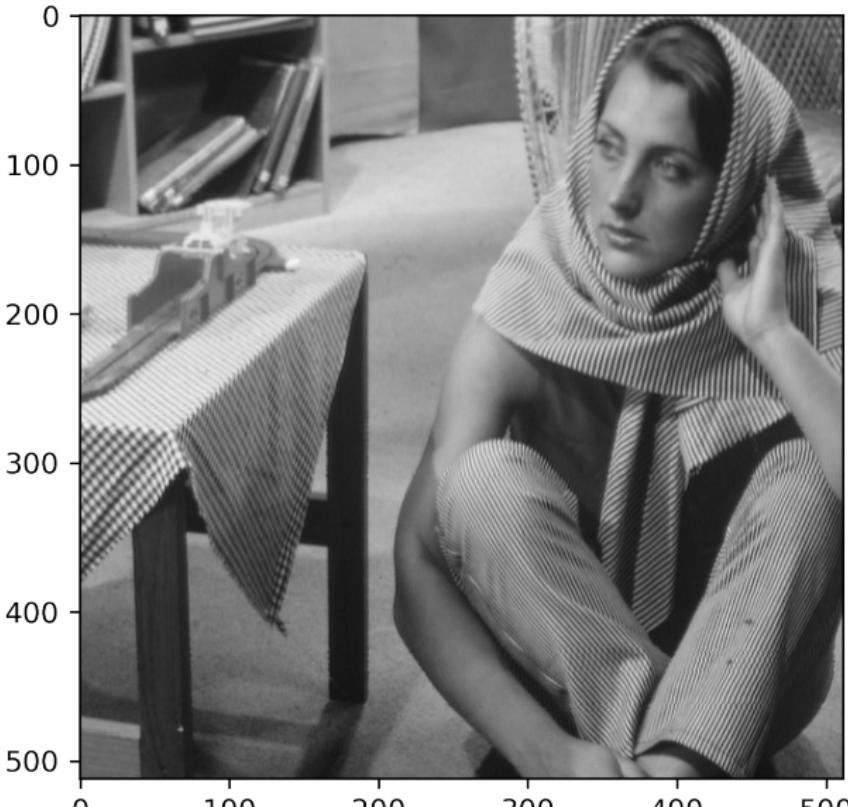
## Diferite distribuții

- ▶ Sinus + zgomot (uniform  $\mathcal{U}[-1, 1]$ )
- ▶ Ce diferă? Tipul distribuției




## Diferite distribuții

### ► Imagine originală



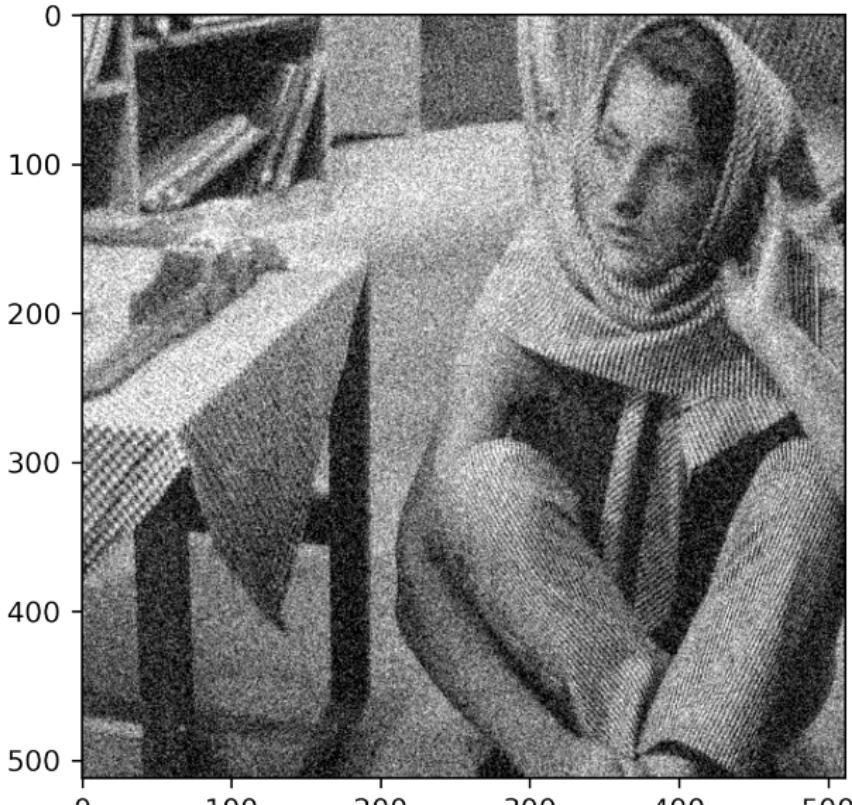
## Diferite distribuții

- ▶ Imagine + zgomot (normal,  $\mu = 0, \sigma^2 = 1$ )



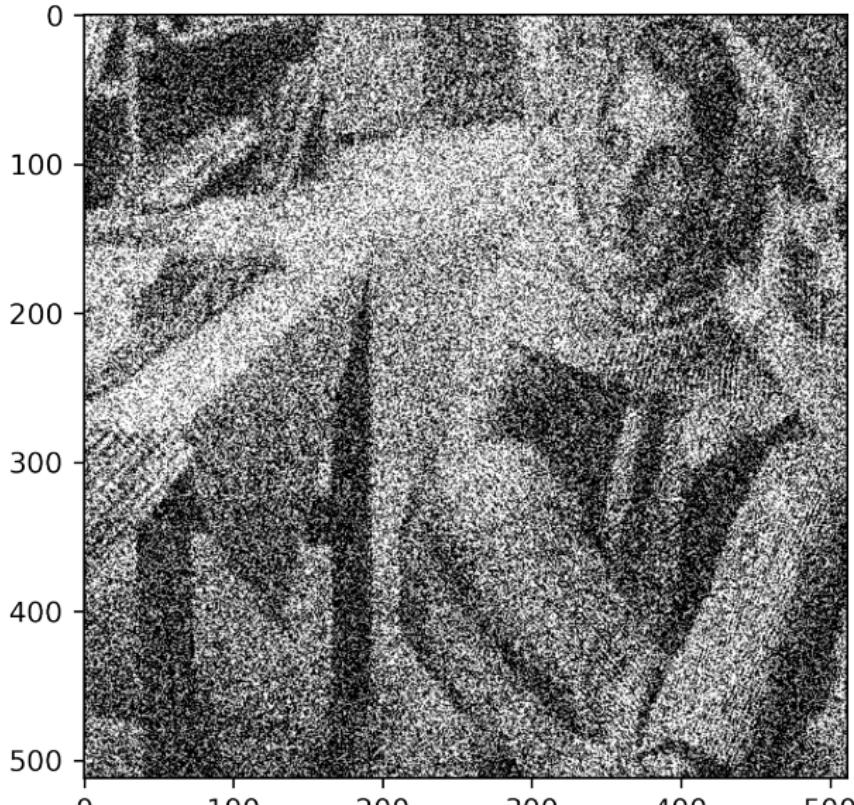
## Diferite distribuții

- ▶ Imagine + zgomot mai mare (normal,  $\mu = 0, \sigma^2 = 10$ )



## Diferite distribuții

- ▶ Imagine + zgomot (uniform,  $\mathcal{U}[-5, 5]$ )



# Distribuția normală




## ► Densitatea de probabilitate:

V.a.  
continuă

$$w_A(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

$$\frac{1}{\sigma\sqrt{2\pi}} \cdot e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

$\mu, \sigma$   
modă




# Distribuția normală

$$\sigma^2 = \text{variantă}$$

- ▶ Are doi parametri:
  - ▶ **Media**  $\mu$  = "centrul" funcției
  - ▶ **Deviatia standard**  $\sigma$  = "lățimea" funcției
    - ▶  $\sigma$  mic = funcție îngustă și înaltă
    - ▶  $\sigma$  mare = funcție largă și joasă
- ▶ Constanta de la începutul expresiei asigură normalizarea (faptul că integrala = 1)
- ▶ Extrem de des întâlnită în practică
- ▶ Orice valoare reală este posibilă ( $w_A(x) > 0, \forall x \in \mathbb{R}$ )
- ▶ Se notează cu  $\mathcal{N}(\mu, \sigma^2)$

$$\mathcal{N}(\mu = 3, \sigma^2 = 7)$$



# Distribuția normală




- ▶ Distribuția descrește pe măsură ce  $x$  se îndepărtează de centrul  $\mu$ 
  - ▶ Datorită termenului  $-(x - \mu)^2$  de la exponent
  - ▶ Valorile cele mai probabile sunt în jurul lui  $\mu$  ( $x - \mu = 0$ )
  - ▶ Valorile apropiate de  $\mu$  sunt mai probabile, valorile mai depărtate de  $\mu$  sunt mai puțin probabile
- ▶ Distribuția exprimă o preferință pentru valori apropiate de  $\mu$ , cu probabilitate din ce în ce mai scăzută la valori mai depărtate de  $\mu$

Exemple de valori generate cu distribuția normală ( $\mu=0$ ,  
 $\sigma^2=1$ )

Sample values from the normal distribution




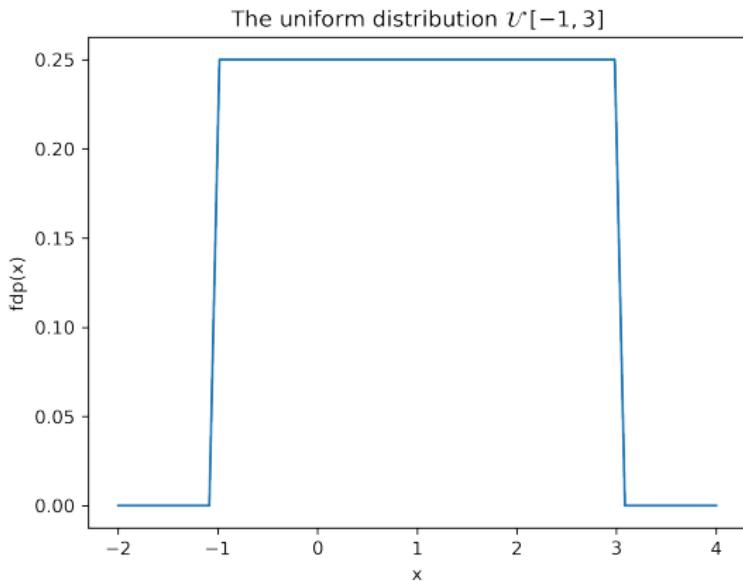
Exemple de valori generate cu distribuția normală ( $\mu=2$ ,  
 $\sigma^2=4$ )



## Distribuția uniformă

- Densitatea de probabilitate = constantă între două limite

$$w_A(x) = \begin{cases} \frac{1}{b-a}, & x \in [a, b] \\ 0, & \text{elsewhere} \end{cases}$$



- ▶ Are doi parametri: limitele  $a$  și  $b$  ale intervalului
- ▶ “Înălțimea” funcției este  $\frac{1}{b-a}$  pentru normalizare
  - ▶ pentru ca integrala (aria) să fie 1
- ▶ Sunt posibile doar valori din intervalul  $[a, b]$ 
  - ▶ valorile din afara intervalului au probabilitatea 0
- ▶ Se notează cu  $\mathcal{U}[a, b]$

## Alte distribuții

- ▶ Nenumărate variante, apar în diverse aplicații

# Calculul probabilității pentru distribuția normală

- ▶ Cum calculăm  $\int_a^b$  dintr-o distribuție normală?
  - ▶ Nu se poate prin formule algebrice, funcție ne-elementară
- ▶ Se folosește *the error function*:

$$\text{erf}(z) = \frac{2}{\sqrt{\pi}} \int_0^z e^{-t^2} dt$$



- ▶ Funcția de repartiție a unei distribuții normale  $\mathcal{N}(\mu, \sigma^2)$

$$F_A(x) = \frac{1}{2} \left( 1 + \text{erf} \left( \frac{x - \mu}{\sigma \sqrt{2}} \right) \right)$$

- ▶ Valorile funcției  $\text{erf}()$  sunt tabelate / se calculează numeric

- ▶ de ex. pe Google, căutați  $\text{erf}(0.5)$
- ▶ Alte valori folosite:
  - ▶  $\text{erf}(-\infty) = -1$
  - ▶  $\text{erf}(\infty) = 1$

$$P(A \in [3, 5]) = ? \quad \int_{\underline{3}}^{\underline{5}} w(x) dx$$



## Exercițiu

$$\mathcal{N}_{\mathbb{R}}(\mu = 3, \sigma^2 = 2)$$

$$P(A \in [2, 4]) = F(4) - F(2)$$

Exercițiu:

- Fie  $A$  o v.a. cu distribuția  $\mathcal{N}(3, 2)$ . Calculați probabilitatea ca  $A \in [2, 4]$

$$F(4) = \frac{1}{2} \left( 1 + \operatorname{erf} \left( \frac{4-3}{\sqrt{2} \cdot \sqrt{2}} \right) \right) = 0.76$$

$$F(2) = \dots \dots \dots \frac{2-3}{\sqrt{2} \cdot \sqrt{2}} = \dots \dots$$

## Suma unei constante cu o v.a.


- ▶ Fie o v.a.  $A$
- ▶ Ce reprezintă  $B = 5 + A$ ?

Răspuns:


- ▶  $B$  este tot o variabilă aleatoare
- ▶  $B$  are același tip de distribuție, dar "translată" cu 5 la dreapta

Exemplu:


- ▶  $A$  este o v.a. cu distribuție normală  $w_A(x) = \mathcal{N}(\mu = 3, \sigma^2 = 2)$
- ▶ Care este distribuția variabilei  $B = 5 + A$ ?
- ▶ Răspuns:  $w_B(x) = \mathcal{N}(\mu = 8, \sigma^2 = 2)$




$$A : \text{zur}$$
$$B = A + 5$$



## V.a. ca funcții de alte v.a


- ▶ O funcție aplicată unei v.a. produce o altă v.a.
- ▶ Exemple: dacă  $A$  este o v.a. distribuită  $\mathcal{U}[0, 10]$ , atunci
  - ▶  $B = 5 + A$  este o altă v.a., distribuită  $\mathcal{U}[5, 15]$
  - ▶  $C = A^2$  este de asemenea o v.a. 
  - ▶  $D = \cos(A)$  este de asemenea o v.a.
- ▶ Motivație: dacă  $A$  este aleatoare, și valorile  $B, C, D$  sunt aleatoare
- ▶  $A, B, C, D$  nu sunt independente
  - ▶ O anumită valoare a uneia implică automat și valoarea celorlalte

## Sisteme de mai multe variabile aleatoare




$(A, B)$

- ▶ Fie un sistem cu două v.a. continue  $A$  și  $B$
- ▶ Care este probabilitatea ca perechea  $(A, B)$  să aibă valoarea în jurul  $(x, y)$ ?
- ▶ Distribuția valorilor perechii  $(A, B)$  este descrisă de:
  - ▶ Densitatea de probabilitate comună  $w_{AB}(x, y)$
  - ▶ Funcția de repartiție comună  $F_{AB}(x, y)$



$$w_{AB}(x, y) = \begin{cases} 0, & \text{dacă } (x, y) \text{ nu aparține drept.} \\ c, & \text{dacă } (x, y) \in \text{intersecție.} \end{cases}$$

$w$



- ▶ Funcția de repartiție comună:

$$F_{AB}(x, y) = P_{AB} \{A \leq x \cap B \leq y\}$$

- ▶ Densitatea de probabilitate comună:

$$w_{AB}(x, y) = \frac{\partial^2 F_{AB}(x, y)}{\partial x \partial y}$$

- ▶ FDP comună descrie probabilitatea ca perechea  $(A, B)$  să aibă valoarea într-o vecinătate a  $(x, y)$
- ▶ Similar pentru v.a discrete:

$$w_{AB}(x, y) = P \{A = x \cap B = y\}$$

- ▶ Două v.a. A și B sunt **independente** dacă valoarea uneia nu influențează în nici un fel valoarea celeilalte
- ▶ Pentru v.a. independente, probabilitatea ca  $A$  să fie în jurul lui  $x$  și  $B$  în jurul lui  $y$  este produsul celor două probabilități

$$w_{AB}(x, y) = w_A(x) \cdot w_B(y)$$

- ▶ Valabilă pentru FR / FDP / FMP, v.a. continue sau aleatoare etc.
- ▶ Similar pentru mai mult de două v.a.

Exercițiu:

- ▶ Calculați probabilitatea ca trei v.a.  $X$ ,  $Y$  și  $Z$  i.i.d.  $\mathcal{N}(-1, 1)$  să fie toate pozitive
  - ▶ **i.i.d** = “independente și identic distribuite”

## Multiple v.a. normale

- ▶ Fie un set de  $N$  v.a. normale  $(A_1, \dots, A_N)$ , cu medii diferite  $\mu_i$  dar aceeași deviație standard  $\sigma$
- ▶ Probabilitatea ca  $(A_1, \dots, A_N)$  să fie în jurul valorii  $(x_1, \dots, x_N)$  este

$$w_{A_1, \dots, A_N}(x_1, \dots, x_N) = \frac{1}{(\sigma\sqrt{2\pi})^N} e^{-\frac{(x_1-\mu_1)^2 + \dots + (x_N-\mu_N)^2}{2\sigma^2}}$$

- ▶ Probabilitatea depinde de **distanța Euclideană** dintre  $\mathbf{x} = (x_1, \dots, x_N)$  și  $\boldsymbol{\mu} = (\mu_1, \dots, \mu_N)$

# Distanța Euclideană

REMINDEERI:

- Distanța Euclideană (geometrică) între 2 vectori N-dimensionalii

$$d(\mathbf{u}, \mathbf{v}) = \|\mathbf{u} - \mathbf{v}\| = \sqrt{(u_1 - v_1)^2 + \dots + (u_N - v_N)^2}$$

- Unidimensional:  $\|\mathbf{u} - \mathbf{v}\| = |u - v|$

$$\text{► 2D: } \|\mathbf{u} - \mathbf{v}\| = \sqrt{(u_1 - v_1)^2 + (u_2 - v_2)^2}$$

$$\text{► 3D: } \|\mathbf{u} - \mathbf{v}\| = \sqrt{(u_1 - v_1)^2 + (u_2 - v_2)^2 + (u_3 - v_3)^2}$$


- ...

$$\text{► N-dimensional: } \|\mathbf{u} - \mathbf{v}\| = \sqrt{\sum_{i=1}^N (u_i - v_i)^2}$$

- ...


$$\text{► Semnale continue: } \|\mathbf{u} - \mathbf{v}\| = \sqrt{\int_{-\infty}^{\infty} (u(t) - v(t))^2 dt}$$

Remindeer:



$$\mathbf{u} = [1, 2, 3, 0, 1]$$

$$\mathbf{v} = [0, 4, 2, 2, 1]$$



$$d(u, v) =$$



$$\sqrt{(1-0)^2 + (2-4)^2 + (3-2)^2 + (0-2)^2 + (1-1)^2}$$

$$d = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2 + (z_1 - z_2)^2}$$

- ▶ Probabilitatea a  $N$  v.a. normale, independente, cu același  $\sigma$  dar diferite  $\mu_i$  depinde de **pătratul distanței Euclidiene față de vectorul medie**  $\mu = (\mu_1, \dots, \mu_N)$ 
  - ▶ Aproape de  $\mu$ : probabilitate mai mare
  - ▶ Deprise de  $\mu$ : probabilitate redusă
  - ▶ Două puncte la aceeași distanță de  $\mu$  au aceeași probabilitate

# Distribuția normală 2D


- Distribuția a 2 v.a. normale (distribuția normală 2D)



## Distribuția normală 2D - vedere de sus

- ▶ Vedere de sus
- ▶ Aici,  $\mu = (0, 0)$
- ▶ Probabilitatea scade pe măsură ce crește distanța față de centru, în cercuri concentrice (simetric)

2D-Gaussian



•  $(x, y)$



# Medii statistice

- V.a. sunt caracterizate prin medii statistice ("momente")

## ① ► Valoarea medie (momentul de ordin 1)

- Pentru v.a. continue:

$$\bar{A} = E\{A\} = \int_{-\infty}^{\infty} x \cdot w_A(x) dx$$



- Pentru v.a. discrete:

$$\bar{A} = E\{A\} = \sum_{x=-\infty}^{\infty} x \cdot w_A(x)$$

$$1 \cdot \frac{1}{6} + 2 \cdot \frac{1}{6} + 3 \cdot \frac{1}{6} + 4 \cdot \frac{1}{6} + 5 \cdot \frac{1}{6} + 6 \cdot \frac{1}{6} = 3.5$$

- (Exemplu: entropia  $H(X)$  = valoarea medie a informației)

- Notație ușoară:  $\mu$




# Ce înseamnă valoarea medie

## ► Ce înseamnă, practic, valoarea medie a unei variabile aleatoare?

- Dacă avem  $N \rightarrow \infty$  valori aleatoare conform distribuției respective, valoarea medie = media tuturor acestor valori;
- Dacă trebuie să prezicem valoarea unei variabile aleatoare  $X$ , și plătim un cost proporțional cu pătratul erorii pe care o facem,  $(u - X)^2$ , valoarea medie  $\mu$  este cea mai bună alegere, întrucât minimizează costul global:



$$\mu = \arg \min_u \int_{-\infty}^{\infty} (u - x)^2 \cdot w(x) dx$$

- Demonstrație: la tablă: derivare, derivata = 0



# Ce înseamnă valoarea medie

- ▶ Valorile care au probabilitate ridicată “trag” valoarea medie înspre ele
- ▶ Pentru distribuții cu formă simetrică (de ex. distribuția normală),  
valoarea medie = valoarea centrală a funcției
  - ▶ Demonstrație: ambele laturi ale funcției “trag” valoare medie înspre ele  
în mod egal, valoarea medie rămâne la mijloc
- ▶ Pentru distribuția normală,  $\bar{X} = \mu$
- ▶ Pentru distribuția uniformă  $\mathcal{U}[a, b]$ ,  $\bar{X} = \frac{a+b}{2}$  (mijlocul intervalului)



# Proprietățile valorii medii

- ▶ Calculul valorii medii este o operație liniară
  - ▶ pentru că, la bază, integrala / suma este o operatie liniară

- ▶ Pentru două variabile aleatoare A și B (independente):

- ▶ Liniaritate

$$E\{c_1A + c_2B\} = c_1E\{A\} + c_2E\{B\}$$

- ▶ Sau:

$$E\{cA\} = cE\{A\}, \forall c \in \mathbb{R}$$

$$\boxed{E\{A + B\} = E\{A\} + E\{B\}}$$

- ▶ Fără demonstrație

Media unei sume = Suma mediilor fier. formen

$$\overline{A+B} = \overline{A} + \overline{B}$$

- ▶ Valoarea pătratică medie = valoarea medie a pătratelor valorilor

- ▶ Momentul de ordin 2

- ▶ Pentru v.a. continue:

*Defin:*

$$\overline{A^2} = E\{A^2\} = \int_{-\infty}^{\infty} x^2 \cdot w_A(x) dx$$

- ▶ Pentru v.a. discrete:

$$\overline{A^2} = E\{A^2\} = \sum_{-\infty}^{\infty} x^2 \cdot w_A(x)$$

$$\overline{ZAR^2} = 1 \cdot \frac{1}{6} + 4 \cdot \frac{1}{6} + 9 \cdot \frac{1}{6} + 16 \cdot \frac{1}{6} + 25 \cdot \frac{1}{6} + 36 \cdot \frac{1}{6}$$

- ▶ Interpretare: media pătratelor = energia medie a unui semnal

*x [m]*

= ...

# Varianța ③


- Varianța = valoarea pătratică medie a abaterii față de valoarea medie  
:)
- V.a. continue:

$$\sigma^2 = \overline{(A - \mu)^2} = \int_{-\infty}^{\infty} (x - \mu)^2 \cdot w_A(x) dx$$

- V.a. discrete:

$$\sigma^2 = \overline{(A - \mu)^2} = \sum_{-\infty}^{\infty} (x - \mu)^2 \cdot w_A(x)$$

- Interpretare: cât de mult variază valorile în jurul mediei
  - $\sigma^2 =$  mare: abateri mari față de medie
  - $\sigma^2 =$  mic: valori concentrate în jurul mediei



## Legătura între cele trei mărimi

$$\mu = \text{valoarea medie}$$

$$\bar{A}, \sqrt{\bar{A}^2}, \sigma^2$$

- Legătura între medie, valoarea pătratică medie și varianță:

$$\begin{aligned}\sigma^2 &= \overline{(A - \mu)^2} \\ &= \overline{A^2 - 2 \cdot A \cdot \mu + \mu^2} \\ &= \overline{A^2} - 2\mu\bar{A} + \mu^2 \\ &= \overline{A^2} - \mu^2\end{aligned}$$

$$\sigma^2 = \overline{A^2} - \mu^2 \quad (\mu = \bar{A})$$

$$\begin{aligned}\sigma^2 &= \overline{(A - \mu)^2} = \overline{(A^2 - 2\mu A + \mu^2)} = \overline{A^2} - \cancel{2\mu A} + \overline{\mu^2} = \overline{A^2} - 2\mu \cdot \cancel{\frac{A}{\mu}} + \mu^2 \\ &\boxed{\sigma^2 = \overline{A^2} - \mu^2}\end{aligned}$$

## Suma variabilelor aleatoare


- ▶ Suma a două sau mai multe v.a. **independente** este tot o v.a.
  - ▶ Distribuția ei = convoluția distribuțiilor v.a. componente
  - ▶ Dacă  $C = A + B$ , atunci:

$$w_C(x) \equiv w_A(x) * w_B(x)$$

- Caz particular: dacă A și B sunt v.a. normale, cu  $\mathcal{N}(\mu_A, \sigma_A^2)$  și  $\mathcal{N}(\mu_B, \sigma_B^2)$ , atunci:  $C = A + B$

$$C = A + B$$


- ▶  $C$  este tot o v.a. cu distribuție normală,  $\mathcal{N}(\mu_C, \sigma_C^2)$ , având:
  - ▶ media = suma mediilor:  $\mu_C = \mu_A + \mu_B$
  - ▶ varianța = suma varianțelor:  $\sigma_C^2 = \sigma_A^2 + \sigma_B^2$



## II.2 Procese aleatoare


# Procese aleatoare

- ▶ Un **proces aleator** = o secvență de variabile aleatoare indexate (înșiruite) în timp
- ▶ Proces aleator **în timp discret**  $f[n]$  = o secvență de v.a. la momente de timp discrete
  - ▶ ex: o secvență de 50 aruncări de zar, cotația zilnică a unor acțiuni la bursă
- ▶ Proces aleator **în timp continuu**  $f(t)$  = o secvență de v.a. la orice moment de timp
  - ▶ ex: un semnal tip zgomot de tensiune
- ▶ Fiecare eșantion dintr-un proces aleator este o v.a. de sine stătătoare
  - ▶ ex.:  $f(t_0)$  = valoarea la momentul  $t_0$  este o v.a.



$x(t)$   
 $x[n]$

- ▶ **Realizare a unui p.a.** = o secvență particulară de realizări ale v.a. componente
  - ▶ ex: un anume semnal de zgomot măsurat cu un osciloscop; am obținut o anume realizare, dar am fi putut obține orice altă realizare
- ▶ Notația uzuală:  $f^{(k)}[n]$  sau  $f^{(k)}(t)$ 
  - ▶  $k$  indică realizarea particulară care se consideră
  - ▶  $t$  sau  $n$  este timpul
- ▶ Când considerăm un p.a., considerăm întregul set de realizări posibile
  - ▶ la fel ca atunci când considerăm o v.a.



$$f^{(k)}(t)$$

## Proces aleator = un fenomen 2-D

- ▶ Un proces aleator trebuie vizualizat în două dimensiuni:


- ▶  $f^{(k)}[n]$  sau  $f^{(k)}(t)$  depind de două variabile:

- ▶  $k$  = realizarea

- ▶  $t$  sau  $n$  = timpul




## Proces aleator = un fenomen 2-D



- ▶ sursa: "Information-Based Inversion and Processing with Applications"  
Edited by Tadeusz J. Ulrych, Mauricio D. Sacchi, Volume 36,

## Proces aleator = un fenomen 2-D



- ▶ sursa: Razdolsky, L. (2014). Random Processes. In Probability-Based Structural Fire Load (pp. 89-136). Cambridge: Cambridge University Press



## Proces aleator = un fenomen 2-D



- ▶ sursa: <https://www.quora.com/What-is-the-difference-between-a-stationary-ergodic-and-a-stationary-non-ergodic-process>

- ▶ Procesele aleatoare au două tipuri de valori medii:
  - ▶ Valori medii **statistice** = calculate la un timp  $t$  sau  $n$  fixat, de-a lungul tuturor realizărilor posibile
  - ▶ Valori medii **temporale** = calculate pentru o realizare  $k$  fixată, de-a lungul timpului

## Două feluri de valori medii



- sursa: <https://www.quora.com/What-is-the-difference-between-a-stationary-ergodic-and-a-stationary-non-ergodic-process>

## Distribuții de ordin 1 ale proceselor aleatoare

- ▶ Fiecare eșantion  $f(t_1)$  dintr-un proces este o v.a.
  - ▶ descris de o **distribuție de ordin 1**
  - ▶ are FR  $F_1(x; t_1)$
  - ▶ are FDP / FMP  $w_1(x; t_1) = \frac{dF_1(x; t_1)}{dx}$
  - ▶ distribuția depinde de momentul  $t_1$
- ▶ Un eșantion la alt moment  $t_2$  este o v.a. diferită, cu funcții posibil diferite
  - ▶ altă FR  $F_1(x; t_2)$
  - ▶ altă FDP / FMP  $w_2(x; t_2) = \frac{dF_1(x; t_2)}{dx}$
- ▶ Aceste funcții descriu distribuția valorilor unui eșantion
- ▶ Indicele  $w_1$  arată că considerăm o singură v.a. din proces (distribuții de ordin 1-)
- ▶ Similar pentru p.a. discrete


## Distribuții de ordin 2

$$\begin{matrix} 4 & 6 \\ 6 & 6 \end{matrix}$$

- ▶ O pereche de v.a.  $f(t_1)$  și  $f(t_2)$  formează un sistem de 2 v.a.:

- ▶ sunt descrise de o distribuție de ordin 2
- ▶ au FR comună  $F_2(x_i, x_j; t_1, t_2)$
- ▶ au FDP / FMP comună  $w_2(x_i, x_j; t_1, t_2) = \frac{\partial^2 F_2(x_i, x_j; t_1, t_2)}{\partial x_i \partial x_j}$
- ▶ distribuția depinde de momentele  $t_1$  și  $t_2$
- ▶ Aceste funcții descriu cum sunt distribuite valorile perechilor (distribuții de ordin 2)
- ▶ Similar pentru p.a. discrete

$$(6, 6)$$



## Distribuții de ordin n

- ▶ Generalizare la un grup de  $n$  eșantioane dintr-un p.a.
- ▶ Un set de  $n$  v.a.  $f(t_1), \dots, f(t_n)$  dintr-un proces aleator  $f(t)$ :
  - ▶ sunt descrise de o distribuție de ordin n
  - ▶ au FR comună  $F_n(x_1, \dots, x_n; t_1, \dots, t_n)$
  - ▶ au FDP / FMP comună  $w_n(x_1, \dots, x_n; t_1, \dots, t_n) = \frac{\partial^2 F_n(x_1, \dots, x_n; t_1, \dots, t_n)}{\partial x_1 \dots \partial x_n}$
  - ▶ depind de momentele de timp  $t_1, t_2, \dots, t_n$
- ▶ Aceste funcții descriu cum sunt distribuite valorile seturilor de  $n$  eșantioane (distribuții de ordin n)
- ▶ Similar pentru p.a. discrete

$$\left( f(t_1), f(t_2), \dots, f(t_n) \right) = (6, 6, \dots, 6)$$

Procesele aleatoare sunt caracterizate de medii statistice și temporale

Pentru procese continue:

## 1. Valoarea medie

$$\overline{f(t_1)} = \mu(t_1) = \int_{-\infty}^{\infty} x \cdot w_1(x; t_1) dx$$

distri. valori lor lui  $f(t_1)$

## 2. Valoarea pătratică medie

$$\overline{f^2(t_1)} = \int_{-\infty}^{\infty} x^2 \cdot w_1(x; t_1) dx$$

### 3. Varianța

$$\sigma^2(t_1) = \overline{\{f(t_1) - \mu(t_1)\}^2} = \int_{-\infty}^{\infty} (x - \mu(t_1))^2 \cdot w_1(x; t_1) dx$$

- ▶ Legătura între aceste trei mărimi:

$$\begin{aligned}\sigma^2(t_1) &= \overline{\{f(t_1) - \mu(t_1)\}^2} \\ &= \overline{f(t_1)^2} - 2\overline{f(t_1)\mu(t_1)} + \overline{\mu(t_1)^2} \\ &= \overline{f^2(t_1)} - \mu(t_1)^2\end{aligned}$$

- ▶ Observații:

- ▶ aceste trei valori sunt calculate pentru toate realizările, la momentul  $t_1$
- ▶ ele caracterizează doar eșantionul de la momentul  $t_1$
- ▶ la alt moment de timp  $t_2$ , v.a.  $f(t_2)$  este diferită, și valorile medii pot dифeri

## Medii statistice - autocorelația

Medii statistice care caracterizează **o pereche** de eșantioane:

4. **Functia de autocorelatie** = media produsului  $f(t_1) \cdot f(t_2)$

$$R_{ff}(t_1, t_2) = \overline{f(t_1)f(t_2)} = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x_1 x_2 w_2(x_1, x_2; t_1, t_2) dx_1 dx_2$$

5. **Functia de corelatie** (pentru două procese aleatoare diferite  $f(t)$  și  $g(t)$ ) = media produsului  $f(t_1) \cdot g(t_2)$

$$R_{fg}(t_1, t_2) = \overline{f(t_1)g(t_2)} = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x_1 y_2 w_2(x_1, y_2; t_1, t_2) dx_1 dy_2$$

► Observații:

- aceste funcții pot fi diferențiate pentru perechi de valori luate la momente diferențiate  $(t_1, t_2)$

# Procese aleatoare discrete

Pentru **procese aleatoare discrete**, se înlocuiește  $\int$  cu  $\sum$ , și notația  $f(t)$  cu  $f[t]$ :

$$\int \xrightarrow{\text{sumă}} \sum_{x=-\infty}^{\infty}$$

$$1. \overline{f[t_1]} = \mu(t_1) = \sum_{x=-\infty}^{\infty} x \cdot w_1(x; t_1)$$

$$2. \overline{f^2[t_1]} = \sum_{x=-\infty}^{\infty} x^2 \cdot w_1(x; t_1)$$

$$3. \sigma^2(t_1) = \overline{(f[t_1] - \mu(t_1))^2} = \sum_{x=-\infty}^{\infty} (x - \mu(t_1))^2 \cdot w_1(x; t_1)$$

$$4. R_{ff}(t_1, t_2) = \overline{f[t_1]f[t_2]} = \sum_{x_1=-\infty}^{\infty} \sum_{x_2=-\infty}^{\infty} x_1 x_2 w_2(x_1, x_2; t_1, t_2)$$

$$5. R_{fg}(t_1, t_2) = \overline{f[t_1]g[t_2]} = \sum_{x_1=-\infty}^{\infty} \sum_{x_2=-\infty}^{\infty} x_1 y_2 w_2(x_1, y_2; t_1, t_2)$$



- $x_1$   $x_2$

- ▶ Dacă avem acces doar la o singură realizare  $f^{(k)}(t)$  a procesului?
- ▶ Calculăm valorile medii **pentru o singură realizare  $f^{(k)}(t)$ , de-a lungul timpului**

# Medii temporale

$\checkmark \pm 0,1$

$$\frac{g_{3,4} + g_{2,3} + g_{3,6}}{3}$$

Medii temporale pentru procese aleatoare continue:


## 1. Valoarea medie temporală

$$\overline{f^{(k)}(t)} = \mu^{(k)} = \lim_{T \rightarrow \infty} \frac{1}{T} \int_{-T/2}^{T/2} f^{(k)}(t) dt$$

realizările  $k$

## 2. Valoarea medie pătratică temporală

$$\overline{[f^{(k)}(t)]^2} = \lim_{T \rightarrow \infty} \frac{1}{T} \int_{-T/2}^{T/2} [f^{(k)}(t)]^2 dt$$



### 3. Varianța temporală

$$\sigma^2 = \overline{\{f^{(k)}(t) - \mu^{(k)}\}^2} = \lim_{T \rightarrow \infty} \frac{1}{T} \int_{-T/2}^{T/2} (f^{(k)}(t) - \underbrace{\mu^{(k)}}_{\text{constant}})^2 dt$$

- Relația dintre cele trei mărimi:

$$\boxed{\sigma^2 = \overline{[f^{(k)}(t)]^2} - [\mu^{(k)}]^2}$$


- Observație:

- aceste valori nu mai depind de timpul  $t$

# Autocorelația temporală

4. **Functia de autocorelatie temporală** = media produsului  $f(t_1) \cdot f(t_2)$

$$\begin{aligned} R_{ff}(t_1, t_2) &= \overline{f^{(k)}(t_1 + t)f^{(k)}(t_2 + t)} \\ &= \lim_{T \rightarrow \infty} \frac{1}{T} \int_{-T/2}^{T/2} f^{(k)}(t_1 + t)f^{(k)}(t_2 + t)dt \end{aligned}$$



5. **Functia de corelatie temporală** (pentru două procese diferite  $f(t)$  și  $g(t)$ )

$$\begin{aligned} R_{fg}(t_1, t_2) &= \overline{f^{(k)}(t_1 + t)g^{(k)}(t_2 + t)} \\ &= \lim_{T \rightarrow \infty} \frac{1}{T} \int_{-T/2}^{T/2} f^{(k)}(t_1 + t)g^{(k)}(t_2 + t)dt \end{aligned}$$

Pentru **procese aleatoare discrete**, se înlocuiește  $\int$  cu  $\sum$ ,  $T$  cu  $N$ , și se împarte la  $2N + 1$  în loc de  $\cancel{2T}$

$$1. \overline{f^{(k)}[t]} = \mu^{(k)} = \lim_{N \rightarrow \infty} \frac{1}{2N+1} \sum_{t=-N}^N f^{(k)}[t]$$

$$2. \overline{[f^{(k)}[t]]^2} = \lim_{N \rightarrow \infty} \frac{1}{2N+1} \sum_{t=-N}^N (f^{(k)}[t])^2$$

$$3. \sigma^2 = \overline{\{f^{(k)}[t] - \mu^{[k]}\}^2} = \lim_{N \rightarrow \infty} \frac{1}{2N+1} \sum_{t=-N}^N (f^{(k)}[t] - \mu^{(k)})^2$$

## 4. Autocorelația temporală:

$$\begin{aligned} R_{ff}(t_1, t_2) &= \overline{f^{(k)}[t_1 + t] f^{(k)}[t_2 + t]} \\ &= \lim_{N \rightarrow \infty} \frac{1}{2N+1} \sum_{t=-N}^N f^{(k)}[t_1 + t] f^{(k)}[t_2 + t] \end{aligned}$$

## 5. Corelația temporală:

$$\begin{aligned} R_{fg}(t_1, t_2) &= \overline{f^{(k)}[t_1 + t] g^{(k)}[t_2 + t]} \\ &= \lim_{N \rightarrow \infty} \frac{1}{2N+1} \sum_{t=-N}^N f^{(k)}[t_1 + t] g^{(k)}[t_2 + t] \end{aligned}$$

- ▶ E posibil să avem o realizare de **lungime finită** (de ex. un vector cu 1000 de eşantioane dintr-o realizare a unui p.a.)
- ▶ Cum calculăm mediile temporale?
- ▶ Se fac sumele/integralele de la  $\int_{t_{min}}^{t_{max}}$  sau  $\sum_{t_{min}}^{t_{max}}$  în loc de la  $-\infty$  la  $\infty$
- ▶ Exemplu: calculați mediile temporale pentru realizarea de lungime finită

$$\{1, -1, 2, -2, 3, -3, 4, -4, 5, -5\}$$

$$\mu = \frac{1 - 1 + 2 - 2 + 3 - 3 + 4 - 4 + 5 - 5}{10} = 0$$



$$\overline{x^2} = \frac{1+1+4+9+9+9+16+16+25+25}{10} =$$

- ▶ Mediile statistice sunt, de obicei, cele de dorit
  - ▶ dar necesită cunoașterea distribuțiilor w(x), care în practică sunt rareori cunoscute
- ▶ În practică, de obicei avem acces doar la o singură realizare, obținută printr-o măsurătoare
  - ▶ deci putem calcula doar mediile temporale pe acea realizare
- ▶ Din fericire, în multe cazuri mediile statistice și temporale sunt identice ("ergodicitate")

## Procese aleatoare staționare

- ▶ Până acum, am considerat că mediile statistice depind de timp
  - ▶ pot fi diferite pentru un eșantion de la  $t_1$  și de la  $t_2$
- ▶ Proces aleator **stationar** = dacă mediile statistice rămân aceleasi la modificarea originii timpului (întârzierea semnalului)
- ▶ Altfel spus: distribuțiile (FDP/FMP) eșantioanelor rămân identice la modificarea originii timpului

$$w_n(x_1, \dots, x_n; t_1, \dots, t_n) = w_n(x_1, \dots, x_n; t_1 + \tau, \dots, t_n + \tau)$$



- ▶ Practic, pentru a fi staționar trebuie ca **toate mediile statistice să nu mai depindă de timp  $t$**

► Proces aleator **staționar în sens strict**:



- ▶ relația e valabilă pentru distribuțiile de orice ordin  $n$
- ▶ valoarea medie, valoarea pătratică medie, varianța, autocorelația și toate celelalte statistici de ordin superior nu depind de originea timpului  $t$

► Proces aleator **staționar în sens larg**:

- ▶ relația e valabilă doar pentru distribuțiile de ordin  $n = 1$  și  $n = 2$  (distribuțiile unui singur eşantion, sau a două eşantioane)
- ▶ **doar** valoarea medie, valoarea pătratică medie, varianța și autocorelația nu depind de originea timpului  $t$ , dar statisticile de ordin superior pot depinde

# Procese aleatoare staționare

- ▶ Este procesul aleator schițat mai jos staționar sau nu?



- ▶ sursa: SEX, LIES & STATISTICS, Ned Wright,  
<http://www.astro.ucla.edu/~wright/statistics/>

- ▶ Răspuns: ne-staționar
- ▶ Se observă că varianța nu este aceeași la toate momentele de timp

## Consecințe ale stationarității

- ▶ Pentru distribuții ale unui singur eșantion (de ordin  $n = 1$ ):


$$w_1(x_i; t_1) = w_1(x_i; t_2) = w_1(x_i)$$

- ▶ Valoarea medie, valoarea medie pătratică, varianta unui eșantion sunt **identice la orice moment de timp  $t$**

$$\overline{f(t)} = \text{constant}, \forall t$$

$$\overline{f^2(t)} = \text{constant}, \forall t$$

$$\sigma^2(t) = \text{constant}, \forall t$$



## Consecințe ale stationarității

- ▶ Pentru distribuții ale unor perechi de eșantioane (de ordin  $n = 2$ ):

$$w_2(x_i, x_j; t_1, t_2) = w_2(x_i, x_j; 0, t_2 - t_1) = w_2(x_i, x_2; t_2 - t_1)$$

z s

- ▶ Funcția de autocorelație depinde doar de diferența de timp  
 $\tau = t_2 - t_1$  dintre eșantioane

$$R_{ff}(t_1, t_2) = R_{ff}(0, t_2 - t_1) = \boxed{R_{ff}(\tau) = \overline{f(t)f(t + \tau)}}$$

0 3

9 12

— 3

- ▶ Depinde doar de valoarea  $\tau = t_2 - t_1$  = diferența de timp dintre cele două eșantioane

## Consecințe ale staționarității

Definiția funcției de autocorelație pentru p.a. **staționare**:

- ▶ Autocorelația statistică: formula rămâne aceeași

- ▶ Autocorelația temporală:

- ▶ pentru p.a. continue

$$R_{ff}(\tau) = \overline{f(t)f(t+\tau)} = \lim_{T \rightarrow \infty} \frac{1}{T} \int_{-T/2}^{T/2} f^{(k)}(t)f^{(k)}(t+\underline{\tau}) dt$$

- ▶ pentru p.a. discrete

$$R_{ff}(\tau) = \overline{f(t)f(t+\tau)} = \lim_{N \rightarrow \infty} \frac{1}{2N+1} \sum_{t=-N}^N f^{(k)}[t]f^{(k)}[t+\tau]$$

- ▶ lungime finită: se limitează integralele / sumele la intervalul avut la dispoziție,  $\int_{t_{min}}^{t_{max}}$  sau  $\sum_{t_{min}}^{t_{max}}$

- ▶ Pentru funcția de **corelație**, definiția este similară cu cea de la autocorelație de mai sus
- ▶ Corelația depinde doar de **diferența de timp**  $\tau = t_2 - t_1$  dintre cele două eșantioane


$$R_{fg}(t_1, t_2) = R_{fg}(0, t_2 - t_1) = R_{fg}(\tau) = \overline{f(t)g(t + \tau)}$$

## Interpretarea autocorelației

$$R_{ff}(\tau) = \overline{f(t) \cdot f(t + \tau)}$$

- $R_{ff}(\tau) = \overline{f(t)f(t + \tau)}$  = media produsului a două eșantioane situate la distanță de  $\tau$


- ne spune dacă eșantioanele variază la fel sau nu
- Idem pentru corelație, doar că eșantioanele provin din p.a. diferite,  $f$  și  $g$



# Interpretarea autocorelației

## ► Exemple:

- ▶  $R_{ff}(0.5) > 0$ : două eșantioane decalate cu 0.5 secunde tind să varieze în aceeași direcție (ambele pozitive, ambele negative => produsele sunt majoritar pozitive)
  - ▶ dacă se cunoaște una dintre ele, se poate "ghici" ceva despre celălaltă
- ▶  $R_{ff}(1) < 0$ : două eșantioane decalate cu 1 secundă tind să varieze în direcții opuse (când unul este pozitiv, celălalt este negativ => produsele sunt majoritar negative)
  - ▶ dacă se cunoaște una dintre ele, se poate "ghici" ceva despre celălaltă
- ▶  $R_{ff}(2) = 0$ : două eșantioane decalate cu 2 secunde sunt necorelate (produsele sunt în medie 0, deci cele două eșantioane au la fel de multe șanse de a fi de același semn sau cu semne contrare)
  - ▶ dacă se cunoaște una dintre ele, nu se mai poate "ghici" ceva despre celălaltă






- ▶ În practică, avem acces la o singură realizare
- ▶ Proces aleator ergodic = dacă mediile temporale pe orice realizare sunt identice cu mediile statistice (foarte lungă).
- ▶ Ergodicitatea înseamnă:
  - ▶ Se pot calcula toate mediile pe baza unei singure realizări (oricare)
    - ▶ dar realizarea respectivă trebuie să fie foarte lungă (lungimea  $\rightarrow \infty$ ) pentru valori precise
  - ▶ Toate realizările sunt similare unele cu altele, dpdv statistic
    - ▶ o realizare este caracteristică pentru întreg procesul aleator

- ▶ Majoritatea proceselor aleatoare de interes sunt ergodice și stationare
  - ▶ de ex. zgomote de tensiune
- ▶ Exemplu de proces aleator ne-ergodic:
  - ▶ se aruncă un zar, următoarele 50 valori sunt identice cu prima valoare
    - ▶ o singură realizare nu e caracteristică pentru tot procesul

## Procese aleatoare ergodice

```
int getRandomNumber()
{
    return 4; // chosen by fair dice roll.
              // guaranteed to be random.
}
```

- ▶ XKCD 221 (link aici: <https://xkcd.com/221/>)
  - ▶ Se consideră toate numerele care s-ar fi putut obține în loc de 4 (1,2,3,5 sau 6)
  - ▶ Care e problema aici?
    - ▶ proces aleator stationar sau ne-stationar?
    - ▶ proces aleator ergodic sau ne-ergodic?



2 1  
2 2  
4 4  
5 3


### I.3 Proprietăți ale autocorelației

# Densitatea spectrală de putere

- ▶ **Densitatea spectrală de putere (DSP)**  $S_{ff}(\omega)$  reprezintă puterea unui semnal în funcție de frecvență ( $f$  sau  $\omega = 2\pi f$ )
- ▶ Pentru un semnal **determinist** (ne-aleator), este dată de modului transf. Fourier la pătrat:

$$S_{ff}(\omega) = |F(\omega)|^2$$

- ▶ Puterea în banda de frecvență  $[f_1, f_2]$  este  $\int_{f_1}^{f_2} S_{ff}(\omega) d\omega$
- ▶ Puterea totală a procesului aleator este  $P = \int_{-\infty}^{\infty} S_{ff}(\omega) d\omega$
- ▶ DSP este o funcție măsurabilă practic:
  - ▶ poate fi determinată experimental
  - ▶ este importantă în aplicații practice (ingineresci)



# Densitatea spectrală de putere



- ▶ Ce reprezintă DSP pentru un proces aleator?
  - ▶ nu mai avem un singur semnal, cu o infinitate de realizări posibile
  - ▶ fiecare realizare are o transformată Fourier proprie, diferită
  - ▶ DSP fiind diferită pentru fiecare realizare în parte, este, ea însăși, un proces aleator
- ▶ **DSP a unui proces aleator** = media DSP pentru toate realizările posibile
- ▶ Are aceeași utilitate și semnificație ca în cazul unui semnal determinist, doar că **în medie** în raport cu toate realizările posibile
  - ▶ pentru o realizare particulară, DSP poate varia în jurul DSP medii

# Teorema Wiener-Hincin

## Teorema Wiener-Hincin:

- Densitatea spectrală de putere = transformata Fourier a funcției de autocorelație

$$S_{ff}(\omega) = \int_{-\infty}^{\infty} R_{ff}(\tau) e^{-j\omega\tau} d\tau \quad \leftarrow \text{Transf. Fourier}$$

*D.S.P.*      *f. de autocorelație*

$$R_{ff}(\tau) = \frac{1}{2\pi} \int_{-\infty}^{\infty} S_{ff}(\omega) e^{j\omega\tau} d\omega \quad \leftarrow \text{Transf. Fourier} \text{ inversor}$$

- Fără demonstrație
- Leagă două concepte de natură diferită
  - Funcția de autocorelație: o proprietate statistică
  - DSP: o proprietate fizică (ține de energia semnalului; importantă în aplicații practice)


## Zgomot alb

- Zgomot alb = un proces aleator cu funcția de autocorelație egală cu un Dirac

$$\underline{R_{ff}(\tau) = \delta(\tau)}$$

- este proces aleator: orice eșantion este o variabilă aleatoare
- autocorelația este un Dirac: este 0 pentru orice  $\tau \neq 0$
- oricare două eșantioane diferite ( $\tau \neq 0$ ) au corelație zero (necorelate)
  - valorile a două eșantioane distincte nu au legătură între ele

$$R_{ff}(\tau) = 0 \quad \text{pt orice } \tau \neq 0$$



# Zgomot alb


$$\delta(t) \longleftrightarrow 1$$

$$DSP = \mathcal{F}\{\delta(t)\} = P$$

- ▶ Densitatea spectrală de putere = transf. Fourier a unui Dirac = constantă  $\forall \omega$

$$S_{ff}(\omega) = \underline{\text{constant}}, \forall \omega$$


- ▶ putere constantă pentru toate frecvențele, până la  $f = \infty$
- ▶ Zgomotul alb poate avea orice distribuție (normală, uniformă etc.)
  - ▶ termenul "zgomot alb" nu se referă la distribuția eșantioanelor, ci la faptul că valorile eșantioanele sunt necorelate



## Zgomot alb de bandă limitată


- ▶ În lumea reală, pentru orice semnal puterea scade la 0 la frecvențe foarte înalte

- ▶ pentru că puterea totală  $P = \int_{-\infty}^{\infty} S_f(\omega)$  nu poate fi infinită
- ▶ se numește zgomot alb de bandă limitată



- ▶ În acest caz, autocorelația = **aproximativ** un Dirac, dar nu chiar infinit de "subtire"

- ▶ eșantioane foarte apropiate sunt totuși corelate
- ▶ de ex. din cauza unor mici capacități parazite




► **AWGN** = Additive White Gaussian Noise

- ▶ Zgomot alb, Gaussian, aditiv
- ▶ tipul/modelul de zgomot cel mai frecvent întâlnit în aplicații

► Înseamnă:

- ▶ **zgomot**: este un proces aleator (fiecare eșantion este aleator, fiecare realizare este diferită)
- ▶ **gaussian**: eșantioanele au distribuția normală
- ▶ **alb**: valorile eșantioanelor sunt necorelate între ele
- ▶ **aditiv**: zgomotul se adună peste semnalul original (adică de ex. nu se multiplică cu acesta)



$$\text{S}(t) + \text{zgomot} =$$

$$\sim + \text{noize}$$

- ▶ Până aici s-a făcut în 2020-2021. Celealte slide-uri din acest fișier nu se cer.

2021 - 2022

## Proprietățile funcției de autocorelație

1. Este o funcție pară

$$R_{ff}(\tau) = R_{ff}(-\tau)$$

- ▶ Demonstrație: Schimbare de variabilă în definiție

2. La infinit, tinde la o valoare constantă

$$R_{ff}(\infty) = \overline{f(t)}^2 = const$$

- ▶ Dem.: două eșantioane la un interval  $\infty$  sunt necesar independente

3. Are valoarea maximă în 0

$$R_{ff}(0) \geq R_{ff}(\tau)$$

- ▶ Dem.: se pornește de la  $(\overline{f(t) - f(t + \tau)})^2 \geq 0$
- ▶ Interpretare: eșantioane diferite mai pot varia diferit, dar un eșantion variază întotdeauna identic cu sine însuși

4. Valoarea în 0 = puterea procesului aleator

$$R_{ff}(0) = \frac{1}{2\pi} \int_{-\infty}^{\infty} S_{ff}(\omega) d\omega$$

- ▶ Dem.: Se pune  $\tau = 0$  în transf. Fourier inversă din teorema Wiener-Hincin

5. Varianța = diferența între valoarea din 0 și cea de la  $\infty$

$$\sigma^2 = R_{ff}(0) - R_{ff}(\infty)$$

- ▶ Dem.:  $R_{ff}(0) = \overline{f(t)^2}$ ,  $R_{ff}(\infty) = \overline{f(t)}^2$

- ▶ Fie un proces aleator aplicat la intrarea unui sistem
  - ▶ fie în timp continuu: intrarea  $x(t)$ , sistemul  $H(s)$ , ieșirea  $y(t)$
  - ▶ fie în timp discret: intrarea  $x[n]$ , sistemul  $H(z)$ , ieșirea  $y[n]$
- ▶ Cum depinde autocorelația ieșirii  $y$  de cea a intrării  $x$ ?
- ▶ Se știe că  $y$  este conoluția lui  $x$  cu răspunsul la impuls  $h$

- ▶ Pentru un proces aleator în timp discret

$$\begin{aligned} R_{yy}(\tau) &= \overline{y[n]y[n + \tau]} \\ &= \overline{\sum_{k_1=-\infty}^{\infty} h[k_1]x[n - k_1] \sum_{k_2=-\infty}^{\infty} h[k_2]x[n + \tau - k_2]} \\ &= \sum_{k_1=-\infty}^{\infty} \sum_{k_2=-\infty}^{\infty} h[k_1]h[k_2] \overline{x[n - k_1]x[n + \tau - k_2]} \\ &= \sum_{k_1=-\infty}^{\infty} \sum_{k_2=-\infty}^{\infty} h[k_1]h[k_2]R_{xx}[\tau - k_1 + k_2] \end{aligned}$$

- ▶ Din teorema Wiener-Hincin se știe că:

$$S_{ff}(\omega) = \sum_{\tau=-\infty}^{\infty} R_{ff}(\tau) e^{-j\omega\tau}$$

► Așadar

$$S_{yy}(\omega) = \sum_{\tau=-\infty}^{\infty} \sum_{k_1=-\infty}^{\infty} \sum_{k_2=-\infty}^{\infty} h[k_1]h[k_2]R_{xx}[\tau - k_1 + k_2]e^{-j\omega\tau}$$

► Schimbare de variabilă  $\tau - k_1 + k_2 = u$

► rezultă  $\tau = u + k_1 - k_2$


$$\begin{aligned} S_{yy}(\omega) &= \sum_{u=-\infty}^{\infty} \sum_{k_1=-\infty}^{\infty} \sum_{k_2=-\infty}^{\infty} h[k_1]h[k_2]R_{xx}[u]e^{-j\omega(u+k_1+k_2)} \\ &= \sum_{u=-\infty}^{\infty} R_{xx}[u]e^{-j\omega u} \sum_{k_1=-\infty}^{\infty} h[k_1]e^{-j\omega k_1} \sum_{k_2=-\infty}^{\infty} h[k_2]e^{j\omega k_2} \\ &= S_{xx}(\omega) \cdot H(\omega) \cdot H^*(\omega) \\ &= S_{xx}(\omega) \cdot |H(\omega)|^2 \end{aligned}$$

$$S_{yy}(\omega) = S_{xx}(\omega) \cdot |H(\omega)|^2$$

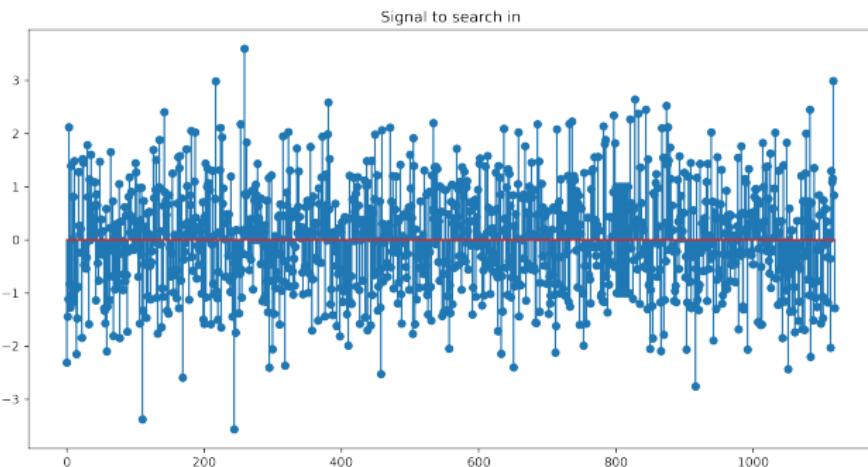
- ▶ DSP a lui  $y = \text{DSP a lui } x$  multiplicată cu răspunsul în amplitudine, la pătrat, al filtrului
- ▶ Relația este valabilă și pentru procese aleatoare continue

- ▶ Căutarea unei anume porțiuni într-un semnal mai mare
- ▶ Corelația a două semnale = o măsura a **similarității** celor două semnale
  - ▶ Funcția de corelație măsoară similaritatea unui semnal cu toate versiunile decalate ale celuilalt
  - ▶ Exemplu numeric la tablă, semnale de lungime finită
- ▶ Corelația poate fi utilizată pentru localizare
  - ▶ Funcția de (auto)corelație are valori mari atunci când cele două semnale se potrivesc
  - ▶ Valori mari sunt atunci când valorile pozitive / negative ale semnalelor se potrivesc
  - ▶ Valori mici atunci când nu se potrivesc


# Semnalul căutat



# Semnalul de dimensiuni mari



# Rezultatul corelației



- ▶ Determinarea răspunsului la impuls al unui sistem necunoscut, liniar și invariant în timp
- ▶ Se bazează pe corelația intrării cu ieșirea sistemului




Figure 1: System identification setup

$$\begin{aligned} R_{fg}(\tau) &= \overline{f[n]g[n + \tau]} \\ &= f[n] \sum_{k=-\infty}^{\infty} h[k]f[n + \tau - k] \\ &= \sum_{k=-\infty}^{\infty} h[k]\overline{f[n]f[n + \tau - k]} \\ &= \sum_{k=-\infty}^{\infty} h[k]R_{ff}[\tau - k] \\ &= h[\tau] * R_{ff}[\tau] \end{aligned}$$

- Dacă intrarea  $f$  este **zgomot alb** cu puterea  $A$ ,  $R_{ff}[n] = A \cdot \delta[n]$ , și

$$R_{fg}(\tau) = h[\tau] * R_{ff}[\tau] = A \cdot h[\tau] * \delta[\tau] = A \cdot h[\tau]$$

- Corelația măsurată este proporțională cu răspunsul la impuls al sistemului necunoscut