

Decizie și Estimare în Prelucrarea Informației



## Capitolul I. Semnale aleatoare

## I.1 Variabile aleatoare

Fie  $X = .$  zar

- **Variabilă aleatoare** = o variabilă care denumește o valoare produsă printr-un fenomen aleator

- Practic, reprezintă *un nume* atașat unei valori arbitrarے
- Prescurtat: v.a.

- Notație uzuală:  $X, Y$  etc..
- Exemple:

- $X$  = Numărul obținut prin aruncarea unui zar
- $V_{in}$  = Voltajul măsurat într-un punct dintr-un circuit

$X =$

5.0012 ✓  
4.9988 ✓  
4.999995 ✓

## Realizări ale unei variabile aleatoare

$$X = 4$$

$$\textcircled{X} = \textcircled{3}$$


- ▶ **Realizare** a unei v.a. = o valoare particulară posibilă
- ▶ **Spațiul realizărilor**  $\Omega$  = mulțimea valorilor posibile ale unei v.a
  - ▶ mulțimea tuturor realizărilor
- ▶ Exemplu: aruncarea unui zar
  - ▶ V.a. se notează  $X$
  - ▶ Se poate obține o realizare  $X = 3$
  - ▶ Dar s-ar fi putut obține orice valoare din spațiul realizărilor

$$\Omega = \{1, 2, 3, 4, 5, 6\}$$

$$\Omega = (4.9V, 5.1V)$$

## Aruncarea unei monede

- ▶ Variabila aleatoare  $X$  = "față obținută la aruncarea unei monede"



(sursa imaginii: <https://www.mathsisfun.com/data/random-variables.html>)

## V.a. discrete și continue

- ▶ **V.a. discretă:** dacă  $\Omega$  este o mulțime discretă
  - ▶ Exemplu: Numărul obținut prin aruncarea unui zar
- ▶ **V.a. continuă:** dacă  $\Omega$  este o mulțime compactă
  - ▶ Exemplu: Valoarea tensiunii măsurate într-un punct

$$Y = (4.9, 5.1)$$


## Unde se întâlnesc variabile aleatoare?

- ▶ Variabilele aleatoare modelează semnale de **zgomot**
- ▶ Exemple:
  - ▶ Se măsoară tensiunea într-un punct dintr-un circuit
  - ▶ Dacă se măsoară de mai multe ori, se obțin valori *ușor diferite*.
  - ▶ Valoarea este afectată de zgomot
  - ▶ Valoarea tensiunii este o *variabilă aleatoare*

## Funcția masă de probabilitate

- ▶ Fie o v.a. discretă  $A$
- ▶ **Functia masă de probabilitate** (FMP) (*probability mass function*)  
= probabilitatea ca  $A$  să aibă valoarea egală cu  $x$

$$w_A(x) = P\{A = x\}$$



- ▶ pe scurt, se mai numește **distribuția** variabilei  $A$
- ▶ Exemplu: FMP pentru valoarea unui zar, grafic pe tablă

## Calculul probabilității cu FMP

•

- ▶ Probabilitatea ca  $A$  să aibă valoarea  $v$

$$P\{A = v\} = w_A(v)$$

- ▶ Probabilitatea ca  $A$  să fie între valorile  $a$  și  $b$  (inclusiv):

$$P\{a \leq A \leq b\} = \sum_{x=a}^b w_A(x)$$


$$\begin{aligned} P(2 \leq A \leq 4) &= \frac{1}{2} = \frac{1}{6} + \frac{1}{6} + \frac{1}{6} \\ &= \sum_{x=a}^b w_A(x) \end{aligned}$$

6


## Functia de repartitie

- ▶ **Functia de repartitie (FR)** = probabilitatea ca  $A$  să aibă valoarea mai mică sau egală cu  $x$

$$F_A(x) = P\{A \leq x\}$$



- ▶ Exemplu: FR pentru un zar, grafic la tablă
- ▶ Pentru v.a. discrete, FR este "în trepte"



## Calculul probabilității cu FR

- ▶ Probabilitatea ca  $A$  să aibă valoarea  $v$

$$P\{A = v\} = F_A(v) - F_A(v - 1)$$

- ▶ Probabilitatea ca  $A$  să fie între valorile  $a$  și  $b$  (inclusiv):

$$\underline{P\{a \leq A \leq b\} = F_A(b) - F_A(a - 1)}$$

$$\begin{aligned}\mathcal{P}(2 \leq A \leq 4) &= F(4) - F(1) \\ P(A \leq 4) - P(A \leq 1) &= F(5) - F(4)\end{aligned}$$


- FR este *suma cumulativă* (un fel de "integrală discretă") a FMP

$$F_A(x) = \sum_{t=-\infty}^{t=x} w_A(t)$$


- Exemplu pentru zar: grafic, la tablă

## Funcția densitate de probabilitate

- ▶ Fie o v.a. continuă A
- ▶ Funcția densitate de probabilitate (FDP) = probabilitatea ca valoarea lui A să fie într-o vecinătate  $\epsilon$  mică în jurul lui x, totul supra  $\epsilon$
- ▶ Se notează  $w_A(x)$ , se mai numește **distribuția** variabilei A
- ▶ Informal: FDP reprezintă probabilitatea ca valoarea lui A să fie **în jurul lui** x



# Variabile aleatoare discrete și continue



(sursa imaginii: "Probability Distributions: Discrete and Continuous", Seema Singh, <https://towardsdatascience.com/probability-distributions-discrete-and-continuous-7a94ede66dc0>)

- ▶ Probabilitatea ca o v.a. continuă  $A$  să ia **exact** o valoare  $x$  este zero
  - ▶ pentru că există o infinitate de valori posibile (v.a. continuă)
  - ▶ de aceea nu se poate defini o funcție masă de probabilitate ca la v.a. discrete
- ▶ De aceea FDP reprezintă probabilitatea de a fi **într-o vecinătate** a valorii  $x$ , și nu exact egal cu  $x$

## Calculul probabilității cu FDP

- ▶ Probabilitatea ca  $A$  să aibă exact valoarea  $v$  este întotdeauna 0

$$\underline{P\{A = v\} = 0}$$

- ▶ Probabilitatea ca  $A$  să fie între valorile  $a$  și  $b$  = integrala FDP între  $a$  și  $b$ :

$$\underline{P\{a \leq A \leq b\} = \int_a^b w_A(x)dx}$$



Discret  $\leftrightarrow$  Continuu.  
 $\sum_a^b$   $\leftrightarrow$   $\int_a^b$

- ▶ **Functia de repartitie (FR)** = probabilitatea ca  $A$  să aibă valoarea mai mică sau egală cu  $x$

$$F_A(x) = P\{A \leq x\}$$

- ▶ Aceeași definiție ca și la v.a. discrete

## Calculul probabilității cu FR

- ▶ Probabilitatea ca valoarea lui A să fie între a și b:

$$P\{a \leq A \leq b\} = F_A(b) - F_A(a)$$

$P(A \leq b) - P(A \leq a)$

- ▶ Nu contează dacă intervalul este deschis sau închis

- ▶  $[a, b]$  sau  $(a, b)$ , nu contează
- ▶ de ce?

$$\begin{aligned} P(2 \leq A \leq 4) &= \\ &= F(4) - F(2) \\ &= P(A \leq 4) - P(A \leq 2) \end{aligned}$$

## Relația între FDP și FR

- FR este **integrala** FDP
- FDP este **derivata** FR


$$\underline{F_A(x)} = \int_{-\infty}^x \underline{w_A(x)} dx$$

$$\begin{aligned}\underline{w_A(x)} &= \frac{dF_A(x)}{dx} \\ &= \lim_{\epsilon \rightarrow 0} \frac{F_A(x + \epsilon) - F_A(x - \epsilon)}{2\epsilon} \\ &= \lim_{\epsilon \rightarrow 0} \frac{P(A \in [x - \epsilon, x + \epsilon])}{2\epsilon}\end{aligned}$$

## Interpretare grafică

- ▶ Probabilitatea ca  $A$  să fie între  $a$  și  $b$  este **suprafața de sub FDP**
  - ▶ adică integrala de la  $a$  la  $b$
- ▶ Probabilitatea ca  $A$  să fie exact egal cu o valoare este zero
  - ▶ aria de sub un punct este nulă


$$P(a \leq A \leq b) = \int_a^b w_A(x) dx$$



$$P(a \leq A \leq b)$$

(sursa: "[https://intellipaat.com/blog/tutorial/statistics-and-probability-tutorial/probability-distributions-of-continuous-variables/\\*](https://intellipaat.com/blog/tutorial/statistics-and-probability-tutorial/probability-distributions-of-continuous-variables/*)")

## V.a. discrete vs continue




Comparatie intre v.a. discrete si continue

- ▶ FR  $F_A(x)$  are aceeași definiție, înseamnă același lucru
- ▶ FDP/FMP  $w_A(x)$  este derivata FR
  - ▶ la v.a. continue:
  - ▶ este o derivată obișnuită
  - ▶ reprezintă probabilitatea de a fi "in jurul" valorii  $x$
- ▶ la v.a. discrete:
  - ▶ un fel de "derivată discretă"
  - ▶ reprezintă probabilitatea de a avea exact valoarea  $x$

$$P(2 \leq A \leq 5.5) = 1.5 \cdot \frac{1}{6} = \frac{1.5}{6}$$

$$P(A=8) = P(8 \leq A \leq 8) = 0$$



$$P(4 \leq A \leq 10) = \underline{1} = \int w_A(x) dx$$


$$P(7 \leq A \leq 10) = \int_7^{10} w_A(x) dx$$

$$= 3 \cdot \frac{1}{6} = \frac{1}{2}$$

## Proprietățile v.a

FR: (f. Repartiție)

- FR este mereu pozitivă,  $F_A(x) \geq 0$
- FR este monoton crescătoare (nu descrește)
- FR pornește din 0 și ajunge la valoarea 1



$$F_A(-\infty) = 0 \quad F_A(\infty) = 1$$

$$F(x) = P(A \leq x)$$

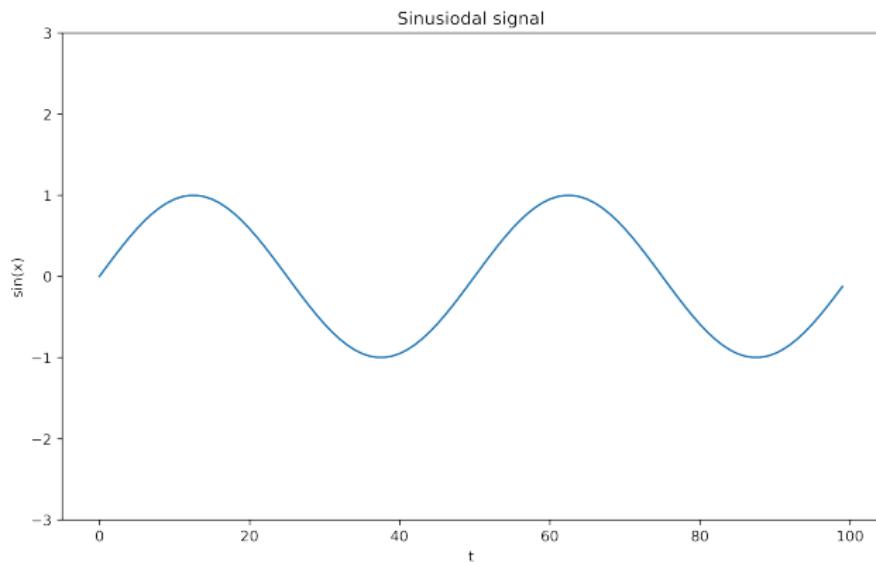
FDP/FMP: (distribuții)

- PDF/PMF sunt mereu pozitive  $w_A(x) \geq 0$
- Integrala/suma pe întreg domeniul = 1


$$\text{Aria totală} = \int_{-\infty}^{\infty} w_A(x)dx = 1 \quad \leftarrow$$

$$\sum_{x=-\infty}^{\infty} w_A(x) = 1 \quad \leftarrow$$

## ► Semnal sinusoidal





- ▶ Sinus + zgomot (normal,  $\mu = 0, \sigma^2 = 1$ )



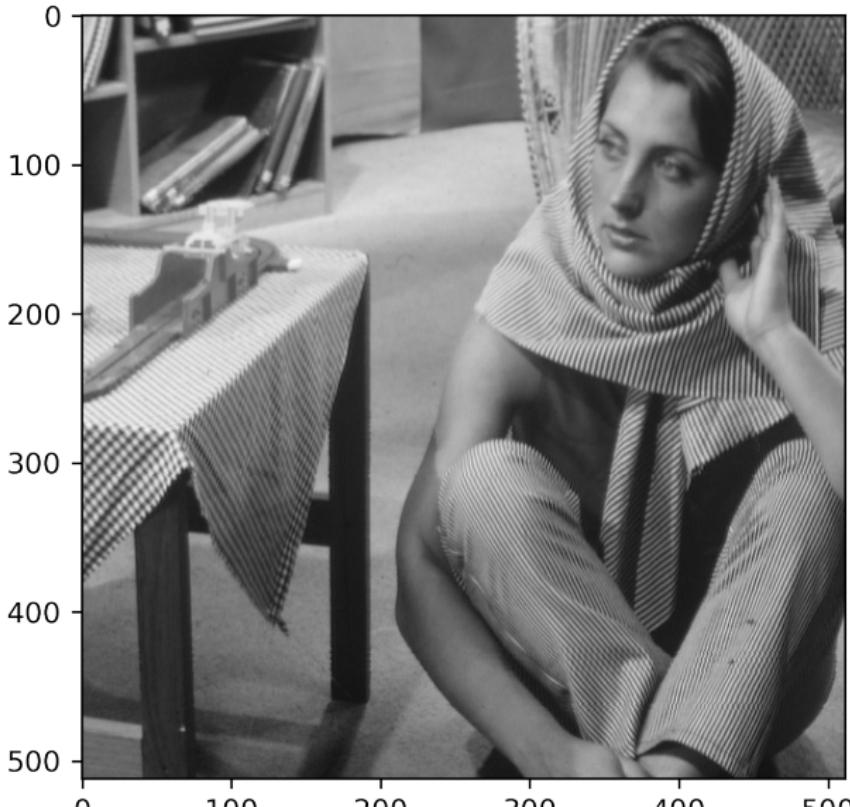
## Diferite distribuții

- ▶ Sinus + zgomot (uniform  $\mathcal{U}[-1, 1]$ )
- ▶ Ce diferă? Tipul distribuției




## Diferite distribuții

### ► Imagine originală



## Diferite distribuții



- ▶ Imagine + zgomot (normal,  $\mu = 0$ ,  $\sigma^2 = 1$ )



pixel + v.a  
Mmumku


## Diferite distribuții

- ▶ Imagine + zgomot mai mare (normal,  $\mu = 0, \sigma^2 = 10$ )



## Diferite distribuții

- ▶ Imagine + zgomot (uniform,  $\mathcal{U}[-5, 5]$ )




# Distribuția normală

"gaussiană"

- Densitatea de probabilitate:

$$w_A(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$





$$\mu = \text{medie}$$

$$\sigma = \text{deviație standard}$$

$$\sigma^2 = \text{varianta}$$

$\sigma = \text{mic}$

$\sigma = \text{mare}$



- ~~sigură~~  $\sigma^2 = \text{varianta}$
- ~~sigură~~  $\sigma^2 = \text{varianta}$

- Are doi parametri:

- **Media**  $\mu$  = "centrul" funcției
- **Deviatia standard**  $\sigma$  = "lățimea" funcției
  - $\sigma$  mic = funcție îngustă și înaltă
  - $\sigma$  mare = funcție largă și joasă


$\sigma^2$  = "variantă"

- Constanta de la începutul expresiei asigură normalizarea (faptul că integrala = 1)
- Extrem de des întâlnită în practică
- Orice valoare reală este posibilă ( $w_A(x) > 0, \forall x \in \mathbb{R}$ )
- Se notează cu  $\mathcal{N}(\mu, \sigma^2)$

$$\mathcal{N}(\mu=0, \sigma^2=5)$$


# Distribuția normală

- ▶ Distribuția descrește pe măsură ce  $x$  se îndepărtează de centrul  $\mu$ 
  - ▶ Datorită termenului  $-(x - \mu)^2$  de la exponent
  - ▶ Valorile cele mai probabile sunt în jurul lui  $\mu$  ( $x - \mu = 0$ )
  - ▶ Valorile apropiate de  $\mu$  sunt mai probabile, valorile mai depărtate de  $\mu$  sunt mai puțin probabile
- ▶ Distribuția exprimă o preferință pentru valori apropiate de  $\mu$ , cu probabilitate din ce în ce mai scăzută la valori mai depărtate de  $\mu$




$$w(x) = \frac{1}{\sqrt{2\pi}} \cdot e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

Exemple de valori generate cu distribuția normală ( $\mu=0$ ,  
 $\sigma^2=1$ )





Exemple de valori generate cu distribuția normală ( $\mu=2$ ,  $\sigma^2=4$ )



## Distribuția uniformă


- ▶ Densitatea de probabilitate = constantă între două limite

$$w_A(x) = \begin{cases} \frac{1}{b-a}, & x \in [a, b] \\ 0, & \text{elsewhere} \end{cases}$$



# Distribuția uniformă

- ▶ Are doi parametri: limitele  $a$  și  $b$  ale intervalului
- ▶ "Înălțimea" funcției este  $\frac{1}{b-a}$  pentru normalizare
  - ▶ pentru ca integrala (aria) să fie 1
- ▶ Sunt posibile doar valori din intervalul  $[a, b]$ 
  - ▶ valorile din afara intervalului au probabilitatea 0
- ▶ Se notează cu  $\mathcal{U}[a, b]$



## Alte distribuții

- ▶ Nenumărate variante, apar în diverse aplicații

# Calculul probabilității pentru distribuția normală

- ▶ Cum calculăm  $\int_a^b$  dintr-o distribuție normală?
  - ▶ Nu se poate prin formule algebrice, funcție ne-elementară
- ▶ Se folosește *the error function*:

$$erf(z) = \frac{2}{\sqrt{\pi}} \int_0^z e^{-t^2} dt \quad = \text{funcție standard}$$

- ▶ Funcția de repartiție a unei distribuții normale  $\mathcal{N}(\mu, \sigma^2)$

$$F_A(X) = \frac{1}{2} \left( 1 + erf\left(\frac{x - \mu}{\sigma\sqrt{2}}\right) \right)$$

- ▶ Valorile funcției  $erf()$  sunt tabelate / se calculează numeric


- ▶ de ex. pe Google, căutați  $erf(0.5)$

- ▶ Alte valori folosite:

- ▶  $erf(-\infty) = -1$
  - ▶  $erf(\infty) = 1$

$$\Leftrightarrow F_A(-\infty) = 0 \quad F_A(\infty) = 1$$


## Exercițiu



$$P(2 \leq A \leq 4) = ?$$

$$= \int_2^4 w(x) dx$$

$$= F(4) - F(2)$$



Exercițiu:

- Fie  $A$  o v.a. cu distribuția  $\mathcal{N}(3, 2)$ . Calculați probabilitatea ca  $A \in [2, 4]$

$$P(2 \leq A \leq 4) = \int_2^4 w_A(x) dx = F_A(4) - F_A(2)$$

$$F_A(4) = \frac{1}{2} \left( 1 + \operatorname{erf} \left( \frac{4-3}{\sqrt{2} \cdot \sqrt{2}} \right) \right) = 0.76$$

$$F_A(2) = \frac{1}{2} \left( 1 + \operatorname{erf} \left( \frac{2-3}{\sqrt{2} \cdot \sqrt{2}} \right) \right) = 0.24$$

$$\Rightarrow P(2 \leq A \leq 4) = 0.52$$

$$\boxed{\begin{aligned} P(-\infty \leq A \leq 4) &= \int_{-\infty}^4 w(x) dx = F(4) - F(-\infty) \\ F(4) &= 0.76 \\ F(-\infty) &= \frac{1}{2} (1 + \operatorname{erf}(-\infty)) = 0 \end{aligned}}$$

## Suma unei constante cu o v.a.


- ▶ Fie o v.a.  $A$
- ▶ Ce reprezintă  $B = 5 + A$ ?

Răspuns:

- ▶  $B$  este tot o variabilă aleatoare
- ▶  $B$  are același tip de distribuție, dar "translată" cu 5 la dreapta

Exemplu:

- ▶  $A$  este o v.a. cu distribuție normală  $w_A(x) = \mathcal{N}(\mu = 3, \sigma^2 = 2)$
- ▶ Care este distribuția variabilei  $B = 5 + A$ ?
- ▶ Răspuns:  $w_B(x) = \mathcal{N}(\mu = 8, \sigma^2 = 2)$



## V.a. ca funcții de alte v.a

- ▶ O funcție aplicată unei v.a. produce o altă v.a.
- ▶ Exemple: dacă  $A$  este o v.a. distribuită  $\mathcal{U}[0, 10]$ , atunci
  - ▶  $B = 5 + A$  este o altă v.a., distribuită  $\mathcal{U}[5, 15]$
  - ▶  $C = A^2$  este de asemenea o v.a.
  - ▶  $D = \cos(A)$  este de asemenea o v.a.
- ▶ Motivație: dacă  $A$  este aleatoare, și valorile  $B, C, D$  sunt aleatoare
- ▶  $A, B, C, D$  nu sunt independente
  - ▶ O anumită valoare a uneia implică automat și valoarea celorlalte

} altă distribuție

- ▶ Fie un sistem cu două v.a. continue  $A$  și  $B$
- ▶ Care este probabilitatea ca perechea  $(A, B)$  să aibă valoarea în jurul  $(x, y)$ ?
- ▶ Distribuția valorilor perechii  $(A, B)$  este descrisă de:
  - ▶ Densitatea de probabilitate comună  $w_{AB}(x, y)$
  - ▶ Funcția de repartiție comună  $F_{AB}(x, y)$

- ▶ Funcția de repartiție comună:

$$\underline{F_{AB}(x, y)} = P_{AB} \{A \leq x \cap B \leq y\}$$

- ▶ Densitatea de probabilitate comună:

$$\underline{w_{AB}(x, y)} = \frac{\partial^2 F_{AB}(x, y)}{\partial x \partial y}$$

- ▶ FDP comună descrie probabilitatea ca perechea  $(A, B)$  să aibă valoarea într-o vecinătate a  $(x, y)$
- ▶ Similar pentru v.a discrete:

$$w_{AB}(x, y) = P \{A = x \cap B = y\}$$

## Variabile independente

- ▶ Două v.a.  $A$  și  $B$  sunt **independente** dacă valoarea uneia nu influențează în nici un fel valoarea celeilalte
- ▶ Pentru v.a. independente, probabilitatea ca  $A$  să fie în jurul lui  $x$  și  $B$  în jurul lui  $y$  este produsul celor două probabilități

$$w_{AB}(x, y) = w_A(x) \cdot w_B(y)$$

- ▶ Valabilă pentru FR / FDP / FMP, v.a. continue sau aleatoare etc.
- ▶ Similar pentru mai mult de două v.a.

$$P((z_{\text{ar1}}, z_{\text{ar2}}) = (6, 6)) = \frac{1}{36}$$

$$= \frac{1}{6} \cdot \frac{1}{6} = P(z_{\text{ar1}} = 6) \cdot P(z_{\text{ar2}} = 6)$$

## Variabile independente

$$P((x, y, z) \geq 0 \text{ simultan}) \stackrel{\text{indep.}}{=} \underbrace{P(x \geq 0)}_{0.16} \cdot \underbrace{P(y \geq 0)}_{0.16} \cdot \underbrace{P(z \geq 0)}_{0.16} = 0.16^3$$

Exercițiu:

- ▶ Calculați probabilitatea ca trei v.a.  $X$ ,  $Y$  și  $Z$  i.i.d.  $\mathcal{N}(-1, 1)$  să fie toate pozitive simultan
- ▶ i.i.d = "independente și identic distribuite"

$$P(X > 0) = \int_0^{\infty} w(x) dx = \underbrace{F(\infty)}_{1} - \underbrace{F(0)}_{\frac{1}{2} \left(1 + \operatorname{erf}\left(\frac{0+1}{\sqrt{2}}\right)\right)} = \dots 0.84$$

## Multiple v.a. normale

- ▶ Fie un set de  $N$  v.a. normale ( $A_1, \dots, A_N$ ), cu medii diferite  $\mu_i$  dar aceeași deviație standard  $\sigma$
- ▶ Probabilitatea ca  $(A_1, \dots, A_N)$  să fie în jurul valorii  $(x_1, \dots, x_N)$  este

$$w_{A_1, \dots, A_N}(x_1, \dots, x_N) = \frac{1}{(\sigma\sqrt{2\pi})^N} e^{-\frac{(x_1-\mu_1)^2 + \dots + (x_N-\mu_N)^2}{2\sigma^2}}$$

$$\|(\mathbf{x}, \boldsymbol{\mu})\|^2 = (x_1 - \mu_1)^2 + \dots + (x_N - \mu_N)^2$$

- ▶ Probabilitatea depinde de **distanța Euclideană** dintre  $\mathbf{x} = (x_1, \dots, x_N)$  și  $\boldsymbol{\mu} = (\mu_1, \dots, \mu_N)$

# Distanța Euclideană

- Distanța Euclideană (geometrică) între 2 vectori N-dimensionali

$$d(\mathbf{u}, \mathbf{v}) = \|\mathbf{u} - \mathbf{v}\| = \sqrt{(u_1 - v_1)^2 + \dots + (u_N - v_N)^2}$$

- Unidimensional:  $\|\mathbf{u} - \mathbf{v}\| = |u - v|$

- 2D:  $\|\mathbf{u} - \mathbf{v}\| = \sqrt{(u_1 - v_1)^2 + (u_2 - v_2)^2}$


- 3D:  $\|\mathbf{u} - \mathbf{v}\| = \sqrt{(u_1 - v_1)^2 + (u_2 - v_2)^2 + (u_3 - v_3)^2}$

- ...

- N-dimensional:  $\|\mathbf{u} - \mathbf{v}\| = \sqrt{\sum_{i=1}^N (u_i - v_i)^2}$

- ...



- Semnale continue:  $\|\mathbf{u} - \mathbf{v}\| = \sqrt{\int_{-\infty}^{\infty} (u(t) - v(t))^2 dt}$



- ▶ Probabilitatea a  $N$  v.a. normale, independente, cu același  $\sigma$  dar diferite  $\mu_i$  depinde de **pătratul distanței Euclidiene față de vectorul medie**  $\mu = (\mu_1, \dots, \mu_N)$ 
  - ▶ Aproape de  $\mu$ : probabilitate mai mare
  - ▶ Deprise de  $\mu$ : probabilitate redusă
  - ▶ Două puncte la aceeași distanță de  $\mu$  au aceeași probabilitate

# Distribuția normală 2D

- Distribuția a 2 v.a. normale (distribuția normală 2D)





$$(A, \bar{B}) = (x, y)$$

## Distribuția normală 2D - vedere de sus

- ▶ Vedere de sus
- ▶ Aici,  $\mu = (0, 0)$
- ▶ Probabilitatea scade pe măsură ce crește distanța față de centru, în cercuri concentrice (simetric)

2D-Gaussian



## Medii statistice

- V.a. sunt caracterizate prin medii statistice ("momente")

- Valoarea medie (momentul de ordin 1)

- Pentru v.a. continue:

$$\bar{A} = E\{A\} = \int_{-\infty}^{\infty} x \cdot w_A(x) dx$$


- Pentru v.a. discrete:

$$\rightarrow \bar{A} = E\{A\} = \sum_{x=-\infty}^{\infty} x \cdot w_A(x)$$

- (Exemplu: entropia  $H(X)$  = valoarea medie a informației)

- Notație ușoară:  $\mu$

$$\mu_A = \bar{A} = E\{A\} =$$




zor:  $\mu = \sum_{x=-\infty}^{\infty} x \cdot w_A(x) = \sum_1^6 x \cdot \frac{1}{6} =$

$$= 1 \cdot \frac{1}{6} + 2 \cdot \frac{1}{6} + 3 \cdot \frac{1}{6} + 4 \cdot \frac{1}{6} +$$

$$+ 5 \cdot \frac{1}{6} + 6 \cdot \frac{1}{6} = \frac{1+2+3+4+5+6}{6} = 3.5$$

## Ce înseamnă valoarea medie

- ▶ Ce înseamnă, practic, valoarea medie a unei variabile aleatoare?
  - ▶ Dacă avem  $N \rightarrow \infty$  valori aleatoare conform distribuției respective, valoarea medie = media tuturor acestor valori;
  - ▶ Dacă trebuie să prezicem valoarea unei variabile aleatoare  $X$ , și plătim un cost proporțional cu pătratul erorii pe care o facem,  $(u - X)^2$ , valoarea medie  $\mu$  este cea mai bună alegere, întrucât minimizează costul global:





$$\mu = \arg \min_u \int_{-\infty}^{\infty} (u - x)^2 \cdot w(x) dx$$

- ▶ Demonstrație: la tablă: derivare, derivata = 0

# Ce înseamnă valoarea medie


- ▶ Valorile care au probabilitate ridicată "trag" valoarea medie înspre ele
- ▶ Pentru distribuții cu formă simetrică (de ex. distribuția normală),  
valoarea medie = valoarea centrală a funcției
  - ▶ Demonstrație: ambele laturi ale funcției "trag" valoare medie înspre ele  
în mod egal, valoarea medie rămâne la mijloc
- ▶ Pentru distribuția normală,  $\bar{X} = \mu$
- ▶ Pentru distribuția uniformă  $\mathcal{U}[a, b]$ ,  $\bar{X} = \frac{a+b}{2}$  (mijlocul intervalului)



- ▶ Calculul valorii medii este o operație **liniară**
  - ▶ pentru că, la bază, integrala / suma este o operatie liniară

- ▶ Pentru două variabile aleatoare A și B (independente):

- ▶ Liniaritate

$$E\{c_1A + c_2B\} = c_1E\{A\} + c_2E\{B\}$$


- ▶ Sau:

$$E\{cA\} = cE\{A\}, \forall c \in \mathbb{R}$$

$$E\{A + B\} = E\{A\} + E\{B\}$$

- ▶ Fără demonstrație

## Valoarea pătratică medie

- ▶ Valoarea pătratică medie = valoarea medie a pătratelor valorilor
- ▶ Momentul de ordin 2
- ▶ Pentru v.a. continue:

$$\overline{A^2} = E\{A^2\} = \int_{-\infty}^{\infty} x^2 \cdot w_A(x) dx$$

- ▶ Pentru v.a. discrete:

$$\overline{A^2} = E\{A^2\} = \sum_{-\infty}^{\infty} x^2 \cdot w_A(x)$$

zor:

puterea

- ▶ Interpretare: media pătratelor = energia medie a unui semnal

$$\begin{aligned}\sum_{1}^{6} x^2 \cdot w(x) &= \frac{1}{6} + \frac{4}{6} + \frac{9}{6} \\ &+ \frac{16}{4} \cdot \frac{1}{6} + \frac{25}{6} \cdot \frac{1}{6} + \frac{36}{5} \cdot \frac{1}{6} = \\ &= \dots\end{aligned}$$

# Varianță

- Varianța = valoarea pătratică medie a abaterii față de valoarea medie  
:) 

- V.a. continue:

$$\sigma^2 = \overline{(A - \mu)^2} = \int_{-\infty}^{\infty} (x - \mu)^2 \cdot w_A(x) dx$$

$(x - \mu)^2$



- V.a. discrete:

$$\sigma^2 = \overline{(A - \mu)^2} = \sum_{-\infty}^{\infty} (x - \mu)^2 \cdot w_A(x)$$

iar:  $\mu = 3.5$

- Interpretare: cât de mult variază valorile în jurul mediei

- $\sigma^2$  = mare: abateri mari față de medie
- $\sigma^2$  = mic: valori concentrate în jurul mediei

$$\begin{aligned}\sigma^2 = & (1-3.5)^2 \cdot \frac{1}{6} + (2-3.5)^2 \cdot \frac{1}{6} + (3-3.5)^2 \cdot \frac{1}{6} \\ & + (4-3.5)^2 \cdot \frac{1}{6} + (5-3.5)^2 \cdot \frac{1}{6} + (6-3.5)^2 \cdot \frac{1}{6}\end{aligned}$$

## Legătura între cele trei mărimi

- ▶ Legătura între medie, valoarea pătratică medie și varianță:

$$\sigma^2 = \overline{(A - \mu)^2}$$

Var. =  $\overline{A^2} - 2 \cdot A \cdot \mu + \mu^2$

$$= \overline{A^2} - 2\mu\overline{A} + \mu^2$$

$= \overline{A^2} - \mu^2$

v.p.m.  $- (\text{media})^2$

$$\sigma^2 = \overline{A^2} - \mu^2$$

## Suma variabilelor aleatoare


$$\left\{ \begin{array}{l} \text{1/6} \\ \text{1/6} \\ \text{1/6} \\ \text{1/6} \\ \text{1/6} \\ \text{1/6} \end{array} \right\} * \left\{ \begin{array}{l} \text{1/6} \\ \text{1/6} \\ \text{1/6} \\ \text{1/6} \\ \text{1/6} \\ \text{1/6} \end{array} \right\} \quad C = A + B$$

- ▶ Suma a două sau mai multe v.a. **independente** este tot o v.a.
- ▶ Distribuția ei = convoluția distribuțiilor v.a. componente
- ▶ Dacă  $C = A + B$ , atunci:


$$w_C(x) = w_A(x) * w_B(x)$$

- ▶ Caz particular: dacă  $A$  și  $B$  sunt v.a. normale, cu  $\mathcal{N}(\mu_A, \sigma_A^2)$  și  $\mathcal{N}(\mu_B, \sigma_B^2)$ , atunci:

- ▶  $C$  este tot o v.a. cu distribuție normală,  $\mathcal{N}(\mu_C, \sigma_C^2)$ , având:
- ▶ media = suma mediilor:  $\mu_C = \mu_A + \mu_B$
- ▶ varianța = suma varianțelor:  $\sigma_C^2 = \sigma_A^2 + \sigma_B^2$




$$\begin{aligned} P(A+B=2) &= \frac{1}{36} \\ P(A+B=3) &= \frac{2}{36} \end{aligned}$$



## II.2 Procese aleatoare

# Procese aleatoare

- ▶ Un **proces aleator** = o secvență de variabile aleatoare indexate (înșiruite) în timp
- ▶ Proces aleator **în timp discret**  $f[n]$  = o secvență de v.a. la momente de timp discrete
  - ▶ ex: o secvență de 50 aruncări de zar, cotația zilnică a unor acțiuni la bursă
- ▶ Proces aleator **în timp continuu**  $f(t)$  = o secvență de v.a. la orice moment de timp
  - ▶ ex: un semnal tip zgomot de tensiune
- ▶ Fiecare eșantion dintr-un proces aleator este o v.a. de sine stătătoare
  - ▶ ex.:  $f(t_0)$  = valoarea la momentul  $t_0$  este o v.a.



## Realizări ale proceselor aleatoare

- ▶ **Realizare** a unui p.a. = o secvență particulară de realizări ale v.a. componente

- ▶ ex: un anume semnal de zgomot măsurat cu un osciloscop; am obținut o anume realizare, dar am fi putut obține orice altă realizare


- ▶ Notația uzuală:  $f^{(k)}[n]$  sau  $f^{(k)}(t)$  *realizare particulară*



- ▶  $k$  indică realizarea particulară care se consideră
- ▶  $t$  sau  $n$  este timpul

- ▶ Când considerăm un p.a., considerăm întregul set de realizări posibile

- ▶ Ia fel ca atunci când considerăm o v.a.



## Proces aleator = un fenomen 2-D


- Un proces aleator trebuie vizualizat în două dimensiuni:

- $f^{(k)}[n]$  sau  $f^{(k)}(t)$  depind de două variabile:

- $k = \underline{\text{realizarea}}$


- $t$  sau  $n = \underline{\text{timpul}}$

## Proces aleator = un fenomen 2-D




- ▶ sursa: "Information-Based Inversion and Processing with Applications"  
Edited by Tadeusz J. Ulrych, Mauricio D. Sacchi, Volume 36,

## Proces aleator = un fenomen 2-D



- ▶ sursa: Razdolsky, L. (2014). Random Processes. In Probability-Based Structural Fire Load (pp. 89-136). Cambridge: Cambridge University Press


# Proces aleator = un fenomen 2-D



- ▶ sursa: <https://www.quora.com/What-is-the-difference-between-a-stationary-ergodic-and-a-stationary-non-ergodic-process>

- ▶ Procesele aleatoare au două tipuri de valori medii:
  - ▶ Valori medii **statistice** = calculate la un timp  $t$  sau  $n$  fixat, de-a lungul tuturor realizărilor posibile
  - ▶ Valori medii **temporale** = calculate pentru o realizare  $k$  fixată, de-a lungul timpului

## Două feluri de valori medii




- sursa: <https://www.quora.com/What-is-the-difference-between-a-stationary-ergodic-and-a-stationary-non-ergodic-process>

## Distribuții de ordin 1 ale proceselor aleatoare

- ▶ Fiecare eșantion  $f(t_1)$  dintr-un proces este o v.a.

- ▶ descris de o **distribuție de ordin 1**
- ▶ are FR  $F_1(x; t_1)$
- ▶ are FDP / FMP  $w_1(x; t_1) = \frac{dF_1(x; t_1)}{dx}$
- ▶ distribuția depinde de momentul  $t_1$


$$w_1(x; t_1) \quad w_1(x; t_2)$$




- ▶ Un eșantion la alt moment  $t_2$  este o v.a. diferită, cu funcții posibil diferite
  - ▶ altă FR  $F_1(x; t_2)$
  - ▶ altă FDP / FMP  $w_2(x; t_2) = \frac{dF_1(x; t_2)}{dx}$
- ▶ Aceste funcții descriu distribuția valorilor unui eșantion
- ▶ Indicele  $w_1$  arată că considerăm o singură v.a. din proces (distribuții de ordin 1-)
- ▶ Similar pentru p.a. discrete

## Distribuții de ordin 2

- ▶ O pereche de v.a.  $f(t_1)$  și  $f(t_2)$  formează un sistem de 2 v.a.:
  - ▶ sunt descrise de o **distribuție de ordin 2**
  - ▶ au FR comună  $F_2(x_i, x_j; t_1, t_2)$
  - ▶ au FDP / FMP comună  $w_2(x_i, x_j; \underline{t_1}, \underline{t_2}) = \frac{\partial^2 F_2(x_i, x_j; t_1, t_2)}{\partial x_i \partial x_j}$
  - ▶ distribuția depinde de momentele  $t_1$  și  $t_2$
- ▶ Aceste funcții descriu cum sunt distribuite valorile perechilor (distribuții de ordin 2)
- ▶ Similar pentru p.a. discrete



$$(f(t_1), f(t_2))$$



## Distribuții de ordin n

- ▶ Generalizare la un grup de  $n$  eșantioane dintr-un p.a.
- ▶ Un set de  $n$  v.a.  $f(t_1), \dots, f(t_n)$  dintr-un proces aleator  $f(t)$ :
  - ▶ sunt descrise de o **distribuție de ordin  $n$**
  - ▶ au FR comună  $F_n(x_1, \dots, x_n; t_1, \dots, t_n)$
  - ▶ au FDP / FMP comună  $w_n(x_1, \dots, x_n; t_1, \dots, t_n) = \frac{\partial^2 F_n(x_1, \dots, x_n; t_1, \dots, t_n)}{\partial x_1 \dots \partial x_n}$
  - ▶ depind de momentele de timp  $t_1, t_2, \dots, t_n$
- ▶ Aceste funcții descriu cum sunt distribuite valorile seturilor de  $n$  eșantioane (*distribuții de ordin  $n$* )
- ▶ Similar pentru p.a. discrete

## Medii statistice

Procesele aleatoare sunt caracterizate de medii **statistice** și **temporale**

Pentru procese continue:

### 1. Valoarea medie

$$\overline{f(t_1)} = \mu(t_1) = \int_{-\infty}^{\infty} x \cdot w_1(x; t_1) dx$$

*A* legea de distribuție

### 2. Valoarea pătratică medie

$$\overline{f^2(t_1)} = \int_{-\infty}^{\infty} x^2 \cdot w_1(x; t_1) dx$$

### 3. Varianța

$$\sigma^2(t_1) = \overline{\{f(t_1) - \mu(t_1)\}^2} = \int_{-\infty}^{\infty} (x - \mu(t_1))^2 \cdot w_1(x; t_1) dx$$

- ▶ Legătura între aceste trei mărimi:

$$\begin{aligned}\sigma^2(t_1) &= \overline{\{f(t_1) - \mu(t_1)\}^2} \\ &= \overline{f(t_1)^2} - 2\overline{f(t_1)\mu(t_1)} + \overline{\mu(t_1)^2} \\ &= \overline{f^2(t_1)} - \mu(t_1)^2\end{aligned}$$

- ▶ Observații:

- ▶ aceste trei valori sunt calculate pentru toate realizările, la momentul  $t_1$
- ▶ ele caracterizează doar eșantionul de la momentul  $t_1$
- ▶ la alt moment de timp  $t_2$ , v.a.  $f(t_2)$  este diferită, și valorile medii pot dифeri

Medii statistice care caracterizează o pereche de eșantioane:

## 4. Funcția de autocorelație

$$R_{ff}(t_1, t_2) = \overline{f(t_1)f(t_2)} = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x_1 x_2 w_2(x_1, x_2; t_1, t_2) dx_1 dx_2 \quad \leftarrow$$

## 5. Funcția de corelație (pentru două procese aleatoare diferite $f(t)$ și $g(t)$ )

$$R_{fg}(t_1, t_2) = \overline{f(t_1)g(t_2)} = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x_1 y_2 w_2(x_1, y_2; t_1, t_2) dx_1 dy_2 \quad \leftarrow$$

### ► Observații:

- aceste funcții pot fi diferențiate pentru perechi de valori luate la momente diferențiate  $(t_1, t_2)$

# Procese aleatoare discrete

Legă de distribuție

Pentru procese aleatoare discrete, se înlocuiește  $\int$  cu  $\sum$ , și notația  $f(t)$  cu  $f[t]$ :

$$1. \overline{f[t_1]} = \mu(t_1) = \sum_{x=-\infty}^{\infty} x \cdot w_1(x; t_1)$$

$$2. \overline{f^2[t_1]} = \sum_{x=-\infty}^{\infty} x^2 \cdot w_1(x; t_1)$$

$$3. \sigma^2(t_1) = \overline{(f[t_1] - \mu(t_1))^2} = \sum_{x=-\infty}^{\infty} (x - \mu(t_1))^2 \cdot w_1(x; t_1)$$


$$4. R_{ff}(t_1, t_2) = \overline{f[t_1]f[t_2]} = \sum_{x_1=-\infty}^{\infty} \sum_{x_2=-\infty}^{\infty} x_1 x_2 w_2(x_1, x_2; t_1, t_2)$$

$$5. R_{fg}(t_1, t_2) = \overline{f[t_1]g[t_2]} = \sum_{x_1=-\infty}^{\infty} \sum_{x_2=-\infty}^{\infty} x_1 y_2 w_2(x_1, y_2; t_1, t_2)$$




## Medii temporale

- ▶ Dacă avem acces doar la o singură realizare  $f^{(k)}(t)$  a procesului?
- ▶ Calculăm valorile medii **pentru o singură realizare  $f^{(k)}(t)$ , de-a lungul timpului**



# Medii temporale



Medii temporale pentru procese aleatoare continue:

## 1. Valoarea medie temporală


realiz  $f^{(k)}$   
pe cote orice

$$\overline{f^{(k)}(t)} = \mu^{(k)} = \lim_{T \rightarrow \infty} \frac{1}{T} \int_{-T/2}^{T/2} f^{(k)}(t) dt$$

## 2. Valoarea medie pătratică temporală

$$[f^{(k)}(t)]^2 = \lim_{T \rightarrow \infty} \frac{1}{T} \int_{-T/2}^{T/2} [f^{(k)}(t)]^2 dt$$

media lui  $[f^{(k)}(t)]^2$



### 3. Varianța temporală


$$\sigma_{(k)}^2 = \overline{\{f^{(k)}(t) - \mu^{(k)}\}^2} = \lim_{T \rightarrow \infty} \frac{1}{T} \int_{-T/2}^{T/2} (f^{(k)}(t) - \mu^{(k)})^2 dt$$

- Relația dintre cele trei mărimi:


$$\sigma_{(k)}^2 = \overline{[f^{(k)}(t)]^2} - [\mu^{(k)}]^2$$

- Observație:

► aceste valori nu mai depind de timpul  $t$ , ci do ~~do~~ realiz. ( $k$ )



~~do~~



$$\rightarrow \mu = 1.49 V$$

$$\rightarrow \mu = 1.435 V$$

$$\rightarrow \mu = 1.51 V$$

## 4. Funcția de autocorelație temporală

$$\begin{aligned} R_{ff}(t_1, t_2) &= \overline{f^{(k)}(t_1 + t)f^{(k)}(t_2 + t)} \\ &= \lim_{T \rightarrow \infty} \frac{1}{T} \int_{-T/2}^{T/2} f^{(k)}(t_1 + t)f^{(k)}(t_2 + t)dt \end{aligned}$$

## 5. Funcția de corelație temporală (pentru două procese diferite $f(t)$ și $g(t)$ )

$$\begin{aligned} R_{fg}(t_1, t_2) &= \overline{f^{(k)}(t_1 + t)g^{(k)}(t_2 + t)} \\ &= \lim_{T \rightarrow \infty} \frac{1}{T} \int_{-T/2}^{T/2} f^{(k)}(t_1 + t)g^{(k)}(t_2 + t)dt \end{aligned}$$

# Procese aleatoare discrete

$$\sum_{t=-\infty}^{\infty} x[n]$$



Pentru **procese aleatoare discrete**, se înlocuiește  $\int$  cu  $\sum$ ,  $T$  cu  $N$ , și se împarte la  $2N + 1$  în loc de  $2T$  m. aritm.

$$1. \overline{f^{(k)}[t]} = \mu^{(k)} = \lim_{N \rightarrow \infty} \frac{1}{2N+1} \sum_{t=-N}^N f^{(k)}[t] \quad \xrightarrow{\hspace{10em}} \quad \sum_{n=-N}^N x[n]$$

$$2. \overline{[f^{(k)}[t]]^2} = \lim_{N \rightarrow \infty} \frac{1}{2N+1} \sum_{t=-N}^N (f^{(k)}[t])^2$$

$$3. \sigma^2 = \overline{(f^{(k)}[t] - \mu^{(k)})^2} = \lim_{N \rightarrow \infty} \frac{1}{2N+1} \sum_{t=-N}^N (f^{(k)}[t] - \mu^{(k)})^2$$

## 4. Autocorelația temporală:

$$\begin{aligned} R_{ff}(t_1, t_2) &= \overline{f^{(k)}[t_1 + t] f^{(k)}[t_2 + t]} \\ &= \lim_{N \rightarrow \infty} \frac{1}{2N+1} \sum_{t=-N}^N f^{(k)}[t_1 + t] f^{(k)}[t_2 + t] \end{aligned}$$

## 5. Corelația temporală:

$$\begin{aligned} R_{fg}(t_1, t_2) &= \overline{f^{(k)}[t_1 + t] g^{(k)}[t_2 + t]} \\ &= \lim_{N \rightarrow \infty} \frac{1}{2N+1} \sum_{t=-N}^N f^{(k)}[t_1 + t] g^{(k)}[t_2 + t] \end{aligned}$$

## Realizări de lungime finită

- E posibil să avem o realizare de lungime finită (de ex. un vector cu 1000 de eșantioane dintr-o realizare a unui p.a.)
- Cum calculăm mediile temporale?
- Se fac sumele/integralele de la  $\int_{t_{min}}^{t_{max}}$  sau  $\sum_{t_{min}}^{t_{max}}$  în loc de la  $-\infty$  la  $\infty$
- Exemplu: calculați mediile temporale pentru realizarea de lungime finită

$$\{1, -1, 2, -2, 3, -3, 4, -4, 5, -5\} \rightarrow \mu = \frac{1 - 1 + 2 - 2 + \dots}{10} =$$

~~$\bar{x}$~~

$$\lim_{N \rightarrow \infty} \frac{\sum}{2N}$$
$$\sigma^2 = \frac{(1-\mu)^2 + (-1-\mu)^2 + (2-\mu)^2 + (-2-\mu)^2 + (3-\mu)^2 + (-3-\mu)^2 + (4-\mu)^2 + (-4-\mu)^2 + (5-\mu)^2 + (-5-\mu)^2}{10}$$

- ▶ Mediile statistice sunt, de obicei, cele de dorit
  - ▶ dar necesită cunoașterea distribuțiilor  $w(x)$ , care în practică sunt rareori cunoscute
- ▶ În practică, de obicei avem acces doar la o singură realizare, obținută printr-o măsurătoare
  - ▶ deci putem calcula doar mediile temporale pe acea realizare
- ▶ Din fericire, în multe cazuri mediile statistice și temporale sunt identice ("ergodicitate")  


## Procese aleatoare staționare

- ▶ Până acum, am considerat că mediile statistice depind de timp
  - ▶ pot fi diferite pentru un eșantion de la  $t_1$  și de la  $t_2$
- ▶ Proces aleator **staționar** = dacă mediile statistice rămân aceleași la modificarea originii timpului (întârzierea semnalului)
- ▶ Altfel spus: distribuțiile (FDP/FMP) eșantioanelor rămân identice la modificarea originii timpului

$$\underline{w_n(x_1, \dots, x_n; t_1, \dots, t_n)} = w_n(x_1, \dots, x_n; t_1 + \tau, \dots, t_n + \tau)$$

- ▶ Practic, pentru a fi staționar trebuie ca **toate mediile statistice să nu mai depindă de timp  $t$**

► Proces aleator **staționar în sens strict**:


- ▶ relația e valabilă pentru distribuțiile de orice ordin  $n$
- ▶ valoarea medie, valoarea pătratică medie, varianța, autocorelația și **toate celelalte** statistici de ordin superior nu depind de originea timpului  $t$

► Proces aleator **staționar în sens larg**:


- ▶ relația e valabilă doar pentru distribuțiile de ordin  $n = 1$  și  $n = 2$  (distribuțiile unui singur eșantion, sau a două eșantioane)
- ▶ **doar** valoarea medie, valoarea pătratică medie, varianța și autocorelația nu depind de originea timpului  $t$ , dar statisticile de ordin superior pot depinde

## Procese aleatoare staționare

- ▶ Este procesul aleator schițat mai jos staționar sau nu?



- ▶ sursa: SEX, LIES & STATISTICS, Ned Wright,  
<http://www.astro.ucla.edu/~wright/statistics/>



- ▶ Răspuns: ne-stationar
- ▶ Se observă că varianța nu este aceeași la toate momentele de timp

## Consecințe ale stationarității

- ▶ Pentru distribuții ale unui singur eșantion (de ordin  $n = 1$ ):

$$w_1(x_i; t_1) = w_1(x_i; t_2) = w_1(x_i)$$

- ▶ Valoarea medie, valoarea medie pătratică, varianța unui eșantion sunt **identice la orice moment de timp  $t$**

$$\overline{f(t)} = \text{constant}, \forall t$$

$$\overline{f^2(t)} = \text{constant}, \forall t$$

$$\sigma^2(t) = \text{constant}, \forall t$$

la orice  $t$

## Consecințe ale stationarității


- ▶ Pentru distribuții ale unor perechi de eșantioane (de ordin  $n = 2$ ):

$$w_2(x_i, x_j; t_1, t_2) = w_2(x_i, x_j; 0, t_2 - t_1) = w_2(x_i, x_2; t_2 - t_1)$$

- ▶ Funcția de autocorelație depinde doar de diferența de timp  
 $\tau = t_2 - t_1$  dintre eșantioane

$$R_{ff}(t_1, t_2) = R_{ff}(0, t_2 - t_1) = \boxed{R_{ff}(\tau) = \overline{f(t)f(t + \tau)}}$$

- ▶ Depinde doar de valoarea  $\tau = t_2 - t_1$  = diferența de timp dintre cele două eșantioane



## Consecințe ale stationarității

Definiția funcției de autocorelație pentru p.a. **stationare**:

- ▶ Autocorelația statistică: formula rămâne aceeași?
- ▶ Autocorelația temporală:
  - ▶ pentru p.a. continue

$$R_{ff}(\tau) = \overline{f(t)f(t+\tau)} = \lim_{T \rightarrow \infty} \frac{1}{T} \int_{-T/2}^{T/2} f^{(k)}(t)f^{(k)}(t+\tau) dt$$

$$\begin{matrix} t_1, t_2 \\ \hline \sigma, \tau \end{matrix}$$

- ▶ pentru p.a. discrete

$$R_{ff}(\tau) = \overline{f(t)f(t+\tau)} = \lim_{N \rightarrow \infty} \frac{1}{2N+1} \sum_{t=-N}^N f^{(k)}[t]f^{(k)}[t+\tau]$$

- ▶ lungime finită: se limitează integralele / sumele la intervalul avut la dispoziție,  $\int_{t_{min}}^{t_{max}}$  sau  $\sum_{t_{min}}^{t_{max}}$

- ▶ Pentru funcția de corelație, definiția este similară cu cea de la autocorelație de mai sus
- ▶ Corelația depinde doar de **diferența de timp**  $\tau = t_2 - t_1$  dintre cele două eșantioane

$$R_{fg}(t_1, t_2) = R_{fg}(0, t_2 - t_1) = R_{fg}(\tau) = \overline{f(t)g(t + \tau)}$$


$f$        $g$

- ▶  $R_{ff}(\tau) = \overline{f(t)f(t + \tau)}$  = **media produsului a două eșantioane situate la distanță de  $\tau$** 
  - ▶ ne spune dacă eșantioanele variază la fel sau nu
- ▶ Idem pentru corelație, doar că eșantioanele provin din p.a. diferite,  $f$  și  $g$

## Interpretarea autocorelației

### ► Exemple:

- ▶  $R_{ff}(0.5) > 0$ : două eșantioane decalate cu 0.5 secunde tind să varieze în aceeași direcție (ambele pozitive, ambele negative => produsele sunt majoritar pozitive)
  - ▶ dacă se cunoaște una dintre ele, se poate "ghici" ceva despre celălătă
- ▶  $R_{ff}(1) < 0$ : două eșantioane decalate cu 1 secundă tind să varieze în direcții opuse (când unul e pozitiv, celălalt e negativ => produsele sunt majoritar negative)
  - ▶ dacă se cunoaște una dintre ele, se poate "ghici" ceva despre celălătă
- ▶  $R_{ff}(2) = 0$ : două eșantioane decalate cu 2 secunde sunt necorelate (produsele sunt în medie 0, deci cele două eșantioane au la fel de multe sanse de a fi de același semn sau cu semne contrare)
  - ▶ dacă se cunoaște una dintre ele, **nu** se mai poate "ghici" ceva despre celălătă




# Procese aleatoare ergodice

- ▶ În practică, avem acces la o singură realizare
- ▶ Proces aleator **ergodic** = dacă mediile temporale pe orice realizare sunt identice cu mediile statistice

- ▶ Ergodicitatea înseamnă:

- ▶ Se pot calcula toate mediile pe baza unei singure realizări (oricare)
  - ▶ dar realizarea respectivă trebuie să fie foarte lungă (lungimea  $\rightarrow \infty$ ) pentru valori precise
- ▶ Toate realizările sunt similare unele cu altele, dpdv statistic
  - ▶ o realizare este caracteristică pentru întreg procesul aleator



## Procese aleatoare ergodice


- ▶ Majoritatea proceselor aleatoare de interes sunt ergodice și staționare
  - ▶ de ex. zgomote de tensiune
- ▶ Exemplu de proces aleator **ne-ergodic**:
  - ▶ se aruncă un zar, următoarele 50 valori sunt identice cu prima valoare
    - ▶ o singură realizare nu e caracteristică pentru tot procesul

## Procese aleatoare ergodice

```
int getRandomNumber()
{
    return 4; // chosen by fair dice roll.
    // guaranteed to be random.
}
```

$\frac{1}{6}$	1 1 1	1 1 1 1	1 1 1 1 1	1 1 1 1 1 1	1 1 1 1 1 1 ...
$\frac{1}{6}$	2 2 2	2 2 2 2	2 2 2 2 2	2 2 2 2 2 2	2 2 2 2 2 2 ...
$\frac{1}{6}$	3 3 3	3 3 3 3	3 3 3 3 3	3 3 3 3 3 3	3 3 3 3 3 3 ...
$\frac{1}{6}$	4 4 4	4 4 4 4	4 4 4 4 4	4 4 4 4 4 4	4 4 4 4 4 4 ...
$\frac{1}{6}$	5 5 5	5 5 5 5	5 5 5 5 5	5 5 5 5 5 5	5 5 5 5 5 5 ...
$\frac{1}{6}$	6 6 6	6 6 6 6	6 6 6 6 6	6 6 6 6 6 6	6 6 6 6 6 6 ...

- ▶ XKCD 221 (link aici: <https://xkcd.com/221/>)
- ▶ Se consideră toate numerele care s-ar fi putut obține în loc de 4 (1,2,3,5 sau 6)
- ▶ Care e problema aici?
  - ▶ proces aleator stationar sau ne-staționar?
  - ▶ proces aleator ergodic sau ne-ergodic?





### I.3 Proprietăți ale autocorelației

## Densitatea spectrală de putere

- ▶ **Densitatea spectrală de putere (DSP)**  $S_{ff}(\omega)$  reprezintă puterea unui semnal în funcție de frecvență ( $f$  sau  $\omega = 2\pi f$ )
- ▶ Pentru un semnal determinist (ne-aleator), este dată de modului transf. Fourier la pătrat:


$$S_{ff}(\omega) = |F(\omega)|^2$$

- ▶ Puterea în banda de frecvență  $[f_1, f_2]$  este  $\int_{f_1}^{f_2} S_{ff}(\omega) d\omega$
- ▶ Puterea totală a procesului aleator este  $P = \int_{-\infty}^{\infty} S_{ff}(\omega) d\omega$
- ▶ DSP este o funcție măsurabilă practic:
  - ▶ poate fi determinată experimental
  - ▶ este importantă în aplicații practice (ingineresci)



# Densitatea spectrală de putere

- ▶ Ce reprezintă DSP pentru un proces aleator?
  - ▶ nu mai avem un singur semnal, cu o infinitate de realizări posibile
  - ▶ fiecare realizare are o transformată Fourier proprie, diferită
  - ▶ DSP fiind diferită pentru fiecare realizare în parte, este, ea însăși, un proces aleator  
 $|F(\omega)|^2$
- ▶ DSP a unui proces aleator = media DSP pentru toate realizările posibile
- ▶ Are aceeași utilitate și semnificație ca în cazul unui semnal determinist, doar că **în medie** în raport cu toate realizările posibile
  - ▶ pentru o realizare particulară, DSP poate varia în jurul DSP medii



# Teorema Wiener-Hincin

## Teorema Wiener-Hincin:

- Densitatea spectrală de putere = transformata Fourier a funcției de autocorelație

$$S_{ff}(\omega) = \int_{-\infty}^{\infty} R_{ff}(\tau) e^{-j\omega\tau} d\tau$$


DSP      f. autocorr

$$R_{ff}(\tau) = \frac{1}{2\pi} \int_{-\infty}^{\infty} S_{ff}(\omega) e^{j\omega\tau} d\omega$$


- Fără demonstrație
- Leagă două concepte de natură diferită
  - Funcția de autocorelație: o proprietate *statistică*
  - DSP: o proprietate *fizică* (ține de energia semnalului; importantă în aplicații practice)



T.F.



T.F invers





# Zgomot alb

- **Zgomot alb** = un proces aleator cu **funcția de autocorelație egală cu un Dirac**


$$R_{ff}(\tau) = \delta(\tau)$$

- este proces aleator: orice eşantion este o variabilă aleatoare
- autocorelația este un Dirac: este 0 pentru orice  $\tau \neq 0$
- oricare două eşantioane diferite ( $\tau \neq 0$ ) au corelație zero (necorelate)
  - valorile a două eşantioane distincte nu au legătură între ele




## Zgomot alb

$$A \cdot \delta(t) \xleftrightarrow{F} 1 \cdot A$$




- ▶ Densitatea spectrală de putere = transf. Fourier a unui Dirac = constantă  $\forall \omega$

$$S_{ff}(\omega) = \underline{\text{constant}}, \forall \omega$$



- ▶ putere constantă pentru toate frecvențele, până la  $f = \infty$
- ▶ Zgomotul alb poate avea orice distribuție (normală, uniformă etc.)
  - ▶ termenul "zgomot alb" nu se referă la distribuția eșantioanelor, ci la faptul că valorile eșantioanele sunt necorelate





## Zgomot alb de bandă limitată

- ▶ În lumea reală, pentru orice semnal puterea scade la 0 la frecvențe foarte înalte



▶ pentru că puterea totală  $P = \int_{-\infty}^{\infty} S_{ff} \omega$  nu poate fi infinită

▶ se numește zgomot alb **de bandă limitată**

- ▶ În acest caz, autocorelația = **aproximativ** un Dirac, dar nu chiar infinit de "subtire"

▶ eșantioane foarte apropiate sunt totuși corelate

▶ de ex. din cauza unor mici capacități parazite



► **AWGN** = Additive White Gaussian Noise

- ▶ Zgomot alb, Gaussian, aditiv
  - ▶ tipul/modelul de zgomot cel mai frecvent întâlnit în aplicații
- Înseamnă:

- ▶ **zgomot**: este un proces aleator (fiecare eșantion este aleator, fiecare realizare este diferită)
- ▶ **gaussian**: eșantioanele au distribuția normală
- ▶ **alb**: valorile eșantioanelor sunt necorelate între ele
- ▶ **aditiv**: zgomotul se adună peste semnalul original (adică de ex. nu se multiplică cu acesta)



- ▶ Până aici s-a făcut în 2020-2021. Celelalte slide-uri din acest fișier nu se cer.



URAAAT!

## Proprietățile funcției de autocorelație

1. Este o funcție pară

$$R_{ff}(\tau) = R_{ff}(-\tau)$$

- ▶ Demonstrație: Schimbare de variabilă în definiție

2. La infinit, tinde la o valoare constantă

$$R_{ff}(\infty) = \overline{f(t)}^2 = const$$

- ▶ Dem.: două eșantioane la un interval  $\infty$  sunt necesar independente

3. Are valoarea maximă în 0

$$R_{ff}(0) \geq R_{ff}(\tau)$$

- ▶ Dem.: se pornește de la  $(\overline{f(t) - f(t + \tau)})^2 \geq 0$
- ▶ Interpretare: eșantioane diferite mai pot varia diferit, dar un eșantion variază întotdeauna identic cu sine însuși

4. Valoarea în 0 = puterea procesului aleator

$$R_{ff}(0) = \frac{1}{2\pi} \int_{-\infty}^{\infty} S_{ff}(\omega) d\omega$$

- ▶ Dem.: Se pune  $\tau = 0$  în transf. Fourier inversă din teorema Wiener-Hincin

5. Varianța = diferența între valoarea din 0 și cea de la  $\infty$

$$\sigma^2 = R_{ff}(0) - R_{ff}(\infty)$$

- ▶ Dem.:  $R_{ff}(0) = \overline{f(t)^2}$ ,  $R_{ff}(\infty) = \overline{f(t)}^2$

- ▶ Fie un proces aleator aplicat la intrarea unui sistem
  - ▶ fie în timp continuu: intrarea  $x(t)$ , sistemul  $H(s)$ , ieșirea  $y(t)$
  - ▶ fie în timp discret: intrarea  $x[n]$ , sistemul  $H(z)$ , ieșirea  $y[n]$
- ▶ Cum depinde autocorelația ieșirii  $y$  de cea a intrării  $x$ ?
- ▶ Se știe că  $y$  este conoluția lui  $x$  cu răspunsul la impuls  $h$

- ▶ Pentru un proces aleator în timp discret

$$\begin{aligned} R_{yy}(\tau) &= \overline{y[n]y[n + \tau]} \\ &= \overline{\sum_{k_1=-\infty}^{\infty} h[k_1]x[n - k_1] \sum_{k_2=-\infty}^{\infty} h[k_2]x[n + \tau - k_2]} \\ &= \sum_{k_1=-\infty}^{\infty} \sum_{k_2=-\infty}^{\infty} h[k_1]h[k_2] \overline{x[n - k_1]x[n + \tau - k_2]} \\ &= \sum_{k_1=-\infty}^{\infty} \sum_{k_2=-\infty}^{\infty} h[k_1]h[k_2]R_{xx}[\tau - k_1 + k_2] \end{aligned}$$

- ▶ Din teorema Wiener-Hincin se știe că:

$$S_{ff}(\omega) = \sum_{\tau=-\infty}^{\infty} R_{ff}(\tau) e^{-j\omega\tau}$$

► Așadar

$$S_{yy}(\omega) = \sum_{\tau=-\infty}^{\infty} \sum_{k_1=-\infty}^{\infty} \sum_{k_2=-\infty}^{\infty} h[k_1]h[k_2]R_{xx}[\tau - k_1 + k_2]e^{-j\omega\tau}$$

► Schimbare de variabilă  $\tau - k_1 + k_2 = u$

► rezultă  $\tau = u + k_1 - k_2$


$$\begin{aligned} S_{yy}(\omega) &= \sum_{u=-\infty}^{\infty} \sum_{k_1=-\infty}^{\infty} \sum_{k_2=-\infty}^{\infty} h[k_1]h[k_2]R_{xx}[u]e^{-j\omega(u+k_1+k_2)} \\ &= \sum_{u=-\infty}^{\infty} R_{xx}[u]e^{-j\omega u} \sum_{k_1=-\infty}^{\infty} h[k_1]e^{-j\omega k_1} \sum_{k_2=-\infty}^{\infty} h[k_2]e^{j\omega k_2} \\ &= S_{xx}(\omega) \cdot H(\omega) \cdot H^*(\omega) \\ &= S_{xx}(\omega) \cdot |H(\omega)|^2 \end{aligned}$$

$$S_{yy}(\omega) = S_{xx}(\omega) \cdot |H(\omega)|^2$$

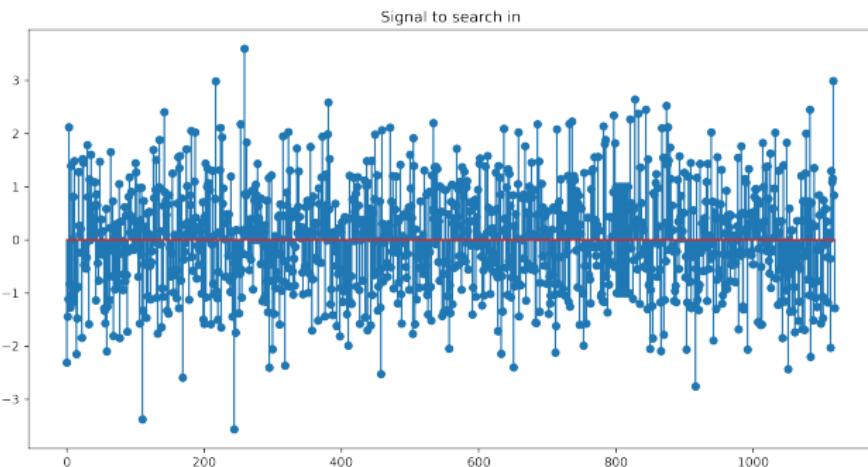
- ▶ DSP a lui  $y = \text{DSP a lui } x$  multiplicată cu răspunsul în amplitudine, la pătrat, al filtrului
- ▶ Relația este valabilă și pentru procese aleatoare continue

- ▶ Căutarea unei anume porțiuni într-un semnal mai mare
- ▶ Corelația a două semnale = o măsura a **similarității** celor două semnale
  - ▶ Funcția de corelație măsoară similaritatea unui semnal cu toate versiunile decalate ale celuilalt
  - ▶ Exemplu numeric la tablă, semnale de lungime finită
- ▶ Corelația poate fi utilizată pentru localizare
  - ▶ Funcția de (auto)corelație are valori mari atunci când cele două semnale se potrivesc
  - ▶ Valori mari sunt atunci când valorile pozitive / negative ale semnalelor se potrivesc
  - ▶ Valori mici atunci când nu se potrivesc


# Semnalul căutat



# Semnalul de dimensiuni mari



# Rezultatul corelației



- ▶ Determinarea răspunsului la impuls al unui sistem necunoscut, liniar și invariant în timp
- ▶ Se bazează pe corelația intrării cu ieșirea sistemului




Figure 1: System identification setup

$$\begin{aligned} R_{fg}(\tau) &= \overline{f[n]g[n + \tau]} \\ &= f[n] \sum_{k=-\infty}^{\infty} h[k]f[n + \tau - k] \\ &= \sum_{k=-\infty}^{\infty} h[k]\overline{f[n]f[n + \tau - k]} \\ &= \sum_{k=-\infty}^{\infty} h[k]R_{ff}[\tau - k] \\ &= h[\tau] * R_{ff}[\tau] \end{aligned}$$

- Dacă intrarea  $f$  este **zgomot alb** cu puterea  $A$ ,  $R_{ff}[n] = A \cdot \delta[n]$ , și

$$R_{fg}(\tau) = h[\tau] * R_{ff}[\tau] = A \cdot h[\tau] * \delta[\tau] = A \cdot h[\tau]$$

- Corelația măsurată este proporțională cu răspunsul la impuls al sistemului necunoscut