

Decizie și Estimare în Prelucrarea Informației

## Capitolul II. Elemente de teorie statistică a detecției

## II.1 Introducere

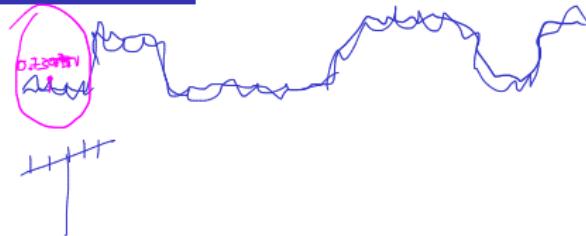
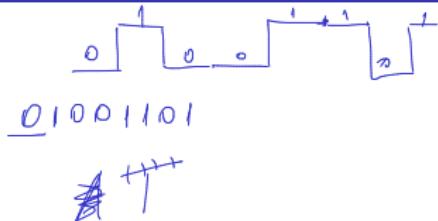
# Introducere

$$0: \Delta_0(t) = 0$$

$$1: \Delta_L(t) = 5$$

$$0: 0\text{ V}$$

$$1: 5\text{ V}$$



- ▶ Detectia semnalelor = a decide care semnal este prezent dintre două sau mai multe posibilități

- ▶ inclusiv că nu există nici un semnal (este 0)

- ▶ Avem la dispoziție observații cu zgomot

- ▶ semnalele sunt afectate de zgomot
  - ▶ zgomotul este aditiv (se adună la semnalul original)

# Contextul problemei de decizie


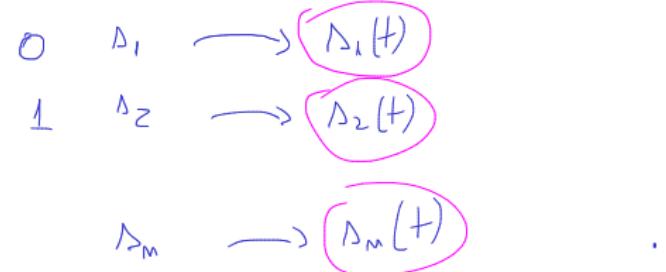


Figure 1: Schema bloc a unui sistem de comunicație



## ► Schema bloc a unui sistem de comunicație:

- Sursa de informație: generează mesajele  $a_n$  cu probabilitățile  $p(a_n)$
- Generator: generează semnalele diferite  $s_1(t), \dots, s_n(t)$
- Modulator: transmite semnalul  $s_n(t)$  la mesajul  $a_n$
- Canal: adaugă zgomot aleator
- Eșantionare: ia eșantioane din semnalul  $s_n(t)$
- Receptor: decide ce mesaj  $a_n$  s-a fost recepționat
- Utilizator: primește mesajele recuperate

$$R(t) = \Delta(t) + z_{\text{zgomot}}(t)$$

# Scenarii practice

## ► Transmisie de date cu diverse modulații binare:

- ▶ nivele constante de tensiune (de ex.  $s_n(t) = \text{constant } 0 \text{ sau } 5V$ )
- ▶ modulație PSK (Phase Shift Keying):  $s_n(t) = \cos(\omega t + \phi)$  cu aceeași frecvență dar faze inițiale diferite
- ▶ modulație FSK (Frequency Shift Keying):  $s_n(t) = \cos(\omega_1 t + \phi_1)$  sau  $\cos(\omega_2 t + \phi_2)$  cu frecvențe diferite
- ▶ modulație OFDM (Orthogonal Frequency Division Multiplexing): caz particular de FSK
- ▶ la recepție se primește semnalul cu zgomot, **se decide** dacă s-a primit 0 sau 1

$$0 \text{ logic} : s_1(t) = 0V$$

$$1 \text{ logic} : s_2(t) = 5V$$

$$0 \text{ logic} : s_1(t) = \cos(2\pi f_1 t)$$

$$1 \text{ logic} : s_2(t) = \cos(2\pi f_2 t)$$

$$\cos(2\pi f_1 t)$$

$$\cos(2\pi f_2 t)$$

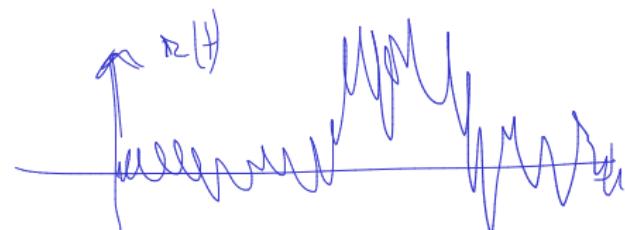
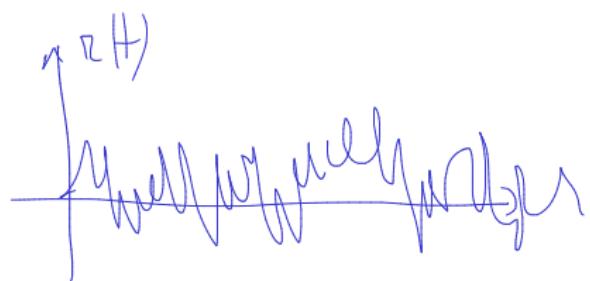
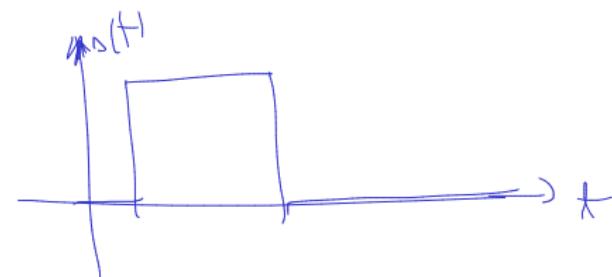
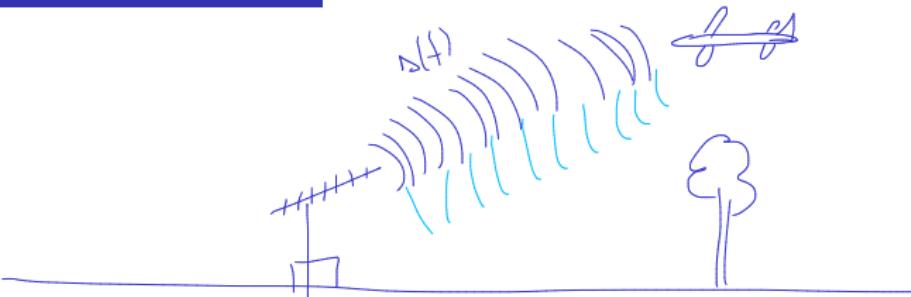
$$\cos(2\pi f_3 t)$$

Loc recepție

# Scenarii practice

## ► Detectii radar

- ▶ se emite un semnal; în cazul unui obstacol, semnalul se reflectă înapoi
- ▶ receptorul aşteaptă posibilele reflectii ale semnalului emis și decide
  - ▶ nu este prezentă o reflectie -> nici un obiect
  - ▶ semnalul reflectat este prezent -> obiect detectat



- ▶ Decizie între mai mult de două semnale
- ▶ Numărul de eșantioane (observații):
  - ▶ un singur eșantion
  - ▶ mai multe eșantioane
  - ▶ observarea întregului semnal continuu, pentru un timp  $T$

## II.2 Detectia semnalelor folosind 1 esantion

## Detectia unui semnal cu 1 esantion

- Cel mai simplu caz: detectia (decizia) folosind un singur esantion

- două mesaje  $a_0$  și  $a_1$  (0 logic sau 1 logic)
- mesajele sunt modulate cu semnalele  $s_0(t)$  și  $s_1(t)$ 
  - pentru  $a_0$ : se transmite  $s(t) = s_0(t)$
  - pentru  $a_1$ : se transmite  $s(t) = s_1(t)$

- peste semnal se suprapune zgomotul  $n(t)$
- se receptionează un semnal cu zgomot,  $r(t) = \underline{s(t)} + \underline{n(t)}$
- la receptie: se preia un singur esantion la timpul  $t_0$ ,  $\boxed{r = r(t_0)}$
- decizie: pe baza  $r(t_0)$ , care semnal a fost cel transmis?

0 : 0 V

1 : 5 V

$r = 1.73 \text{ V}$

$$s(t) = \begin{cases} s_0(t) \\ s_1(t) \end{cases} \text{ sau}$$

Am nășterea expunție în

- ▶ Există două ipoteze:
  - ▶  $H_0$ : semnalul adevărat este  $s(t) = s_0(t)$  (s-a transmis  $a_0$ )
  - ▶  $H_1$ : semnalul adevărat este  $s(t) = s_1(t)$  (s-a transmis  $a_1$ )
- ▶ Receptorul poate lua una din **două decizii**:
  - ▶  $D_0$ : receptorul decide că semnalul corect este  $s(t) = s_0(t)$
  - ▶  $D_1$ : receptorul decide că semnalul corect este  $s(t) = s_1(t)$

# Rezultate posibile

- Există 4 situații posibile:

1. **Rejecție corectă**: ipoteza corectă este  $H_0$ , decizia este  $D_0$

- ▶ Probabilitatea este  $P_r = P(D_0 \cap H_0)$
- ▶ "True Negative"

2. **Alarmă falsă**: ipoteza corectă este  $H_0$ , decizia este  $D_1$

- ▶ Probabilitatea este  $P_{af} = P(D_1 \cap H_0)$
- ▶ "False Positive"

3. **Pierdere**: ipoteza corectă este  $H_1$ , decizia este  $D_0$

- ▶ Probabilitatea este  $P_p = P(D_0 \cap H_1)$
- ▶ "False Negative"

4. **Detectie corectă**: ipoteza corectă este  $H_1$ , decizia este  $D_1$

- ▶ Probabilitatea este  $P_d = P(D_1 \cap H_1)$
- ▶ "True Positive"

► Terminologia are la origine aplicații radar:

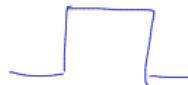
- ▶ un semnal se emite de către sursă
- ▶ semnal recepționat = o posibilă reflectie din partea unei ținte, puternic afectată de zgomot
- ▶  $H_0$  = nu există un obiect, nu există semnal reflectat (doar zgomot)
- ▶  $H_1$  = există un obiect, există un semnal reflectat
- ▶ de aici numele “alarmă falsă”, “pierdere” etc.

# Zgomotul

- În general se consideră zgomot **aditiv, alb, staționar**

$$r(t) = s(t) + \text{zgomot}(t)$$

- aditiv = zgomotul se adună cu semnalul



- alb = eșantioane distincte sunt necorelate



- staționar = are aceleasi proprietati statistice la orice moment de timp

- Semnalul de zgomot  $n(t)$  este necunoscut

- este o realizare a unui proces aleator



- se cunoaste doar distribuția sa, nu și valorile particulare

## Eşantionul preluat la recepție

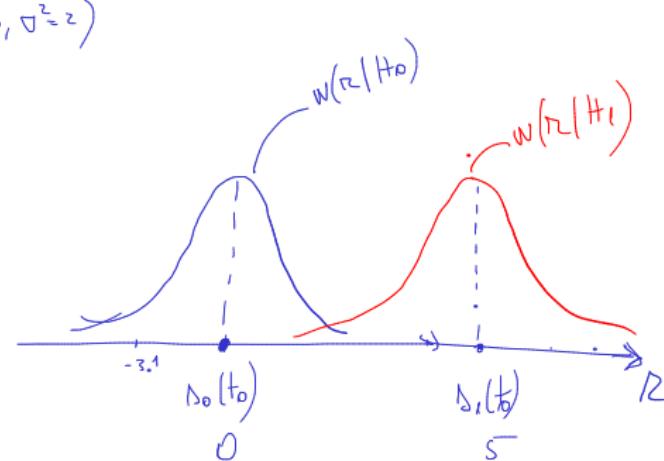

- ▶ La recepție se primește semnalul  $r(t) = s(t) + n(t)$ 
  - ▶  $s(t)$  = semnalul original, fie  $s_0(t)$ , fie  $s_1(t)$
  - ▶  $n(t)$  = semnalul de zgomot necunoscut
- ▶ Valoarea eşantionului luat la momentul  $t_0$  este  $\overset{R}{r}(t_0) = s(t_0) + \underset{\text{a }}{\textcircled{n}}(t_0)$ 
  - ▶  $s(t_0)$  = fie  $s_0(t_0)$ , fie  $s_1(t_0)$
  - ▶  $n(t_0)$  este un eşantion din semnalul de zgomot  $=$  o variabilă aleatorie

- ▶ Eșantionul  $n(t_0)$  este o variabilă aleatoare
  - ▶ fiind un eșantion de zgomot (un eșantion dintr-un proces aleator)
  - ▶ v.a. continuă, intervalul valorilor posibile e continuu
- ▶  $r(t_0) = s(t_0) + n(t_0)$  = o constantă + o variabilă aleatoare
  - ▶ este de asemenea o variabilă aleatoare
  - ▶  $s(t_0)$  este o constantă, egală fie cu  $\underline{s_0(t_0)}$ , fie cu  $\underline{s_1(t_0)}$
- ▶ Care e distribuția lui  $r(t_0)$ ?
  - ▶ o constantă + o v.a. = aceeași distribuție ca v.a., dar translată cu valoarea constantei

# Functii de plauzibilitate

$H_0$

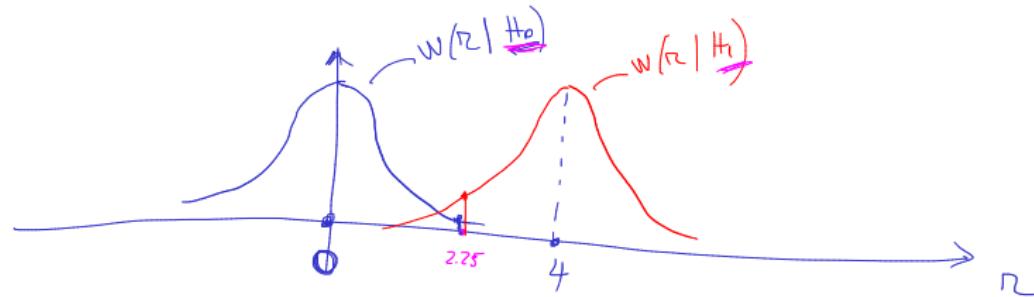
- ▶ Fie distribuția zgromotului cunoscută,  $w(x)$
- ▶ Distribuția lui  $r$  este  $w(x)$  translată cu  $s(t_0)$
- ▶ În ipoteza  $H_0$ , distribuția eșantionului este  $w(r|H_0) = w(x)$  translată cu  $s_0(t_0)$
- ▶ În ipoteza  $H_1$ , distribuția eșantionului este  $w(r|H_1) = w(x)$  translată cu  $s_1(t_0)$
- ▶  $w(r|H_0)$  și  $w(r|H_1)$  se numesc **distribuții conditionate** sau **funcțiile de plauzibilitate**
  - ▶ “|” înseamnă “conditionat de”, “dat fiind”
  - ▶ adică dat fiind una sau cealaltă dintre ipoteze
  - ▶  $r$  reprezintă necunoscuta funcției



$$H_0: \text{Dacă } s_0 \text{ transmis } s_0(t) \Rightarrow r = s_0(t_0) + \text{zgromot}$$

$$H_1: \text{Dacă } s_1 \text{ transmis } s_1(t) \Rightarrow r = s_1(t_0) + \text{zgromot}$$

# Functii de plauzibilitate



Exemplu:

- Un semnal constant  $s(t)$  poate avea două valori posibile, 0 sau 4. Semnalul este afectat de zgomot  $\mathcal{N}(\mu = 0, \sigma^2 = 2)$ . Care e distribuția unui eșantion  $r$ , în ambele ipoteze?

$$r = s(t) + \text{zgomot}$$

\ / \ /

fie 0    fie 4

Decizie pe baza celor două distribuții:

- ▶ Avem două distribuții posibile (câte una în fiecare ipoteză)
- ▶ Avem un eşantion  $r = r(t_0)$ , care poate proveni din oricare distribuție       $= 2.25$
- ▶ Care ipoteză **decidem** a fi adevărată?

## Plauzibilitatea unui parametru

- În general, plauzibilitatea (likelihood) unui parametru  $P$  pe baza unor **observații**  $O$  = densitatea de probabilitate a lui  $O$ , dacă parametrul are valoarea  $P$ :

$$\underline{L(P|O)} = w(O|P)$$

- În cazul nostru:
  - parametrul necunoscut = care ipoteză  $H$  este cea adevărată
  - observațiile = eșantionul  $r$
- **Plauzibilitatea unei ipoteze  $H$  pe baza observației  $r$  este:**

Plauzib. ipotezei  $H_0$  =  $L(H_0|r)$  =  $w(r|H_0)$  = Prob. lui  $r$ , presupunând că  $H_0$  e adevărată

$$L(H_1|r) = w(r|H_1)$$

## Criteriul plauzibilității maxime (Maximum Likelihood)

- ▶ **Criteriul plauzibilității maxime** ("Maximum Likelihood"): se alege ipoteza cu cea mai mare plauzibilitate de a fi generat eșantionul observat  $r = r(t_0)$

- ▶ "alegem ipoteza cea mai plauzibilă"
- ▶ "se alege ipoteza cu plauzibilitatea mai mare"

$L = \frac{\text{plauzibilitate}}{L}$

$$\frac{L(H_1|r)}{L(H_0|r)} = \frac{w(r|H_1)}{w(r|H_0)} \stackrel{H_1}{\gtrless} 1 \stackrel{H_0}{\lessgtr} 1$$

- ▶ Se alege valoarea maximă dintre  $w(r(t_0)|H_0)$  și  $w(r(t_0)|H_1)$
- ▶ Se compară **raportul de plauzibilitate** cu 1

$$\frac{L(H_1|r)}{L(H_0|r)} = \frac{w(r|H_1)}{w(r|H_0)}$$

Report de plauzibilitate

Decizie  $H_1$ ,  $H_1 > H_0$

## Exemplu: zgomot gaussian

PM


Exemplu (continuare):

- ▶ Un semnal constant  $s(t)$  poate avea două valori posibile, 0 sau 4. Semnalul este afectat de zgomot  $\mathcal{N}(\mu = 0, \sigma^2 = 2)$ .

- ▶ Care e decizia luată cu criteriul ML, pentru un eşantion  $r = 1.6$ ?

- ▶ La tablă:

- ▶ schită a celor două distribuții conditionate  $w(r|H_0)$  și  $w(r|H_1)$
- ▶ discuție: ce decizie se ia pentru diferite valori ale lui  $r$
- ▶ discuție: care este pragul  $T$  pentru decizii



Exemplu: Frunze

Din care copac a căzut frunza?




?




## Exemplu: Frunze

Alegem copacul cu **plauzibilitatea maximă**:



$\Rightarrow D_1$



# Zgomot cu distribuție normală (AWGN)

- ▶ Caz particular: zgomotul are distribuția normală  $\mathcal{N}(0, \sigma^2)$

- ▶ zgomot de tip AWGN

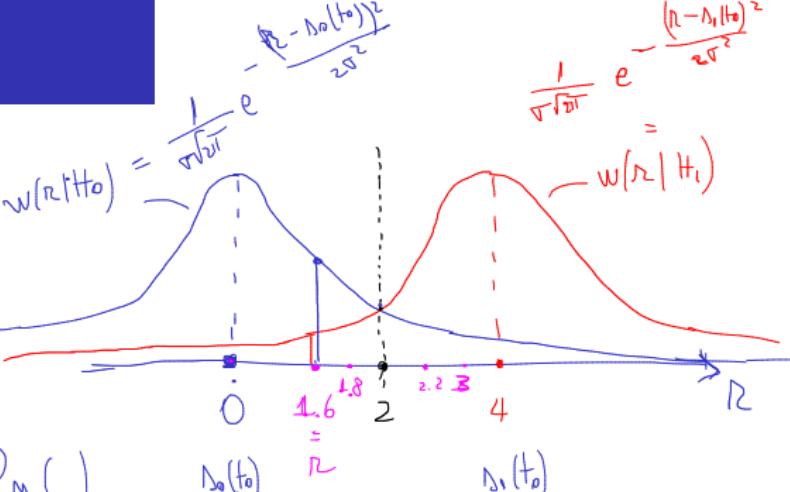
- ▶ Raportul de plauzibilitate este  $\frac{w(r|H_1)}{w(r|H_0)} = \frac{e^{-\frac{(r-s_1(t_0))^2}{2\sigma^2}} H_1}{e^{-\frac{(r-s_0(t_0))^2}{2\sigma^2}} H_0} \geq 1$

- ▶ Pentru distribuția normală, e preferabil să aplicăm **logaritmul natural**

- ▶ logaritmul este o funcție monoton crescătoare, deci nu schimbă rezultatul comparației
- ▶ dacă  $A < B$ , atunci  $\log(A) < \log(B)$

$$\ln(\ ) - \ln(\ ) \stackrel{=0}{\geq} \ln(1) \quad \cdot 2\sigma^2$$

$$\frac{-(r-\mu_1(t_0))^2}{2\sigma^2} + \frac{(r-\mu_0(t_0))^2}{2\sigma^2} \geq 0$$



## Zgomot cu distribuție normală (AWGN)

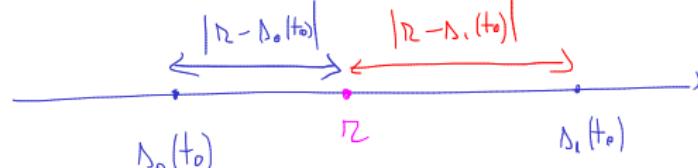
- ▶ Aplicarea logaritmului natural la ambii termeni ai relației conduce la:

$$-(r - s_1(t_0))^2 + (r - s_0(t_0))^2 \stackrel{H_1}{\underset{H_0}{\gtrless}} 0$$

$$\left[ \left( r - s_0(t_0) \right)^2 \stackrel{H_1}{\underset{H_0}{\gtrless}} \left( r - s_1(t_0) \right)^2 \right] \quad \left[ \sqrt{\text{...}} \right]$$

- ▶ Care este echivalent cu:

$$|r - s_0(t_0)| \stackrel{H_1}{\underset{H_0}{\gtrless}} |r - s_1(t_0)|$$



- ▶ Notă:  $|r - A| = \text{distanța}$  dintre  $r$  și  $A$

▶  $|r| = \text{distanța de la } r \text{ la } 0$

- ▶ Așadar, se alege distanță minimă dintre  $r(t_0)$  și  $s_1(t_0)$  sau  $s_0(t_0)$

- ▶ Criteriul ML pentru zgomot gaussian: ipoteza se alege pe baza **celei mai apropiate** valori dintre  $s_0(t_0)$  și  $s_1(t_0)$  față de eșantionul  $r = r(t_0)$ 
  - ▶ principiul **cel mai apropiat vecin** ("nearest neighbor")
  - ▶ un principiu foarte general, întâlnit în multe alte scenarii
  - ▶ un receptor ce folosește ML se mai numește **receptor de distanță minimă** ("minimum distance receiver")

## Etape pentru decizia pe baza ML

1. Se schițează cele două distribuții condiționate  $w(r|H_0)$  și  $w(r|H_1)$
2. Se determină care dintre cele două funcții este mai mare în dreptul valorii eșantionului observat  $r = r(t_0)$

## Etape pentru decizia pe baza ML, zgromot gaussian

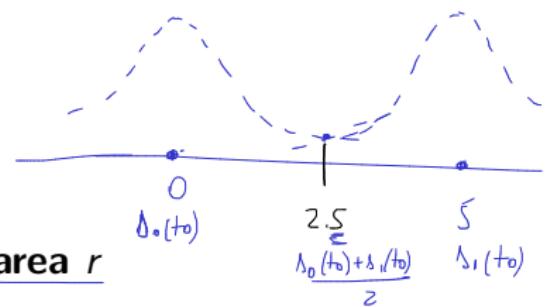
- ▶ Doar dacă zgromotul este gaussian, identic pentru toate ipotezele:
  1. Se determină  $s_0(t_0)$  = valoarea semnalului original, în absența zgromotului, în cazul ipotezei  $H_0$
  2. Se determină  $s_1(t_0)$  = valoarea semnalului original, în absența zgromotului, în cazul ipotezei  $H_1$
  3. Se compară cu eșantionul observat  $r(t_0)$ , se alege cea mai apropiată valoare

## Decizie pe bază de prag

- ▶ Alegerea valorii celei mai apropiate = același lucru cu compararea r cu un prag  $T = \frac{s_0(t_0) + s_1(t_0)}{2}$

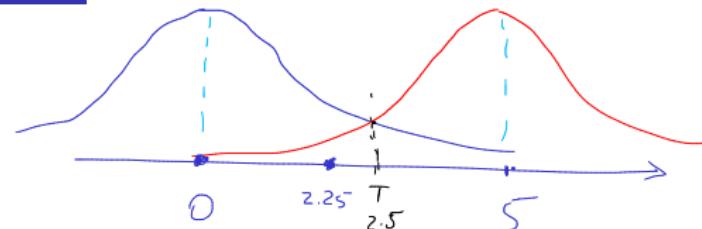
▶ i.e. dacă cele două valori sunt 0 și 5, luăm o decizie prin compararea lui  $r$  cu 2.5

- ▶ La criteriul ML , pragul = punctul de intersecție al celor două distribuții conditionate



## Exercițiu

- Un semnal poate avea două valori posibile, 0 sau 5. Semnalul este afectat de zgomot alb, gaussian, cu distribuția  $\mathcal{N}(\mu = 0, \sigma^2 = 2)$ . Receptorul ia un singur eșantion, cu valoarea  $r = 2.25$




$\rightarrow D_0$

- Scriți expresiile celor două distribuții condiționate, și reprezentați-le
- Ce decizie se ia pe baza criteriului plauzibilității maxime?
- Dar dacă semnalul 0 este afectat de zgomot gaussian  $\mathcal{N}(0, 0.5)$ , iar semnalul 5 de zgomot uniform  $U[-4, 4]$ ?
- Repetați b. și c. dacă valoarea 0 se înlocuiește cu -1

$$W(r|H_0) = \frac{1}{\sqrt{2\pi}} e^{-\frac{(r-0)^2}{2\sigma^2}}$$

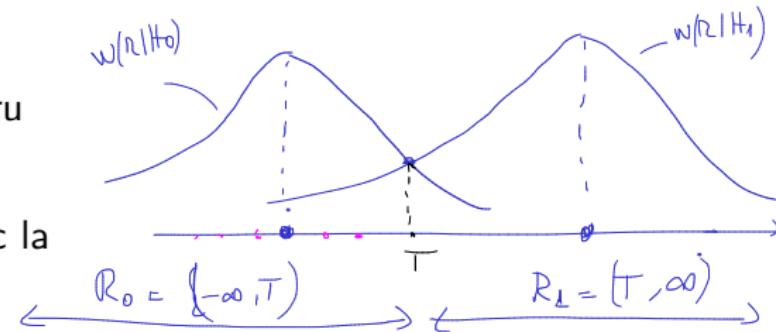
$$\geq \frac{1}{8}$$



# Regiuni de decizie

- ▶ **Regiuni de decizie** = intervalul de valori ale eșantionului  $r$  pentru care se ia o anumită decizie
- ▶ Regiunea de decizie  $R_0$  = intervalul de valori ale lui  $r$  care conduc la decizia  $D_0$
- ▶ Regiunea de decizie  $R_1$  = intervalul de valori ale lui  $r$  care conduc la decizia  $D_1$
- ▶ Regiunile de decizie acoperă întreg domeniul de valori ale lui  $r$  (toată axa reală)
- ▶ Exemplu: indicați regiunile de decizie la exercițiul anterior

- ▶  $R_0 = [-\infty, 2.5]$
- ▶  $R_1 = [2.5, \infty]$



## Plauzibilitate vs probabilitate

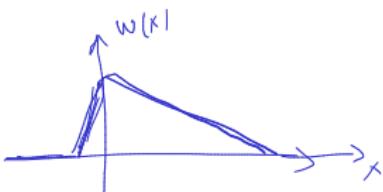
- ▶ Distincție subtilă între termenii “probabilitate” și “plauzibilitate”
- ▶ Să considerăm distribuția condiționată  $w(r|H_i)$  de la exemplul anterior:

$$\frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(r - s_i(t_0))^2}{2\sigma^2}}$$


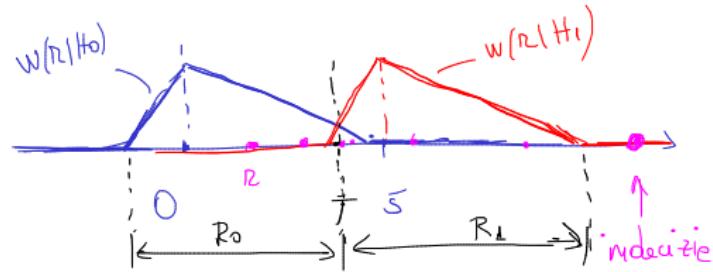
- ▶ Care este necunoscută în această expresie?
  - ▶ În general,  $r$
  - ▶ dar în cazul deciziei noastre este  $i$ , iar  $r$  este cunoscut

- ▶ Pentru aceeași expresie matematică a funcției de distribuție:
  - ▶ dacă se cunosc parametrii statistici (de ex.  $\mu, \sigma, H_i$ ), și necunoscuta este valoarea însăși (de ex.  $r, x$ ) atunci funcția o interpretăm ca densitatea de **probabilitate**
  - ▶ dacă se cunoaște valoarea însăși (de ex.  $r, x$ ), și necunoscuta este un parametru statistic (de ex.  $\mu, \sigma, i$ ), atunci avem o **funcție de plauzibilitate**

## Generalizări




- ▶ Dacă zgomotul are altă distribuție?
  - ▶ Se schițează distribuțiile condiționate
  - ▶ Se evaluatează pentru  $r = r(t_0)$
  - ▶ Criteriul ML = se alege cea mai mare funcție  $w(r|H_i)$  în punctul  $r$  dat
- ▶ Regiunile de decizie sunt date de **punctele de intersecție** ale distribuțiilor condiționate
  - ▶ Pot fi mai multe intersectări, în general, deci mai multe praguri



- ▶ Dacă zgomotul are distribuție diferită în ipoteza  $H_0$  față de ipoteza  $H_1$ ?
- ▶ Similar:

- ▶ Se schițează distribuțiile condiționate
- ▶ Se evaluatează pentru  $r = r(t_0)$
- ▶ Criteriul ML = se alege **cea mai înaltă funcție**  $w(r|H_i)$  în punctul  $r$  dat



# Generalizări

$$s_0 = 0 \quad s_1 = 5$$

$$s_0 = \cos(2\pi 0.3t) \quad s_1 = \sin(2\pi 0.3t)$$


- ▶ Dacă cele două semnale  $s_0(t)$  și  $s_1(t)$  sunt constante / nu sunt constante?
- ▶ Nu contează forma semnalelor
- ▶ Tot ce contează sunt **valorile celor două semnale la momentul de eșantionare  $t_0$** :

▶  $s_0(t_0) = A$   
 ▶  $s_1(t_0) = B$

$$s_0(t) = \cos(2\pi f t) \Rightarrow$$


$$s_1(t) = \sin(2\pi f t) \Rightarrow$$

$$t_{t_0} = 0.38c.$$



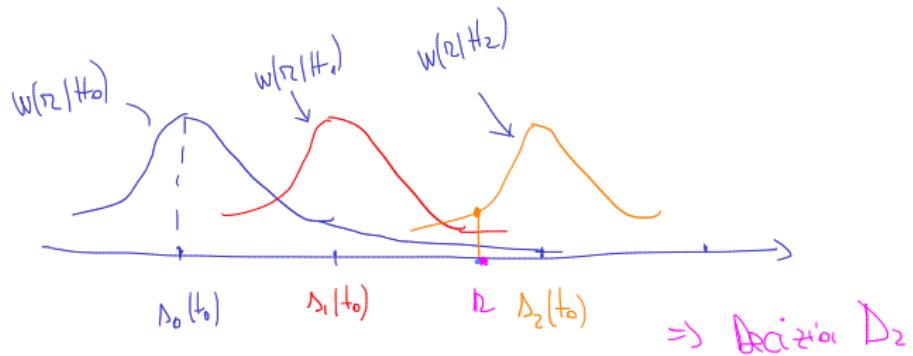
$$s_0(t_0) = \cos(2\pi f t_0) =$$

$$s_1(t_0) = \sin(2\pi f t_0) =$$



# Generalizări

- ▶ Dacă avem mai mult de 2 ipoteze?
- ▶ Se extinde raționamentul la  $n$  ipoteze
  - ▶ Avem  $n$  semnale posibile  $s_0(t), \dots, s_{n-1}(t)$
  - ▶ Avem  $n$  valori diferențiale  $s_0(t_0), \dots, s_{n-1}(t_0)$
  - ▶ Avem  $n$  distribuții condiționate  $w(r|H_i)$
  - ▶ Se alege distribuția  $w(r|H_i)$  **cea mai înaltă** pentru  $r = r(t_0)$  dat



- ▶ Dacă se iau mai multe eșantioane din semnale?
- ▶ Va fi tratat separat într-un subcapitol ulterior

## Multiple separate detection

- ▶ Într-un proces de comunicație, fiecare detectie/decizie produce valoarea unui bit (mesaj)
- ▶ Se repetă o altă detectie separată pentru bitul (mesajul) următor, și tot așa

## La Seminar

- Un semnal poate avea patru valori posibile: -6, -2, 2, 6. Fiecare valoare este transmisă timp de o secundă. Semnalul este afectat de zgomot alb cu distribuție normală. Receptorul ia un singur eșantion pe secundă. Folosind criteriul plauzibilității maxime, decideți ce semnal s-a transmis, dacă receptorul primește eșantioanele următoare:

4, 6.6, -5.2, 1.1, 0.3, -1.5, 7, -7, 4.4

# Probabilități condiționate

- ▶ Putem calcula **probabilitățile condiționate** ale celor 4 rezultate posibile

- ▶ Fie regiunile de decizie:

- ▶  $R_0$ : dacă  $r \in R_0$ , decizia este  $D_0$
- ▶  $R_1$ : dacă  $r \in R_1$ , decizia este  $D_1$

- ▶ Probabilitatea condiționată a rejectiei corecte


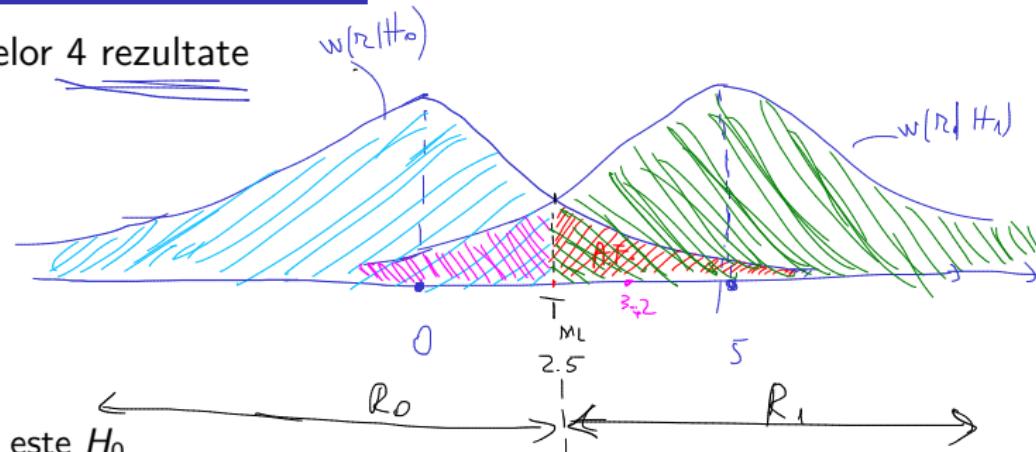
- ▶ = probabilitatea de a lua decizia  $D_0$  când ipoteza este  $H_0$
- ▶ = probabilitatea ca  $r$  să fie în  $R_0$ , calculată pe distribuția  $w(r|H_0)$

$$P(D_0|H_0) = \int_{R_0} w(r|H_0) dx$$

- ▶ Probabilitatea condiționată a alarmei false

- ▶ = probabilitatea de a lua decizia  $D_1$  când ipoteza este  $H_0$
- ▶ = probabilitatea ca  $r$  să fie în  $R_1$ , calculată pe distribuția  $w(r|H_0)$

$$P(D_1|H_0) = \int_{R_1} w(r|H_0) dx$$



## ▶ Probabilitatea condiționată de pierdere

- ▶ = probabilitatea de a lua decizia  $D_0$  când ipoteza este  $H_1$
- ▶ = probabilitatea ca  $r$  să fie în  $R_0$ , calculată pe distribuția  $w(r|H_1)$

$$P(D_0|H_1) = \int_{R_0} w(r|H_1) dx$$

## ▶ Probabilitatea condiționată a detectiei corecte

- ▶ = probabilitatea de a lua decizia  $D_1$  când ipoteza este  $H_1$
- ▶ = probabilitatea ca  $r$  să fie în  $R_1$ , calculată pe distribuția  $w(r|H_1)$

$$P(D_1|H_1) = \int_{R_1} w(r|H_1) dx$$

- ▶ Relații între probabilitățile condiționate
  - ▶ suma  $P(D_0|H_0) + P(D_1|H_0) = 1$  (rejecție corectă + alarmă falsă)
  - ▶ suma  $P(D_0|H_1) + P(D_1|H_1) = 1$  (pierdere + detectie corectă)
  - ▶ De ce? Justificați.

# Probabilități condiționate

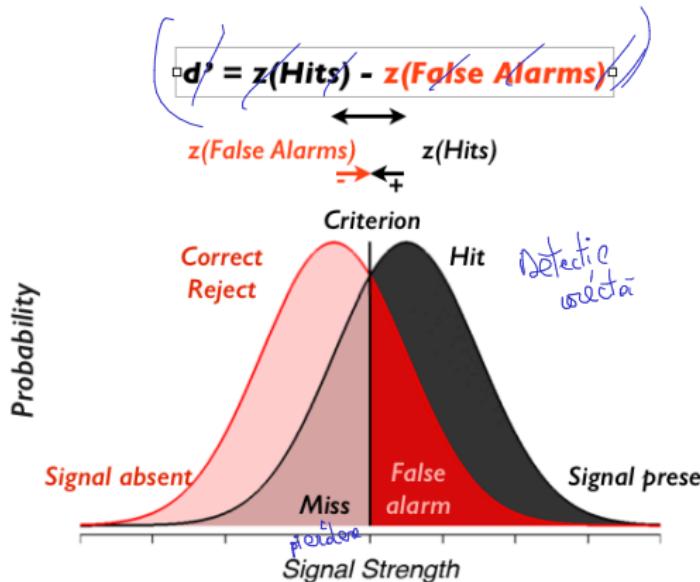


Figure 2: Probabilități condiționate

- ▶ Ignorați textul, contează zonele colorate
- ▶ [sursa: <http://gru.stanford.edu/doku.php/tutorials/sdt>]\*

## Probabilitățile celor 4 rezultate

- ▶ Probabilitățile condiționate sunt calculate **dat fiind** una sau alta dintre ipoteze

- ▶ Nu includ și probabilitățile **ipotezelor înselor**

- ▶ adică,  $P(H_0)$  = probabilitatea de a avea ipoteza  $H_0$
  - ▶  $P(H_1)$  = probabilitatea de a avea ipoteza  $H_1$

- ▶ Pentru a le lua în calcul, se multiplică cu  $P(H_0)$  sau  $P(H_1)$

- ▶  $P(H_0)$  și  $P(H_1)$  se numesc probabilitățile **inițiale** (sau **a priori**) ale ipotezelor

$$P(D_1 \cap H_1) = P(D_1 | H_1) \cdot P(H_1)$$

# Reamintire (TCI): regula lui Bayes

## ► Reamintire (TCI): regula lui Bayes

$$P(A \cap B) = P(B|A) \cdot P(A)$$

si  
„condiționat de”  
„deacă”

## ► Interpretare:

- ▶ Probabilitatea  $P(A)$  este extrasă afară din din  $P(B|A)$
- ▶  $P(B|A)$  nu mai conține nici o informație despre  $P(A)$ , sănsele ca  $A$  chiar să aibă loc
- ▶ Exemplu:  $P(\text{gol} | \text{"șut la poartă"}) = \frac{1}{2}$ . Câte goluri se înscriv?

## ► La noi:

$$P(D_i \cap H_j) = P(D_i|H_j) \cdot P(H_j)$$

- ▶ pentru toți  $i$  și  $j$  (în toate cele 4 cazuri)

$$\begin{aligned} P(B|A) &= \frac{P(A \cap B)}{P(A)} \\ &= \frac{P(A|B) \cdot P(B)}{P(A)} \end{aligned}$$

$$P(B|A) \cdot P(A)$$

## Exercițiu

$$\frac{P(D_i | H_j)}{P(D_i \cap H_j)} = P(D_i | H_j) \cdot \underset{\text{"si' }}{P(H_j)}$$

- Un semnal constant poate avea două valori posibile, 0 sau 5.

Semnalul este afectat de zgomot gaussian  $\mathcal{N}(\mu = 0, \sigma^2 = 2)$ .

Receptorul decide pe baza criteriului plauzibilității maxime, folosind un singur eșantion din semnal.

a. Calculați probabilitatea condiționată a alarmei false

$$P(D_1 | H_0)$$

b. Calculați probabilitatea condiționată de pierdere

$$P(D_0 | H_1)$$

c. Dacă  $P(H_0) = \frac{1}{3}$  și  $P(H_1) = \frac{2}{3}$ , calculați probabilitatea rejecției corecte și a detectiei corecte (nu cele condiționate)

$$P(D_0 | H_0) \cdot \underline{\underline{P(H_0)}}$$

$$\underline{\underline{P(D_1 | H_1) \cdot P(H_1)}}$$

## Dezavantaje ale criteriului plauzibilității maxime

w( $n | \quad$ )


- ▶ Criteriul ML compară distribuțiile conditionate ale eșantionului observat
  - ▶ conditionate de ipotezele  $H_0$  sau  $H_1$
- ▶ Condiționarea de ipotezele  $H_0$  și  $H_1$  ignoră probabilitatea celor două ipoteze  $H_0$  și  $H_1$ 
  - ▶ Decizia e aceeași indiferent dacă  $P(H_0) = 99.99\%$  și  $P(H_1) = 0.01\%$ , sau invers
- ▶ Dacă  $P(H_0) > P(H_1)$ , am vrea să împingem pragul de decizie înspre  $H_1$ , și vice-versa
  - ▶ pentru că este mai probabil ca semnalul să fie  $s_0(t)$
  - ▶ și de aceea vrem să “favorizăm”/“încurajăm” decizia  $D_0$
- ▶ Avem nevoie de un criteriu mai general . . .

## Exemplu: Terenuri de fotbal


$$P(H_0) = \frac{1}{7}$$

$$w(n \mid H_0) \cdot P(H_0)$$


$$w(r \mid H_1) \cdot P(H_1)$$



$$P(H_1) = \frac{6}{7}$$



TODO



## Criteriul probabilității minime de eroare

- ▶ Se iau în calcul probabilitățile  $P(H_0)$  și  $P(H_1)$
- ▶ Se urmărește minimizarea probabilității totale de eroare

$$P_e = P_{af} + P_p \quad = \quad P(D_1 \cap H_0) + P(D_0 \cap H_1)$$

- ▶ erori = alarmă falsă și pierdere
- ▶ Trebuie să găsim un nou criteriu
  - ▶ adică, alte regiuni de decizie  $R_0$  și  $R_1$

# Probabilitatea de eroare

- ▶ Probabilitatea unei alarme false este:

$$\begin{aligned} P(D_1 \cap H_0) &= P(D_1|H_0) \cdot P(H_0) \\ &= (1 - P(D_0|H_0)) \cdot P(H_0) = \int_{R_1} w(r|H_0) dx \cdot P(H_0) \\ &= (1 - \int_{R_0} w(r|H_0) dx) \cdot P(H_0) = P(H_0) - P(H_0) \cdot \int_{R_0} w(r|H_0) dx \end{aligned}$$

- ▶ Probabilitatea de pierdere este:

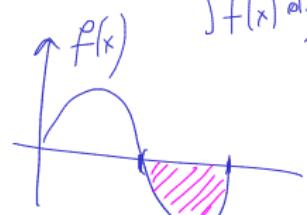
$$\begin{aligned} P(D_0 \cap H_1) &= P(D_0|H_1) \cdot P(H_1) \\ &= \int_{R_0} w(r|H_1) dx \cdot P(H_1) \end{aligned}$$

$$R_0 = (-\infty, T]$$

$$\int f(x) dx$$

- ▶ Probabilitatea totală a erorilor (suma lor) este:

$$P_e = P(H_0) + \int_{-\infty}^T [w(r|H_1) \cdot P(H_1) - w(r|H_0) \cdot P(H_0)] dx \leftarrow \text{Vream minimum!}$$



## Probabilitatea de eroare minimă

- ▶ Urmărim minimizarea  $P_e$ , adică să minimizăm integrala
- ▶ Putem alege  $R_0$  cum dorim, pentru acest scop
- ▶ Pentru a minimiza integrala, se alege  $R_0$  astfel încât pentru toți  $r \in R_0$ , termenul din integrala este **negativ**
  - ▶ integrarea pe întregul interval în care o funcție este negativă conduce la valoarea minimă
- ▶ Așadar, când  $w(r|H_1) \cdot P(H_1) - w(r|H_0) \cdot P(H_0) < 0$  avem  $r \in R_0$ , adică decizia  $D_0$
- ▶ Invers, dacă  $w(r|H_1) \cdot P(H_1) - w(r|H_0) \cdot P(H_0) > 0$  avem  $r \in R_1$ , adică decizia  $D_1$
- ▶ Astfel

$$w(r|H_1) \cdot P(H_1) - w(r|H_0) \cdot P(H_0) \stackrel{H_1}{\geqslant} 0$$
$$\frac{w(r|H_1)}{w(r|H_0)} \stackrel{H_1}{\geqslant} \frac{P(H_0)}{P(H_1)}$$

## Criteriul probabilității minime de eroare

$$P(H_0) = P(H_1) = \frac{1}{2} \Rightarrow M.L.$$

### ► Criteriul probabilității minime de eroare (MPE):

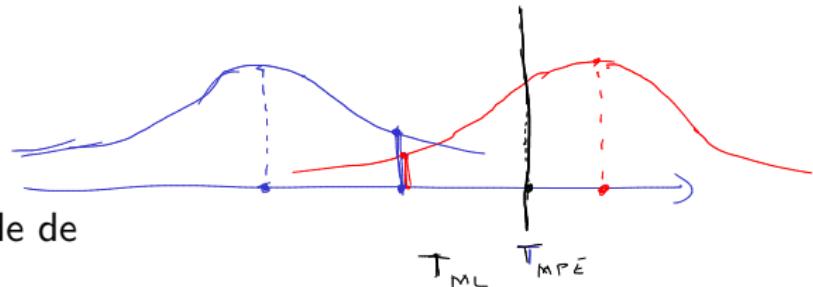
$$\left[ \frac{w(r|H_1)}{w(r|H_0)} \stackrel{H_1}{\gtrless} \frac{P(H_0)}{P(H_1)} \right]$$

(=)

$$\left[ \frac{\frac{w(r|H_1) \cdot P(H_1)}{w(r|H_0) \cdot P(H_0)}}{\frac{w(r|H_0) \cdot P(H_0)}{w(r|H_1) \cdot P(H_1)}} \stackrel{H_1}{\gtrless} \frac{1}{1} \right]$$

### ► prescurtat MPE (Minimum Probability of Error)

- ▶ Criteriul MPE este o generalizare a criteriului ML, depinde de probabilitățile celor două ipoteze (cazuri, simboluri)
  - ▶ se exprimă tot sub forma unui raport de plauzibilitate
- ▶ Când una dintre ipoteze este mai probabilă decât cealaltă, pragul este împins în favoarea sa, înspre cealaltă ipoteză
- ▶ Criteriul ML este un caz particular al MPE pentru for  
 $P(H_0) = P(H_1) = \frac{1}{2}$



$$\begin{array}{c} P(H_0) > P(H_1) \\ 4/5 \qquad \qquad \qquad 1/5 \end{array}$$

## Criteriul probabilității minime de eroare - zgomot gaussian

- ▶ Presupunând că zgomotul este gaussian (normal),  $\mathcal{N}(0, \sigma^2)$

$$\frac{w(r|H_1)}{w(r|H_0)} = \frac{e^{-\frac{(r-s_1(t_0))^2}{2\sigma^2}}}{e^{-\frac{(r-s_0(t_0))^2}{2\sigma^2}}} \cdot \frac{1}{\sqrt{2\pi}} \cdot \frac{1}{\sqrt{2\pi}}$$

$$e^{\frac{(r-s_0(t_0))^2}{2\sigma^2} - \frac{(r-s_1(t_0))^2}{2\sigma^2}} \geq \frac{P(H_0)}{P(H_1)} \quad \left| \mu(\cdot) \right.$$

- ▶ Se aplică logaritmul natural

$$-\frac{(r-s_1(t_0))^2}{2\sigma^2} + \frac{(r-s_0(t_0))^2}{2\sigma^2} \stackrel{H_1}{\gtrless} \ln \left( \frac{P(H_0)}{P(H_1)} \right) \quad \left| \cdot 2\sigma^2 \right.$$

- ▶ Echivalent

$$(r-s_0(t_0))^2 \stackrel{H_1}{\gtrless} (r-s_1(t_0))^2 + 2\sigma^2 \cdot \ln \left( \frac{P(H_0)}{P(H_1)} \right)$$

- ▶ sau, dacă se desfac parantezele:

$$r \stackrel{H_1}{\gtrless} \frac{s_0(t_0) + s_1(t_0)}{2} + \frac{\sigma^2}{s_1(t_0) - s_0(t_0)} \cdot \ln \left( \frac{P(H_0)}{P(H_1)} \right)$$

## Interpretarea 1: Comparație între distanțe

- ▶ La criteriul ML, se compară distanțele (la pătrat):

$$\rightarrow |r - s_0(t_0)| \stackrel{H_1}{\underset{H_0}{\gtrless}} |r - s_1(t_0)|$$

$$\rightarrow (r - s_0(t_0))^2 \stackrel{H_1}{\underset{H_0}{\gtrless}} (r - s_1(t_0))^2$$

- ▶ La criteriul MPE, se compară pătratul distanțelor, dar cu un termen suplimentar în favoarea ipotezei mai probabile:

$$(r - \underline{s}_0(t_0))^2 \stackrel{H_1}{\underset{H_0}{\gtrless}} (r - \underline{s}_1(t_0))^2 + 2\sigma^2 \cdot \ln \left( \frac{P(H_0)}{P(H_1)} \right)$$

suplimentar

- ▶ termenul depinde de raportul  $\frac{P(H_0)}{P(H_1)}$

## Interpretarea 2: valoarea de prag

- ▶ La criteriul ML, se compară  $r$  cu un prag  $T$


$$r \stackrel{H_1}{\geq} \frac{s_0(t_0) + s_1(t_0)}{2}$$

- ▶ La criteriul MPE, pragul este împins înspre ipoteza mai puțin probabilă:

$$r \stackrel{H_1}{\geq} \frac{s_0(t_0) + s_1(t_0)}{2} + \underbrace{\frac{\sigma^2}{s_1(t_0) - s_0(t_0)} \cdot \ln \left( \frac{P(H_0)}{P(H_1)} \right)}_{\text{termen suplimentar}}$$

$\frac{P(H_0)}{P(H_1)}$


▶ În funcție de raportul  $\frac{P(H_0)}{P(H_1)}$   $T_{MPE}$



Depinde:



## Exerciții



$$P(H_0) = \frac{4}{5} \quad P(H_1) = \frac{1}{5}$$

► Fie decizia între două semnale constante:  $s_0(t) = -5$  și  $s_1(t) = 5$ .

Semnalele sunt afectate de zgomot alb cu distribuție gaussiană

$\mathcal{N}(0, \sigma^2 = 1)$  Receptorul ia un singur eșantion cu valoarea  $r$ .

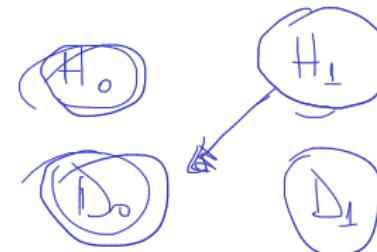
- Să se găsească regiunile de decizie conform criteriului MPE
- Calculați probabilitatea alarmei false și probabilitatea de pierdere
- Repetați a) și b) dacă  $s_1(t)$  este afectat de zgomot uniform  $\mathcal{U}[-4, 4]$ ?

a)  $T_{MPE} = \underbrace{\frac{-5 + 5}{2}}_{\text{mean}} + \frac{1}{5+5} \cdot \ln(4) = \frac{\ln(4)}{10} = \boxed{0.06}$

b)  $P_{of} = P(D_1 \cap H_0) = \underbrace{P(D_1 | H_0) \cdot P(H_0)}_{T_{ML}} = \int_{0.06}^{\infty} w(r | H_0) dr \cdot P(H_0)$   
 $P_p = P(D_0 \cap H_1) = \underbrace{P(D_0 | H_1) \cdot P(H_1)}_{T_{ML}} = \int_{-\infty}^{0.06} w(r | H_1) dr \cdot P(H_1)$

## Criteriul riscului minim

- ▶ Dacă ne afectează mai mult un anume tip de erori (de ex. alarme false) decât celelalte (pierderi)?
  - ▶ Criteriul MPE tratează toate erorile la fel
  - ▶ Ne trebuie un criteriu mai general
- ▶ Idee: se atribuie un cost fiecărui scenariu, apoi se minimizează costul mediu
- ▶  $C_{ij}$  = costul deciziei  $D_i$ ; când ipoteza adevărată este  $H_j$ 
  - ▶  $C_{00}$  = costul unei rejectii corecte
  - ▶  ~~$C_{10}$~~  = costul unei alarme false
  - ▶  ~~$C_{01}$~~  = costul unei pierderi
  - ▶  $C_{11}$  = costul unei detectii corecte
- ▶ Ideea de "costuri" și minimizarea costului mediu este general întâlnită
  - ▶ de ex. TCI: codare: "costul" unui mesaj este lungimea cuvântului de cod, vrem să minimizăm costul mediu, adică lungimea medie



## Criteriul riscului minim

$$R = C_{00} \cdot 25\% + C_{10} \cdot 5\% + C_{01} \cdot 2\% + C_{11} \cdot 68\%$$

- Definim riscul = **media costurilor**

$$R = \underbrace{C_{00}P(D_0 \cap H_0)}_{+} + \underbrace{C_{10}P(D_1 \cap H_0)}_{+} + \underbrace{C_{01}P(D_0 \cap H_1)}_{+} + \underbrace{C_{11}P(D_1 \cap H_1)}_{+}$$

- Criteriul riscului minim: se minimizează riscul R

- adică se minimizează costul mediu
- se mai numește “criteriul costului minim”

# Calcule

$$P(D_0 \cap H_0) = P(D_0 | H_0) \cdot P(H_0) = P(H_0) \cdot \int_{R_0} w(r | H_0) dr \quad | \cdot C_{00}$$

$$P(D_1 \cap H_0) = P(D_1 | H_0) \cdot P(H_0) = P(H_0) \cdot \left(1 - \int_{R_0} w(r | H_0) dr\right) \quad | \cdot C_{10}$$

$$P(D_0 \cap H_1) = P(H_1) \cdot \int_{R_1} w(r | H_1) dr \quad | \cdot C_{01}$$

$$P(D_1 \cap H_1) = P(H_1) \cdot \left(1 - \int_{R_1} w(r | H_1) dr\right) \quad | \cdot C_{11}$$

## Demonstrație la tablă

se folosește regula lui Bayes

## Concluzie: regula de decizie este

$$R = C_{10} \cdot P(H_0) + C_{11} \cdot P(H_1) + \int_{R_0} \left[ w(r | H_0) (C_{00} \cdot P(H_0) - C_{10} \cdot P(H_0)) + w(r | H_1) (C_{01} \cdot P(H_1) - C_{11} \cdot P(H_1)) \right] dr$$

Vrem minim!

$$\frac{w(r | H_1)}{w(r | H_0)} \frac{H_1}{H_0} \frac{(C_{10} - C_{00}) \cdot P(H_0)}{(C_{01} - C_{11}) \cdot P(H_1)}$$

$$w(r | H_0) \cdot P(H_0) (C_{00} - C_{10}) \geq_{H_0} w(r | H_1) \cdot P(H_1) (C_{11} - C_{01})$$



$$\Rightarrow R_0 : \text{unde este } < 0 \quad (\Rightarrow w(r | H_0) \cdot P(H_0) (C_{00} - C_{10}) < w(r | H_1) \cdot P(H_1) (C_{11} - C_{01}))$$

$R_0 :$

$\Rightarrow 0$

$$\int_{R_1} = 1 - \int_{R_0}$$

## Criteriul riscului minim

$$C_{01} - C_{11} = C_{10} - C_{00}$$

$\Rightarrow$  MPE

**Criteriul riscului minim (MR):**

$$\frac{w(r|H_1)}{w(r|H_0)} \stackrel{H_1}{\gtrless} \frac{(C_{10} - C_{00})p(H_0)}{(C_{01} - C_{11})p(H_1)}$$

$$\Leftrightarrow \frac{\underset{\text{erorare}}{\downarrow} w(r|H_1) \cdot P(H_1) \cdot \underset{\text{OK}}{\downarrow} (C_{01} - C_{11})}{\underset{\text{erorare}}{\uparrow} w(r|H_0) \cdot P(H_0) \cdot \underset{\text{OK}}{\uparrow} (C_{10} - C_{00})} \stackrel{H_1}{\gtrless} \stackrel{H_0}{\lneq} 1$$

- prescurtat MR (Minimum Risk)

- ▶ Criteriul MR este o generalizare a MPE (la rândul lui o generalizare a ML)
  - ▶ se exprimă tot printr-un raport de plauzibilitate
- ▶ Atât probabilitățile cât și costurile pot influența decizia în favoarea uneia sau alteia dintre ipoteze
- ▶ Caz particular: dacă  $C_{10} - C_{00} = C_{01} - C_{11}$ , MR se reduce la criteriul MPE
  - ▶ de ex.: dacă  $C_{00} = C_{11} = 0$  și  $C_{10} = C_{01}$

## În zgomot gaussian

- Dacă zgomotul este gaussian (normal), la fel ca în celelalte criterii, se aplică logaritmul natural
- Se obține:

$$(r - s_0(t_0))^2 \stackrel{H_1}{\underset{H_0}{\gtrless}} (r - s_1(t_0))^2 + 2\sigma^2 \cdot \ln \left( \frac{(C_{10} - C_{00})p(H_0)}{(C_{01} - C_{11})p(H_1)} \right)$$

► sau

$$r \stackrel{H_1}{\underset{H_0}{\gtrless}} \frac{s_0(t_0) + s_1(t_0)}{2} + \frac{\sigma^2}{s_1(t_0) - s_0(t_0)} \cdot \ln \left( \frac{(C_{10} - C_{00})p(H_0)}{(C_{01} - C_{11})p(H_1)} \right)$$

T<sub>MR</sub>

## Interpretarea 1: Comparație între distanțe

- ▶ La criteriul MPE, se compară pătratul distanțelor, dar cu un termen suplimentar în favoarea ipotezei mai probabile:

$$(r - s_0(t_0))^2 \stackrel{H_1}{\underset{H_0}{\gtrless}} (r - s_1(t_0))^2 + 2\sigma^2 \cdot \ln \left( \frac{P(H_0)}{P(H_1)} \right)$$

- ▶ termenul depinde de raportul  $\frac{P(H_0)}{P(H_1)}$
- ▶ La criteriul MR, pe lângă probabilități apar și costurile

$$(r - s_0(t_0))^2 \stackrel{H_1}{\underset{H_0}{\gtrless}} (r - s_1(t_0))^2 + 2\sigma^2 \cdot \ln \left( \frac{(C_{10} - C_{00})p(H_0)}{(C_{01} - C_{11})p(H_1)} \right)$$

## Interpretarea 2: Valoarea de prag

- ▶ La criteriul MPE, pragul este împins înspre ipoteza mai puțin probabilă:

$$r \stackrel{H_1}{\underset{H_0}{\gtrless}} \frac{s_0(t_0) + s_1(t_0)}{2} + \frac{\sigma^2}{s_1(t_0) - s_0(t_0)} \cdot \ln \left( \frac{P(H_0)}{P(H_1)} \right)$$

- ▶ În funcție de raportul  $\frac{P(H_0)}{P(H_1)}$
- ▶ La criteriul MR, pragul este influențat și de costuri

$$r \stackrel{H_1}{\underset{H_0}{\gtrless}} \frac{s_0(t_0) + s_1(t_0)}{2} + \frac{\sigma^2}{s_1(t_0) - s_0(t_0)} \cdot \ln \left( \frac{(C_{10} - C_{00})p(H_0)}{(C_{01} - C_{11})p(H_1)} \right)$$

$\ln \left( \frac{0,001}{}$

T

# Influența costurilor

- ▶ Criteriul MR împinge decizia înspre **minimizarea scenariilor cu cost ridicat**
- ▶ Exemplu: din ecuații:

- ▶ ce se întâmplă dacă costul  $C_{01}$  crește, iar celealte rămân la fel?
- ▶ ce se întâmplă dacă costul  $C_{10}$  crește, iar celealte rămân la fel?
- ▶ ce se întâmplă dacă ambele costuri  $C_{01}$  și  $C_{10}$  cresc, iar celealte rămân la fel?



## Forma generală a criteriilor ML, MPE și MR

- ▶ Criteriile ML, MPE și MR au toate forma următoare

$$\frac{w(r|H_1)}{w(r|H_0)} \stackrel{H_1}{\gtrless} K$$

- ▶ pentru ML:  $K = 1$
- ▶ pentru MPE:  $K = \frac{P(H_0)}{P(H_1)}$
- ▶ pentru MR:  $K = \frac{(C_{10} - C_{00})p(H_0)}{(C_{01} - C_{11})p(H_1)}$

## Forma generală a criteriilor ML, MPE și MR

În zgomot gaussian, criteriile se reduc la:

- Compararea pătratului distanțelor:

$$(r - s_0(t_0))^2 \underset{H_0}{\overset{H_1}{\gtrless}} (r - s_1(t_0))^2 + 2\sigma^2 \cdot \ln(K)$$

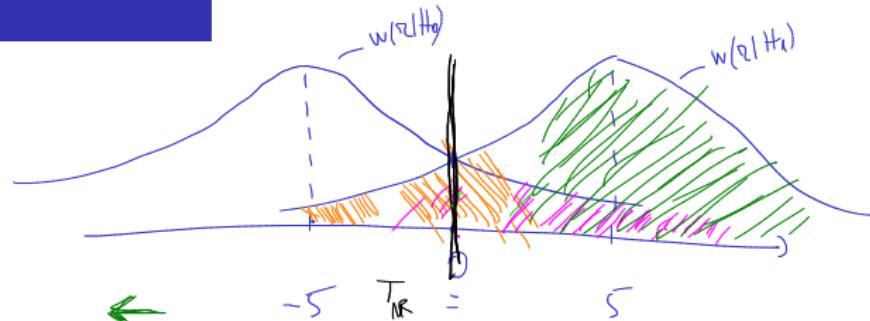
- Compararea eșantionului  $r$  cu un prag  $T$ :

$$r \underset{H_0}{\overset{H_1}{\gtrless}} \underbrace{\frac{s_0(t_0) + s_1(t_0)}{2} + \frac{\sigma^2}{s_1(t_0) - s_0(t_0)} \cdot \ln(K)}_T$$

- ▶ Un sistem *airbag* detectează un accident prin eșantionarea semnalului de la un senzor cu 2 valori posibile:  $s_0(t) = 0$  (OK) sau  $s_1(t) = 5$  (accident).
- ▶ Semnalul este afectat de zgomot gaussian  $\mathcal{N}(\mu = 0, \sigma^2 = 1)$ .
- ▶ Se ia un singur eșantion din semnal.
- ▶ Costurile scenariilor sunt:  $C_{00} = 0$ ,  $C_{01} = 100$ ,  $C_{10} = 10$ ,  $C_{11} = -100$ 
  - a. Găsiți regiunile de decizie  $R_0$  și  $R_1$ .

## Criteriul Neyman-Pearson

- Un criteriu mai general decât toate cele de până acum
- Criteriul Neyman-Pearson: se maximizează probabilitatea de detectie ( $P(D_1 \cap H_1)$ ) păstrând probabilitatea alarmei false sub o limită fixată ( $P(D_1 \cap H_0) \leq \lambda$ )
  - Se deduce pragul  $T$  din constrângerea la limită  $P(D_1 \cap H_0) = \lambda$
- Criteriile ML, MPE și MR sunt cazuri particulare ale Neyman-Pearson, pentru diverse valori ale  $\lambda$ .



$\Rightarrow$  Când  $\lambda \rightarrow 0 \Rightarrow T \Rightarrow \infty$

Când  $\lambda \rightarrow 1 \Rightarrow T \Rightarrow -\infty$

- ▶ O sursă de informație produce două mesaje cu probabilitățile  $p(a_0) = \frac{2}{3}$  și  $p(a_1) = \frac{1}{3}$ .  10
- ▶ Mesajele sunt codate ca semnale constante cu valorile  $-5$  ( $a_0$ ) și  $5$  ( $a_1$ ).
- ▶ Semnalele sunt afectate de zgomot alb cu distribuție uniformă  $U[-5, 5]$ .
- ▶ Receptorul ia un singur eșantion  $r$ .
  - a. Găsiți regiunile de decizie conform criteriului Neymar-Pearson, pentru  $P_{fa} \leq 10^{-2}$
  - b. Care este probabilitatea de detecție corectă?

## Aplicație: Semnale diferențiale sau unipolare

- ▶ Aplicație: transmisie binară cu semnale constante (de ex. nivele constante de tensiune)

- ▶ Două modalități frecvent întâlnite:

- ▶ Semnal unipolar: o valoare este 0, cealaltă este nenulă
    - ▶  $s_0(t) = 0, s_1(t) = A$


- ▶ Semnal diferențial: două valori nenele cu semne contrare, aceeași valoare absolută

- ▶  $s_0(t) = -\frac{A}{2}, s_1(t) = \frac{A}{2}$

- ▶ Care metodă este mai bună?

$$\begin{array}{ll} \Delta_0(+): & \Delta_1(+): \\ 0 \vee & 5 \vee \end{array}$$

$$\begin{array}{ll} \Delta_0(-): & \Delta_1(-): \\ -2.5 \vee & 2.5 \vee \end{array}$$



- ▶ Pentru că există aceeași diferență între nivele, performanțele deciziei sunt identice
- ▶ Dar puterea medie a semnalelor diferă
- ▶ Pentru semnale diferențiale:  $P = \left(\pm \frac{A}{2}\right)^2 = \frac{A^2}{4}$
- ▶ Pentru semnale unipolare:  $P = P(H_0) \cdot 0 + P(H_1)(A)^2 = \frac{A^2}{2}$ 
  - ▶ presupunând probabilități egale  $P(H_0) = P(H_1) = \frac{1}{2}$
- ▶ Semnalul diferențial necesită putere la jumătate față de cel unipolar (mai bine)

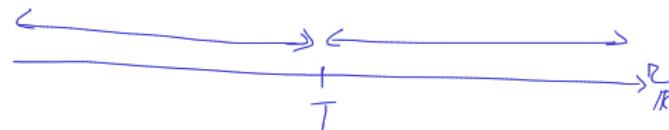
## Sumar: criterii de decizie

- ▶ Am văzut: decizie între două semnale, bazată pe 1 eșantion
- ▶ Toate criteriile au la bază raportul de plauzibilitate

$$\frac{w(r|H_1)}{w(r|H_0)} \stackrel{H_1}{\gtrless} K \quad \begin{array}{c} K = \\ \swarrow \quad \searrow \\ k = \\ \swarrow \quad \searrow \\ k = \end{array}$$




- ▶ Criterii diferite conduc la valori diferite pentru  $K$
- ▶ În funcție de distribuția zgomotului, axa reală este împărțită în regiuni de decizie
  - ▶ regiunea  $R_0$ : dacă  $r$  este aici, se decide  $D_0$
  - ▶ regiunea  $R_1$ : dacă  $r$  este aici, se decide  $D_1$
- ▶ Pentru zgomot gaussian, granița între regiuni (valoarea de prag) este:

$$T = \frac{s_0(t_0) + s_1(t_0)}{2} + \frac{\sigma^2}{s_1(t_0) - s_0(t_0)} \cdot \ln(K)$$



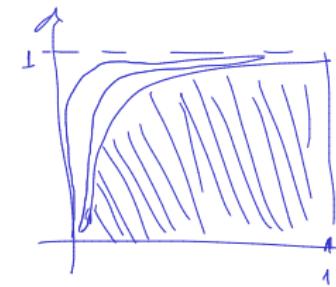
## Caracteristica de operare a receptorului (ROC)

- ▶ Performanța unui receptor este ilustrată cu un grafic numit **“Caracteristica de operare a receptorului”** (“**Receiver Operating Characteristic**”, ROC)
- ▶ Reprezintă probabilitatea  $P_{cd} = P(D_1|H_1)$  în funcție de probabilitatea  $P_{af} = P(D_1|H_0)$ 
  - ▶ pentru diferite praguri T
  - ▶ fiecare T corespunde unui punct de pe grafic



## Caracteristica de operare a receptorului (ROC)

- ▶ Există întotdeauna un **compromis** între  $P_d$ (bun) și  $P_{fa}$ (rău)
  - ▶ creșterea  $P_d$  implică și creșterea  $P_{fa}$
  - ▶ pentru a fi siguri că nu ratăm nici un semnal (creșterea  $P_d$ ), plătim prin creșterea probabilității de alarme false
- ▶ Criterii diferite = diferite praguri  $K$  = diferite puncte pe grafic = compromisuri diferite
  - ▶ dar întotdeauna e vorba de un compromis
- ▶ O măsură a performanței globale este **Area Under the Curve** (AUC)
  - ▶ indiferent de alegerea unui prag sau a altuia

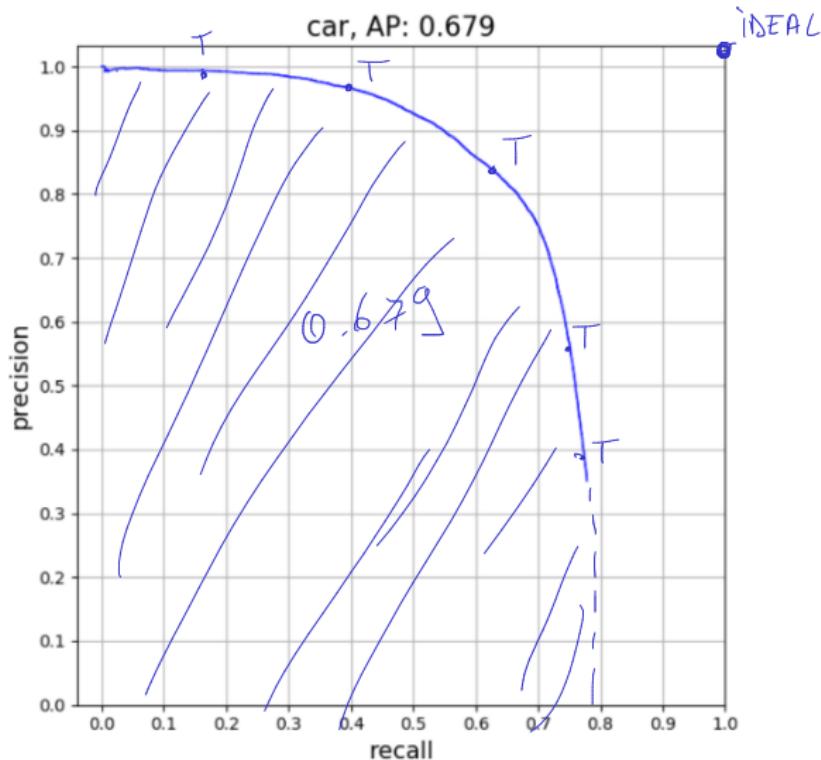


## Caracteristica Precision vs Recall

- ▶ Un grafic similar este cel de Precision vs Recall
- ▶ **Precision** =  $\frac{P(D_1 \cap H_1)}{P(D_1 \cap H_1) + P(D_1 \cap H_0)}$ 
  - ▶ = True Positives / (True Positives + False Positives)
- ▶ **Recall** =  $\frac{P(D_1 \cap H_1)}{P(D_1 \cap H_1) + P(D_0 \cap H_1)} = P(D_1 | H_1)$ 
  - ▶ = True Positives / (True Positives + False Negatives)

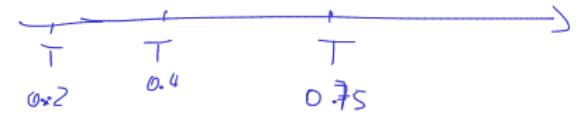
# Caracteristica Precision vs Recall

Exemplu de grafic Precision vs Recall dintr-o aplicație practică



# Caracteristica Precision vs Recall

Aplicația pentru care este obținut graficul precedent:



$$D_1 \cap H_2$$

$$D_0 \cap H_1$$

$$D_1 \cap H_0$$

$$D_0 \cap H_0$$

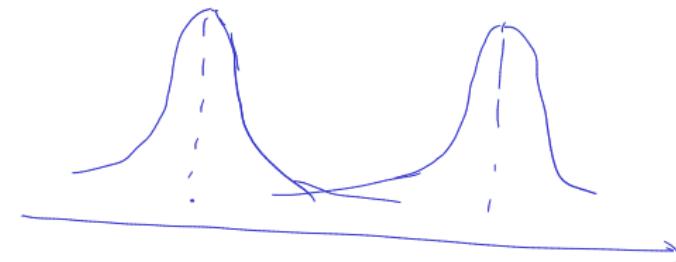
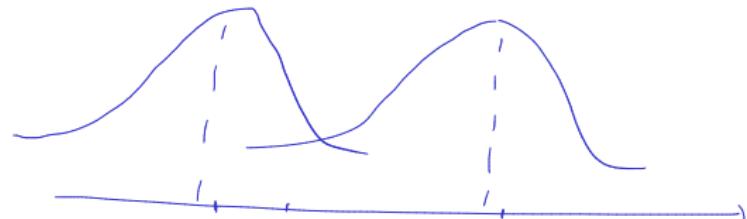
# Raport Semnal-Zgomot

- ▶ Cum putem îmbunătăți performanțele de detecție?

- ▶ i.e. creșterea  $P_d$  pentru același  $P_{af}$
- ▶ independent de alegerea unui prag sau a altuia  
 $T$

- ▶ Două soluții:

- ▶ Creșterea diferenței dintre  $s_0(t)$  și  $s_1(t)$  (se crește puterea semnalului)
- ▶ Scăderea zgomotului (se scade **puterea zgomotului**)
- ▶ i.e. se crește **raportul Semnal-Zgomot**



- ▶ Următoarele trei slide-uri nu se cer pentru examenul 2020-2021 (până la Raportul semnal zgromot).

2021 – 2022

## Performanțele detecției în zgomot alb gaussian

- ▶ Considerăm probabilități egale  $P(H_0) = P(H_1) = \frac{1}{2}$ 
  - ▶ Sau, echivalent, considerăm doar probabilități condiționate
- ▶ Deciziile se iau pe baza raportului de plauzibilitate

$$\frac{w(r|H_1)}{w(r|H_0)} \stackrel{H_1}{\gtrless} K$$

- ▶ Probabilitatea detecției corecte este

$$\begin{aligned}P_d &= P(D_1|H_1) \\&= \int_T^{\infty} w(r|H_1) \\&= (F(\infty) - F(T)) \\&= \frac{1}{2} \left( 1 - \operatorname{erf} \left( \frac{T - s_1(t_0)}{\sqrt{2}\sigma} \right) \right) \\&= Q \left( \frac{T - s_1(t_0)}{\sqrt{2}\sigma} \right)\end{aligned}$$

## Performanțele detecției în zgomot alb gaussian

- ▶ Probabilitatea alarmei false este

$$\begin{aligned} P_{fa} &= P(D_1|H_0) \\ &= \int_T^{\infty} w(r|H_0) \\ &= (F(\infty) - F(T)) \\ &= \frac{1}{2} \left( 1 - \operatorname{erf} \left( \frac{T - s_0(t_0)}{\sqrt{2}\sigma} \right) \right) \\ &= Q \left( \frac{T - s_0(t_0)}{\sqrt{2}\sigma} \right) \end{aligned}$$

- ▶ Rezultă  $\frac{T - s_0(t_0)}{\sqrt{2}\sigma} = Q^{-1}(P_{fa})$ ,
- ▶ Și:  $\frac{T - s_1(t_0)}{\sqrt{2}\sigma} = Q^{-1}(P_{fa}) + \frac{s_0(t_0) - s_1(t_0)}{\sqrt{2}\sigma}$

## Performanțele detecției în zgomot alb gaussian

- ▶ Înlocuind în  $P_d$ , obținem:

$$P_d = Q \left( \underbrace{Q^{-1}(P_{fa})}_{\text{constant}} + \frac{s_0(t_0) - s_1(t_0)}{\sqrt{2}\sigma} \right)$$

- ▶ Fie un scenariu simplu:


- ▶  $s_0(t_0) = 0$
- ▶  $s_1(t_0) = A = \text{constant}$

- ▶ Obținem:

$$P_d = Q \left( \underbrace{Q^{-1}(P_{fa})}_{\text{constant}} - \frac{A}{\sqrt{2}\sigma} \right)$$

# Raportul semnal zgomot

- ▶ **Raportul semnal zgomot (SNR)** =  $\frac{\text{puterea semnalului original}}{\text{puterea zgomotului}}$



- ▶ Puterea medie a unui semnal = valoarea pătratică medie =  $\overline{X^2}$ 
  - ▶ Puterea semnalului original este  $\frac{A^2}{2}$
  - ▶ Puterea zgomotului este  $\overline{X^2} = \sigma^2$  (pentru valoare medie nulă  $\mu = 0$ )
- ▶ În cazul nostru,  $\text{SNR} = \frac{A^2}{2\sigma^2}$

$$P_d = Q \left( \underbrace{Q^{-1}(P_{fa})}_{\text{constant}} - \sqrt{\text{SNR}} \right)$$

- ▶ Pentru  $P_{fa}$  de valoare fixă,  $P_d$  crește odată cu SNR
  - ▶  $Q$  este o funcție monoton descrescătoare

# Performanța depinde de SNR

- ▶ Performanța receptorului crește odată cu creșterea SNR
  - ▶ SNR mare: performanță bună
  - ▶ SNR mic: performanță slabă

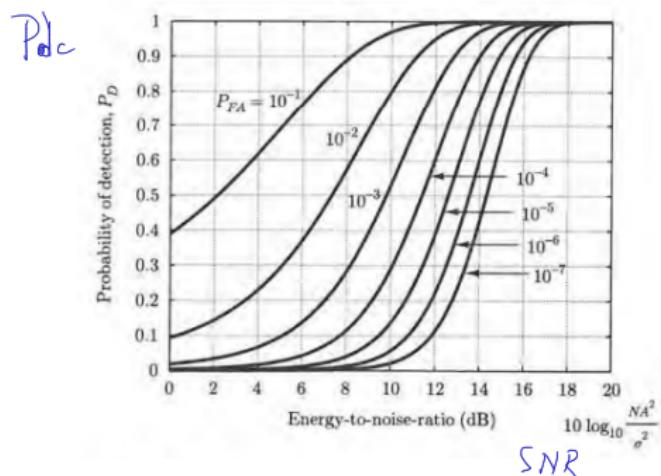



Figure 6: Performanțele detectiei depend de SNR

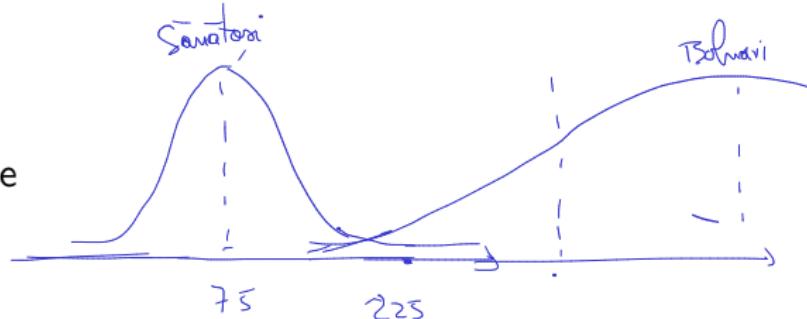
[sursa: *Fundamentals of Statistical Signal Processing, Steven Kay*]

- ▶ Se pot utiliza aceste criterii de decizie în alte aplicații?
  - ▶ nu pentru a decide între semnale, ci în alte scopuri
- ▶ Matematic, problema se pune sub forma următoare:
  - ▶ avem 2 (sau mai multe) distribuții posibile
  - ▶ avem 1 valoare observată
  - ▶ determinăm cea mai plauzibilă distribuție, pe baza valorii observate
- ▶ În acest caz particular, decidem între două semnale
- ▶ Dar acest model matematic se poate aplica și în alte contexte:
  - ▶ medicină: un semnal ECG indică o boală sau nu?
  - ▶ business: va cumpăra clientul un produs, sau nu?
  - ▶ De obicei se folosesc mai multe eşantioane, dar principiul matematic este același



Exemplu (pur imaginar):

- ▶ O persoană sănătoasă cu greutatea  $= X$  kg are concentrația de trombocite pe ml de sânge distribuită aproximativ  $\mathcal{N}(\mu = 10 \cdot X, \sigma^2 = 20)$ .
- ▶ O persoană suferind de boala B are o valoare mult mai scăzută, distribuită aproximativ  $\mathcal{N}(100, \sigma^2 = 10)$ .
- ▶ În urma analizelor de laborator, ai obținut valoarea  $r = 255$ . Greuata ta este 70 kg.
- ▶ Decideți: sănătos sau nu?



### II.3 Detectia semnalelor cu mai multe esantioane

- ▶ Contextul rămâne același:
  - ▶ Se transmite un semnal  $s(t)$
  - ▶ Există **două ipoteze**:
    - ▶  $H_0$ : semnalul original este  $s(t) = s_0(t)$
    - ▶  $H_1$ : semnalul original este  $s(t) = s_1(t)$
  - ▶ Receptorul poate lua **două decizii**:
    - ▶  $D_0$ : se decide că semnalul a fost  $s(t) = s_0(t)$
    - ▶  $D_1$ : se decide că semnalul a fost  $s(t) = s_1(t)$
  - ▶ Există 4 scenarii posibile

- ▶ Contextul rămâne același:
  - ▶ Semnalele sunt afectate de zgomot (necunoscut)
  - ▶ Se recepționează un semnal  $r(t) = s(t) + n(t)$
- ▶ Se iau N eșantioane din  $r(t)$ , nu doar 1
  - ▶ Fiecare eșantion  $r_i = r(t_i)$  se ia la momentul  $t_i$
- ▶ Eșantioanele formează **vectorul de eșantioanelor**

$$\mathbf{r} = [r_1, r_2, \dots, r_N]$$

- ▶ Fiecare eșantion  $r_i$  este o **variabilă aleatoare**
  - ▶  $r(t_i) = s(t_i) + n(t_i) = \text{constantă} + \text{o v.a.}$
- ▶ Vectorul **r** reprezintă un set de  $N$  v.a. dintr-un proces aleator
- ▶ Considerând întreg vectorul **r**, valorile vectorului **r** sunt descrise de **distribuții de ordin  $N$**

- ▶ În ipoteza  $H_0$ :

$$w_N(\mathbf{r}|H_0) = w_N(r_1, r_2, \dots, r_N|H_0)$$

- ▶ În ipoteza  $H_1$ :

$$w_N(\mathbf{r}|H_1) = w_N(r_1, r_2, \dots, r_N|H_1)$$

- ▶ Se aplică **aceleași criterii** bazate pe raportul de plauzibilitate în cazul unui singur eșantion

$$\frac{w_N(\mathbf{r}|H_1)}{w_N(\mathbf{r}|H_0)} \stackrel{H_1}{\gtrless} K$$

- ▶ Observații
  - ▶  $\mathbf{r}$  este un vector; prin el se consideră plauzibilitatea tuturor eșantioanelor
  - ▶  $w_N(\mathbf{r}|H_0)$  = plauzibilitatea vectorului  $\mathbf{r}$  în ipoteza  $H_0$
  - ▶  $w_N(\mathbf{r}|H_1)$  = plauzibilitatea vectorului  $\mathbf{r}$  în ipoteza  $H_1$
  - ▶ valoarea lui  $K$  este dată de criteriul de decizie utilizat
- ▶ Interpretare: se alege ipoteza cea mai plauzibilă de a fi generat datele observate
  - ▶ identic ca la 1 eșantion, doar că acum datele = mai multe eșantioane

- ▶ Presupunând că zgomotul este alb, eșantioanele  $r_i$  sunt independente
- ▶ În acest caz, distribuția totală  $w_N(\mathbf{r}|H_j)$  se poate descompune ca un produs

$$w_N(\mathbf{r}|H_j) = w(r_1|H_j) \cdot w(r_2|H_j) \cdot \dots \cdot w(r_N|H_j)$$

- ▶ de ex. plauzibilitatea obținerii vectorului [5.1, 4.7, 4.9] = plauzibilitatea obținerii lui 5.1  $\times$  plauzibilitatea obținerii lui 4.7  $\times$  plauzibilitatea obținerii lui 4.9
- ▶ Funcțiile  $w(r_i|H_i)$  sunt distribuțiile condiționate ale fiecărui eșantion
  - ▶ de care am mai văzut deja

- ▶ Prin urmare, criteriile bazate pe raportul de plauzibilitate devin

$$\frac{w_N(\mathbf{r}|H_1)}{w_N(\mathbf{r}|H_0)} = \frac{w(r_1|H_1)}{w(r_1|H_0)} \cdot \frac{w(r_2|H_1)}{w(r_2|H_0)} \cdots \frac{w(r_N|H_1)}{w(r_N|H_0)} \stackrel{H_1}{\underset{H_0}{\gtrless}} K$$

- ▶ Raportul de plauzibilitate al unui vector de eșantioane = produsul rapoartelor plauzibilitate ale fiecărui eșantion
- ▶ **Se înmulțesc** rapoartele de plauzibilitate ale fiecărui eșantion înparte, și se aplică criteriile asupra rezultatului final

- ▶ Toate criteriile de decizie pot fi scrise astfel:

$$\frac{w_N(\mathbf{r}|H_1)}{w_N(\mathbf{r}|H_0)} = \frac{w(r_1|H_1)}{w(r_1|H_0)} \cdot \frac{w(r_2|H_1)}{w(r_2|H_0)} \cdots \frac{w(r_N|H_1)}{w(r_N|H_0)} \stackrel{H_1}{\gtrless} K$$

- ▶ Valoarea lui  $K$  se alege ca pentru 1 eșantion:

- ▶ criteriul ML:  $K = 1$
- ▶ criteriul MPE:  $K = \frac{P(H_0)}{P(H_1)}$
- ▶ criteriul MR:  $K = \frac{(C_{10} - C_{00})p(H_0)}{(C_{01} - C_{11})p(H_1)}$

## Caz particular: AWGN

- ▶ AWGN = “Additive White Gaussian Noise” = Zgomot alb, gaussian, aditiv

- ▶ În ipoteza  $H_1$ :  $w(r_i|H_1) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(r_i-s_1(t_i))^2}{2\sigma^2}}$

- ▶ În ipoteza  $H_0$ :  $w(r_i|H_0) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(r_i-s_0(t_i))^2}{2\sigma^2}}$

- ▶ Raportul de plauzibilitate al vectorului  $\mathbf{r}$

$$\frac{w_N(\mathbf{r}|H_1)}{w_N(\mathbf{r}|H_0)} = \frac{e^{-\frac{\sum(r_i-s_1(t_i))^2}{2\sigma^2}}}{e^{-\frac{\sum(r_i-s_0(t_i))^2}{2\sigma^2}}} = e^{\frac{\sum(r_i-s_0(t_i))^2 - \sum(r_i-s_1(t_i))^2}{2\sigma^2}}$$

- Raportul de plauzibilitate global se compară cu  $K$ :

$$\frac{w_N(\mathbf{r}|H_1)}{w_N(\mathbf{r}|H_0)} = e^{\frac{\sum(r_i - s_0(t_i))^2 - \sum(r_i - s_1(t_i))^2}{2\sigma^2}} \stackrel{H_1}{\underset{H_0}{\gtrless}} K$$

- Se aplică logaritmul natural, obținându-se:

$$\sum(r_i - s_0(t_i))^2 \stackrel{H_1}{\underset{H_0}{\gtrless}} \sum(r_i - s_1(t_i))^2 + 2\sigma^2 \ln(K)$$

## Interpretarea 1: distanță geometrică

- ▶ Sumele reprezintă **distanță geometrică** la pătrat:

$$\sum(r_i - s_1(t_i))^2 = \|\mathbf{r} - \mathbf{s}_1(\mathbf{t})\|^2 = d(\mathbf{r}, s_1(t))^2$$

$$\sum(r_i - s_0(t_i))^2 = \|\mathbf{r} - \mathbf{s}_0(\mathbf{t})\|^2 = d(\mathbf{r}, s_0(t))^2$$

- ▶ distanță între vectorul observat  $\mathbf{r}$  și semnalele originale  $s_1(t)$ , respectiv  $s_0(t)$
- ▶ vectori cu  $N$  eșantioane  $\Rightarrow$  distanță între vectori de dimensiune  $N$
- ▶ Totul se reduce la a compara distanțele

## Interpretarea 1: distanță geometrică

- ▶ Criteriul Maximum Likelihood:

- ▶  $K = 1, \ln(K) = 0$
- ▶ se alege **distanța minimă** între  $\mathbf{r}$  și vectorii  $s_1(t)$ , respectiv  $s_0(t)$ )
- ▶ de unde și numele “receptor de distanță minimă”

- ▶ Criteriul Minimum Probability of Error:

- ▶  $K = \frac{P(H_0)}{P(H_1)}$
- ▶ Apare un termen suplimentar, în favoarea ipotezei mai probabile

- ▶ Criteriul Minimum Risk:

- ▶  $K = \frac{(C_{10} - C_{00})p(H_0)}{(C_{01} - C_{11})p(H_1)}$
- ▶ Termenul suplimentar depinde și de probabilități, și de costuri

Exercițiu:

- ▶ Un semnal poate avea două valori, 0 (ipoteza  $H_0$ ) sau 6 (ipoteza  $H_1$ ). Semnalul este afectat de AWGN  $\mathcal{N}(0, \sigma^2 = 1)$ . Receptorul ia 5 eșantioane cu valorile  $\{1.1, 4.4, 3.7, 4.1, 3.8\}$ .
  - a. Ce decizie se ia conform criteriului plauzibilității maxime?
  - b. Ce decizie se ia conform criteriului probabilității minime de eroare. dacă  $P(H_0) = 2/3$  și  $P(H_1) = 1/3$ ?
  - c. Ce decizie se ia conform criteriului roscului minim. dacă  $P(H_0) = 2/3$  și  $P(H_1) = 1/3$ , iar  $C_{00} = 0$ ,  $C_{10} = 10$ ,  $C_{01} = 20$ ,  $C_{11} = 5$ ?

Alt exercițiu:

- ▶ Fie detecția unui semnal  $s(t) = 3 \sin(2\pi ft)$  care poate fi prezent (ipoteza  $H_1$ ) sau absent ( $s_0(t) = 0$ , ipoteza  $H_0$ ). Semnalul este afectat de zgomot alb Gaussian  $\mathcal{N}(0, \sigma^2 = 1)$ . Receptorul ia două eșantioane.
  - a. Care sunt cele mai bune momente de eșantionare  $t_1$  și  $t_2$  pentru a maximiza performanțele detecției?
  - b. Receptorul ia două eșantioane  $\{1.1, 4.4\}$ , la momentele de timp  $t_1 = \frac{0.125}{f}$  și  $t_2 = \frac{0.625}{f}$ . Care este decizia, conform criteriului plauzibilității maxime?
  - c. Dacă se folosește criteriul probabilității minime de eroare, cu  $P(H_0) = 2/3$  și  $P(H_1) = 1/3$ ?
  - d. Dacă se folosește criteriul riscului minim, cu  $P(H_0) = 2/3$  și  $P(H_1) = 1/3$ , iar  $C_{00} = 0$ ,  $C_{10} = 10$ ,  $C_{01} = 20$ ,  $C_{11} = 5$ ?
  - e. Dar dacă receptorul ia un al treilea eșantion la momentul  $t_3 = \frac{0.5}{f}$ . Se poate îmbunătăți detecția?

## Interpretarea 2: produs scalar

- Dacă se descompun parantezele:

$$\sum_{H_0} (r_i - s_0(t_i))^2 \stackrel{H_1}{\gtrless} \sum (r_i - s_1(t_i))^2 + 2\sigma^2 \ln(K)$$

- Se obține:

$$\begin{aligned} \sum (r_i)^2 + \sum s_0(t_i)^2 - 2 \sum r_i s_0(t_i) &\stackrel{H_1}{\gtrless} \sum (r_i)^2 + \\ &+ \sum s_1(t_i)^2 - 2 \sum r_i s_1(t_i) + 2\sigma^2 \ln(K) \end{aligned}$$

- Echivalent cu:

$$\sum r_i s_1(t_i) - \frac{\sum (s_1(t_i))^2}{2} \stackrel{H_1}{\gtrless} \sum r_i s_0(t_i) - \frac{\sum (s_0(t_i))^2}{2} + \sigma^2 \ln(K)$$

## Interpretarea 2: produs scalar

- ▶ Algebră: **produsului scalar** al vectorilor **a** și **b**:

$$\langle a, b \rangle = \sum_i a_i b_i$$

- ▶  $\sum r_i s_1(t_i) = \langle \mathbf{r}, \mathbf{s}_1(\mathbf{t}) \rangle$  este produsul scalar al vectorului  
 $\mathbf{r} = [r_1, r_2, \dots, r_N]$  cu  $\mathbf{s}_1(\mathbf{t}_i) = [s_1(t_1), s_1(t_2), \dots, s_1(t_N)]$
- ▶  $\sum r_i s_0(t_i) = \langle \mathbf{r}, \mathbf{s}_0(\mathbf{t}) \rangle$  este produsul scalar al vectorului  
 $\mathbf{r} = [r_1, r_2, \dots, r_N]$  cu  $\mathbf{s}_0(\mathbf{t}_i) = [s_0(t_1), s_0(t_2), \dots, s_0(t_N)]$
- ▶  $\sum (s_1(t_i))^2 = \sum s_1(t_i) \cdot s_1(t_i) = \langle \mathbf{s}_1(\mathbf{t}), \mathbf{s}_1(\mathbf{t}) \rangle = E_1$  este **energia**  
vectorului  $s_1(t)$
- ▶  $\sum (s_0(t_i))^2 = \sum s_0(t_i) \cdot s_0(t_i) = \langle \mathbf{s}_0(\mathbf{t}), \mathbf{s}_0(\mathbf{t}) \rangle = E_0$  este **energia**  
vectorului  $s_0(t)$

- Decizia se poate rescrise sub forma:

$$\langle \mathbf{r}, \mathbf{s}_1 \rangle - \frac{E_1}{2} \stackrel{H_1}{\gtrless} \langle \mathbf{r}, \mathbf{s}_0 \rangle - \frac{E_0}{2} + \sigma^2 \ln(K)$$

- Interpretare: **comparăm produsele scalare**
  - se scad energiile semnalelor, pentru o comparație corectă
  - există de asemenea termenul care depinde de criteriul ales

► Caz particular:

- Dacă cele două semnale au energii egale:

$$E_1 = \sum s_1(t_i)^2 = E_0 = \sum s_0(t_i)^2$$

- Exemple:

- modulație BPSK:  $s_1 = A \cos(2\pi ft)$ ,  $s_0 = -A \cos(2\pi ft)$

- modulație 4-PSK:  $s_{n=0,1,2,3} = A \cos(2\pi ft + n\frac{\pi}{4})$

- Atunci formula se simplifică:

$$\langle \mathbf{r}, \mathbf{s}_1 \rangle \stackrel{H_1}{\underset{H_0}{\gtrless}} \langle \mathbf{r}, \mathbf{s}_0 \rangle + \sigma^2 \ln(K)$$

- ▶ În domeniul prelucrărilor de semnale, produsul scalar măsoară **similitudinea** a două semnale
- ▶ Interpretare: verificăm dacă vectorul eșantioanelor **r** este **mai asemănător** cu  $s_1(t)$  sau cu  $s_0(t)$ 
  - ▶ Se alege cel mai similar cu **r**
  - ▶ Se scad și energiile semnalelor (necesar d.p.d.v. matematic)
- ▶ **Produsul scalar** a doi vectori **a** și **b**:

$$\langle a, b \rangle = \sum_i a_i b_i$$

## Implementare cu circuite de corelare

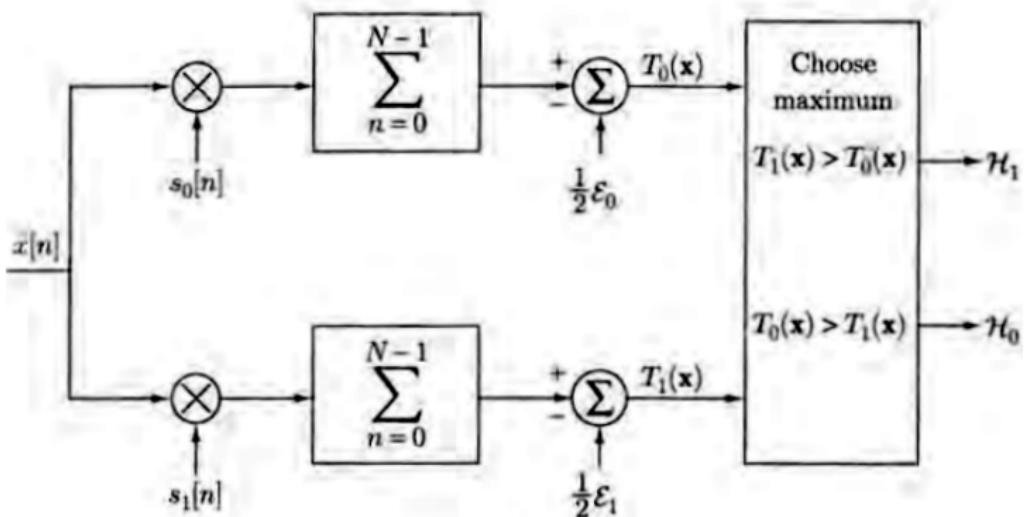


Figure 7: Decizie între două semnale

[sursa: *Fundamentals of Statistical Signal Processing, Steven Kay*]

- ▶ Cum se calculează produsul scalar a două semnale  $r[n]$  și  $s[n]$  de lungime  $N$ ?

$$\langle \mathbf{r}, \mathbf{s} \rangle = \sum r_i s(t_i)$$

- ▶ Fie  $h[n]$  semnalul  $h[n]$  **oglindit**

- ▶ Începe la momentul 0, durează până la momentul  $N - 1$ , dar este oglindit

$$h[n] = s[N - 1 - n]$$

- ▶ Exemplu:

- ▶ dacă  $s[n] = [1, 2, 3, 4, 5, 6]$
- ▶ atunci  $h[n] = s[N - 1 - n] = [6, 5, 4, 3, 2, 1]$

- ▶ Convoluția lui  $r[n]$  cu  $h[n]$  este

$$y[n] = \sum_k r[k]h[n - k] = \sum_k r[k]h[N - 1 - n + k]$$

- ▶ Rezultatul convoluției, la finalul semnalului de intrare,  $y[N - 1]$  ( $n = N - 1$ ), este chiar produsul scalar:

$$y[N - 1] = \sum_k r[k]s[k]$$

- ▶ Pentru detecția unui semnal  $s[n]$  se poate folosi un **filtru a cărui răspuns la impuls = oglindirea lui**  $s[n]$ , luându-se eșantionul de la finalul semnalului de intrare

$$h[n] = s[N - 1 - n]$$

- ▶ se obține valoarea produsului scalar
- ▶ **Filtru adaptat** = un filtru proiectat să aibă răspunsul la impuls egal cu oglindirea semnalului care se dorește a fi detectat (eng. “matched filter”)
  - ▶ filtrul este *adaptat* semnalului dorit

- ▶ Se folosește un filtru adaptat la semnalul  $s_1(t_i)$
- ▶ Se folosește un filtru adaptat la semnalul  $s_0(t_i)$
- ▶ Se eșantionează ieșirile la momentul final  $n = N - 1$ 
  - ▶ se obțin valorile produselor scalare
- ▶ Se folosește regula de decizie cu produse scalare

## Detectia semnalelor cu filtre adaptate

- Dacă  $s_0(t) = 0$ , avem nevoie doar de un singur filtru adaptat pentru  $s_1(t)$ , și se compară rezultatul cu un prag

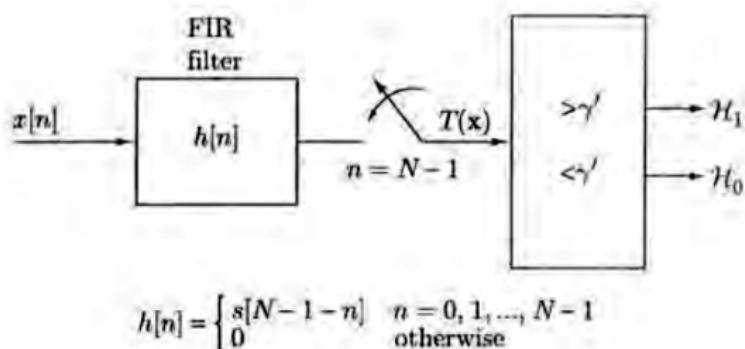


Figure 8: Detectie folosind un filtru adaptat

[sursa: *Fundamentals of Statistical Signal Processing, Steven Kay*]

## II.4 Detectia unui semnal oarecare cu observare continuă

## Observarea continuă a unui semnal oarecare

- ▶ Observare continuă = fără eşantionare, se foloseşte **întreg semnalul continuu**
  - ▶ similar cazului cu  $N$  eşantioane, dar cu  $N \rightarrow \infty$
- ▶ Semnalele originale sunt  $s_0(t)$  și  $s_1(t)$
- ▶ Semnalele sunt afectate de zgomot
  - ▶ Presupunem **doar zgomot Gaussian**, pentru simplitate
- ▶ Semnalul recepționat este  $r(t)$

- ▶ Se extinde cazul precedent cu  $N$  eșantioane la cazul unui semnal continuu,  $N \rightarrow \infty$
- ▶ Fiecare semnal  $r(t)$ ,  $s_1(t)$  și  $s_0(t)$  reprezintă un punct într-un spațiu Euclidian infinit dimensional
- ▶ **Distanța** între două semnale este:

$$d(\mathbf{r}, \mathbf{s}) = \sqrt{\int (r(t) - s(t))^2 dt}$$

- ▶ **Produsul scalar** între două semnale:

$$\langle \mathbf{r}, \mathbf{s} \rangle = \int r(t)s(t)dt$$

- ▶ Similar cu cazul  $N$  dimensional, dar cu integrală în loc de sumă

- În cazul AWGN este aceeași regula de decizie:

$$d(\mathbf{r}, \mathbf{s}_0)^2 \stackrel{H_1}{\gtrless} d(\mathbf{r}, \mathbf{s}_1)^2 + 2\sigma^2 \ln(K)$$

- Distanță = se calculează cu formula precedentă, cu integrală
- Aceleași criterii de decizie:
  - Criteriul Maximum Likelihood:  $K = 1, \ln(K) = 0$ 
    - se alege **distanța minimă**
  - Criteriul Minimum Probability of Error:  $K = \frac{P(H_0)}{P(H_1)}$
  - Criteriul Minimum Risk:  $K = \frac{(C_{10} - C_{00})p(H_0)}{(C_{01} - C_{11})p(H_1)}$

- În cazul AWGN este aceeași regulă de decizie:

$$\langle \mathbf{r}, \mathbf{s}_1 \rangle - \frac{E_1}{2} \stackrel{H_1}{\geq} \stackrel{H_0}{\leq} \langle \mathbf{r}, \mathbf{s}_0 \rangle - \frac{E_0}{2} + \sigma^2 \ln(K)$$

- Produsul scalar = formula precedentă, cu integrală
- Toate interpretările rămân identice
  - se schimbă doar **tipul de semnal** cu care lucrăm

- ▶ Produsul scalar a două semnale se poate calcula cu un **filtru adaptat**
- ▶ **Filtru adaptat** = filtru proiectat să aibă răspunsul la impuls egal cu **oglindirea** semnalului căutat
  - ▶ dacă semnalul original  $s(t)$  are lungimea  $T$
  - ▶ atunci  $h(t) = s(T - t)$
  - ▶ filtrul este analogic, răspunsul la impuls este continuu
- ▶ Ieșirea unui filtru adaptat la momentul  $t = T$  este egală cu produsul scalar al intrării  $r(t)$  cu  $s(t)$

- ▶ Se folosește un filtru adaptat la semnalul  $s_1(t)$
- ▶ Se folosește un alt filtru adaptat la semnalul  $s_0(t)$
- ▶ Se eșantionează ieșirile filtrelor la sfârșitul semnalelor,  $t = T$ 
  - ▶ se obțin valorile produselor scalare
- ▶ Se utilizează regula de decizie cu produse scalare

- ▶ Recapitulare: Spații vectoriale Euclidiene
- ▶ Spațiu vectorial
  - ▶ suma a două elemente = rămâne în același spațiu
  - ▶ multiplicarea cu o constantă = rămâne în același spațiu
  - ▶ există operații aritmetice de bază: sumă, multiplicare cu o constantă
  - ▶ Exemple
    - ▶ 1D = o dreaptă
    - ▶ 2D = un plan
    - ▶ 3D = spațiu tridimensional
    - ▶ N-D = ...
    - ▶  $\infty$ -D = ..

- ▶ Operația fundamentală: **produsul scalar**

- ▶ pentru semnale discrete

$$\langle \mathbf{x}, \mathbf{y} \rangle = \sum_i x_i y_i$$

- ▶ pentru semnale continue

$$\langle \mathbf{x}, \mathbf{y} \rangle = \int x(t) y(t)$$

- ▶ Norma (lungimea) unui vector = radical(produsul scalar cu sine însuși)

$$\|\mathbf{x}\| = \sqrt{\langle \mathbf{x}, \mathbf{x} \rangle}$$

- ▶ Distanța între doi vectori = norma diferenței dintre ei

$$d(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|$$

- ▶ Energia unui semnal = normă la pătrat

$$E_x = \|\mathbf{x}\|^2 = \langle \mathbf{x}, \mathbf{x} \rangle$$

- ▶ Unghiul dintre doi vectori

$$\cos(\alpha) = \frac{\langle x, y \rangle}{\|x\| \cdot \|y\|}$$

- ▶ are valoare între -1 și 1
- ▶ dacă  $\langle x, y \rangle = 0$ , vectorii sunt **ortogonali** (perpendiculari)

- ▶ Bonus: transformata Fourier = produs scalar cu  $e^{j\omega t}$

$$\mathcal{F}\{x(t)\} = \langle x(t), e^{j\omega t} \rangle = \int x(t) e^{-j\omega t}$$

- ▶ pentru semnale complexe, al doilea termen se conjugă, de aceea este  $-j$  în loc de  $j$

$$\langle \mathbf{x}, \mathbf{y} \rangle = \sum_i x_i y_i^*$$

$$\langle \mathbf{x}, \mathbf{y} \rangle = \int x(t) y(t)^*$$

- ▶ Identic pentru semnale discrete

- ▶ Concluzie: definirea algoritmilor în mod generic, pe bază de produse scalare / distanțe / norme, este extrem de folositoare!
  - ▶ se aplică automat tuturor spațiilor vectoriale
  - ▶ un singur algoritm, utilizări pentru multiple tipuri de semnale

## II.5 Detectia semnalelor cu distributii necunoscute

- ▶ Până acum, se cunoștea dpdv. matematic statistica tuturor datelor:
  - ▶ Se cunoșteau semnalele:
    - ▶  $s_0(t) = \dots$
    - ▶  $s_1(t) = \dots$
  - ▶ Se cunoștea zgomotul
    - ▶ gaussian, uniform, etc.
  - ▶ Se cunoșteau distribuțiile condiționate:
    - ▶  $w(r|H_0) = \dots$
    - ▶  $w(r|H_1) = \dots$
- ▶ În aplicații reale, lucrurile pot fi mai complicate

## Exemplu

- ▶ Dacă semnalele  $s_0(t)$  și  $s_1(t)$  nu există / nu se cunosc?
- ▶ Exemplu: recunoașterea feței unei persoane
  - ▶ Identificarea persoanei A sau B bazată pe o imagine a feței
  - ▶ Avem:
    - ▶ 100 imagini ale persoanei A, în condiții diverse
    - ▶ 100 imagini ale persoanei B, în condiții diverse

- ▶ Să comparăm recunoașterea fetelor cu detectia semnalelor
- ▶ Aspecte comune:
  - ▶ două ipoteze  $H_0$  (persoana A) și  $H_1$  (persoana B)
  - ▶ un vector de eșantioane  $\mathbf{r}$  = imaginea pe baza căreia se face decizia
  - ▶ se pot lua două decizii
  - ▶ 4 scenarii: rejecție corectă, alarmă falsă, pierdere, detectie corectă
- ▶ Ce diferă? Nu există formule matematice
  - ▶ nu există semnalele "originale"  $s_0(t) = \dots$  și  $s_1(t) = \dots$
  - ▶ (fetele persoanelor A și B nu pot fi exprimate matematic ca semnale)
  - ▶ În schimb, avem multe exemple din fiecare distribuție
    - ▶ 100 imagini ale lui A = exemple ale  $\mathbf{r}$  în ipoteza  $H_0$
    - ▶ 100 imagini ale lui B = exemple ale  $\mathbf{r}$  în ipoteza  $H_1$

- ▶ Terminologia folosită în domeniul **învățării automate** (*machine learning*):
  - ▶ Acest tip de problemă = problemă de **clasificare** a semnalelor
    - ▶ se dă un vector de date, găsiți-i clasa
  - ▶ **Clase de semnal** = categoriile posibile ale semnalelor (ipotezele  $H_i$ , persoanele A/B etc)
  - ▶ **Set de antrenare** = un set de semnale cunoscute inițial
    - ▶ de ex. 100 de imagini ale fiecărei persoane
    - ▶ setul de date va fi folosit în procesul de decizie

- ▶ Setul de antrenare conține informațiile pe care le-ar conține distribuțiile condiționate  $w(r|H_0)$  și  $w(r|H_1)$ 
  - ▶  $w(r|H_0)$  exprimă cum arată valorile lui  $r$  în ipoteza  $H_0$
  - ▶  $w(r|H_1)$  exprimă cum arată valorile lui  $r$  în ipoteza  $H_1$
  - ▶ setul de antrenare exprimă același lucru, nu prin formule, dar prin multe exemple
- ▶ Cum se face clasificarea în aceste condiții?

## Algoritmul *k-Nearest Neighbours* (k-NN)

► Intrare:

- set de antrenare cu vectorii  $\mathbf{x}_1 \dots \mathbf{x}_N$ , din  $L$  clase posibile de semnal  
 $C_1 \dots C_L$
- clasele vectorilor de antrenare sunt cunoscute
- vector de test  $\mathbf{r}$  care trebuie clasificat
- parametrul  $k$

1. Se calculează distanța între  $\mathbf{r}$  și fiecare vector de antrenare  $\mathbf{x}_i$ 
    - se poate utiliza distanța Euclidiană, aceeași utilizată pentru detectia semnalelor din secțiunile precedente
  2. Se aleg cei mai apropiati  $k$  vectori de  $\mathbf{r}$  (cei  $k$  "nearest neighbours")
  3. Se determină clasa lui  $\mathbf{r}$  = clasa majoritară între cei  $k$  cei mai apropiati vecini
- Ieșire: clasa vectorului  $\mathbf{r}$

# Algoritmul k-NN

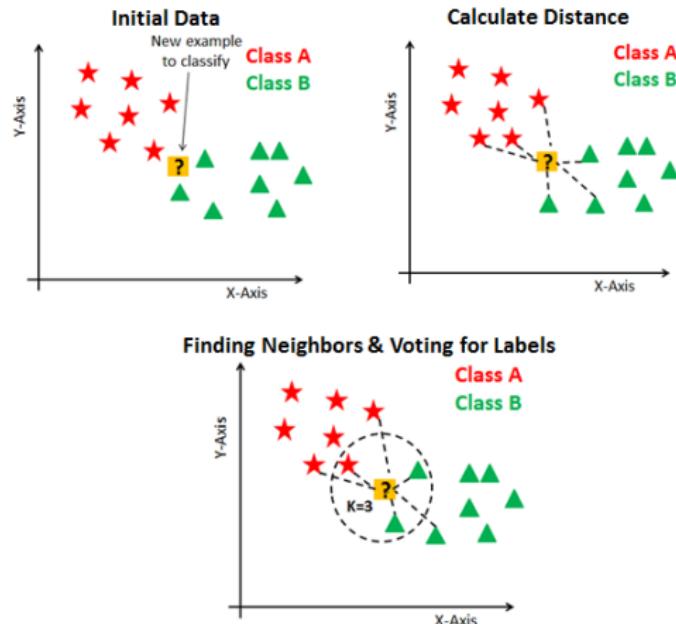


Figure 9: Algoritmul k-NN ilustrat [1]

[1] sursa: "KNN Classification using Scikit-learn", Avinash Navlani,

<https://www.datacamp.com/community/tutorials/k-nearest-neighbor-classification-scikit-learn>

- ▶ Dacă setul de antrenare este foarte mare, algoritmul k-NN devine similar cu decizia pe baza criteriului ML
- ▶ Numărul de vectori situați într-o vecinătate a unui punct  $r$  este proporțional cu  $w(r|H_i)$
- ▶ Mai mulți vecini din clasa A decât din clasa B  $\Leftrightarrow w(r|H_A) > w(r|H_B)$

- ▶ Exemplu: frunze și copaci :) de povestit

## Exercițiu

1. Fie următorul set de antrenare, compus din 5 vectori din clasa A și alți 5 vectori din clasa B:

► Clasa A:

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ -2 \end{bmatrix} \quad \mathbf{v}_2 = \begin{bmatrix} -1 \\ 1 \end{bmatrix} \quad \mathbf{v}_3 = \begin{bmatrix} -4 \\ 2 \end{bmatrix} \quad \mathbf{v}_4 = \begin{bmatrix} 2 \\ 1 \end{bmatrix} \quad \mathbf{v}_5 = \begin{bmatrix} -2 \\ -2 \end{bmatrix}$$

► Clasa B:

$$\mathbf{v}_6 = \begin{bmatrix} 7 \\ 0 \end{bmatrix} \quad \mathbf{v}_7 = \begin{bmatrix} 2 \\ 3 \end{bmatrix} \quad \mathbf{v}_8 = \begin{bmatrix} 3 \\ 2 \end{bmatrix} \quad \mathbf{v}_9 = \begin{bmatrix} -3 \\ 8 \end{bmatrix} \quad \mathbf{v}_{10} = \begin{bmatrix} -2 \\ 5 \end{bmatrix}$$

Determinați clasa vectorului  $\mathbf{x} = \begin{bmatrix} -3 \\ 6 \end{bmatrix}$  utilizând algoritmul k-NN, cu  $k = 1, k = 3, k = 5, k = 7$  and  $k = 9$

- ▶ k-NN este un algoritm de învățare supervizată
  - ▶ se cunosc clasele vectorilor din setul de antrenare
- ▶ Efectul lui  $k$ : netezirea frontierei de decizie:
  - ▶  $k$  mic: frontieră foarte cotită / "șifonată" / cu multe coturi
  - ▶  $k$  mare: frontieră mai netedă
- ▶ Cum se găsește o valoare optimă pentru  $k$ ?

- ▶ Cum se găsește o valoare optimă pentru  $k$ ?
  - ▶ prin încercări ("băbește")
- ▶ "**Cross-validation**" = folosirea unui mic set de test pentru a verifica care valoare a parametrului e mai bună
  - ▶ acest set de date se numește set de "**cross-validare**"
  - ▶ se impune  $k = 1$ , se testează cu setul de "*cross-validare*" câți vectori sunt clasificați corect
  - ▶ se repetă pentru  $k = 2, 3, \dots, max$
  - ▶ se alege valoarea lui  $k$  cu care s-au obținut rezultatele cele mai bune

- ▶ Cum se evaluatează performanța algoritmului k-NN?
  - ▶ Se folosește un set de date de testare, și se calculează procentajul vectorilor clasificați corect
- ▶ Setul de date pentru evaluarea finală trebuie să fie diferit de setul de “*cross-validation*”
  - ▶ pentru evaluarea finală se folosesc date pe care algoritmul nu le-a mai utilizat niciodată
- ▶ Cum se împarte setul de date disponibile?

- ▶ Presupunem că avem în total 200 imagini tip fețe, 100 imagini ale persoanei A și 100 ale lui B
- ▶ Setul de date total se împarte în:
  - ▶ Set de antrenare
    - ▶ vectorii care vor fi utilizati de algoritm
    - ▶ cel mai numeros, aprox. 60% din datele totale
    - ▶ de ex. 60 imagini ale persoanei A și 60 ale lui B
  - ▶ Set de *cross-validation*
    - ▶ utilizat pentru a testa algoritmul în vederea alegerii parametrilor optimi ( $k$ )
    - ▶ mai mic, aprox. 20% din date (de ex. 20 imagini ale lui A și 20 ale lui B)
  - ▶ Set de testare
    - ▶ utilizat pentru evaluarea finală a algoritmului, cu valorile parametrilor fixate
    - ▶ mai mic, aprox. 20% din date (de ex. 20 imagini ale lui A și 20 ale lui B)

- ▶ k-Means: un algoritm pentru **clusterizarea** datelor
  - ▶ identificarea grupurilor de date apropriate între ele
- ▶ Un exemplu de algoritm de învățare nesupervizată
  - ▶ “învățare nesupervizată” = nu se cunosc clasele semnalelor din setul de antrenare

# Algoritmul *k-Means*

## Algoritmul *k-Means*

- ▶ Intrare:
  - ▶ set de antrenare cu vectorii  $\mathbf{x}_1 \dots \mathbf{x}_N$
  - ▶ numărul de clase  $C$
- ▶ Inițializare: centroizii  $C$  iau valori aleatoare

$$\mathbf{c}_i \leftarrow \text{valori aleatoare}$$

- ▶ Repetă
  1. Clasificare: se clasifică fiecare vector  $\mathbf{x}$  pe baza celui mai apropiat centroid:
$$\text{class}x = \arg \min_i d(\mathbf{x}, \mathbf{c}_i), \forall \mathbf{x}$$
  2. Actualizare: se actualizează centroizii  $\mathbf{c}_i = \text{media vectorilor } \mathbf{x} \text{ din clasa } i$

$$\mathbf{c}_i \leftarrow \text{media vectorilor } \mathbf{x}, \forall \mathbf{x} \text{ din clasa } i$$

- ▶ Ieșire: centroizii  $\mathbf{c}_i$ , clasele tuturor vectorilor de intrare  $\mathbf{x}_n$

## Algoritmul *k-Means*

Algoritmul *k-Means* explicitat video:

- ▶ Urmăriți video-ul următor, de la 6:28 to 7:08

<https://www.youtube.com/watch?v=4b5d3muPQmA>

- ▶ Urmăriți video-ul următor, de la 3:05 la final

<https://www.youtube.com/watch?v=luRb3y8qKX4>

## Algoritmul *k-Means*

- ▶ Algoritmul *k-Means* poate să nu conveargă spre niște grupuri adecvate de date
  - ▶ rezultatele depind de inițializarea aleatoare a centroizilor
  - ▶ se rulează de mai multe ori, se alege cel mai bun rezultat
  - ▶ există metode de inițializare optimizate (*k-Means++*)

## Exercițiu

1. Fie datele următoare:

$$\{\mathbf{v}_n\} = [1.3, -0.1, 0.5, 4.7, 5.1, 5.8, 0.4, 4.8, -0.7, 4.9]$$

Utilizați algoritmul k-Means pentru a găsi doi centroizi  $\mathbf{c}_1$  și  $\mathbf{c}_2$ , pornind de la valorile aleatoare  $\mathbf{c}_1 = -0.5$  și  $\mathbf{c}_2 = 0.9$ . Realizați 5 iterații ale algoritmului.