

Decizie și Estimare în Prelucrarea Informației

## Capitolul III. Elemente de Teoria Estimării

### III.1 Introducere

## Ce înseamnă "estimare"?

- ▶ Un emițător transmite un semnal  $s_\Theta(t)$  care depinde de parametru necunoscut  $\Theta$
- ▶ Semnalul este afectat de zgomot, se recepționează

$$\boxed{r(t)} = s_\Theta(t) + \underline{\text{zgomot}}$$

- ▶ Vrem să găsim valoarea parametrului  $\Theta$ 
  - ▶ pe baza eșantioanelor din semnalul recepționat, sau a întregului semnal
  - ▶ datele recepționate au zgomot  $\Rightarrow$  parametrul este "estimat"
- ▶ Valoarea găsită este  $\hat{\Theta}$ , estimatul lui  $\Theta$ 
  - ▶ există întotdeauna eroare de estimare  $\epsilon = \hat{\Theta} - \Theta$

$$A = \begin{cases} A \\ S \end{cases}$$

$$\begin{aligned}s_\Theta(t) &= \textcircled{A} \\ &= \cos(\underline{\omega t}) \\ &= \textcircled{A} \cdot \cos(2\pi f t)\end{aligned}$$

$$\begin{cases} s_\Theta(t) = \cos(2\pi f t) \\ s_r(t) = 0 \end{cases}$$


$$s_r(t) = A \cdot \cos(2\pi f t), A = \begin{cases} A \\ 1 \end{cases}$$

# Ce înseamnă "estimare"?

7.1 7.15 6.93 6.74 7.02

$\hat{A} =$

$$D(t) = A$$



## ► Exemple:

- ▶ Amplitudinea unui semnal constant:  $r(t) = A + \text{zgomot}$ , trebuie estimat  $A$
- ▶ Faza unui semnal sinusoidal:  $r(t) = \cos(2\pi ft + \phi) + \text{zgomot}$ , de estimat  $\phi$
- ▶ Exemple mai complicate:
  - ▶ De estimat/decis ce cuvânt este pronunțat într-un semnal vocal

$$\varepsilon = \hat{A} - A = -0.1$$

## Estimare și Detectie/Decizie

$$\delta(A) = A \quad , \quad \hat{A} = ?$$

$$\delta(A) = A, \quad A = \begin{cases} 0 \\ 5 \end{cases} \quad , \quad \hat{A} = \begin{cases} 0 \\ 5 \end{cases} ?$$

- ▶ Fie următoarea problemă de estimare:

Se recepționează un semnal  $r(t) = A + \text{zgomot}$ , estimați-l pe  $A$

- ▶ La detectie: se alege între două valori cunoscute ale  $A$ :

- ▶ de ex.  $A$  poate fi 0 sau 5 (ipotezele  $H_0$  și  $H_1$ )
- ▶ La estimare:  $A$  poate fi oricât  $\Rightarrow$  se alege între o infinitate de opțiuni ale  $A$ 
  - ▶  $A$  poate fi orice valoare din  $\mathbb{R}$ , în general

## Decizie

- ▶ Detectie = Estimare **restrânsă** doar la un set discret de opțiuni
- ▶ Estimare = Detectie cu un număr infinitt de opțiuni posibile
- ▶ Metodele statistice sunt similare
  - ▶ În practică, distincția între estimare și detectie nu este strictă
  - ▶ (de ex. când trebuie să alegem între 1000 de ipoteze, este "detectie" sau "estimare"?)

$$\Delta_0(t) \subset -1000000$$

$$\Delta_1(t) = -599\dots59$$

$$\Delta_2(t) = -999\dots58$$

## Semnalul recepționat

$w(x)$

- ▶ Semnalul recepționat este  $r(t) = s_{\Theta}(t) + zgomot$ 
  - ▶ este afectat de zgomot
  - ▶ depinde de parametrul necunoscut  $\Theta$
- ▶ Considerăm N eșantioane din  $r(t)$ , luate la momentele de timp  $t_i$

$$\underline{\mathbf{r}} = [r_1, r_2, \dots, r_N]$$

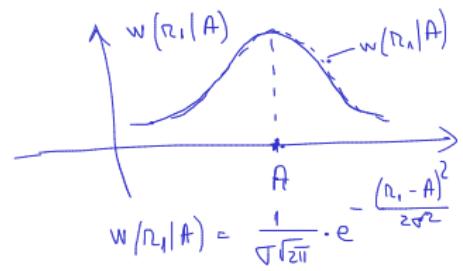
- ▶ Eșantioanele depind de valoarea lui  $\Theta$        $\Rightarrow$        $\hat{\Theta}$

## Semnalul recepționat

Exemplu:

$$\Delta_{\Theta}(t) = A$$

$$r_i(t) = A + z_{\text{gomer}} \sim N(\mu=0, \sigma^2)$$



- ▶ Fiecare eşantion  $r_i$  este o variabilă aleatoare ce depinde de  $\Theta$  (și de zgomer)

- ▶ Fiecare esantion are o distribuție care depinde de  $\Theta$

$$w_i(r_i | \Theta)$$

$$w_i(r_i | \Theta)$$

~

$$w(r_i | \frac{\Theta_0}{\Theta_1})$$

- ▶ Întregul vector de esantioane  $r$  este o variabilă aleatoare N-dimensională ce depinde de  $\Theta$  (și de zgomer)

- ▶ Are o distribuție N-dimensională ce depinde de  $\Theta$
  - ▶ Egală cu produsul tuturor  $w_i(r_i | \Theta)$



$$w(r | \Theta) = \underbrace{w_1(r_1 | \Theta)} \cdot \underbrace{w_2(r_2 | \Theta)} \cdot \dots \cdot \underbrace{w_N(r_N | \Theta)}$$

# Tipuri de estimare

► Considerăm două tipuri de estimare:

1. **Estimare de plauzibilitate maximă** (Maximum Likelihood Estimation, MLE): În afară de  $r$  nu se cunoaște nimic despre  $\Theta$ , decât cel mult vreun domeniu de existență (de ex.  $\Theta > 0$ )
2. **Estimare Bayesiană**: În afară de  $r$  se mai cunoaște o distribuție a priori  $w(\Theta)$  a lui  $\Theta$ , care indică ce valori ale lui  $\Theta$  sunt mai probabile / mai puțin probabile

► caz mai general decât primul



Estimare ML (Maximum Likelihood)

~ Adjectiv M.L.

~ Detection M.P.E.  
M.R.

$P(H_0)$   
 $P(H_1)$

C<sub>00</sub>

C<sub>10</sub>

C<sub>01</sub>

C<sub>11</sub>

## II.2 Estimarea de plauzibilitate maximă (Maximum Likelihood)

## Estimarea tip Maximum Likelihood

- Dacă nu se cunoaște vreo distribuție *a priori* se folosește metoda estimării de plauzibilitate maximă ("Maximum Likelihood", ML)
- Se definește **plauzibilitatea** unei valori  $\Theta$ , dat fiind vectorul de observații  $r$ :

$$L(\Theta|r) = \underbrace{w(\Theta|r)}_{\text{likelihood}} \cdot w(r|\Theta) = \text{probabilitatea de a se fi generat } r \text{ dacă param. erau fi avut valoarea } \Theta$$

- $L(\Theta|r)$  reprezintă funcția de plauzibilitate
- A se compara cu formula din Cap. 2, slide 20

- e aceeași
- aici "ghicim" pe  $\Theta$ , acolo "ghiceam" pe  $H_i$



# Estimarea tip Maximum Likelihood

$$\hat{\theta}_{ML}$$

$$L(\theta|r) = \text{o funcție de } \theta$$


Estimarea de plauzibilitate maximă (Maximum Likelihood, ML):

- ▶ Estimatul  $\hat{\theta}_{ML}$  este valoarea care maximizează plauzibilitatea, dat fiind valorile observate  $r$

- ▶ i.e. valoarea care maximizează  $L(\theta|r)$ , adică maximizează  $w(r|\theta)$

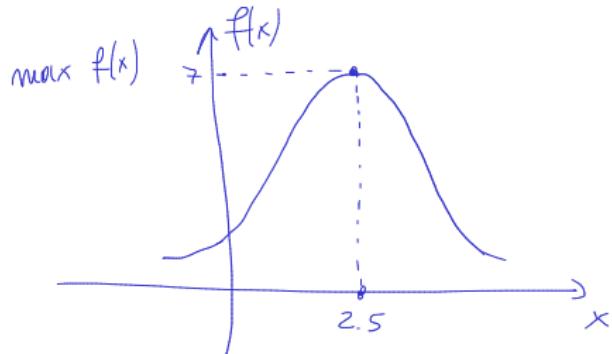
$$\hat{\theta}_{ML} = \arg \max_{\theta} L(\theta|r) = \arg \max_{\theta} w(r|\theta)$$

- ▶ Dacă  $\theta$  aparține doar unui anumit interval, se face maximizarea doar pe acel interval




## ▶ Notări matematice generale

- ▶  $\arg \max_x f(x) =$  "valoarea  $x$  care maximizează funcția  $f(x)$ "
- ▶  $\max_x f(x) =$  "valoarea maximă a funcției  $f(x)$ "



$$2.5 = \arg\max f(x)$$
$$7 = \max f(x)$$



## Estimare vs decizie Maximum Likelihood

- ▶ Estimarea ML este foarte similară cu decizia ML!
- ▶ Criteriul de decizie ML:
  - ▶ “se alege ipoteza cu plauzibilitate mai mare”:

$$\frac{L(H_1|r)}{L(H_0|r)} = \frac{w(r|H_1)}{w(r|H_0)} \stackrel{H_1}{\gtrless} 1$$

- ▶ Estimare ML:
  - ▶ “se alege valoarea care maximizează plauzibilitatea”

$$\hat{\Theta}_{ML} = \arg \max_{\Theta} L(\Theta|r) = \arg \max_{\Theta} w(r|\Theta)$$


# Găsirea maximului

- ▶ Cum se rezolvă problema de maximizare?
  - ▶ adică cum se găsește estimatul  $\hat{\Theta}_{ML}$  care maximizează  $L(\Theta | \text{vec} r)$
- ▶ Maximul se găsește prin derivare și egalare cu 0

$$\frac{dL(\Theta | \mathbf{r})}{d\Theta} = 0$$

- ▶ Se poate aplica **logaritmul natural** asupra funcției  $L(\Theta | \mathbf{r})$  înainte de derivare (funcția "log-likelihood")

$$\frac{d \ln(L(\Theta | \mathbf{r}))}{d\Theta} = 0$$



arcpnolx  $f(x) = \operatorname{argmax} \ln(f(x))$

## Procedura de găsire a estimatului

Procedura de găsire a estimatului ML:

1. Se găsește expresia funcției

$$\underline{L(\Theta|\mathbf{r})} = w(\mathbf{r}|\Theta)$$

2. Se pune condiția ca derivata lui  $L(\Theta|\mathbf{r})$  sau a lui  $\ln(L(\Theta|\mathbf{r}))$  să fie 0

$$\frac{dL(\Theta)}{d\Theta} = 0, \text{ sau } \frac{d \ln(L(\Theta))}{d\Theta} = 0$$

3. Se rezolvă ecuația, se găsește valoarea  $\hat{\Theta}_{ML}$
4. Se verifică că derivata a doua în punctul  $\hat{\Theta}_{ML}$  este negativă, pentru a verifica că este un punct de maxim

- ▶ Întrucât derivata = 0 și pentru maxime și pentru minime
- ▶ uneori sărim peste această etapă




## Exemple

$$D_\theta(t) = A$$

$$r_i(t) = A + \text{zgomot}, \quad N(\mu=0, \sigma^2 = \sigma_z^2)$$

$$r_i = [5, 7, 8, 6.1, 5.3]$$

$$L(\theta|r_i) = w(r_i|\theta) = \frac{1}{\sqrt{2\pi\sigma_z^2}} \cdot e^{-\frac{(r_i - A)^2}{2\sigma_z^2}}$$



de 5 ori

- ▶ Estimarea unui semnal constant în zgomot gaussian:

Găsiți estimatul Maximum Likelihood pentru un semnal de valoare constantă  $s_\theta(t) = A$  din 5 măsurători afectate de zgomot

$r_i = A + \text{zgomot}$ , cu valori egale cu  $[5, 7, 8, 6.1, 5.3]$ . Zgomotul este AWGN  $N(\mu = 0, \sigma_z^2)$ .

- ▶ Soluție: la tablă
- ▶ Estimatul  $\hat{A}_{ML}$  este chiar valoarea medie a eșantioanelor

▶ (deloc surprinzător)

$$L(A|r_i) = w(r_i|\theta) = \left( \frac{1}{\sqrt{2\pi\sigma_z^2}} \right)^5 \cdot e^{-\frac{(r_1-A)^2 + (r_2-A)^2 + (r_3-A)^2 + (r_4-A)^2 + (r_5-A)^2}{2\sigma_z^2}}$$

$$\ln(L(A|r_i)) = \ln\left(\left(\frac{1}{\sqrt{2\pi\sigma_z^2}}\right)^5\right) + \frac{(5-A)^2 + (7-A)^2 + (8-A)^2 + (6.1-A)^2 + (5.3-A)^2}{2\sigma_z^2}$$


# Simulare numerică

Traceback (most recent call last):

```
File "source.py", line 1, in <module>
```

```
    import matplotlib.pyplot as plt, numpy as np, math;
```

```
ModuleNotFoundError: No module named 'matplotlib'
```



$$2) \frac{d}{da} (\ln L(a|z)) = 0 \quad (\Rightarrow)$$

$$\frac{1}{2} \left( z(5-a) + z(7-a) + z(8-a) + z(6.1-a) + z(5.3-a) \right) = 0$$

$$\Rightarrow 5-a + 7-a + 8-a + 6.1-a + 5.3-a = 0$$

$$\Rightarrow 31.4 = 5a$$

$$\Rightarrow \hat{a}_{ML} = \frac{31.4}{5} = \frac{5+7+8+6.1+5.3}{5} = 6.28$$

## Aproximare a unei curbe


curve fitări

- ▶ Estimare = aproximare a unei curbe

- ▶ se găsește cea mai bună potrivire a lui  $s_\theta(t)$  <sup>cu</sup> ~~pri~~ datele  $r$

- ▶ Din exemplul grafic anterior:

- ▶ avem un set de date  $r$
  - ▶ se cunoaște forma semnalului = o dreaptă orizontală ( $A$  constant)
  - ▶ se aproximează în mod optim dreapta prin setul de date




$$s_\theta(t) = \underline{\theta} \cdot t$$

$$r_i = \underline{\theta} \cdot t_i + z_{\text{genuf}} \\ s_\theta(t_i)$$

## Semnal oarecare în AWGN (Additive White Gaussian Noise)

- ▶ Fie semnalul original  $s_\Theta(t)$
- ▶ Zgomotul este AWGN  $\mathcal{N}(\mu = 0, \sigma^2)$
- ▶ Eșantioanele  $r_i$  sunt luate la momentele  $t_i$
- ▶ Eșantioanele  $r_i$  au distribuție normală, cu media  $\mu = s_\Theta(t_i)$  și varianța  $\sigma^2$
- ▶ Funcția de plauzibilitate globală = produsul plauzibilităților fiecărui eșantion  $r_i$

$$\begin{aligned} & s_\Theta(t) + z_{\text{gumot}} \\ t_i: r_i &= s_\Theta(t_i) + z_{\text{gumot}} \end{aligned}$$



$$\begin{aligned} L(\Theta | \mathbf{r}) = w(\mathbf{r} | \Theta) &= \prod_{i=1}^N \frac{1}{\sigma \sqrt{2\pi}} e^{-\frac{(r_i - s_\Theta(t_i))^2}{2\sigma^2}} \\ &= \left( \frac{1}{\sigma \sqrt{2\pi}} \right)^N \cdot e^{-\frac{\sum_{i=1}^N (r_i - s_\Theta(t_i))^2}{2\sigma^2}} \end{aligned}$$

## Semnal oarecare în AWGN

- Logaritmul plauzibilității ("log-likelihood") este

$$\ln(L(\Theta|\mathbf{r})) = \underbrace{\ln\left(\frac{1}{\sigma\sqrt{2\pi}}\right)^N}_{\text{constant}} - \frac{\sum(r_i - s_\Theta(t_i))^2}{2\sigma^2}$$

✓ din  $\Theta$  care face funcția asta să fie maximă

Vrem termenul acesta să mai mic !

$$d(r, s_\Theta)$$

$$d = [r_1 \ r_2 \ \dots \ r_n]$$
$$s_\Theta = [s_\Theta(t_1) \ s_\Theta(t_2) \ \dots \ s_\Theta(t_n)]$$

## Semnal oarecare în AWGN

- Maximul funcției = minimul exponentului

$$\hat{\Theta}_{ML} = \arg \max_{\Theta} L(\Theta | \mathbf{r}) = \arg \min_{\Theta} \sum_{i=1}^n (r_i - s_{\Theta}(t_i))^2 = \underset{\Theta}{\operatorname{arg\,min}} d(\mathbf{r}, s_{\Theta})^2$$

AWGN  
număratorul

- Termenul  $\sum(r_i - s_{\Theta}(t_i))^2$  este **distanța**  $d(\mathbf{r}, s_{\Theta})$  la pătrat

$$d(\mathbf{r}, s_{\Theta}) = \sqrt{\sum (r_i - s_{\Theta}(t_i))^2}$$

$$(d(\mathbf{r}, s_{\Theta}))^2 = \sum (r_i - s_{\Theta}(t_i))^2$$

- ▶ Estimarea ML se poate scrie sub forma:

$$\hat{\Theta}_{ML} = \arg \max_{\Theta} L(\Theta | \mathbf{r}) = \arg \min_{\Theta} d(\mathbf{r}, \mathbf{s}_{\Theta})^2$$

- ▶ Estimatul de plauzibilitate maximă (ML)  $\hat{\Theta}_{ML}$  = valoarea care face  $s_{\Theta}(t_i)$  **cel mai apropiat de vectorul recepționat r**
  - ▶ mai aproape = potrivire mai bună = mai probabil
  - ▶ cel mai aproape = cea mai bună potrivire = cel mai probabil = plauzibilitate maximă

# Semnal oarecare în AWGN

- ▶ Estimare ML în zgomot gaussian = minimizarea distanței
- ▶ Aveam aceeași interpretare și la decizia ML!
  - ▶ dar la decizie alegeam minimul din 2 opțiuni
  - ▶ aici alegem minimul dintre toate opțiunile posibile
- ▶ Relația e valabilă pentru orice fel de spații vectoriale
  - ▶ vectori cu N elemente, semnale continue, etc
  - ▶ doar se înlocuiește definiția distanței Euclidiene

Exemplu: problema de pe slide-ul 18 :

$$\mathbf{r} = [5 \quad 7 \quad 8 \quad 6.1 \quad 5.3]$$

$$\mathbf{s}_0 = [A \quad A \quad A \quad A \quad A]$$

$$D = \sigma^2 (\mathbf{r}, \mathbf{s}_0)^2 = (A-5)^2 + (A-7)^2 + (A-8)^2 + (A-6.1)^2 + (A-5.3)^2$$

$$\frac{\partial D}{\partial A} = \cancel{2(A-5)} + \cancel{2(A-7)} + \cancel{2(A-8)} + \cancel{2(A-6.1)} + \cancel{2(A-5.3)} \\ = 0$$

$$\Rightarrow \hat{A}_{ML} = \frac{5+7+8+6.1+5.3}{5} = 6.28$$

$$\hat{A}_{ML} = \frac{r_1 + r_2 + \dots + r_N}{N} = \frac{1}{N} \sum_{i=1}^N r_i \quad \begin{matrix} \text{medie} \\ \text{aritmetică!} \end{matrix}$$

## Semnal oarecare în AWGN

Procedura pentru estimarea tip ML în zgomot AWGN:

1. Se scrie expresia pentru pătratul distanței:

$$D = (d(\mathbf{r}, s_\Theta))^2 = \sum (r_i - s_\Theta(t_i))^2$$


2. Vrem minimul, deci egalăm derivata cu 0:

$$\frac{dD}{d\Theta} = \sum 2(r_i - s_\Theta(t_i))(-\frac{ds_\Theta(t_i)}{d\Theta}) = 0$$

3. Se rezolvă și obținem valoarea  $\hat{\Theta}_{ML}$

4. Se verifică că derivata a doua în punctul  $\hat{\Theta}_{ML}$  este pozitivă, pentru a se verifica că punctul este un minim

- ▶ uneori sărim peste această etapă



Estimarea frecvenței  $f$  a unui semnal sinusoidal

- ▶ Găsiți estimatul Maximum Likelihood pentru frecvența  $f$  a unui semnal  $s_\Theta(t) = \cos(2\pi ft_i)$ , din 10 măsurători afectate de zgomot  $r_i = \cos(2\pi ft_i) + \text{zgomot}$  de valori [...]. Zgomotul este AWGN  $\mathcal{N}(\mu = 0, \sigma^2)$ . Momentele de eșantionare sunt

$$t_i = [0, 1, 2, 3, 4, 5, 6, 7, 8, 9]$$


- ▶ Soluție: la tablă

$$\underline{r} = [r_1, r_2, \dots, r_{10}]$$

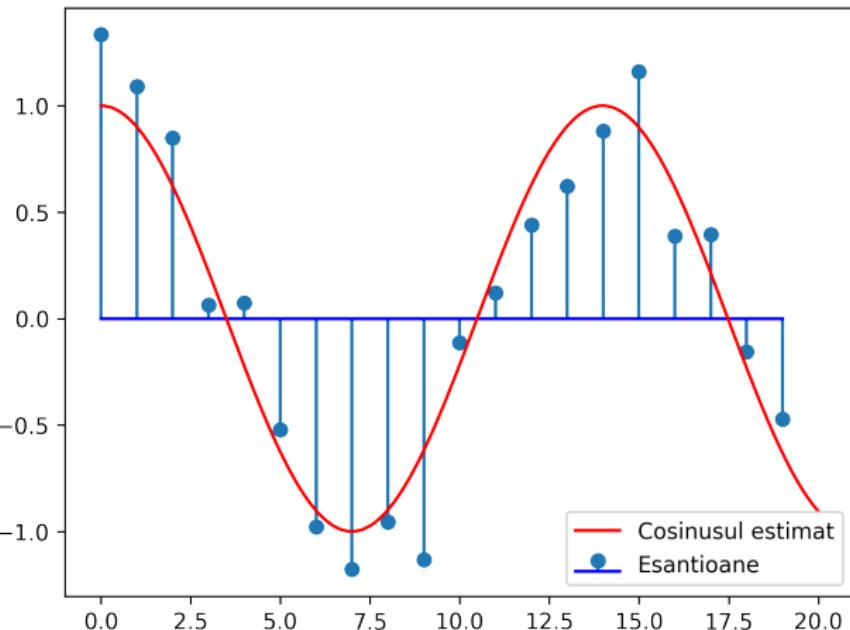
$$\underline{s}_0 = [\cos(2\pi f t_0), \cos(2\pi f t_0), \dots, \cos(2\pi f t_0)]$$

$$D = d(r, s_0)^2$$

Funcția de plauzibilitate este  $L(\theta | \mathbf{r}) = L(f | \mathbf{r}) \quad (\theta = f)$



## Simulare numerică



## Parametri multipli

- Dacă semnalul depinde de mai mulți parametri?

- de ex. amplitudinea, frecvența și faza inițială a unui cosinus:

$$s(t) = A \cos(2\pi ft + \phi)$$

- Se va considera  $\Theta$  ca fiind un vector:

$$\Theta = [A, f, \phi]$$

$$\Theta = [\Theta_1, \Theta_2, \dots, \Theta_M]$$

- e.g.  $\Theta = [\Theta_1, \Theta_2, \Theta_3] = [A, f, \phi]$

# Parametri multipli

rezonat gaussian:

$$D = d(r, \underbrace{s_0}_{A, f, \varphi})^2 = D(A, f, \varphi) \text{ depinde de mai multe necunoscute}$$

- Se rezolvă cu aceeași procedură, dar în loc de o singură derivată vom avea  $M$  deriveate
- Se rezolvă sistemul:

$$\begin{cases} \frac{\partial L}{\partial \Theta_1} = 0 \\ \frac{\partial L}{\partial \Theta_2} = 0 \\ \dots \\ \frac{\partial L}{\partial \Theta_M} = 0 \end{cases}$$

$$r = [r_1, r_2, r_3, r_4, \dots]$$

$$s_0 = [A \cos(2\pi f_1 t_1 + \varphi), A \cos(2\pi f_2 t_2 + \varphi), A \cos(2\pi f_3 t_3 + \varphi), A \cos(2\pi f_4 t_4 + \varphi), \dots]$$

$$D = d(r, s_0)^2 = (A \cos(2\pi f_1 t_1 + \varphi) - r_1)^2 + \dots + (A \cos(2\pi f_4 t_4 + \varphi) - r_4)^2$$

- uneori este dificil/imposibil

$$\left\{ \begin{array}{l} \frac{\partial D}{\partial A} = 0 \\ \frac{\partial D}{\partial f} = 0 \\ \frac{\partial D}{\partial \varphi} = 0 \end{array} \right. \Rightarrow A, f, \varphi = \dots$$

## Coborâre după gradient (Gradient Descent)

- ▶ Cum se estimează parametrii  $\Theta$  în cazuri complicate?
  - ▶ În aplicații reale, unde pot fi foarte mulți parametri ( $\Theta$  este vector)
- ▶ De obicei nu se pot găsi valorile optime prin formule directe
- ▶ Se îmbunătățesc valorile în mod iterativ cu algoritmi tip coborâre după gradient (Gradient Descent)

# Coborâre după gradient (Gradient Descent)

1. Se initializează parametrii cu valori aleatoare  $\Theta^{(0)}$

2. Repetă la fiecare iteratie  $k$ :

2.1 Se calculează funcția  $J(\Theta^{(k)} | \mathbf{r})$

2.2 Se calculează derivatele  $\frac{\partial J}{\partial \Theta_i^{(k)}}$  pentru toți  $\Theta_i$  ("Gradient")

2.3 Se actualizează toate valorile  $\Theta_i$ , prin scăderea derivatei ("Descent"):


$$\Theta_i^{(k+1)} = \Theta_i^{(k)} - \mu \frac{\partial J}{\partial \Theta_i^{(k)}}$$

new value      old value      step size      derivative

► sau, sub formă vectorială:

$$\Theta^{(k+1)} = \Theta^k - \mu \frac{\partial J}{\partial \Theta^{(k)}}$$

3. Până la îndeplinirea unui criteriu de terminare (de ex. parametrii nu se mai modifică mult)



## Coborâre după gradient (Gradient Descent)

- ▶ Explicații la tablă
- ▶ Exemplu: regresia logistică cu valori 2D
  - ▶ exemplu la tablă

- ▶ Cel mai proeminent exemplu: **Rețele Neurale Artificiale** (a.k.a. “Rețele Neurale”, “Deep Learning”, etc.)
  - ▶ Pot fi văzute ca un exemplu de estimare ML
  - ▶ Se utilizează algoritmul Gradient Descent, pentru găsirea parametrilor
  - ▶ Aplicații de vârf: recunoașterea de imagini, automated driving etc.
- ▶ Mai multe informații despre rețele neurale / machine learning:
  - ▶ căutați cursuri sau cărți online
  - ▶ IASI AI Meetup

## Deplasarea și varianta estimatorilor

Exemplu:  $\mathbf{r} = [5 \ 7 \ 8 \ 6.1 \ 5.3]$   
 $\mathbf{s}_n = [A \ A \ A \ A \ A]$

$$\hat{\theta}_{ML} = \frac{1}{N} \sum_{i=1}^N r_i$$

- ▶ Cum caracterizăm calitatea unui estimator?
- ▶ Un estimator  $\hat{\theta}$  este o variabilă aleatoare
  - ▶ poate avea diverse valori, pentru că se calculează pe baza eșantioanelor receptionate, care depend de zgomot
  - ▶ exemplu: se repetă aceeași estimare pe calculatoare diferite  $\Rightarrow$  valori estimate ușor diferite
- ▶ Fiind o variabilă aleatoare, se pot defini:
  - ▶ valoarea medie a estimatorului:  $E\{\hat{\theta}\}$  = media valorilor estimate
  - ▶ varianța estimatorului:  $E\{(\hat{\theta} - \theta)^2\}$

estimatorul  
măstru       $E[\hat{\theta}]$   
 $\hat{\theta}$   
 median  
estimatorul

# Deplasarea și varianța estimatorilor




Figure 1: Deplasarea și varianța estimatorilor

## Deplasarea unui estimator

- **Deplasarea** ("bias") unui estimator = diferența dintre valoarea medie a estimatorului și valoarea adevărată  $\Theta$

$$\text{Deplasare} = E\{\hat{\Theta}\} - \Theta$$

- Estimator **nedeplasat** = valoarea medie a estimatorului este egală cu valoarea adevărată a parametrului  $\Theta$

$$E\{\hat{\Theta}\} = \Theta$$

- Estimator **deplasat** = valoarea medie a estimatorului diferă de valoarea adevărată a parametrului  $\Theta$

- diferența  $E\{\hat{\Theta}\} - \Theta$  este **deplasarea** estimatorului


## Deplasarea unui estimator

- Exemplu: semnal constant  $A$ , zgomot Gaussian (cu media  $\mu = 0$  și variansă  $\sigma^2 = 1$ ), estimatorul de plauzibilitate maximă este  $\hat{A}_{ML} = \frac{1}{N} \sum_i r_i$

$$\left| \begin{array}{l} E\{x+y\} = E\{x\} + E\{y\} \\ E\{a \cdot x\} = a \cdot E\{x\} \end{array} \right.$$

- Atunci:

$$\begin{aligned} E\{\hat{A}_{ML}\} &= \frac{1}{N} E\left\{\sum_i r_i\right\} \\ &= \frac{1}{N} \sum_{i=1}^N E\{r_i\} \\ &= \frac{1}{N} \sum_{i=1}^N E\{A + \text{zgomot}\} \\ &= \frac{1}{N} \sum_{i=1}^N \underbrace{E\{A\}}_{=A} + \underbrace{E\{\text{zgomot}\}}_{=0} \\ &= A \end{aligned}$$



- Acest estimator este nedeplasat

## Varianța unui estimator

$$\Delta_{\theta}(\hat{\theta}) = A$$

Exemplu:

$$\hat{A}_{ML} = \frac{1}{N} \sum_{i=1}^N r_i$$

$$\nabla_{\hat{A}}^2 = ?$$

Vrem să afiliam

$$Z = X + Y$$

$$\nabla_Z^2 = \nabla_X^2 + \nabla_Y^2$$

dacă  $X, Y$  necondate

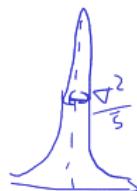

---


$$Z = a \cdot X$$

$$\nabla_Z^2 = a^2 \cdot \nabla_X^2$$

- ▶ **Varianța** unui estimator măsoară "abaterile" estimatorului în jurul valorii medii

- ▶ aceasta e definiția varianței  $\sigma^2$  în general
- ▶ Dacă un estimator are **varianță** mare, valoarea estimată poate fi departe de cea reală, chiar dacă estimatorul este nedeplasat
- ▶ De obicei se preferă estimatori cu **varianță mică**, tolerându-se o eventuală mică deplasare



$$\nabla_{\hat{A}_{ML}}^2 = \frac{1}{N} \cdot \nabla_{\text{zgmenit}}^2$$

∴

$$\begin{aligned} \nabla_{\hat{A}_{ML}}^2 &= \nabla_{\left\{ \frac{1}{N} \cdot \sum_{i=1}^N r_i \right\}}^2 \\ &= \left( \frac{1}{N} \right)^2 \cdot \nabla_{\left\{ \sum_{i=1}^N r_i \right\}}^2 \\ &= \left( \frac{1}{N} \right)^2 \cdot \sum \nabla_{\{r_i\}}^2 \\ &= \left( \frac{1}{N} \right)^2 \cdot \sum \nabla_{\{A + \text{zgmenit}\}}^2 \\ &\quad \text{zgmenit} \xrightarrow{\nabla_{\{A\}}^2 = 0} \nabla_{\{\text{zgmenit}\}}^2 \\ &= \left( \frac{1}{N} \right)^2 \cdot \sum_{i=1}^N \nabla_{\text{zgmenit}}^2 \\ &= \frac{1}{N} \cdot \nabla_{\text{zgmenit}}^2 \end{aligned}$$

## II.3 Estimare Bayesiană

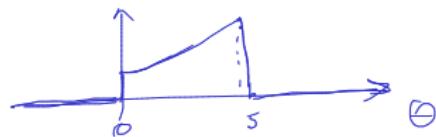
# Estimare Bayesiană

- ▶ **Estimarea Bayesiană** ia în calcul termeni suplimentari pe lângă


$$L(\theta|n) = w(r|\Theta)$$

- ▶ o distribuție a priori  $w(\Theta)$
- ▶ optional, o funcție de cost

$$w(\theta)$$



- ▶ Se obține echivalentul din estimare pentru criteriile de decizie MPE și MR



# Estimare Bayesiană

- Se definește **distribuția a posteriori** a lui  $\Theta$ , dat fiind observațiile  $r$ , folosind **regula lui Bayes**:

$$w(\theta|r) = \frac{w(r|\theta) \cdot w(\theta)}{w(r)}$$

w(r) = c = nu ne înfluentaž

- Termenii:

- $\theta$  este parametrul necunoscut
- $r$  este vectorul de observații
- $w(\theta|r)$  este probabilitatea ca parametrul să aibă valoarea  $\theta$ , dat fiind vectorul de observații  $r$ ;
- $w(r|\theta)$  este funcția de plauzibilitate  $= L(\theta|r)$
- $w(\theta)$  este distribuția **a priori** a lui  $\theta$
- $w(r)$  este distribuția **a priori** a lui  $r$ ; se presupune a fi constantă

$r$  = cunoscut  $\Rightarrow w(r) = \text{un număr}$

M.L.:  $L(\theta|r) = w(r|\theta)$

Contur: nu e o densitate față de  $\theta$

Bayes:  $w(\theta|r)$

Regula lui Bayes:

$$P(A \cap B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

(=)

$$\begin{aligned} P(A \cap B) &= P(B|A) \cdot P(A) \\ &= P(A|B) \cdot P(B) \end{aligned}$$

Exemplu

$$\begin{aligned} P(NV|D) &= 90\% \\ P(V|D) &= 10\% \\ P(D|NV) &= \frac{P(NV|D) \cdot P(D)}{P(NV)} \\ P(D|V) &= \frac{P(V|D) \cdot P(D)}{P(V)} \end{aligned}$$



# Regula lui Bayes

$$w(\Theta | \mathbf{r})$$

- Relația precedentă arată că, în general, estimarea lui  $\Theta$  depinde de două lucruri:

1. De vectorul observațiilor  $\mathbf{r}$ , prin termenul  $w(\mathbf{r} | \Theta)$
2. De informația "a priori" avută despre  $\Theta$ , prin termenul  $w(\Theta)$

- Numele este "estimare Bayesiană"

- Thomas Bayes = matematician englez, a descoperit regula cu acest nume
- Notiunile bazate pe regula lui Bayes poartă deseori numele de "Bayesiane"

$$\left\{ \begin{array}{l} \frac{P(D|NV)}{P(D|V)} = \frac{P(NV|D) \cdot P(D)}{P(NV)} \cdot \frac{P(V)}{P(V|D) \cdot P(D)} \\ \frac{P(D|NV)}{P(D|V)} = \frac{\cancel{P(NV|D)}}{\cancel{P(V|D)}} \cdot \frac{P(V)}{P(NV)} \end{array} \right.$$

$$\frac{P(D|NV)}{P(D|V)} = \frac{0.90}{0.10} \cdot \frac{0.30}{0.70}$$

$$\frac{P(D|NV)}{P(D|V)} = \frac{9}{1} \cdot \frac{3}{7} = \frac{27}{7} \approx 4$$


## Distribuția a priori

- ▶ Presupunem că se știe de dinainte o distribuție a lui  $\Theta$ ,  $w(\Theta)$ 
  - ▶ știm de dinainte care e probabilitatea de a fi a anume valoare sau alta
  - ▶ se numește distribuția a priori
- ▶ Estimarea trebuie să ia în calcul și distribuția a priori  $w(\Theta)$ 
  - ▶ estimatul va fi “tras” înspre valori mai probabile

# Estimatorul MAP

- ▶ Cunoaștem distribuția a posteriori  $w(\Theta|r)$ . Care este valoarea estimată?
- ▶ Se poate alege valoarea care are probabilitate maximă
- ▶ Estimatorul Maximum A Posteriori (MAP) este :

$$\hat{\Theta}_{MAP} = \arg \max_{\Theta} w(\Theta|r) = \arg \max_{\Theta} w(r|\Theta) \cdot w(\Theta)$$




- ▶ Estimatorul MAP alege acea valoare  $\Theta$  unde distribuția a posteriori  $w(\Theta|r)$  este maximă
- ▶ Estimatorul MAP maximizează **produsul** dintre plauzibilitate și **distribuția a priori**  $w(\Theta)$

# Estimatorul MAP

$$\cancel{n(t)} = f + \text{nois} \sim N(\mu=0, \sigma^2=3)$$

$$n_L = 5$$

Exemplu: Imagine



# Relația dintre estimarea MAP și ML

- ▶ Estimatorul ML:


$$\hat{\Theta}_{ML} = \arg \max w(\mathbf{r}|\Theta)$$

- ▶ Estimatorul MAP:


$$\hat{\Theta}_{MAP} = \arg \max w(\mathbf{r}|\Theta) \cdot w(\Theta)$$

- ▶ Estimatorul ML este un caz particular de MAP pentru  $w(\Theta)$  constant

- ▶  $w(\Theta) = \text{constant}$  înseamnă că toate valorile lui  $\Theta$  sunt *a priori* echiprobabile
- ▶ i.e. nu avem extra informații despre valoarea lui  $\Theta$



- ▶ Criteriul probabilității minime de eroare:  
$$\frac{w(r|H_1)}{w(r|H_0)} \stackrel{H_1}{\underset{H_0}{\gtrless}} \frac{P(H_0)}{P(H_1)}$$
- ▶ Se poate re scrie ca  $w(r|H_1) \cdot P(H_1) \stackrel{H_1}{\underset{H_0}{\gtrless}} w(r|H_0)P(H_0)$ 
  - ▶ adică se alege ipoteza pentru care  $w(r|H_i) \cdot P(H_i)$  este mai mare
- ▶ **Criteriul de decizie MPE:** se alege ipoteza care maximizează  $w(r|H_i) \cdot P(H_i)$ 
  - ▶ dintre cele două ipoteze  $H_0, H_1$
- ▶ **Estimarea MAP:** se alege valoarea care maximizează  $w(\mathbf{r}|\Theta) \cdot w(\Theta)$ 
  - ▶ dintre toate valorile posibile pentru  $\Theta$
- ▶ Același principiu!




# Funcția de cost

- ▶ Vrem să găsim un echivalent și pentru criteriul MR
- ▶ Avem nevoie de un echivalent pentru costurile  $C_{ij}$
- ▶ Eroarea de estimare = diferența între estimatul  $\hat{\Theta}$  și valoarea reală  $\Theta$

$$\epsilon = \hat{\Theta} - \Theta$$

- ▶ Funcția de cost  $C(\epsilon) =$  atribuie un cost pentru fiecare eroare de estimare posibilă

- ▶ când  $\epsilon = 0$ , costul  $C(0) = 0$
- ▶ erori  $\epsilon$  mici au costuri mici
- ▶ erori  $\epsilon$  mari au costuri mari



# Functia de cost

- ▶ Funcții de cost uzuale:

- ▶ Pătratică:

$$C(\epsilon) = \epsilon^2 = (\hat{\Theta} - \Theta)^2$$




- ▶ Uniformă:

$$C(\epsilon) = \begin{cases} 0, & \text{if } |\epsilon| = |\hat{\Theta} - \Theta| \leq E \\ 1, & \text{if } |\epsilon| = |\hat{\Theta} - \Theta| > E \end{cases}$$

- ▶ Liniară:

$$C(\epsilon) = |\epsilon| = |\hat{\Theta} - \Theta|$$

- ▶ De desenat la tablă



- ▶ Funcția de cost  $C(\epsilon)$  reprezintă echivalentul costurilor  $C_{ij}$  de la detectie
  - ▶ la detectie aveam doar 4 valori:  $C_{00}$ ,  $C_{01}$ ,  $C_{10}$ ,  $C_{11}$
  - ▶ aici avem un cost pentru fiecare eroare posibilă  $\epsilon$
- ▶ Funcția de cost dictează ce valoarea alegem din distribuția  $w(\Theta|r)$

# I Importanța funcției de cost

- Fie distribuția a posteriori următoare:




Figure 2: Unbalanced posterior distribution

- Care este estimatorul MAP?  $\hat{\theta}_{MAP} =$

- Dacă avem funcția de cost următoare:

- dacă estimarea  $\hat{\theta}$  este < valoarea reală  $\theta$ , te costă 1000 \$
- dacă estimarea  $\hat{\theta}$  este > valoarea reală  $\theta$ , platești 1 \$
- schimbăm valoarea estimată ? :)

1	2	3	4	5	6
50%	5%	5%	5%	5%	30%

→ 1).  $C(\epsilon) = \text{uniformă} \Rightarrow \text{Ghicesc 1}$

→ 2).  $C(\epsilon) = \epsilon^2 = (\hat{\theta} - \theta)^2$

Ghicesc 1 :

$$50\% \cdot 0 + 5\% \cdot 1^2 + 5\% \cdot 2^2 + 5\% \cdot 3^2 +$$

$$+ 5\% \cdot 4^2 + 30\% \cdot 25 = \\ = 0.05 \cdot 30 + 0.3 \cdot 25 =$$

Ghicesc 2 :

$$50\% \cdot 1^2 + 5\% \cdot 0 + 5\% \cdot 1^2 + 5\% \cdot 2^2 +$$

$$5\% \cdot 3^2 + 30\% \cdot 4^2 = \\ = 0.5 + 0.05 \cdot 19 + 0.3 \cdot 16 =$$

- ▶ Distribuția a posteriori  $w(\Theta|r)$  dă probabilitatea fiecărei valori  $\hat{\Theta}$  de a fi cea corectă
- ▶ Alegerea unui estimat  $\hat{\Theta}$  implică o anume eroare  $\epsilon$
- ▶ Eroarea de estimare are un anumit cost  $C(\epsilon)$
- ▶ **Riscul** = valoarea medie a costului =  $C(\epsilon) \times$  probabilitatea:

$$R = \int_{-\infty}^{\infty} C(\epsilon) w(\Theta|r) d\Theta$$

$$= \int_{-\infty}^{\infty} C(\epsilon) \cdot w(\Theta|r) d\Theta$$

## The Bayesian risk

- ▶ Alegem valoarea  $\hat{\Theta}$  care minimizează costul mediu  $R$

$$\hat{\Theta} = \arg \min_{\Theta} \int_{-\infty}^{\infty} C(\epsilon) w(\Theta | \mathbf{r}) d\Theta$$

- ▶ O obținem înlocuind  $C(\epsilon)$  cu definiția sa, și derivând după  $\hat{\Theta}$ 
  - ▶ Atenție: se derivează după  $\hat{\Theta}$ , nu  $\Theta$ !

## Estimatorul EPMM (eroare pătratică medie minimă) (MMSE)

- Când funcția de cost este pătratică  $C(\epsilon) = \epsilon^2 = (\hat{\Theta} - \Theta)^2$

$$R = \int_{-\infty}^{\infty} (\hat{\Theta} - \Theta)^2 w(\Theta | \mathbf{r}) d\Theta$$

? C(ε) w(Θ|r) posteriori

$$\frac{d}{d\hat{\Theta}} \left[ \dots \right] d\Theta = \int_{-\infty}^{\infty} \frac{d}{d\hat{\Theta}} (\dots) d\Theta$$

- Vrem  $\hat{\Theta}$  care minimizează  $R$ , deci derivăm

$$\frac{dR}{d\hat{\Theta}} = 2 \int_{-\infty}^{\infty} (\hat{\Theta} - \Theta) w(\Theta | \mathbf{r}) d\Theta = 0$$

- Echivalent cu

$$\hat{\Theta} \underbrace{\int_{-\infty}^{\infty} w(\Theta | \mathbf{r}) d\Theta}_{1} = \int_{-\infty}^{\infty} \Theta w(\Theta | \mathbf{r}) d\Theta$$

1 media distri. w(θ|r) dθ

- Estimatorul de eroare pătratică medie minimă (EPMM) ("Minimum Mean Squared Error, MMSE"):

$$\hat{\Theta}_{EPMM} = \int_{-\infty}^{\infty} \Theta \cdot w(\Theta | \mathbf{r}) d\Theta$$

$$\begin{aligned}
 \frac{dR}{d\hat{\Theta}} &= \left( \frac{d}{d\hat{\Theta}} \int_{-\infty}^{\infty} (\hat{\Theta} - \Theta)^2 w(\Theta | \mathbf{r}) d\Theta \right) = \\
 &= \int_{-\infty}^{\infty} 2(\hat{\Theta} - \Theta) \cdot w(\Theta | \mathbf{r}) d\Theta = 0 \\
 &= \int_{-\infty}^{\infty} \hat{\Theta} \cdot w(\Theta | \mathbf{r}) d\Theta - \int_{-\infty}^{\infty} \Theta \cdot w(\Theta | \mathbf{r}) d\Theta = 0
 \end{aligned}$$

- ▶ **Estimatorul EPMM:** estimatorul  $\hat{\Theta}$  este **valoarea medie a distribuției a posteriori**  $w(\Theta|\mathbf{r})$

$$\hat{\Theta}_{EPMM} = \int_{-\infty}^{\infty} \Theta \cdot w(\Theta|\mathbf{r}) d\Theta$$

$$\int x \cdot w(x) dx$$

- ▶ EPMM = “Eroare Pătratică Medie Minimă”
- ▶ valoarea medie = sumă (integrală) din fiecare  $\Theta$  ori probabilitatea sa  $w(\Theta|\mathbf{r})$
- ▶ Estimatprul EPMM se obține din distribuția a posteriori  $w(\Theta|\mathbf{r})$ , considerând funcția de cost pătratică

# Estimatorul MAP

- Dacă funcția de cost este uniformă:

$$C(\epsilon) = \begin{cases} 0, & \text{if } |\epsilon| = |\hat{\theta} - \theta| \leq E \\ 1, & \text{if } |\epsilon| = |\hat{\theta} - \theta| > E \end{cases}$$

- Stim că  $\theta = \hat{\theta} - \epsilon$
- Se obține

$$R = \int_{-\infty}^{\infty} C(\epsilon) \cdot w(\theta|r) d\theta$$

$$R = \int_{-\infty}^{\hat{\theta}-E} w(\theta|r) d\theta + \int_{\hat{\theta}+E}^{\infty} w(\theta|r) d\theta$$


$$R = 1 - \int_{\hat{\theta}-E}^{\hat{\theta}+E} w(\theta|r) d\theta$$

$$\int_{-\infty}^{\infty} w(\theta|r) d\theta = 1$$

$$\begin{aligned} \epsilon &= \hat{\theta} - \theta \Rightarrow \theta = \hat{\theta} - \epsilon \\ C(\epsilon) &\stackrel{\text{când}}{=} 0 \quad |\epsilon| \leq E \\ -E &\leq \epsilon \leq E \\ -E &\leq \hat{\theta} - \theta \leq E \quad |-\hat{\theta}| \\ -E - \hat{\theta} &\leq -\theta \leq E - \hat{\theta} \\ \boxed{\hat{\theta} - E \geq \theta \geq \hat{\theta} + E} \end{aligned}$$

Când  $\theta \in [\hat{\theta} - E, \hat{\theta} + E] \Rightarrow C(\epsilon) = 0$

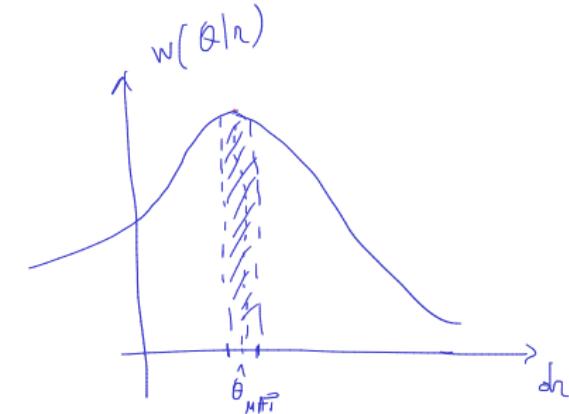
Când  $\theta \notin [\hat{\theta} - E, \hat{\theta} + E] \Rightarrow C(\epsilon) = 1$



# Estimatorul MAP

- ▶ Pentru minimizarea  $R$ , trebuie să maximizăm  $\int_{\hat{\Theta}-E}^{\hat{\Theta}+E} w(\Theta|r)d\Theta$ , integrala din jurul punctului  $\hat{\Theta}$
- ▶ Pentru  $E$  foarte mic, funcția  $w(\Theta|r)$  este aproximativ constantă, deci se va alege punctul unde funcția este maximă
- ▶ **Estimatorul Maximum A Posteriori (MAP)** = valoarea  $\hat{\Theta}$  care maximizează  $w(\Theta|r)$

$$\hat{\Theta}_{MAP} = \arg \max_{\Theta} w(\Theta|r) = \arg \max_{\Theta} w(r|\Theta) \cdot w(\Theta)$$



- ▶ Estimatorul MAP:  $\hat{\Theta} = \text{valoarea care maximizează distribuția a posteriori}$
- ▶ Estimatorul EPMM:  $\hat{\Theta} = \text{valoarea medie a distribuției a posteriori}$




Figure 3: Estimatorul MAP vs EPMM(MMSE)

- ▶ Estimatorul MAP = minimizează costul mediu, folosind funcția de cost uniformă
  - ▶ ca le detectie: criteriul MPE = criteriul MR când costurile sunt la fel
- ▶ Estimatorul EPMM = minimizează costul mediu, folosind funcția de cost pătratică
  - ▶ similar cu criteriul MR, dar la estimare

# Exercițiu


D

Exercițiu: valoare constantă, 1 măsurătoare, zgomot Gaussian același  $\sigma$

- ▶ Vrem să estimam temperatura de astăzi din Sahara
- ▶ Termometrul indică 40 grade, dar valoarea este afectată de zgomot Gaussian  $\mathcal{N}(0, \sigma^2 = 2)$  (termometru ieftin)
- ▶ Se știe că de obicei în această perioadă a anului temperatura este în jur de 35 grade, cu o distribuție Gaussiană  $\mathcal{N}(35, \sigma^2 = 2)$ .
- ▶ Estimați valoarea reală a temperaturii folosind estimarea ML, MAP și EPMM(MMSE)

37.5

$$\frac{1}{(\sqrt{2\pi})^2} \cdot e^{-\frac{(\theta - 40)^2 + (\theta - 35)^2}{2\sigma^2}}$$



Exercițiu: valoare constantă, 1 măsurătoare, zgomot Gaussian același  $\sigma$

- ▶ Dacă avem trei termometre, care indică 40, 38, 41 grade?

Exercițiu: valoare constantă, 1 măsurătoare, zgomot Gaussian  $\sigma$  diferit


- ▶ Dacă temperatura în această perioadă a anului are distribuție Gaussiană  $\mathcal{N}(35, \sigma_2^2 = 3)$ 
  - ▶ cu varianță diferită,  $\sigma_2 \neq \sigma$

## Semnal oarecare în zgomot Gaussian (AWGN)

$$r(t) = s_\Theta(t) + \text{zgomot}$$

- Fie semnalul original "curat"  $s_\Theta(t)$
- Zgomotul este Gaussian (AWGN)  $\mathcal{N}(\mu = 0, \sigma^2)$
- Ca în cazul estimării de plauzibilitate maximă, funcția de plauzibilitate este:

$$w(r|\Theta) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\sum_{i=1}^N \frac{(r_i - s_\Theta(t_i))^2}{2\sigma^2}} = w(r_1|\Theta) \cdot w(r_2|\Theta) \cdot \dots \cdot w(r_N|\Theta) =$$



- Dar acum aceasta se **înmulțește cu**  $w(\Theta)$

$$w(r|\Theta) \cdot w(\Theta)$$

## Semnal oarecare în zgomot Gaussian (AWGN)


- ▶ Estimatorul MAP este cel care maximizează produsul

$$\hat{\Theta}_{MAP} = \arg \max_{\Theta} w(\mathbf{r}|\Theta) w(\Theta)$$

*aplicăm ln()*

- ▶ Logaritmând:

$$\begin{aligned}\hat{\Theta}_{MAP} &= \arg \max_{\Theta} \left( \ln(w(\mathbf{r}|\Theta)) + \ln(w(\Theta)) \right) \\ &= \arg \max_{\Theta} -\frac{\sum(r_i - s_{\Theta}(t_i))^2}{2\sigma^2} + \ln(w(\Theta))\end{aligned}$$



## Distribuție "a priori" Gaussiană

- Dacă distribuția "a priori" este de asemenea Gaussiană  $\mathcal{N}(\mu_\Theta, \sigma_\Theta^2)$

$$\ln(w(\Theta)) = -\frac{\sum(\Theta - \mu_\Theta)^2}{2\sigma_\Theta^2}$$

- Estimatorul MAP devine

$$\hat{\Theta}_{MAP} = \arg \min \underbrace{\frac{\sum(r_i - s_\Theta(t_i))^2}{2\sigma^2}}_{d(r, s_\Theta(t))^2} + \cancel{\frac{\sum(\Theta - \mu_\Theta)^2}{2\sigma_\Theta^2}}$$

- Poate fi rescris

$$\hat{\Theta}_{MAP} = \arg \min d(r, s_\Theta)^2 + \underbrace{\frac{\sigma^2}{\sigma_\Theta^2}}_{\lambda} \cdot d(\Theta, \mu_\Theta)^2$$

$$\hat{\Theta}_{MAP} = \underset{\Theta}{\operatorname{arg \min}} \quad d(r, s_\Theta)^2 + \lambda \cdot d(\Theta, \mu_\Theta)^2$$

$$w(\theta) = \frac{1}{\sigma_\theta \sqrt{2\pi}} \cdot e^{-\frac{(\theta-\mu_\theta)^2}{2\sigma^2}}$$

$$f_{\Theta}(w(\theta)) = \text{ct} + -\frac{(\theta-\mu_\theta)^2}{2\sigma^2}$$

orlovoax  $-f(x)$   
 $\Rightarrow$   
 orlovan  $f(x)$

## Interpretare

- ▶ Estimatorul MAP în zgomot Gaussian și cu distribuție “a priori” Gaussiană


$$\hat{\Theta}_{MAP} = \arg \min \left[ d(\mathbf{r}, s_{\Theta})^2 + \underbrace{\frac{\sigma^2}{\sigma_{\Theta}^2} \cdot d(\Theta, \mu_{\Theta})^2}_{\lambda} \right]$$

- ▶  $\hat{\Theta}_{MAP}$  este apropiat de valoarea medie  $\mu_{\Theta}$  și de asemenea face ca semnalul adeverat să fie apropiat de eșantioanele recepționate  $\mathbf{r}$

- ▶ Exemplu: “caut locuință aproape de serviciu dar și aproape de Mall”
  - ▶  $\lambda$  controlează importanța relativă a celor doi termeni

- ▶ Cazuri particulare

- ▶  $\sigma_{\Theta}$  foarte mic = distribuția “a priori” este foarte specifică (îngustă) =  $\lambda$  mare = termenul al doilea este dominant =  $\hat{\Theta}_{MAP}$  foarte apropiat de  $\mu_{\Theta}$
- ▶  $\sigma_{\Theta}$  foarte mare = distribuția “a priori” este foarte nespecifică =  $\lambda$  mic = primul termen este dominant =  $\hat{\Theta}_{MAP}$  apropiat de estimatorul de plauzibilitate maximă



$$\begin{aligned}\hat{x} &= \underset{x}{\operatorname{arg \min}} \quad d(x, \text{serviciu})^2 + 0.2 \cdot d(x, \text{Mall})^2 \\ &\quad + 0.3 \cdot d(x, \text{Parc})^2 \\ &\quad + (\text{Supr} - 65)^2\end{aligned}$$

- ▶ În general, aplicațiile practice:
  - ▶ utilizează diverse tipuri de distribuții “a priori”
  - ▶ estimează **mai mulți parametri** (un vector de parametri)
- ▶ Aplicații
  - ▶ reducerea zgromotului din semnale
  - ▶ restaurarea semnalelor (parti lipsă din imagini, imagini *blurate* etc)
  - ▶ compresia semnalelor

### 1. Urmărirea unui obiect (“single object tracking”) prin filtrare Kalman


- ▶ urmărirea unui obiect prin măsurători succesive (e.g. din imagini successive)
- ▶ la fiecare nouă măsurătoare avem două distribuții ale poziției:
  - ▶ cea dată de măsurătoare respectivă,  $w(r|\Theta)$
  - ▶ cea precisă pe baza poziției și vitezei de data trecută
  - ▶ ambele presupuse a fi Gaussiene, caracterizate doar prin medie și varianță
- ▶ cele două se combină prin regula lui Bayes => o distribuție mai precisă  $w(\Theta|r)$ , tot Gaussiană
- ▶ poziția exactă se estimează prin EPMM (media lui  $w(\Theta|r)$ )
- ▶  $w(\Theta|r)$  prezice poziția de la momentul următor

# Single object tracking


Secondo 2:



Secondo 1:




Secondo 0:



$\leftarrow$   
3.1m

## Single object tracking



## Aplicații practice

### 2. Constrained Least Squares (CLS) image restoration

- Avem o imagine  $I_{zg}$  afectată de erori (zgomot, pixeli lipsă, blurare)

$$I_{zg} = I_{true} + Z$$


- Estimăm imaginăea originală prin:

$$\hat{I}_{true} = \underset{\hat{I}}{\operatorname{argmin}} \|I - I_{zg}\|_2^2 + \lambda \cdot \|HighPass\{I\}\|_2^2$$

$\downarrow$        $\underbrace{\|\cdot\|_2^2}_{d(I, I_{zg})^2}$        $\uparrow$        $\underbrace{\|\cdot\|_2^2}_{d(HighPass(I), 0)^2}$

- Exemple:

- <https://www.mathworks.com/help/images/deblurring-images-using-a-regularized-filter.html>
- <https://demonstrations.wolfram.com/ImageRestorationForDegradedImages>
- Google it



# Constrained Least Squares (CLS) image restoration