

Decizie și Estimare în Prelucrarea Informației

Capitolul III. Elemente de Teoria Estimării

III.1 Introducere

Ce înseamnă "estimare"?

- ▶ Un emițător transmite un semnal $s_\Theta(t)$ care depinde de parametru **necunoscut** Θ
- ▶ Semnalul este afectat de zgomot, se recepționează

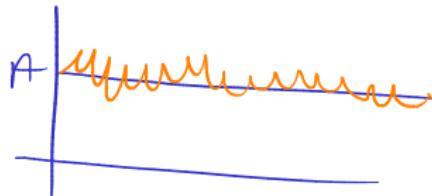
$$r(t) = \underline{s_\Theta(t)} + \underline{\text{zgomot}}$$

- ▶ Vrem să **găsim** valoarea parametrului Θ
 - ▶ pe baza eșantioanelor din semnalul recepționat, sau a întregului semnal
 - ▶ datele recepționate au zgomot \Rightarrow parametrul este "estimat"
- ▶ Valoarea găsită este $\hat{\Theta}$, estimatul lui Θ
 - ▶ există întotdeauna eroare de estimare $\epsilon = \hat{\Theta} - \Theta$

$$\begin{aligned} s_\Theta(t) &= \Theta \\ s_\Theta(t) &= \cos(2\pi \Theta^n t) \end{aligned}$$

necunoscut

Ce înseamnă “estimare”?



► Exemple:

► Amplitudinea unui semnal constant: $r(t) = \underbrace{A}_{\Lambda_\theta(\cdot)} + \text{zgomot}$, trebuie estimat A

► Faza unui semnal sinusoidal: $r(t) = \cos(2\pi ft + \underbrace{\phi}_{\Lambda_\theta(\cdot)}) + \text{zgomot}$, de estimat ϕ

► Exemple mai complicate:

► De estimat/decis ce cuvânt este pronunțat într-un semnal vocal

Estimare și Detectie/Decizie

$$\text{Decizie } \Delta(t) = \begin{cases} \Delta_0(t) = 0 \\ \Delta_1(t) = 5 \end{cases}$$
$$r(t) = A(t) + z\text{gomot}$$
$$A \quad \rightarrow D_0 : 0$$
$$D_1 : 5$$

- ▶ Fie următoarea problemă de estimare:

Se recepționează un semnal $r(t) = A + z\text{gomot}$, estimați-l pe A

- ▶ La detectie: se alege între **două valori cunoscute** ale A :

▶ de ex. A poate fi 0 sau 5 (ipotezele H_0 și H_1)

- ▶ La estimare: A poate fi oricât \Rightarrow se alege între **o infinitate de opțiuni** ale A

▶ A poate fi orice valoare din \mathbb{R} , în general

- ▶ Detectie = Estimare **restrânsă** doar la un set discret de opțiuni
- ▶ Estimare = Detectie cu un număr **infinnit de opțiuni** posibile
- ▶ Metodele statistice sunt similar
 - ▶ În practică, distincția între estimare și detectie nu este strictă
 - ▶ (de ex. când trebuie să alegem între 1000 de ipoteze, este “detectie” sau “estimare”?)

- ▶ Semnalul recepționat este $r(t) = s_{\Theta}(t) + zgomot$
 - ▶ este afectat de zgomot
 - ▶ depinde de parametrul necunoscut Θ
- ▶ Considerăm N eșantioane din $r(t)$, luate la momentele de timp t_i

$$\underline{\mathbf{r} = [r_1, r_2, \dots r_N]}$$

- ▶ Eșantioanele depind de valoarea lui Θ

Semnalul recepționat

- ▶ Fiecare eșantion r_i este o variabilă aleatoare ce depinde de Θ (și de zgomot)

- ▶ Fiecare eșantion are o distribuție care depinde de Θ

$$\xrightarrow{w_i} w_i(r_i|\Theta)$$

$$w(r_i; \Theta_0, \Theta_1)$$

- ▶ Întregul vector de esantioane r este o variabilă aleatoare N -dimensională ce depinde de Θ (și de zgomot)

- ▶ Are o distribuție N -dimensională ce depinde de Θ
- ▶ Egală cu produsul tuturor $w_i(r_i|\Theta)$

$$w(r|\Theta) = w_1(r_1|\Theta) \cdot w_2(r_2|\Theta) \cdot \dots \cdot w_N(r_N|\Theta)$$

Tipuri de estimare

- ▶ Considerăm două tipuri de estimare:

estimare $\hat{\theta}_{ML}$

- 1. **Estimare de plauzibilitate maximă** (Maximum Likelihood Estimation, MLE): În afară de r nu se cunoaște nimic despre Θ , decât cel mult vreun domeniu de existență (de ex. $\Theta > 0$)
- 2. **Estimare Bayesiană**: În afară de r se mai cunoaște o distribuție a priori $w(\Theta)$ a lui Θ , care indică ce valori ale lui Θ sunt mai probabile / mai puțin probabile
 - ▶ caz mai general decât primul

Bayes

II.2 Estimarea de plauzibilitate maximă (Maximum Likelihood)

- ▶ Dacă nu se cunoaște vreo distribuție *a priori* se folosește metoda estimării de plauzibilitate maximă (“Maximum Likelihood”, ML)
- ▶ Se definește **plauzibilitatea** unui valori Θ , dat fiind vectorul de observații r :

$$L(\Theta|r) = w(\Theta|r) \quad w(r|\Theta)$$

Likelihood = L

- ▶ $L(\Theta|r)$ reprezintă funcția de plauzibilitate
- ▶ A se compara cu formula din Cap. 2, slide 20
 - ▶ e aceeași
 - ▶ aici “ghicim” pe Θ , acolo “ghiceam” pe H_i

Estimarea de plauzibilitate maximă (Maximum Likelihood, ML):

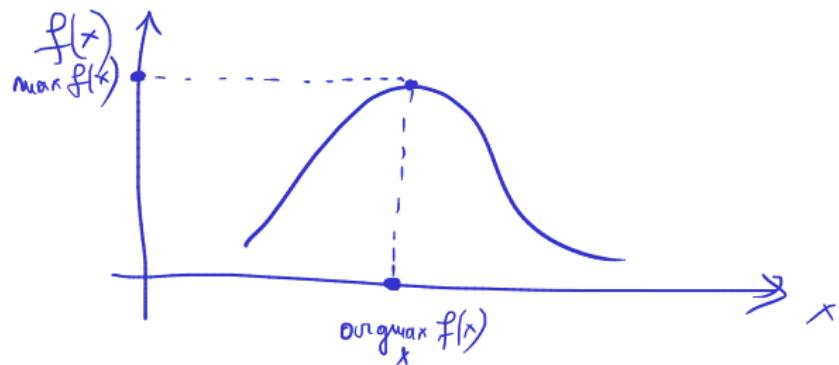
- ▶ Estimatul $\hat{\Theta}_{ML}$ este **valoarea care maximizează plauzibilitatea, dat fiind valorile observate r**
 - ▶ i.e. valoarea care maximizează $L(\Theta|r)$, adică maximizează $w(r|\Theta)$

$$\hat{\Theta}_{ML} = \arg \max_{\Theta} L(\Theta|r) = \arg \max_{\Theta} w(r|\Theta)$$

- ▶ Dacă Θ aparține doar unui anumit interval, se face maximizarea doar pe acel interval

▶ Notări matematice generale

- ▶ $\arg \max_x f(x) =$ "valoarea x care maximizează funcția $f(x)$ "
- ▶ $\max_x f(x) =$ "valoarea maximă a funcției $f(x)$ "



Estimare vs decizie Maximum Likelihood

► Estimarea ML este foarte similară cu decizia ML!

► Criteriul de decizie ML:

► “se alege ipoteza cu plauzibilitate mai mare”:

$$\frac{L(H_1|r)}{L(H_0|r)} = \frac{w(r|H_1)}{w(r|H_0)} \stackrel{H_1}{\gtrless} 1$$

► Estimare ML:

► “se alege valoarea care maximizează plauzibilitatea” = “alege Θ cu plauzibilitatea maximă”

$$\hat{\Theta}_{ML} = \arg \max_{\Theta} L(\Theta|r) = \arg \max_{\Theta} w(r|\Theta)$$

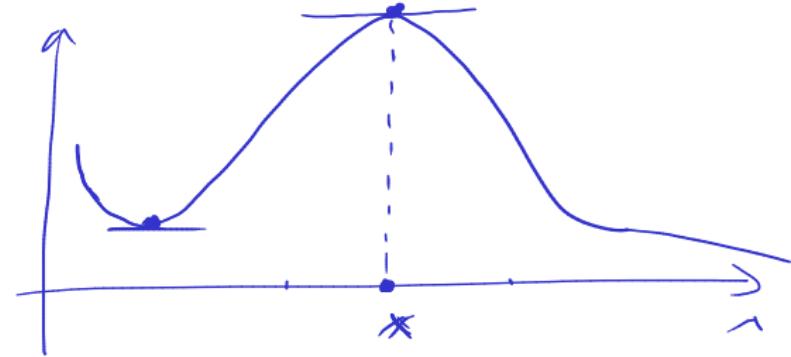
Găsirea maximului

- ▶ Cum se rezolvă problema de maximizare?
 - ▶ adică cum se găsește estimatul $\hat{\Theta}_{ML}$ care maximizează $L(\Theta | \mathbf{r})$
- ▶ Maximul se găsește prin derivare și egalare cu 0

$$\frac{dL(\Theta | \mathbf{r})}{d\Theta} = 0$$

- ▶ Se poate aplica **logaritmul natural** asupra funcției $L(\Theta | \mathbf{r})$ înainte de derivare (funcția "log-likelihood")

$$\frac{d \ln(L(\Theta | \mathbf{r}))}{d\Theta} = 0$$



Procedura de găsire a estimatului ML

Procedura de găsire a estimatului ML:

1. Se găsește expresia funcției

$$L(\Theta | \mathbf{r}) = w(\mathbf{r} | \Theta) = w(r_1 | \Theta) \cdot w(r_2 | \Theta) \cdots \cdot w(r_N | \Theta)$$

2. Se pune condiția ca derivata lui $L(\Theta | \mathbf{r})$ sau a lui $\ln(L(\Theta | \mathbf{r}))$ să fie 0

$$\frac{dL(\Theta)}{d\Theta} = 0, \text{ sau } \frac{d \ln(L(\Theta))}{d\Theta} = 0$$

3. Se rezolvă ecuația, se găsește valoarea $\hat{\Theta}_{ML}$

4. Se verifică că derivata a doua în punctul $\hat{\Theta}_{ML}$ este negativă, pentru a verifica că este un punct de maxim

- ▶ Întrucât derivata = 0 și pentru maxime și pentru minime
- ▶ uneori sărim peste această etapă

Exemple

- ▶ Estimarea unui semnal constant în zgomot gaussian:

Găsiți estimatul Maximum Likelihood pentru un semnal de valoare constantă $s_{\theta}(t) = A$ din 5 măsurători afectate de zgomot

$r_i = A + \text{zgomot}$, cu valori egale cu $[5, 7, 8, 6.1, 5.3]$. Zgomotul este AWGN $\mathcal{N}(\mu = 0, \sigma^2)$.

$$\begin{matrix} r_1 & r_2 & r_3 & r_4 & r_5 \\ A & ? & ? & ? & ? \end{matrix}$$

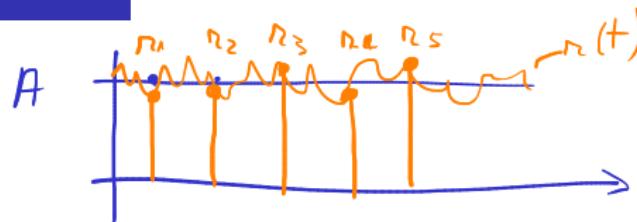
- ▶ Soluție: la tablă

- ▶ Estimatul \hat{A}_{ML} este chiar valoarea medie a eșantioanelor

▶ (de loc surprinzător)

$$w(r| \theta) = \left(\frac{1}{\sqrt{2\pi}} \right)^5 \cdot e^{-\frac{(5-A)^2 + (7-A)^2 + (8-A)^2 + (6.1-A)^2 + (5.3-A)^2}{2\sigma^2}}$$

Vreau maxim!



$$1) w(r| \theta) = w(r_1| \theta) \cdot \dots \cdot w(r_5| \theta)$$

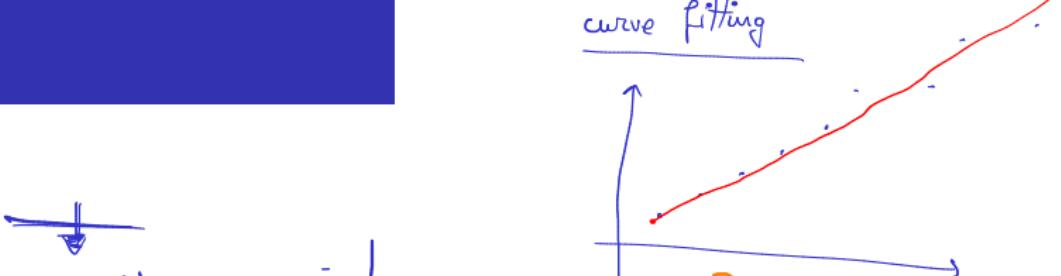
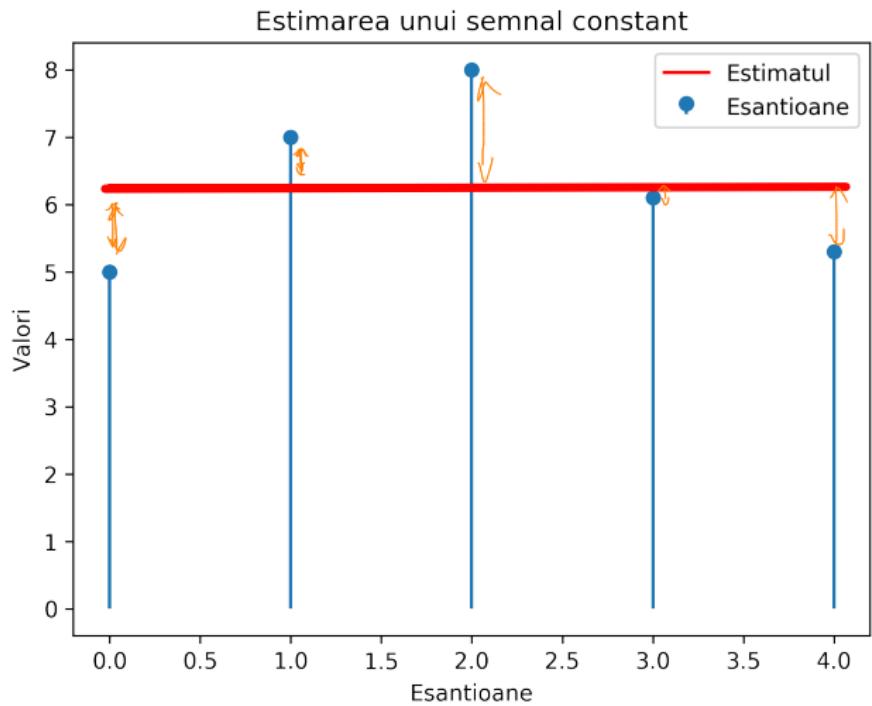
$$w(r_1| \theta) = \frac{1}{\sqrt{2\pi}} e^{-\frac{(r_1 - A)^2}{2\sigma^2}}$$

$$w(r_2| \theta) = \frac{1}{\sqrt{2\pi}} e^{-\frac{(r_2 - A)^2}{2\sigma^2}}$$

$$w(r_3| \theta) = \frac{1}{\sqrt{2\pi}} e^{-\frac{(r_3 - A)^2}{2\sigma^2}}$$

$$\begin{matrix} w(r_4| \theta) \\ w(r_5| \theta) \end{matrix}$$

Simulare numerică



Vream să minimizăm!

$$f(\hat{A}) = \ln \left(\frac{1}{\sqrt{2\pi}} \right)^5 = \frac{\sum (r_i - \hat{A})^2}{2\sigma^2}$$

D

Vream să minimizăm!

2) $\frac{dD}{d\hat{A}} = 0 \quad (=)$

$$2(5-\hat{A})(-1) + 2(7-\hat{A})(-1) + 2(8-\hat{A})(-1) + 2(6.1-\hat{A})(-1) + 2(5.3-\hat{A})(-1) = 0$$

$$31.4 - 5\hat{A} = 0 \Rightarrow \hat{A}_{ML} = \frac{31.4}{5} = 6.28$$

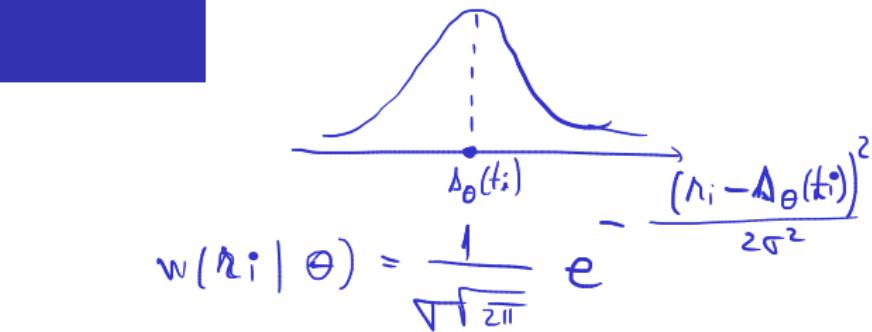
- ▶ Estimare = aproximare a unei curbe
 - ▶ se găsește cea mai bună potrivire a lui $s_\Theta(t)$ privind datele \mathbf{r}
- ▶ Din exemplul grafic anterior:
 - ▶ avem un set de date \mathbf{r}
 - ▶ se cunoaște forma semnalului = o dreaptă orizontală (A constant)
 - ▶ se aproximează în mod optim dreapta prin setul de date

Semnal oarecare în AWGN

- ▶ Fie semnalul original $s_\Theta(t)$
- ▶ Zgomotul este AWGN $\mathcal{N}(\mu = 0, \sigma^2)$
- ▶ Eșantioanele r_i sunt luate la momentele t_i
- ▶ Eșantioanele r_i au distribuție normală, cu media $\mu = s_\Theta(t_i)$ și varianța σ^2
- ▶ Funcția de plauzibilitate globală = produsul plauzibilităților fiecărui eșantion r_i

$$L(\Theta | \mathbf{r}) = w(\mathbf{r} | \Theta) = \prod_{i=1}^N \frac{1}{\sigma \sqrt{2\pi}} e^{-\frac{(r_i - s_\Theta(t_i))^2}{2\sigma^2}}$$

$$= \left(\frac{1}{\sigma \sqrt{2\pi}} \right)^N \cdot e^{-\sum_i \frac{(r_i - s_\Theta(t_i))^2}{2\sigma^2}}$$



Vrem θ a.t. să fie maxim!

Semnal oarecare în AWGN

- Logaritmul plauzibilității ("log-likelihood") este

$$\ln(L(\Theta|\mathbf{r})) = \underbrace{\ln\left(\frac{1}{\sigma\sqrt{2\pi}}\right)^N}_{\text{constant}} - \underbrace{\frac{\sum_i(r_i - s_\Theta(t_i))^2}{2\sigma^2}}$$

Vrem $\hat{\Theta}$ a.i. să fie minim!

Vrem $\hat{\Theta}$ a.i. să fie maxim!

Semnal oarecare în AWGN

- Maximul funcției = minimul exponentului

$$\hat{\Theta}_{ML} = \arg \max_{\Theta} L(\Theta | \mathbf{r}) = \arg \min_{\Theta} \sum_i (r_i - s_{\Theta}(t_i))^2$$

- Termenul $\sum(r_i - s_{\Theta}(t_i))^2$ este **distanța** $d(\mathbf{r}, s_{\Theta})$ la pătrat

$$d(\mathbf{r}, s_{\Theta}) = \sqrt{\sum (r_i - s_{\Theta}(t_i))^2}$$

$$(d(\mathbf{r}, s_{\Theta}))^2 = \sum (r_i - s_{\Theta}(t_i))^2$$

$$\mathbf{r} = [r_1 \ r_2 \ \dots \ r_N]$$

$$\Delta_{\Theta} = [\Delta_{\Theta}(t_1) \ \Delta_{\Theta}(t_2) \ \dots \ \Delta_{\Theta}(t_N)]$$

$$d(\mathbf{r}, \Delta_{\Theta})^2 = (r_1 - \Delta_{\Theta}(t_1))^2 + (r_2 - \Delta_{\Theta}(t_2))^2 + \dots$$

- ▶ Estimarea ML se poate rescrie sub forma:

$$\hat{\Theta}_{ML} = \arg \max_{\Theta} L(\Theta | \mathbf{r}) = \arg \min_{\Theta} d(\mathbf{r}, \mathbf{s}_{\Theta})^2$$

- ▶ Estimatul de plauzibilitate maximă (ML) $\hat{\Theta}_{ML}$ = valoarea care face $s_{\Theta}(t_i)$ **cel mai apropiat de vectorul recepționat r**
 - ▶ mai aproape = potrivire mai bună = mai probabil
 - ▶ cel mai aproape = cea mai bună potrivire = cel mai probabil = plauzibilitate maximă

Semnal oarecare în AWGN

- ▶ Estimare ML în zgomot gaussian = **minimizarea distanței**
- ▶ Aveam aceeași interpretare și la decizia ML:
 - ▶ dar la decizie alegeam minimul din 2 opțiuni
 - ▶ aici alegem minimul dintre toate opțiunile posibile
- ▶ Relația e valabilă pentru orice fel de spații vectoriale
 - ▶ vectori cu N elemente, semnale continue, etc
 - ▶ doar se înlocuiește definiția distanței Euclidiene



Semnal oarecare în AWGN

Procedura pentru estimarea tip ML în zgomot AWGN:

1. Se scrie expresia pentru pătratul distanței:

$$D = (d(\mathbf{r}, s_\Theta))^2 = \sum (r_i - s_\Theta(t_i))^2$$

2. Vrem minimul, deci egalăm derivata cu 0:

$$\frac{dD}{d\Theta} = \sum 2(r_i - s_\Theta(t_i))(-\frac{ds_\Theta(t_i)}{d\Theta}) = 0$$

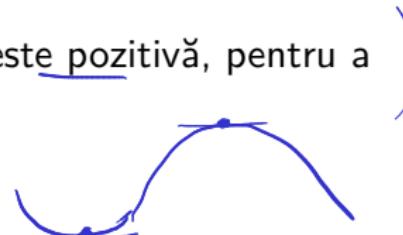
3. Se rezolvă și obținem valoarea $\hat{\Theta}_{ML}$

4. Se verifică că derivata a doua în punctul $\hat{\Theta}_{ML}$ este pozitivă, pentru a se verifica că punctul este un minim

- uneori sărim peste această etapă

$$\mathbf{r} = [\dots \dots \dots]$$

$$\mathbf{s}_\Theta = [\dots \dots \dots \dots]$$



Estimarea frecvenței f a unui semnal sinusoidal

- ▶ Găsiți estimatul Maximum Likelihood pentru frecvența f a unui semnal $s_\Theta(t) = \cos(2\pi ft)$, din 10 măsurători afectate de zgomot $r_i = \cos(2\pi ft_i) + \text{zgomot}$ de valori [...]. Zgomotul este AWGN $\mathcal{N}(\mu = 0, \sigma^2)$. Momentele de eșantionare sunt $t_i = [0, 1, 2, 3, 4, 5, 6, 7, 8, 9]$
- ▶ Soluție: la tablă

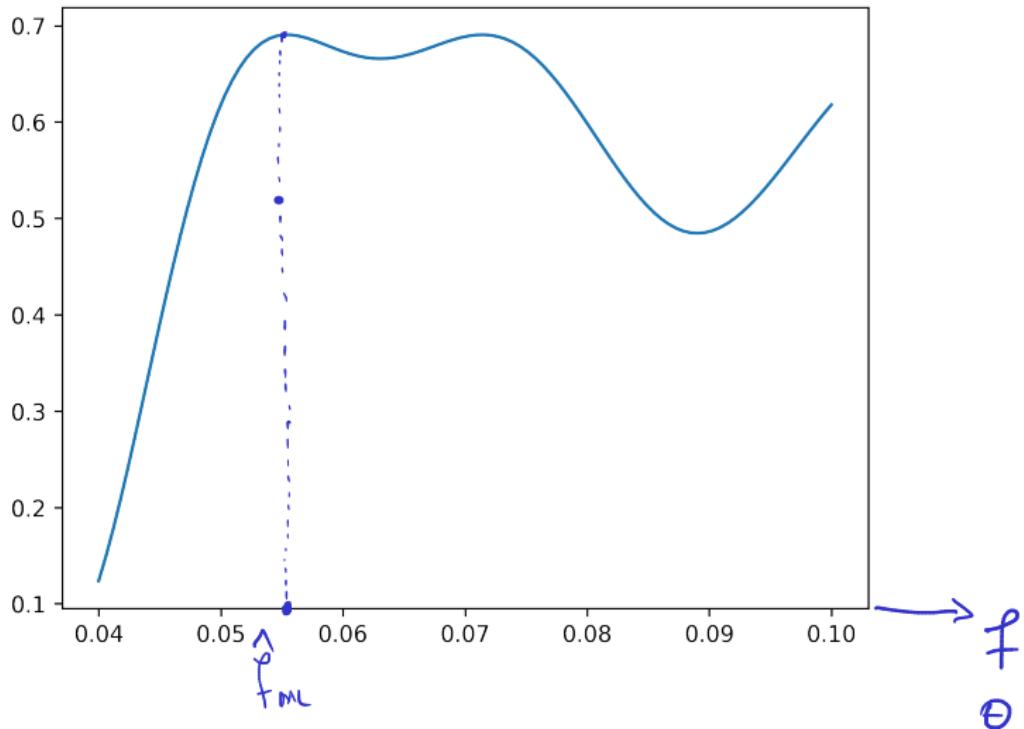
$$\mathbf{R} = \begin{bmatrix} \cdot & \cdot \end{bmatrix}$$

$$\mathbf{A}_\Theta = \begin{bmatrix} \cos(2\pi f \cdot 0) & \cos(2\pi f \cdot 1) & \cdots & \cos(2\pi f \cdot 9) \end{bmatrix}$$

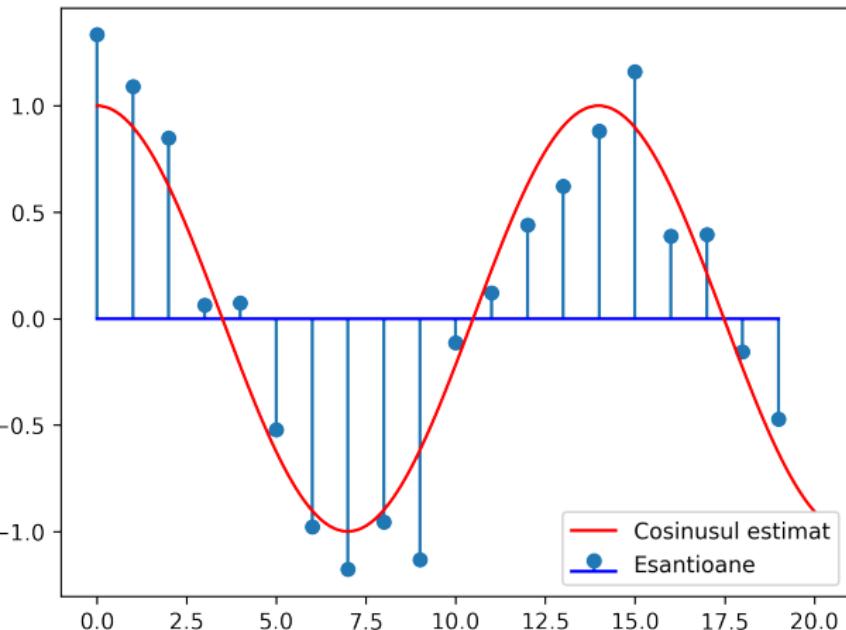
$$\mathbf{D} = \left(d(n - \mathbf{A}_\Theta) \right)^2$$

Funcția de plauzibilitate este

$$L(\theta | \mathbf{r}) = w(\mathbf{r} | \theta)$$



Simulare numerică



- ▶ Dacă semnalul depinde de mai mulți parametri?
 - ▶ de ex. amplitudinea, frecvența și faza inițială a unui cosinus:

$$s_{\Theta}(t) = A \cos(2\pi f t + \phi)$$

- ▶ Se va considera Θ ca fiind un vector:

$$\Theta = [\Theta_1, \Theta_2, \dots, \Theta_M]$$

- ▶ e.g. $\Theta = [\Theta_1, \Theta_2, \Theta_3] = [A, f, \phi]$

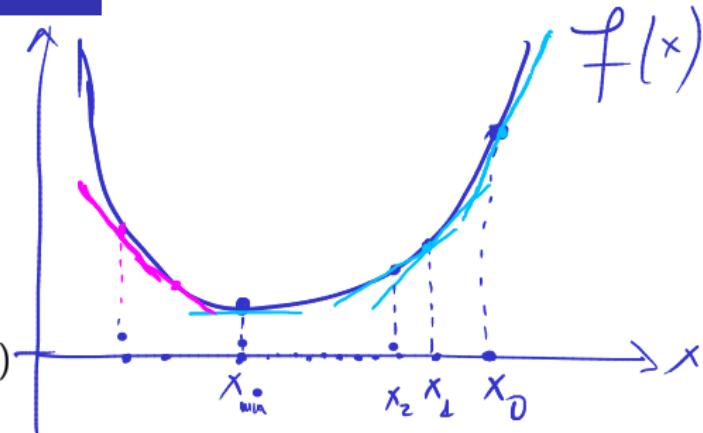
- ▶ Se rezolvă cu aceeași procedură, dar în loc de o singură derivată vom avea M deriveate
- ▶ Se rezolvă sistemul:

$$\left\{ \begin{array}{l} \frac{\partial L}{\partial \Theta_1} = 0 \\ \frac{\partial L}{\partial \Theta_2} = 0 \\ \dots \\ \frac{\partial L}{\partial \Theta_M} = 0 \end{array} \right. \quad \left. \begin{array}{l} \frac{\partial L}{\partial A} = 0 \\ \frac{\partial L}{\partial P} = 0 \\ \frac{\partial L}{\partial \phi} = 0 \end{array} \right\}$$

- ▶ uneori este dificil/imposibil

Coborâre după gradient (Gradient Descent)

- ▶ Cum se estimează parametrii Θ în cazuri complicate?
 - ▶ În aplicații reale, unde pot fi foarte mulți parametri (Θ este vector)
- ▶ De obicei nu se pot găsi valorile optime prin formule directe
- ▶ Se îmbunătățesc valorile în mod iterativ cu algoritmi tip **coborâre după gradient** (Gradient Descent)



$$x_{k+1} = x_k - \mu \cdot \left. \frac{d}{dx} f(x) \right|_{x=x_k}$$

Coborâre după gradient (Gradient Descent)

1. Se initializează parametrii cu valori aleatoare $\Theta^{(0)}$

$$\Theta = [\theta_1, \theta_2, \dots, \theta_n]$$

2. Repetă la fiecare iterare k :

2.1 Se calculează funcția $L(\Theta^{(k)} | r)$

$$d(r, \theta)$$

2.2 Se calculează derivatele $\frac{\partial L}{\partial \Theta_i^{(k)}}$ pentru toți Θ_i ("Gradient")

2.3 Se actualizează toate valorile Θ_i prin scăderea derivatei ("Descent"):

$$\Theta_i^{(k+1)} = \Theta_i^{(k)} - \mu \frac{\partial L}{\partial \Theta_i^{(k)}}$$

► sau, sub formă vectorială:



$$\Theta^{(k+1)} = \Theta^k - \mu \frac{\partial L}{\partial \Theta^{(k)}}$$

3. Până la îndeplinirea unui criteriu de terminare (de ex. parametrii nu se mai modifică mult)

Coborâre după gradient (Gradient Descent)

- ▶ Explicații la tablă
- ▶ Exemplu: regresia logistică cu valori 2D
 - ▶ exemplu la tablă

- ▶ Cel mai proeminent exemplu: **Rețele Neurale Artificiale** (a.k.a. “Rețele Neurale”, “Deep Learning”, etc.)
 - ▶ Pot fi văzute ca un exemplu de estimare ML
 - ▶ Se utilizează algoritmul *Gradient Descent* pentru găsirea parametrilor
 - ▶ Aplicații de vârf: recunoașterea de imagini, automated driving etc.
- ▶ Mai multe informații despre rețele neurale / machine learning:
 - ▶ căutați cursuri sau cărți online
 - ▶ IASI AI Meetup

Deplasarea și varianta estimatorilor

$$\Theta \simeq \hat{\Theta}_{ML}$$

- ▶ Cum caracterizăm calitatea unui estimator?
- ▶ Un estimator $\hat{\Theta}$ este o variabilă aleatoare
 - ▶ poate avea diverse valori, pentru că se calculează pe baza eșantioanelor recepționate, care depind de zgomot
 - ▶ exemplu: se repetă aceeași estimare pe calculatoare diferite => valori estimate ușor diferite
- ▶ Fiind o variabilă aleatoare, se pot defini:
 - ▶ valoarea medie a estimatorului: $E\{\hat{\Theta}\}$
 - ▶ varianța estimatorului: $E\{(\hat{\Theta} - \Theta)^2\}$

Deplasarea și varianța estimatorilor

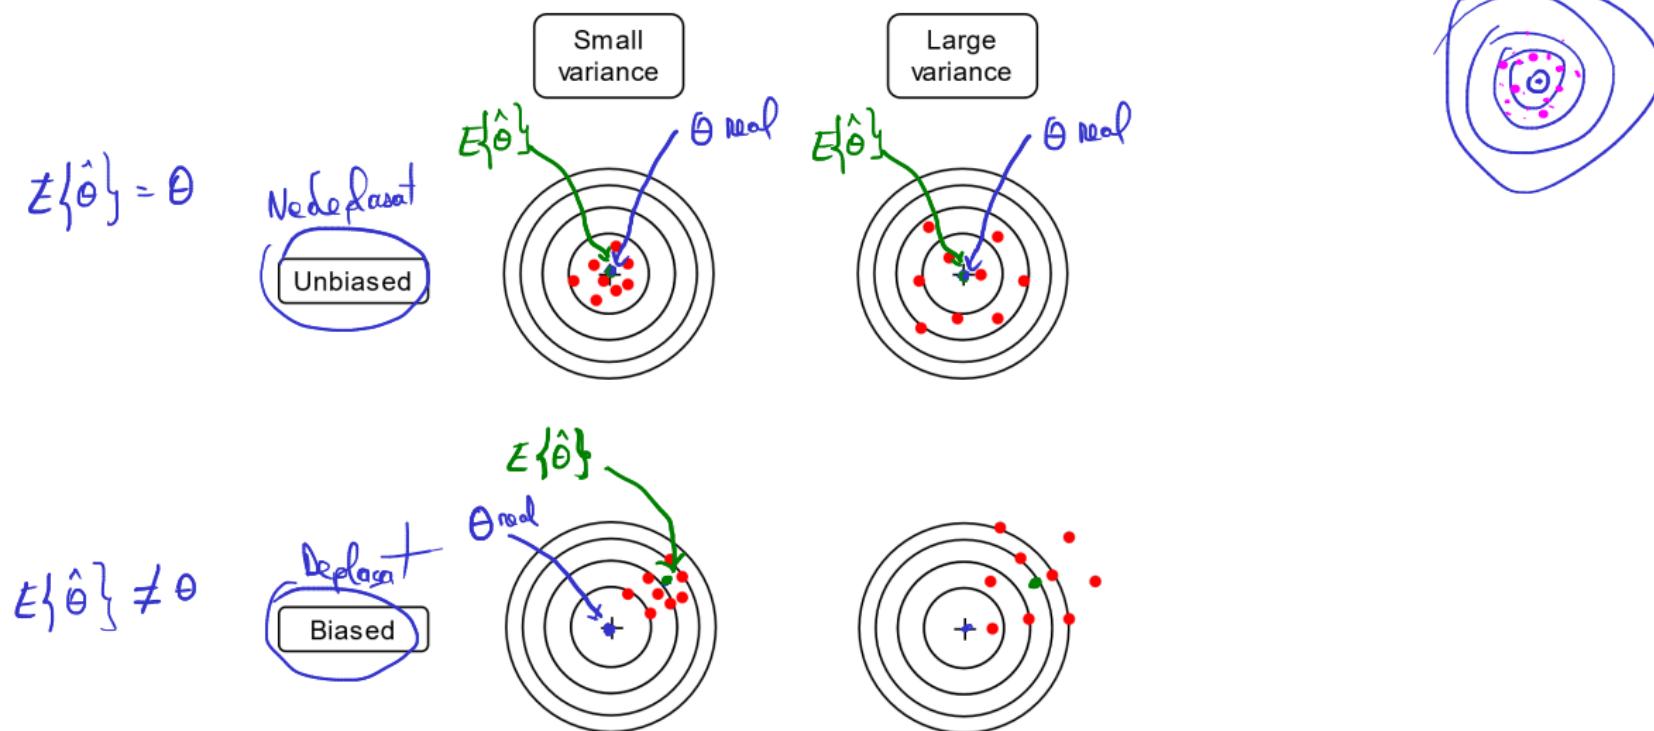


Figure 1: Deplasarea și varianța estimatorilor

- **Deplasarea** ("bias") unui estimator = diferența dintre valoarea medie a estimatorului și valoarea adevărată Θ

$$\text{Deplasare} = E \{ \hat{\Theta} \} - \Theta$$

- Estimator **nedeplasat** = valoarea medie a estimatorului este egală cu valoarea adevărată a parametrului Θ

$$E \{ \hat{\Theta} \} = \Theta$$

- Estimator **deplasat** = valoarea medie a estimatorului diferă de valoarea adevărată a parametrului Θ

- diferența $E \{ \hat{\Theta} \} - \Theta$ este **deplasarea** estimatorului

Deplasarea unui estimator

- Exemplu: semnal constant A , zgomot Gaussian (cu media), estimatorul de plauzibilitate maximă este $\hat{A}_{ML} = \frac{1}{N} \sum_i r_i$
- Atunci:

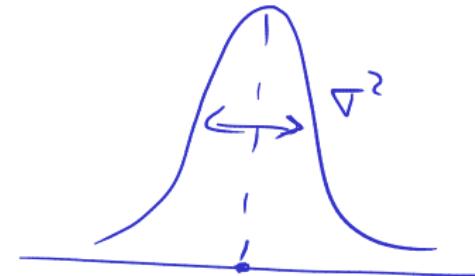
$$\begin{aligned} E\{\hat{A}_{ML}\} &= \frac{1}{N} E\left\{\sum_i r_i\right\} \\ &= \frac{1}{N} \sum_{i=1}^N E\{r_i\} \\ &= \frac{1}{N} \sum_{i=1}^N E\{A + \text{zgomot}\} \\ &= \frac{1}{N} \sum_{i=1}^N A \\ &= A \end{aligned}$$

- Acest estimator este nedeplasat

Varianța unui estimator

$$\sigma^2 = E \{ (\hat{\theta} - E\{\hat{\theta}\})^2 \}$$

- ▶ **Varianța unui estimator** măsoară "abaterile" estimatorului în jurul valorii medii
 - ▶ aceasta e definiția varianței σ^2 în general
- ▶ Dacă un estimator are **varianță mare**, valoarea estimată poate fi departe de cea reală, chiar dacă estimatorul este nedeplasat
- ▶ De obicei se preferă estimatori cu **varianță mică**, tolerându-se o eventuală mică deplasare

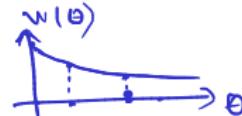


II.3 Estimare Bayesiană

- ▶ **Estimarea Bayesiană** ia în calcul termeni suplimentari pe lângă

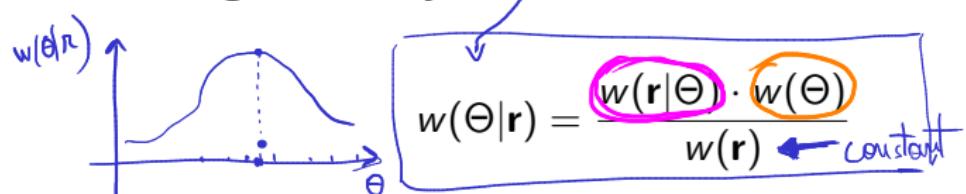
$w(\theta)$

- ▶ o distribuție a priori $w(\theta)$
 - ▶ optional, o funcție de cost
- ▶ Se obține echivalentul din estimare pentru criteriile de decizie MPE și MR



Estimare Bayesiană

- ▶ Se definește **distribuția a posteriori** a lui Θ , dat fiind observațiile r , folosind **regula lui Bayes**:



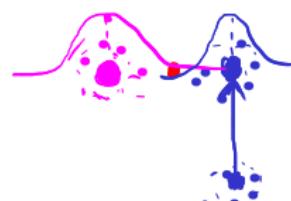
- ▶ Termenii:
 - ▶ θ este parametrul necunoscut
 - ▶ r este vectorul de observații *cunoscut*
 - ▶ $w(\theta|r)$ este probabilitatea ca parametrul să aibă valoarea θ , dat fiind vectorul de observații r ;
 - ▶ $w(r|\theta)$ este funcția de plauzibilitate
 - ▶ $w(\theta)$ este **distribuția a priori** a lui θ
 - ▶ $w(r)$ este **distribuția a priori** a lui r ; se presupune a fi constantă

Regula lui Bayes:

$$\begin{aligned} P(A \cap B) &= P(A|B) \cdot P(B) \\ &= P(B|A) \cdot P(A) \end{aligned}$$

↓

← $P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$



- ▶ Relația precedentă arată că, în general, estimarea lui Θ depinde de două lucruri:
 1. De vectorul observațiilor r , prin termenul $w(r|\Theta)$
 2. De informația "a priori" avută despre Θ , prin $w(\Theta)$
- ▶ Numele este "estimare Bayesiană"
 - ▶ Thomas Bayes = matematician englez, a descoperit regula cu acest nume
 - ▶ Notiunile bazate pe regula lui Bayes poartă deseori numele de "Bayesiane"

„*a priori*”

- ▶ Presupunem că se știe de dinainte o distribuție a lui Θ , $w(\Theta)$
 - ▶ știm de dinainte care e probabilitatea de a fi a anume valoare sau alta
 - ▶ se numește distribuția *a priori*
- ▶ Estimarea trebuie să ia în calcul și distribuția *a priori*
 - ▶ estimatul va fi “tras” înspre valori mai probabile

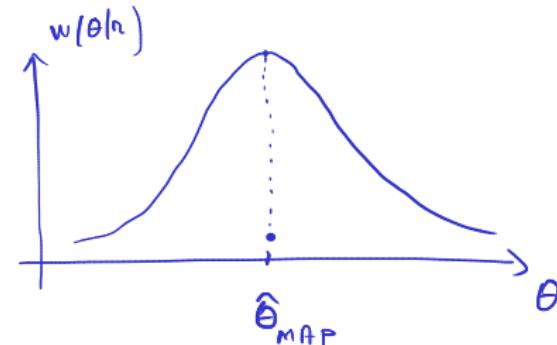
Estimatorul MAP

$$w(r|\theta) \cdot w(\theta) / w(r)$$

=

- ▶ Cunoaștem distribuția a posteriori $w(\Theta|r)$. Care este valoarea estimată?
- ▶ Se poate alege valoarea care are probabilitate maximă
- ▶ Estimatorul Maximum A Posteriori (MAP) este

$$\hat{\Theta}_{MAP} = \arg \max_{\Theta} w(\Theta|r) = \arg \max_{\Theta} w(r|\Theta) \cdot w(\Theta)$$



- ▶ Estimatorul MAP alege acea valoare Θ unde distribuția a posteriori $w(\Theta|r)$ este maximă
- ▶ Estimatorul MAP maximizează **produsul** dintre plauzibilitate și **distribuția a priori** $w(\Theta)$

Estimatorul MAP

Exemplu: Imagine

Relația dintre estimarea MAP și ML

- ▶ Estimatorul ML:

$$\hat{\Theta}_{ML} = \arg \max_{\Theta} w(\mathbf{r}|\Theta)$$

- ▶ Estimatorul MAP:

$$\hat{\Theta}_{MAP} = \arg \max_{\Theta} w(\mathbf{r}|\Theta) \cdot w(\Theta)$$

- ▶ Estimatorul ML este un caz particular de MAP pentru $w(\Theta)$ constant

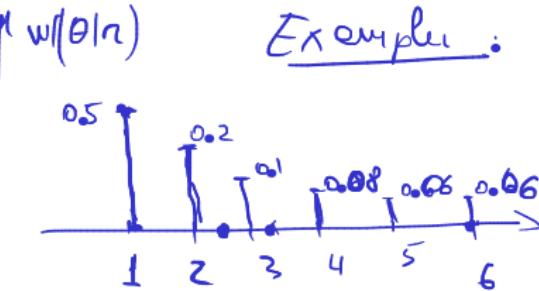
- ▶ $w(\Theta) = \text{constant}$ înseamnă că toate valorile lui Θ sunt *a priori* echiprobabile
- ▶ i.e. nu avem extra informații despre valoarea lui Θ

- ▶ Criteriul probabilității minime de eroare: $\frac{w(r|H_1)}{w(r|H_0)} \underset{H_0}{\gtrless} \frac{P(H_0)}{P(H_1)} \cdot \frac{P(H_1)}{P(H_0)}$
- ▶ Se poate rescrie ca $\frac{w(r|H_1) \cdot P(H_1)}{H_0} \underset{H_0}{\gtrless} w(r|H_0)P(H_0)$ $w(r|H_i) \cdot P(H_i)$, \max_{H_i} sau $\hat{P}_i = 0$
- ▶ adică se alege ipoteza pentru care $w(r|H_i) \cdot P(H_i)$ este mai mare
- ▶ **Criteriul de decizie MPE:** se alege ipoteza care maximizează $w(r|H_i) \cdot P(H_i)$
 - ▶ dintre cele două ipoteze H_0, H_1
- ▶ **Estimarea MAP:** se alege valoarea care maximizează $w(r|\Theta) \cdot w(\Theta)$
 - ▶ dintre toate valorile posibile pentru Θ
- ▶ Același principiu!

Estim. MAP \longleftrightarrow *Crit. M.P.E.*

Funcția de cost

- ▶ Vrem să găsim un echivalent și pentru criteriul MR
- ▶ Avem nevoie de un echivalent pentru costurile C_{ij}
- ▶ **Eroarea de estimare** = diferența între estimatul $\hat{\Theta}$ și valoarea reală Θ
$$\epsilon = \hat{\Theta} - \Theta$$
- ▶ **Funcția de cost** $C(\epsilon) =$ atribuie un cost pentru fiecare eroare de estimare posibilă
 - ▶ când $\epsilon = 0$, costul $C(0) = 0$
 - ▶ erori ϵ mici au costuri mici
 - ▶ erori ϵ mari au costuri mari



1).

$$2. (\hat{\theta} - \theta)^2$$

$$\text{est.} = 1 \quad [\begin{matrix} 50\% & \rightarrow 0 \\ 6\% & \rightarrow 25 \end{matrix}]$$

$$\text{est.} = 2 \quad [\begin{matrix} 6 \% & \rightarrow 16 \\ 50\% & \rightarrow 1 \end{matrix}]$$

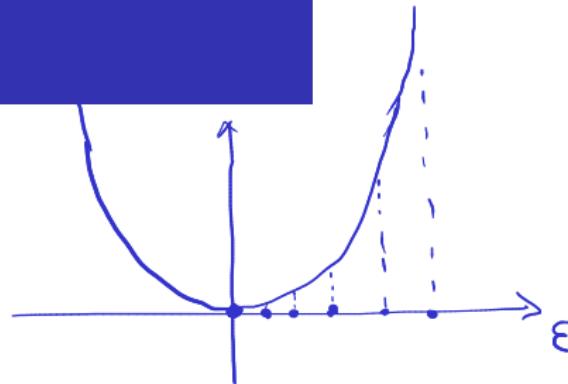
Functia de cost

- ▶ Funcții de cost uzuale:

- ▶ Pătratică:

"Eroare pătratică"

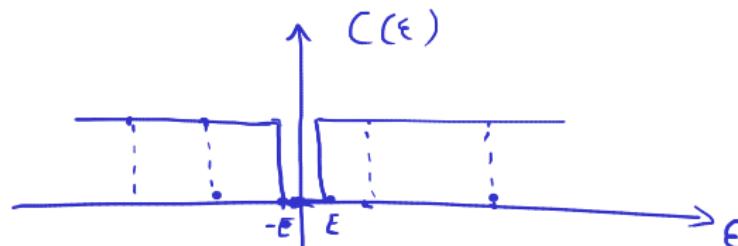
$$C(\epsilon) = \epsilon^2 = (\hat{\Theta} - \Theta)^2$$



- ▶ Uniformă:

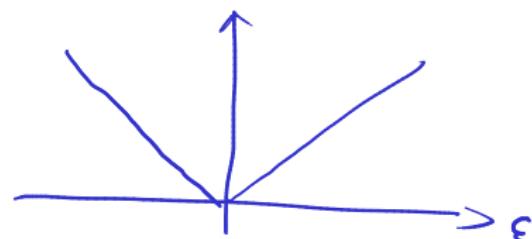
totul sau nimic

$$C(\epsilon) = \begin{cases} 0, & \text{if } |\epsilon| = |\hat{\Theta} - \Theta| \leq E \\ 1, & \text{if } |\epsilon| = |\hat{\Theta} - \Theta| > E \end{cases}$$



- ▶ Liniară:

$$C(\epsilon) = |\epsilon| = |\hat{\Theta} - \Theta|$$



- ▶ De desenat la tablă

Funcția de cost

- ▶ Funcția de cost $C(\epsilon)$ reprezintă echivalentul costurilor C_{ij} de la detectie
 - ▶ la detectie aveam doar 4 valori: C_{00} , C_{01} , C_{10} , C_{11}
 - ▶ aici avem un cost pentru fiecare eroare posibilă ϵ
- ▶ Funcția de cost dictează ce valoarea alegem din distribuția $w(\Theta|r)$

I Importanța funcției de cost

- Fie distribuția a posteriori următoare:

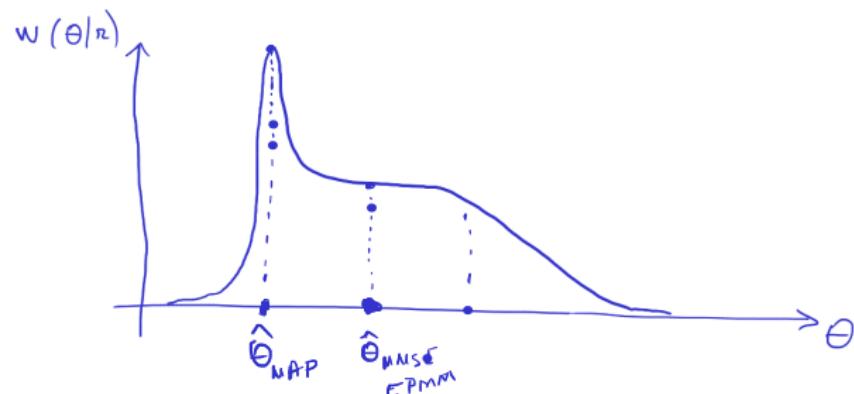


Figure 2: Unbalanced posterior distribution

- Care este estimatorul MAP?
- Dacă avem funcția de cost următoare:
 - dacă estimarea $\hat{\theta}$ este $<$ valoarea reală θ , te costă 1000 \$
 - dacă estimarea $\hat{\theta}$ este $>$ valoarea reală θ , platești 1 \$
 - schimbăm valoarea estimată ? :)

- ▶ Distribuția a posteriori $w(\Theta|r)$ dă probabilitatea fiecărei valori $\hat{\Theta}$ de a fi cea corectă
- ▶ Alegerea unui estimat $\hat{\Theta}$ implică o anume eroare ϵ
- ▶ Eroarea de estimare are un anumit cost $C(\epsilon)$
- ▶ **Riscul** = valoarea medie a costului = $C(\epsilon) \times$ probabilitatea:

$$R = \int_{-\infty}^{\infty} C(\epsilon)w(\Theta|r)d\Theta$$

The Bayesian risk

- ▶ Alegem valoarea $\hat{\Theta}$ care **minimizează costul mediu** R

$$\hat{\Theta} = \arg \min_{\Theta} \int_{-\infty}^{\infty} C(\epsilon) w(\Theta | \mathbf{r}) d\Theta$$

- ▶ O obținem înlocuind $C(\epsilon)$ cu definiția sa, și derivând după $\hat{\Theta}$
 - ▶ Atenție: se derivează după $\hat{\Theta}$, nu Θ !

Estimatorul EPMM (eroare pătratică medie minimă)

- Când funcția de cost este pătratică $C(\epsilon) = \epsilon^2 = (\hat{\Theta} - \Theta)^2$ = Eroare pătratică

$$R = \int_{-\infty}^{\infty} (\hat{\Theta} - \Theta)^2 w(\Theta | \mathbf{r}) d\Theta$$

- Vrem $\hat{\Theta}$ care minimizează R , deci derivăm

$$\frac{dR}{d\hat{\Theta}} = 2 \int_{-\infty}^{\infty} (\hat{\Theta} - \Theta) w(\Theta | \mathbf{r}) d\Theta = 0$$

- Echivalent cu

$$\underbrace{\hat{\Theta} \int_{-\infty}^{\infty} w(\Theta | \mathbf{r}) d\Theta}_{1} = \int_{-\infty}^{\infty} \Theta w(\Theta | \mathbf{r}) d\Theta$$

- Estimatorul de eroare pătratică medie minimă (EPMM) (“Minimum Mean Squared Error, MMSE”):

$$\hat{\Theta}_{EPMM} = \int_{-\infty}^{\infty} \Theta \cdot w(\Theta | \mathbf{r}) d\Theta = \text{media}$$

$$\bar{x} = \int_{-\infty}^{\infty} x \cdot w(x) dx$$

- ▶ **Estimatorul EPMM**: estimatorul $\hat{\Theta}$ este valoarea medie a distribuției a posteriori $w(\Theta|r)$

$$\hat{\Theta}_{EPMM} = \int_{-\infty}^{\infty} \overbrace{\Theta}^x \cdot \overbrace{w(\Theta|r)}^{w(x)} d\Theta$$

MMSE = "Minimum Mean Squared Error"

- ▶ EPMM = "Eroare Pătratică Medie Minimă"
- ▶ valoarea medie = sumă (integrală) din fiecare Θ ori probabilitatea sa $w(\Theta|r)$
- ▶ Estimatprul EPMM se obține din distribuția a posteriori $w(\Theta|r)$, considerând funcția de cost pătratică

Estimatorul MAP

- Dacă funcția de cost este uniformă

$$C(\epsilon) = \begin{cases} 0, & \text{if } |\epsilon| = |\hat{\Theta} - \Theta| \leq E \\ 1, & \text{if } |\epsilon| = |\hat{\Theta} - \Theta| > E \end{cases}$$

$E \rightarrow \circ$

- Stim că $\Theta = \hat{\Theta} - \epsilon$
- Se obține

$$R = \int_{-\infty}^{\hat{\Theta}-E} w(\Theta|\mathbf{r})d\Theta + \int_{\hat{\Theta}+E}^{\infty} w(\Theta|\mathbf{r})d\Theta$$

$$R = 1 - \int_{\hat{\Theta}-E}^{\hat{\Theta}+E} w(\Theta|\mathbf{r})d\Theta$$

Estimatorul MAP

- ▶ Pentru minimizarea R , trebuie să maximizăm $\int_{\hat{\Theta}-E}^{\hat{\Theta}+E} w(\Theta|\mathbf{r})d\Theta$, integrală din jurul punctului $\hat{\Theta}$
- ▶ Pentru E foarte mic, funcția $w(\Theta|\mathbf{r})$ este aproximativ constantă, deci se va alege punctul unde funcția este maximă
- ▶ **Estimatorul Maximum A Posteriori (MAP)** = valoarea $\hat{\Theta}$ care maximizează $w(\Theta|\mathbf{r})$

$$\hat{\Theta}_{MAP} = \arg \max_{\Theta} w(\Theta|\mathbf{r}) = \arg \max_{\Theta} \cancel{w(\mathbf{r}|\Theta)} \cdot w(\Theta)$$

Interpretare

- ▶ Estimatorul MAP: $\hat{\Theta} = \text{valoarea care maximizează distribuția a posteriori}$
- ▶ Estimatorul EPMM: $\hat{\Theta} = \text{valoarea medie a distribuției a posteriori}$

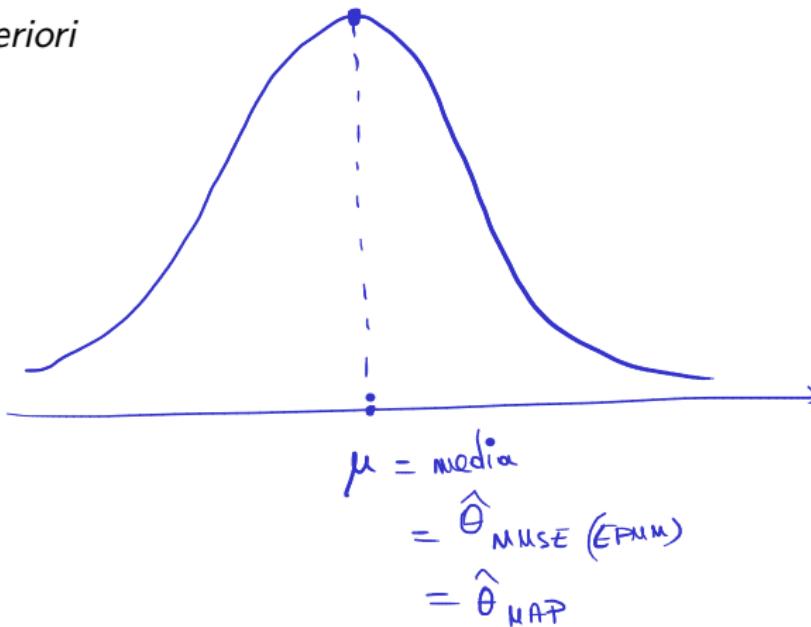
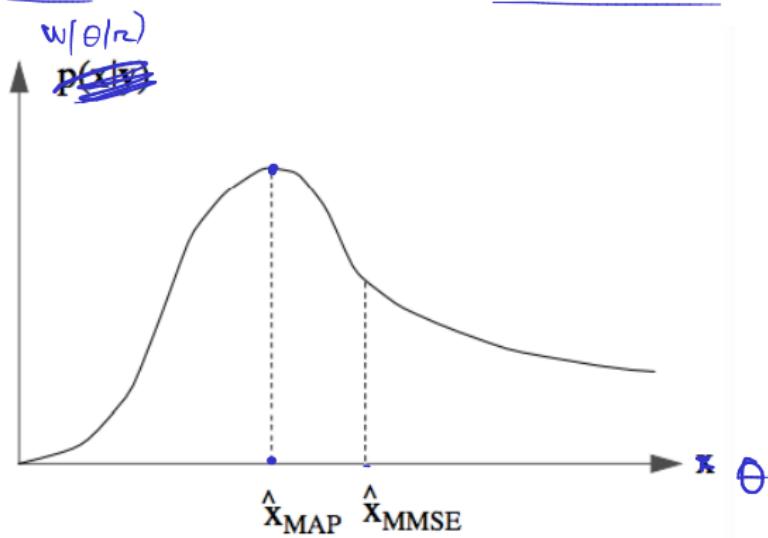
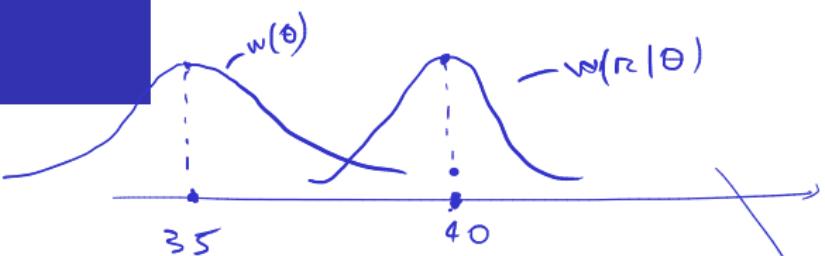


Figure 3: Estimatorul MAP vs EPMM(MMSE)

- ▶ Estimatorul MAP = minimizează costul mediu, folosind funcția de cost uniformă
 - ▶ ca le detectie: criteriul MPE = criteriul MR când costurile sunt la fel
- ▶ Estimatorul MMSE = minimizează costul mediu, folosind funcția de cost pătratică
 - ▶ similar cu criteriul MR, dar la estimare

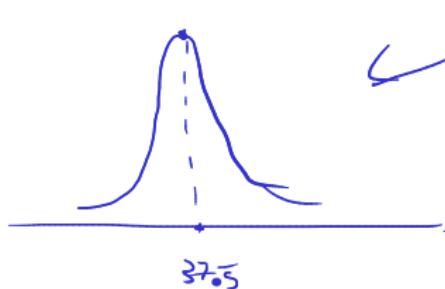
Exercițiu



Exercițiu: valoare constantă, 1 măsurătoare, zgomot Gaussian același σ

- ▶ Vrem să estimam temperatura de astăzi din Sahara
- ▶ Termometrul indică 40 grade, dar valoarea este afectată de zgomot Gaussian $\mathcal{N}(0, \sigma^2 = 2)$ (termometru ieftin) } $\rightarrow w(r|\theta)$
- ▶ Se știe că de obicei în această perioadă a anului temperatura este în jur de 35 grade, cu o distribuție Gaussiană $\mathcal{N}(35, \sigma^2 = 2)$. } $\rightarrow w(T)$
- ▶ Estimați valoarea reală a temperaturii folosind estimarea ML, MAP și EPMM(MMSE)

$$r = 40 = T + \text{zgomot}$$



37.5